

Subject :

Year . Month . Date .

$$\cdot \underline{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, f(\underline{x}) : R^n \rightarrow R, \frac{\partial f}{\partial \underline{x}} = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix} = f_x(\underline{x}) = \nabla_{\underline{x}}^T f(\underline{x}) \quad \text{مُسْتَقِلُّ بِالدَّرَجَاتِ}$$

$$\cdot \frac{\partial^2}{\partial \underline{x}} (f_x(\underline{x})) = f_{xx}(\underline{x}) = \left[ \frac{\partial^2 f}{\partial x_i \partial x_j} \right] = [H_{ij}] = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{pmatrix} \rightarrow \text{Hessian Matrix}$$

$$\cdot f \in C^2 \rightarrow \text{جُنْبُحٌ مُسْتَقِلٌّ بِالدَّرَجَاتِ} \Rightarrow H = H^T$$

$$f \in C^1 \rightarrow \text{جُنْبُحٌ}$$

$$f \in C \rightarrow \text{جُنْبُحٌ}$$

$$\cdot f(x, y) = y^T A x \rightarrow \frac{\partial f}{\partial x} = A^T y$$

أولاً:

$$y^T A x = [y_1, \dots, y_n] \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \sum_{j=1}^n \sum_{i=1}^n y_j a_{ij} x_i = \sum_{j=1}^n y^T a_j x_j$$

$$\frac{\partial}{\partial x_k} (y^T A x) = \frac{\partial}{\partial x_k} \left( \sum_j y^T a_j x_j \right) = y^T a_k$$

$$\Rightarrow \frac{\partial}{\partial x} (y^T A x) = \begin{pmatrix} y^T a_1 \\ \vdots \\ y^T a_n \end{pmatrix} = \begin{pmatrix} a_1^T y \\ \vdots \\ a_n^T y \end{pmatrix} = \begin{pmatrix} a_1^T \\ \vdots \\ a_n^T \end{pmatrix} y = A^T y$$

$$\cdot \frac{\partial (A x)}{\partial x} = \frac{\partial}{\partial x} \left( \sum_{i=1}^n a_{i1} x_i \right) = \begin{pmatrix} a_{11} & -a_{11} & \dots & a_{1n} \\ a_{12} & \vdots & \ddots & \vdots \\ a_{1n} & \dots & a_{nn} & \vdots \end{pmatrix} = A^T$$

$$\cdot \frac{\partial y_m(x)}{\partial x_{n+1}} = \begin{pmatrix} \frac{\partial y_1}{\partial x_1} & \cdots & \frac{\partial y_m}{\partial x_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial y_1}{\partial x_n} & \cdots & \frac{\partial y_m}{\partial x_n} \end{pmatrix}_{n \times m}$$

$$\cdot \frac{\partial}{\partial x} (x^T A x) = A^T x + A x \quad \xrightarrow{\text{جُنْبُحٌ مُسْتَقِلٌّ بِالدَّرَجَاتِ}} x^T A x = (x^T A x)^T = x^T A^T x \xrightarrow{\text{جُنْبُحٌ مُسْتَقِلٌّ بِالدَّرَجَاتِ}} = A x$$

$$f(x) = f(x^*) + f_x^T(x^*)(x - x^*) + \frac{1}{2!} (x - x^*)^T H(x^*)(x - x^*) + \text{H.O.T}$$

$$f_x^T(x^*) = \left[ \frac{\partial f}{\partial x_1} \cdots \frac{\partial f}{\partial x_n} \right] \Big|_{x=x^*} = \frac{1}{2} \frac{\partial^2 f}{\partial x_1^2} \Delta x_1^2 + \frac{1}{2} \frac{\partial^2 f}{\partial x_1 \partial x_2} \Delta x_1 \Delta x_2 + \cdots + \frac{1}{2} \frac{\partial^2 f}{\partial x_n^2} \Delta x_n^2$$

Batus

**Subject :**

Year .      Month .      Date .

$$x - x^* = \Delta x, \quad x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad x^* = \begin{pmatrix} x_1^* \\ \vdots \\ x_n^* \end{pmatrix} \rightarrow \Delta x = \begin{pmatrix} x_1 - x_1^* \\ \vdots \\ x_n - x_n^* \end{pmatrix} = \begin{pmatrix} \Delta x_1 \\ \vdots \\ \Delta x_n \end{pmatrix}$$

## سِنْتِ عَلَامِ سَارِسِ

هر سه جی میں (نیشن) سب دنیا میں ایران تعین عدالت سدھن میں ازداری کی

نهن تئرمه د جست د منم ۳ طایی اسکاریزینه هارد؛ حال می اسکاریزه در مساله گون بخوازم

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, A = \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \dots & a_{mn} \end{bmatrix} = \sum a_{ij} x_i x_j$$

! مُنْتَهِيَّةٌ بِمُنْتَهِيَّةٍ

**میرزا مارس** حفظہ اللہ عزیز میں سے (نہیں سنت) ایک اور

$$\forall x \in \mathbb{R}^n, x \neq 0, x^T A x \geq 0$$

مَعْنَى نَفْعٍ (نَفْعٌ مِنْ نَفْعٍ) بَيْنَ مَا تَرَسَّبَ A سَلْكٌ مِنْ سُبَّ (نَفْعٌ مِنْ سُبَّ) بَيْنَ مَا تَرَسَّبَ A - اِرْتَأَيْ

قصبة (شطوان) یعنی جلی سرخ سفت بدن (نہ یعنی سوت بدن) مارس (Anus) اس کا نام

سَمَّا سَمَّا زَرْنَيْ دَرْسَ A مِنْ سَمَّا (نَهْمَنْ سَمَّا) :

۱۰۷

$$A = \frac{1}{2} (A + A^T) + \frac{1}{2} (A - A^T)$$

جواب

$$x^T A x = \frac{1}{2} x^T (A + A^T) x + \frac{1}{2} x^T (A - A^T) x$$

~~$x^T (A - A^T) x$~~

$$C = C^T = \frac{1}{2} x^T (A^T - A) x = -C$$

$$\Rightarrow C = -C \Rightarrow C = 0$$

$$\Rightarrow x^T A x = x^T \left( \frac{A + A^T}{2} \right) x$$

الاسناد

**تمہارے ساتھ اپنے تحریکی کام کرنے والے**

۱. نرمن سنه هارس ستونز ۲۰، بیمار رنده ی عقیم طانه از سرمه ۲ داشته باشد:

Subject :

Year . Month . Date .

بردار دسته تعمیم یافته از مسأله معمولی بردار دسته از مسأله معمولی

$$(M - \lambda I)x = 0$$

$$[(M - \lambda I)x]^T [(M - \lambda I)x] = y^T y \neq 0 \rightarrow$$

$$= x^T (M - \lambda I)^T (M - \lambda I)x = x^T (M^T - \lambda I)(M - \lambda I)x = x^T (M - \lambda I)^2 x = 0$$

بنابراین مارس معمولی بردار دسته تعمیم یافته از مسأله ۲ ندارد. بنابراین مارس معمولی بردار دسته تعمیم یافته از مسأله

پر کسر نخواهد داشت و در نتیجه حکم بردار دسته مارس معمولی است از مسأله ابتداء برای مارس معمولی

End

نتیجه : معادله دسته مارس معمولی حسنه حسته

لذت نفع نسبتی مارس معمولی بردار دسته از مارس معمولی بردار دسته از مارس معمولی بردار دسته از مارس معمولی

$$M\gamma_i = (\alpha_i + j\beta_i)\gamma_i \xrightarrow{\gamma_i^{*T}} \gamma_i^{*T} M \gamma_i = \gamma_i^{*T} (\alpha_i + j\beta_i) \gamma_i$$

$$\gamma_i^{*T} M^T = (\alpha_i - j\beta_i) \gamma_i^{*T} \xrightarrow{\gamma_i^{*T}} \gamma_i^{*T} M^T \gamma_i = (\alpha_i - j\beta_i) \gamma_i^{*T} \gamma_i$$

$$\Rightarrow (\alpha_i - j\beta_i) \|\gamma_i\|^2 = (\alpha_i + j\beta_i) \|\gamma_i\|^2 \Rightarrow -\beta_i = \beta_i \Rightarrow \beta_i = 0$$

برای دو طبقه دسته مارس معمولی بردار دسته از مارس معمولی بردار دسته از مارس معمولی

$$\Lambda = Q^{-1} M Q$$

$$M^T = M = Q \Lambda Q^{-1} = (Q^{-1})^T \Lambda Q^T \Rightarrow \Lambda = Q^{-1} (Q^{-1})^T \Lambda Q^T Q$$

$$\Lambda = \Lambda^T = Q^T Q \Lambda (Q^{-1}) (Q^{-1})^T = Q^T Q \Lambda (Q^T Q)^{-1} = P \Lambda P^{-1}$$

$$P = \begin{bmatrix} \alpha_1 & & 0 \\ i \alpha_2 & \ddots & i \\ 0 & \cdots & \alpha_n \end{bmatrix} = Q^T Q, \begin{bmatrix} q_1^T \\ \vdots \\ q_n^T \end{bmatrix} [q_1, \dots, q_n] \rightarrow \begin{cases} i \neq j & q_i^T q_j = 0 \\ i = j & q_i^T q_j = \alpha_i > 0 \end{cases}$$

Batus

Subject :

Year . Month . Date .

بردارهای رُیه مارس متناسب در بودن جرم خودند. اگر بردارهای رُیه متناسب باشند باید داشت

$$\|q_i\|^2 = q_i^T q_i = 1 \Rightarrow \alpha_i = 1 \Rightarrow Q^T Q = I \Rightarrow Q^T = Q^{-1} \quad \text{لذا مطابقت}$$

قضیه مارس متناسب  $M$  معنی است (نه عن) اگر آن دو نوع اگر و برعکس

(ا) اگر مارس رُیه مارس سبّت (سبّت رفع این)

$$1) \lambda_i \geq 0 : x^T M x = x^T Q \Lambda Q^T x = \underbrace{x^T Q}_{y^T} \underbrace{\Lambda^{\frac{1}{2}} \Lambda^{\frac{1}{2}} Q^T x}_{y^T} = y^T y \geq 0 \xrightarrow{\text{cause}} y \neq 0 : \text{سبّت}$$

$$2) x^T M x \geq 0 , x^T M x = x^T Q \Lambda Q^T x = y^T \Lambda y = \sum \lambda_i y_i^2 \geq 0 \Rightarrow \text{cauchy} \lambda_i \geq 0$$

:  $M = N^T N$  مارس غیر رُیه (رُیه) صدقه باشد  $N_{n \times n}$  (۲)

$$1) M \cdot M = Q \underbrace{\Lambda^{\frac{1}{2}} \Lambda^{\frac{1}{2}}}_{N^T} Q^T = N^T N \quad \text{لبست}$$

$$2) M = N^T N : x^T M x = \underbrace{x^T N^T}_{y^T} \underbrace{N x}_{y} = y^T y \geq 0$$

(۳) درستی اوصیه اصرعیم (ردیه اصرعیم) مارس سبّت (سبّت رفع این)

اللی اوصیه اصرعیم رکارهای اصرعیم رفع اصرعیم

$$\begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}_B \text{ اصرعیم } \rightarrow a_{11}, \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}_C \text{ اصرعیم } \rightarrow a_{11}, a_{22}, \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$$

$$A_3 \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}_C \text{ اصرعیم } \rightarrow a_{11}, \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, A_2 \text{ اصرعیم } \rightarrow a_{11}, a_{22}, a_{33}, B, C, \begin{bmatrix} a_{11} & a_{13} \\ a_{31} & a_{33} \end{bmatrix}, A$$

این ترتیب همچنان درستی اوصیه اصرعیم رفع اصرعیم + بین عبارت درستی باشد درستی اوصیه

لطفاً بپرسید اگر تایزه شده باشد (عنوان متن سبّت این) از فهم پرسیده

Batus

Subject :

Year . Month . Date .

**Ex.**  $A = \begin{bmatrix} a & c \\ c & d \end{bmatrix} \xrightarrow{\text{معادل}} \begin{cases} ad - c^2 > 0 \\ a > 0 \end{cases}$

$$x^T A x = ax_1^2 + dx_2^2 - 2cx_1x_2 \geq ax_1^2 + dx_2^2 - 2|c||x_1||x_2|$$

$$= (\sqrt{a}|x_1| - \sqrt{d}|x_2|)^2 + (2\sqrt{ad} - 2|c|)|x_1||x_2|$$

)

$\sqrt{ad} > |c|$   $\Rightarrow$   $x_1 = x_2 = 0$ ,  $x_1, x_2 \in \mathbb{R}$   
 $\Rightarrow ad - c^2 > 0$

**Ex.**  $A = \begin{bmatrix} 10 & 1 & -2 \\ 1 & 4 & 1 \\ -2 & 1 & 1 \end{bmatrix} \xrightarrow{\text{معادل}} \frac{A+A^T}{2} = \begin{bmatrix} 11 & 2 & -1 \\ 2 & 5 & 1 \\ -1 & 1 & 2 \end{bmatrix}$

$\det(A) = 10 > 0$ ,  $|11, 2, -1| = 39 > 0$ ,  $|A| = 17 > 0 \Rightarrow$  متن سُلسله

$\text{eig}(A) = 0.4, 3.95, 10.63 > 0$  متن سُلسله

**Ex.**  $A = \begin{bmatrix} -1 & 1 & -1 \\ 1 & -3 & -2 \\ -1 & -2 & -11 \end{bmatrix} \xrightarrow{-1 < 0} \text{معادل} A$

$-A = \begin{bmatrix} 1 & -1 & 1 \\ 1 & 3 & 2 \\ 1 & 2 & 11 \end{bmatrix} \xrightarrow{1 > 0, |1, -1| = 2 > 0, |A| > 0} \text{متن سُلسله} A$

: (n) (جایل) حدیت یکیم در نیز اشاره ای باشد که محدود تابع نسبت به صفر است

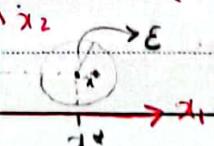
$f: \mathbb{R}^n \rightarrow \mathbb{R} \rightarrow D \subseteq \mathbb{R}^n, x^* \in D$

نقطه محاسبه

نقطه محاسبه  $f(x^*)$  در محدود  $D$  بعد از  $x^*$  نسبت به صفر است

$\exists \epsilon > 0 : \forall x \in D \text{ with } \|x - x^*\| < \epsilon : f(x^*) < f(x)$

Batus



$$f(x_1) < f(x^*) < f(x_2)$$

**Subject :**

Year .      Month .      Date .

$f(x^*) \leq f(x)$  ،  $x$  global Min  $\forall x^*$  برای هر  $x \in D$

+ اسے درایل نہ بھروسے (global/local)  $f(x) \leq f_{(x)}$  برقرار رکھیں، درجہ بیت لئے دو طبقے میں (global/local)

وَالْمُنْهَاجُ الْمُسْتَقِرُ (strict) وَالْمُنْهَاجُ الْمُسْتَقِرُ

$$f(\mathbf{x}^* + \Delta \mathbf{x}) = f(\mathbf{x}^*) + \left( \frac{\partial f}{\partial \mathbf{x}} \Big|_{\mathbf{x}=\mathbf{x}^*} \right)^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T \left( \frac{\partial^2 f}{\partial \mathbf{x}^2} \Big|_{\mathbf{x}=\mathbf{x}^*} \right) \Delta \mathbf{x} + \text{HOT}$$

مختصر مجموعه اسناد حسنه در سی اکتبر ۱۹۵۲ حل آن (نیزه) بجا تیره صورت گرفته است

$$\Delta x = -\eta \left( \frac{\partial f}{\partial x} \Big|_{x=x^*} \right) \quad \bullet \eta \ll 1$$

$$\lim_{\eta \rightarrow 0} \frac{\sigma(\eta)}{\eta} = 0$$

$$f(x^* + \Delta x) = f(x^*) - \gamma \left( \frac{\partial f}{\partial x} \Big|_{x=x^*} \right)^T \left( \frac{\partial f}{\partial x} \Big|_{x=x^*} \right) + \tilde{O}(\gamma)$$

$$= f(x^*) - \gamma \left\| \frac{\partial f}{\partial x} \Big|_{x=x^*} \right\|^2 + o(\gamma)$$

$$-\gamma \left\| \frac{\partial f}{\partial x} \right\|_{x=x^*}^2 + o(\gamma) < 0 \Rightarrow f(x^* + \delta x) < f(x^*)$$

برای این سرطان مربوط لعل برای این سرطان  $\rightarrow 0$   $\left| \frac{df}{dx} \right|_{x=2}$

$$f(x^* + \Delta x) = f(x^*) + 0 + \frac{1}{2} \Delta x^T \frac{\partial^2 f(x^*)}{\partial x^2} \Delta x + O(\|\Delta x\|^2)$$

$$\frac{\partial^2 f}{\partial x^2} \Big|_{x=x^*} = H(x^*) > 0 \quad (\text{PSD})$$

$$H(x^*) < 0 \rightarrow \exists \varepsilon, \| \Delta x \| < \varepsilon, \frac{1}{2} \Delta x^T H(x^*) \Delta x + O(\| \Delta x \|^2) < 0,$$

$$\Rightarrow f(x^* + \Delta x) < f(x^*) \Rightarrow X_1$$

اگر  $H(x)$  غیر منحصر ہے باز میں تصور کر سکے جو اسے دلیل حاصل ہے اسی سریں ماتھا  $\Delta x$  کا  $\frac{1}{2}$  میں

Subject :

Year . Month . Date .

$$\frac{\partial^2 f}{\partial x^2} \Big|_{x=x^*} = H(x^*) > 0 \quad (\text{PQ})$$

$$f(x^* + \Delta x) - f(x^*) = \frac{1}{2} \Delta x^T H(x^*) \Delta x + O(\|\Delta x\|^2)$$

$$\exists \varepsilon, \|\Delta x\| < \varepsilon \Rightarrow \frac{1}{2} \Delta x^T H(x^*) \Delta x + O(\|\Delta x\|^2) > 0 \Rightarrow f(x^* + \Delta x) - f(x^*) > 0$$

$$\Rightarrow f(x^*) < f(x^* + \Delta x)$$

نحوه، سایر تابع برای تابع  $f$  میگیرند که داشته باشند

$$f(x^* + \Delta x) = f(x^*) + \nabla f(x^*) \Delta x + \Delta x^T H(x^*) \Delta x + \text{H.o.T} \rightarrow \text{Minimum } f(x^*)$$

$$f(x^* + \Delta x) = f(x^*) + \Delta x^T H(x^*) \Delta x + \text{H.o.T} \quad \text{if } H(x^*) > 0 \rightarrow \text{eig}(H(x^*)) > 0$$

$$\begin{aligned} & \text{اگر برای هر رکورسیون } \Delta x \text{ که full rank هست، میگیریم:} \\ & \Rightarrow \Delta x^T H(x^*) \Delta x = (\sum \alpha_i v_i)^T H(x^*) (\sum \alpha_i v_i) = (\sum \alpha_i v_i)^T (\sum \alpha_i \lambda_j v_i) = \sum \alpha_i^2 \lambda_i / \lambda_i \end{aligned}$$

پس از اینکه میگیریم  $f(x^* + \Delta x) - f(x^*) > 0$  میتوانیم در نتیجه  $f(x^*)$  نسبت بین  $\Delta x$  را محاسبه کنیم.

نحوه، اگر  $\Delta x$  ای داشته باشیم که برای هر فرآیند  $\Delta x$  میگیریم و برای هر تابع  $f$  داشته باشیم که  $f(x^*)$

$\text{cir}(H(x^*)) > 0$  میگیریم، میتوانیم  $f(x^*) - f(x^* + \Delta x)$  را محاسبه کنیم:  $= \sum \alpha_i \lambda_i \|v_i\|^2 \Delta x_i^2$ .

نحوه، اگر  $\Delta x$  ای داشته باشد که  $H(x^*) \Delta x = 0$  باشد، میتوانیم  $\Delta x$  را محاسبه کنیم!

جیوه شفافیت

$$f(x) = x_1^2 + x_2^2 + 3x_1 x_2 + 2x_2 - x_1 + 3$$

$$x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

Batus

Subject :

Year . Month . Date .

$$\frac{\partial f}{\partial x} = \begin{pmatrix} 2x_1 + 3x_2 - 1 \\ 2x_2 + 3x_1 + 2 \end{pmatrix} = 0 \Rightarrow x^* = \begin{pmatrix} -8/5 \\ 7/5 \end{pmatrix}$$

$$H(x) = \frac{\partial^2 f}{\partial x^2} = \begin{pmatrix} 2 & 3 \\ 3 & 2 \end{pmatrix}$$

$\Rightarrow \text{eig}(H) : \det(\lambda I - H) = 0$

$$(\lambda - 2)^2 - 9 = 0 \Rightarrow \lambda - 2 = \pm 3$$

$$\Rightarrow \begin{cases} \lambda = 5 \\ \lambda = -1 \end{cases}$$

لذلك فإن  $x^*$  هي نقطة極小

Ex.  $f(x) = x^T A x + b^T x + c$

الحل :  $\frac{\partial f}{\partial x} = (A + A^T)x + b \xrightarrow[\text{نحو ذلك}]{U=A+A^T} x = -(A + A^T)b$

$$\frac{\partial^2 f}{\partial x^2} = A + A^T \xrightarrow[\text{ND}]{\text{نحو ذلك}}$$

فهي مساله دوسيه

Ex.  $f(x) = \frac{1}{2} x_2^2 + x_1 + x_2$

$$= x^T \underbrace{\begin{bmatrix} 0 & 1 \\ 1 & 2 \end{bmatrix}}_A x + (1, 1)^T x \Rightarrow A + A^T = \begin{bmatrix} 0 & 1 \\ 1 & 1 \end{bmatrix} \xrightarrow[\text{N=1}]{\text{نحو ذلك}}$$

لذلك  $A + A^T$  موجب ايجابي

Ex.  $f(x) = \frac{1}{2} x_1^2 + \frac{1}{2} x_2^2 + x_1 x_2 + x_1 + x_2 = x^T \underbrace{\begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & \frac{1}{2} \end{bmatrix}}_A x + (1, 1)^T x$

$$A + A^T = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \xrightarrow[\text{نحو ذلك}]{(0-1)^2 - 1 = 0} \lambda = \pm 1 \Rightarrow \lambda_1 = 2, \lambda_2 = 0$$

$$\frac{\partial f}{\partial x} = \begin{pmatrix} x_1 + x_2 + 1 \\ x_1 + x_2 + 1 \end{pmatrix} = 0 \Rightarrow x_1 + x_2 + 1 = 0 \Rightarrow$$

$$f(x) = \frac{1}{2} (x_1 + x_2 + 1)^2 \rightarrow$$
 معرفة حاصل ضرب

Concave, Convex

تعريف :  $f$  هي خصوصية if  $0 \leq \alpha \leq 1$  و  $x_1, x_2 \in \mathbb{R}^n$  فـ  $f(\alpha x_1 + (1-\alpha)x_2) \leq \alpha f(x_1) + (1-\alpha)f(x_2)$

Batus

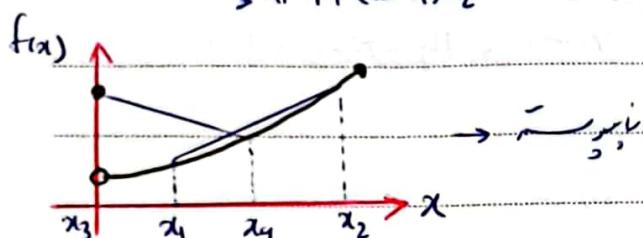
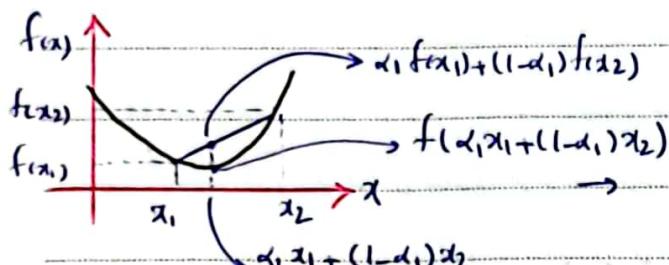
Subject :

Year . Month . Date .

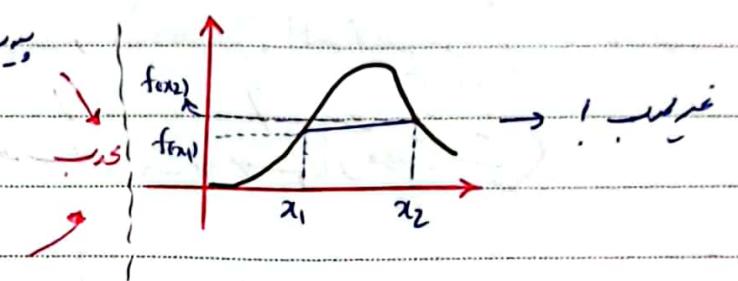
$$\text{نفرض: } x_1, x_2 \in \mathbb{R} \rightarrow \alpha x_1 + (1-\alpha)x_2 \in \mathbb{R}$$

نفرض:  $x_1 + x_2, 0 < \alpha < 1$

$$f(\alpha x_1 + (1-\alpha)x_2) < \alpha f(x_1) + (1-\alpha)f(x_2)$$



نفرض:  $f$  هي محدبة (Strictly Convex)



نفرض:  $f$  هي محدبة (Concave)

نفرض:  $f = g$  هي محدبة (Strictly Concave)

Convex

$$\sum_{i=1}^n \alpha_i f_i \leq f_n(\alpha_1 x_1 + (1-\alpha_1)x_2) \leq \alpha f_1(x_1) + (1-\alpha)f_2(x_2) \quad (1)$$

$$\sum_{i=1}^n \alpha_i f_i \leq f_n(\alpha_1 x_1 + (1-\alpha_1)x_2) \leq \alpha f_n(x_1) + (1-\alpha)f_n(x_2)$$

$$\sum_{i=1}^n \alpha_i f_i(\alpha x_1 + (1-\alpha)x_2) \leq \alpha \sum_{i=1}^n \alpha_i f_i(x_1) + (1-\alpha) \sum_{i=1}^n \alpha_i f_i(x_2)$$

$$\text{نفرض: } \Gamma_C = \{x \in \mathbb{R}, f(x) \leq c\}, \text{ حيث } c \text{ هو علامة مرتفعة لـ } f$$

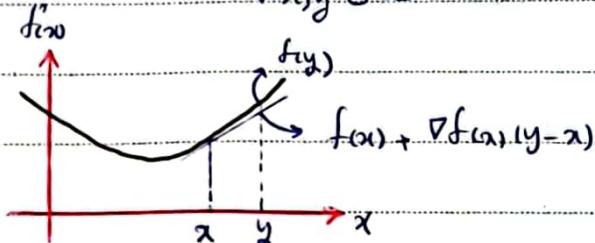
$$x_1 \in \Gamma_c \rightarrow f(x_1) \leq c \rightarrow f(\alpha x_1 + (1-\alpha)x_2) \leq \alpha f(x_1) + (1-\alpha)f(x_2) \leq c$$

$$x_2 \in \Gamma_c \rightarrow f(x_2) \leq c \rightarrow \alpha x_1 + (1-\alpha)x_2 \in \Gamma_c \Rightarrow \dots$$

Batus

$$f(y) \geq f(x) + \nabla f(x) \cdot (y - x) \quad \text{أى دالة } f \in C^1 \text{ متميزة} \quad (3)$$

(لما زادت)



(درسته) (اسریتی  $f$ )  $f$  خوب است اگر  $f$  در  $\Omega$  محدود باشد و  $f$  در  $L^2(\Omega)$  قابل داشت.

$$f(y) = f(x) + \nabla f(x)^T (y - x) + \frac{1}{2} (y - x)^T H_f(x + \alpha(y - x)) (y - x)$$

۷۰) مارکیز نتھی اور ادن دیکھنے والے ہیں تاں دیکھنے



$$f'(c) = \frac{f(b) - f(a)}{b-a}, \quad c \in [a, b]$$

$$f(b) = f(a) + (b-a)f'(c)$$

$$Hf > 0 \quad ! \quad (y-x)^T H (x_1 + \alpha(y-x_1)) (y-x) > 0$$

$$\Rightarrow f(y) \geq f(x) + \nabla f(x)(y-x) \Rightarrow \exists \lambda \text{ s.t}$$

لیہب سے بڑتے، برعاصی حفت، ۷۰ جنگ میں میں دیناں مار لیں۔

$\exists z, x, z^T H/(z)z < 0 \rightarrow \text{exists } y \text{ s.t. } (1) \text{ is true}$

۲۰۱۷-۱۸۰۰-۲۰۱۷

$$\Rightarrow (y-x)^T H_f(x)(y-x) < 0 \rightarrow y - x \text{ نسبت به } f(x) \text{ پایه است.}$$

$$f(y) \leq f(x) + \nabla f(x)(y-x)$$

Batus

س فخر نی اصرار

**Subject :**

Year .      Month .      Date .

۲) استحصال بر جمله در یک کتاب هر چند ممکن است global (local)

$x^* : f(x^*) \leq f(y) \forall y \in S$

$$f(\alpha y + (1-\alpha)x^*) \leq \alpha f(y) + (1-\alpha)f(x^*) < f(x^*)$$

$$\{0 < \alpha \leq 1\}$$

$$\lim_{\alpha \rightarrow 0} \alpha y + (1-\alpha)x^* = x^* \Rightarrow \lim_{\alpha \rightarrow 0} f(\alpha y + (1-\alpha)x^*) = f(x^*)$$

$$\dots \Rightarrow f(x^*) < f(x) \Rightarrow X \Rightarrow \dots \checkmark$$

$$x, y \in M \Rightarrow \alpha x + (1-\alpha)y \in M$$

٦) فرض  $f$  متماثل على  $\mathbb{R}$  و  $M(x)$  هو

$$\alpha x + (1-\alpha)y \in \mathcal{L} \rightarrow f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y) = f(x) = f(y)$$

$$f(\alpha x + (1-\alpha)y) = f(x) = f(y)$$

$$\Rightarrow \alpha x + (1-\alpha)y \in M$$

۷) تاج نمود ایشان رئیس استاد بارگاه ایشان بخوبیت ایشان

$$x, y \in M \Rightarrow \alpha x + (1-\alpha)y \in M$$

$$\Rightarrow f(x) = f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha)f(y) = f(x) \Rightarrow x$$

۱) نرخن نهایی مشتقات دلبر  $f$  برگزیده باشد و در مجموعه کسرات از دو مجموعه برآورده باشند.

$\nabla f(x^*) = 0 \Rightarrow$  جایزه ایستادن

Local & global Min

$$f(y) \geq f(x) + \nabla f(x)(y-x) \xrightarrow{\frac{x=x^*}{f'(x^*)=0}} f(y) \geq f(x^*) \quad \forall y \in \Omega \text{ such that } y \neq x^*$$

اے خاصتے سری جس دنستہ لٹھستان پندرہ بارہ!

Subject :

Year .      Month .      Date .

$$f(x) = \frac{1}{2} x^T p_{n \times n} x + q^T x + r$$

## صلف و توابع سرس :

از اول مسأله خوب است که  $P + P^T$  مثبت است، اگر  $P$  متعادل نبود کن ایک دو ماتریس

بایس خلیفه زمانه را نیز بدل اینجاست رسیده ایم.

$$Df^T = \frac{1}{2} (P + P^T)x + q - Px + q = 0 \Rightarrow Px = -q$$

$$\nabla^2 f = H - P \rightarrow \text{جواب ممکن} \rightarrow \begin{cases} f \geq 0 & \text{اگر } P \geq 0 \\ f < 0 & \text{اگر } P > 0 \end{cases}$$

لما  $A$  ماتریس full rank باشد،  $Px = q$  دارای یک جواب متمم است.

Ex.  $f(x) = x^4$      $f'(x) = 4x^3$ ,  $f''(x) = 12x^2 = 0 \Rightarrow x = 0 \Rightarrow f > 0$

با این نتیجه  $H_f > 0$  نیز میتوان  $f$  را در برابر باشد.

$$\text{Ex. } f(x_1, y) = x_1^2/y \quad y > 0 \quad \nabla f^T(x_1, y) = \begin{pmatrix} 2x_1/y \\ -x_1^2/y^2 \end{pmatrix}$$

$$\nabla^2 f(x_1, y) = \begin{pmatrix} \frac{2}{y} & -\frac{2x}{y^2} \\ -\frac{2x}{y^2} & \frac{2x^2}{y^3} \end{pmatrix} = H(x_1, y) = \frac{2}{y^3} \begin{pmatrix} y^2 & -xy \\ -xy & x^2 \end{pmatrix} \rightarrow x^2, y^2, \left| \begin{pmatrix} y^2 & -xy \\ -xy & x^2 \end{pmatrix} \right| > 0$$

نیز مدن سنت ملائکہ

$$\nabla^T f(x,y) = \begin{pmatrix} \frac{2x}{y} \\ -\frac{x^2}{y^2} \end{pmatrix} = 0 \rightarrow \begin{cases} x=0 \\ y>0 \end{cases} \rightarrow (0,y) \rightarrow f(0,y) \text{ is a local minimum}$$

الرسام هنري سارج : ١) الرسم درسية داخل (نذر نسب (50))

Subject :

Year . Month . Date .

$$f(x + \Delta x) = f(x) + f_x^T \Delta x + \frac{1}{2} \Delta x^T H(x) \Delta x + \text{HOT}$$

$x_{k+1}$

$$f_k \rightarrow \underline{f(x_k + \Delta x_k)} \approx f(x_k) + f_x^T(x_k) \Delta x_k \quad \left\{ \begin{array}{l} \Delta x_k = x_{k+1} - x_k \\ x_{k+1} = x_k + \Delta x_k \end{array} \right. \rightarrow \text{بر قدر این}$$

$$\Delta x_k = d_k u_k \rightarrow u_k = -\frac{f_x(x_k)}{\|f_x(x_k)\|}, d_k^* = \underset{d_k}{\operatorname{Argmin}} f(x_k + d_k u_k)$$

اگر داشتیم  $\min_{d_k} f(x_k + d_k u_k)$  باشد، آنگاه  $d_k^*$  برابر با  $-\frac{f_x(x_k)}{\|f_x(x_k)\|}$  خواهد بود.

1)  $\|\nabla f(x_k)\| \leq \epsilon_f$

2)  $|f(x_i) - f(x_{i-1})| < \epsilon_f \rightarrow$  برای جزو  $i$

3)  $\|x_i - x_{i-1}\| < \epsilon_x \rightarrow$  برای  $i$

4)  $d_k \in [k, 0], 0 < k < 1$

5)  $a = \text{Number of iterations}$

$f(x) = \frac{1}{2} x^T A x + b^T x + c \rightarrow f_x(x) = Ax + b$

$$\rightarrow x_{k+1} = x_k - d_k \left( \frac{Ax_k + b}{\|Ax_k + b\|} \right)$$

$f(x_k + d_k u_k) = \frac{1}{2} (x_k + d_k u_k)^T A (x_k + d_k u_k) + b^T (x_k + d_k u_k) + c$

$\frac{\partial f}{\partial d_k} = \left( \frac{\partial f}{\partial (x_k + d_k u_k)} \right)^T \frac{\partial (x_k + d_k u_k)}{\partial d_k} = [A(x_k + d_k u_k) + b]^T u_k = 0$

$\Rightarrow [A(x_k + d_k u_k) + b]^T u_k = x_k^T A u_k + d_k u_k^T A u_k + b^T u_k = 0$

cause  $Hx = u_k^T A u_k > 0 \Rightarrow d_k = \frac{-u_k^T (Ax_k + b)}{u_k^T A u_k} = \frac{u_k^T f_x(x_k)}{u_k^T A u_k}$

$$u_k = \frac{-f_x(u_k)}{\|f_x(u_k)\|}$$

$$d_k = \frac{f_x^T(x_k) f_x(x_k)}{f_x^T(x_k) A f_x(x_k)} \times \frac{f_x^T(x_k)}{\|f_x(x_k)\|}$$

**ubject :**

'ear .      Month .      Date .

$$x_{k+1} = x_k + \Delta x_k = x_k + u_k \quad u_k = x_k - \frac{f_x^T(x_k) f_x(x_k)}{f_x^T(x_k) A f_x(x_k)}$$

$$\text{Ex. } f(x) = x_1^2 + 2x_2^2 = \frac{1}{2} x^T \begin{pmatrix} 2 & 0 \\ 0 & 5 \end{pmatrix} x, \quad x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

$$f_{\alpha}(x) = \begin{pmatrix} s\alpha_1 \\ s\alpha_2 \end{pmatrix}, \quad H = A > 0$$

Starting point is  $x_0 = \begin{pmatrix} 2 \\ 2 \end{pmatrix}$ ,  $f(x_0) = 104$ ,  $f_x(x_0) = \begin{pmatrix} 4 \\ 100 \end{pmatrix}$

$$\Rightarrow x_1 = x_0 - \frac{(4 \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}) \begin{pmatrix} 4 \\ 100 \end{pmatrix}}{(4 \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}) \begin{pmatrix} 2 & 0 \\ 0 & 50 \end{pmatrix} \begin{pmatrix} 4 \\ 100 \end{pmatrix}} \quad \begin{pmatrix} 4 \\ 100 \end{pmatrix} = \begin{pmatrix} 1.92 \\ -0.003 \end{pmatrix} \rightarrow f(x_1) = 3.69$$

$$1 + 10^4 \rightarrow 3,64$$

$$\text{Ex. } 3x_1 - \cos(x_2 x_3) - \frac{3}{2} = 0 \rightarrow e_1 = 3x_1 - \cos(x_2 x_3) - \frac{3}{2}$$

$$\left\{ \begin{array}{l} 9x_1^2 - 6.25x_2^2 + 2x_2 - 1 = 0 \rightarrow e_2(x) = 9x_1^2 - 6.25x_2^2 + 2x_2 - 1 \\ \exp(-x_1 x_2) + 20x_3 - \frac{10\pi - 3}{3} = 0 \rightarrow e_3(x) = \exp(-x_1 x_2) + 20x_3 - \frac{10\pi - 3}{3} \end{array} \right.$$

$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

$$x_0 = \begin{pmatrix} \cdot \\ \cdot \\ \cdot \end{pmatrix} \rightarrow F(x_0) = \frac{1}{2} ((-2.5)^2 + (-1)^2 + (10.472)^2) = 58.456, \quad F_{\pi}(x_0) = \begin{pmatrix} -7.5 \\ -2 \\ 209.44 \end{pmatrix}$$

$$\lambda_1 = x_0 - \lambda_0 \frac{F_{\lambda}(x_0)}{\|F_{\lambda}(x_0)\|} = x_0 - \lambda_0 \begin{pmatrix} -7.5 \\ -2 \\ 209.94 \end{pmatrix} / \sqrt{F_{\lambda}(x_0) \cdot F_{\lambda}(x_0)^T}$$

$\lambda_0 = 0.001 \Rightarrow \lambda_1 = \begin{pmatrix} 0.0075 \\ 0.002 \\ -0.20994 \end{pmatrix} \Rightarrow F(\lambda_1) = 23.306 < 58.456$

$$f(x_k + \Delta x_k) \approx f(x_k) + \nabla f(x_k)^T \Delta x_k + \frac{1}{2} \Delta x_k^T H(x_k) \Delta x_k$$

$$\nabla f(x_k + \Delta x_k) = \nabla^T f(x_k) + H(x_k) \Delta x_k = 0 \quad (\text{iff } H(x_k) \succ 0) \quad \Delta x_k = -H^{-1}(x_k) \nabla^T f(x_k)$$

$$\Rightarrow \hat{x}_{k+1} = x_k - H^{-1}(x_k) V^T f(x_k)$$

برای حساب مساحت هر زمینه بزرگی از آن بجزءی داشت شود

**Subject :**

---

Year .      Month .      Date .

$$\text{Ex. } f(x) = \frac{1}{2}x^T A x + b^T x + c \rightarrow \nabla^T f(x) = Ax + b, H(x) = A > 0$$

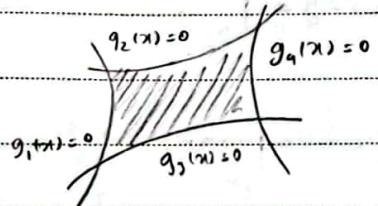
$$\nabla^T f(x) = Ax + b \Rightarrow x^* = -A^{-1}b$$

نیز اپنے ملک کا بھائی تھا جس کو اپنے پیارے بھائی کے نام سے کہا جاتا تھا۔

نحوه برای استفاده از تراکمی ریسون SD دستور است: استفاده از SD سه‌ملل ایندیکاتور تراکمی به صورتی دستی

اسناد از دو کتاب نسیخ و سیفی در مکتبه شاهزاده عباس

$$\begin{array}{l} \text{Minimize } f(x) \\ x \in \mathbb{R}^n \end{array} \quad \left\{ \begin{array}{ll} h_1(x) = 0 & g_1(x) \leq 0 \\ h_2(x) = 0 & g_2(x) \leq 0 \\ \vdots & \vdots \\ h_m(x) = 0 & g_p(x) \leq 0 \end{array} \right. \quad m \leq n$$



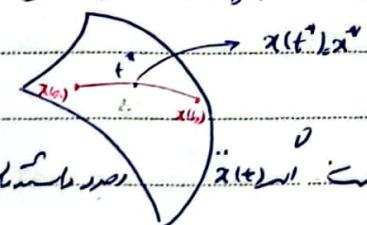
$j=1, \dots, m$      $i=1, \dots, p$

**تقریب** : بحکم راه از احصار درجه تقدیر ممکن نیست اما ممکن است

تمید تاریخی بازخواستگان مسید تاریخی بخوبی تدوینی این جهتی باشند نیاز نیست

مسنون (الرجاء) سفن شهر ابريل ١٩٥٣

وَالْمُؤْمِنُونَ هُمُ الْأَوَّلُونَ مِنْ أَنْفُسِهِمْ وَاللَّهُ يَعْلَمُ مَا يَعْمَلُونَ



و سید مسیح ایشان را درست نمود از مردم گفتم ایشان خواهد بود.

$x^* = x(t^*) \rightarrow \text{order } t^* \text{ of last step} \rightarrow \text{last step is } x^* - \text{last } x(t)$ .

۱۰۷- مسکن ایرانی ها در سرزمین اسلام

Batus

سُسْ جَمَارِيْ مُهَمَّاد حَمَارِيْ لَفَتَةٌ سَرَّادٌ

Subject :

Year . Month . Date .

تعریف این نشانه را در درست روش اسیداری می‌دانیم  $\nabla h(x^*) = 0$

متضاد است

این سایر معنی تعریف است

این نشانه را در درست روش اسیداری می‌دانیم  $\nabla h(x^*) = 0$  که  $x^*$  را می‌گویند

$$M = \{y : \nabla h(x^*) y = 0\}$$

$$h(x(t)) = 0$$

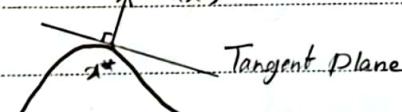
مشتق

$$\frac{d}{dt} \nabla h(x(t)) \dot{x}(t) \Big|_{t=t^*} = 0$$

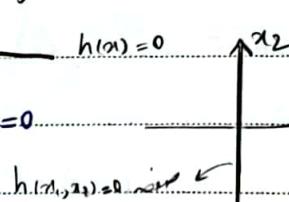
$$\nabla h(x) = \begin{bmatrix} \nabla h_1(x) \\ \nabla h_2(x) \\ \vdots \\ \nabla h_m(x) \end{bmatrix}_{m \times n}$$

$$\begin{cases} h_1 = 0 \\ \vdots \\ h_m = 0 \end{cases}$$

بنابراین جبارهای را درست روش اسیداری می‌دانیم  $\nabla h(x^*) = 0$  و  $x^*$  را می‌گویند

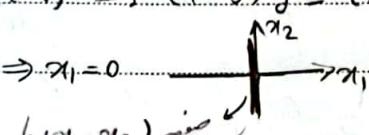


Ex.  $h(x_1, x_2) = x_1 = 0$



آنچه داشتیم  $\nabla h(x_1, x_2) = (1, 0) \rightarrow (1, 0)y = (1, 0)\begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = 0 \Rightarrow y_1 = 0 \Rightarrow M = \{y_1 = 0\}$

Ex.  $h(x_1, x_2) = x_1^2 = 0 \Rightarrow x_1 = 0$



$\nabla h(x^*) = (2x_1^*, 0) \xrightarrow{x_1=0} (0, 0) \Rightarrow$  اینجا می‌دانیم  $x^*$  را می‌گیریم

$\forall y \in \mathbb{R}^2, \nabla h(x^*) y = 0 \Rightarrow M = \mathbb{R}^2 \Rightarrow$  مجموعه

X.

Batus

Subject :

Year . Month . Date .

$$y \in \mathbb{R}^n \text{ such that } \nabla f(x)^\top y = 0 \text{ if and only if } f(x) \text{ is a critical point of } h(x).$$

لیست، بین نشانههایی که میتوانند مقدار  $y$  را که  $\nabla f(x)^\top y = 0$  باشد، داشته باشند، ازین سه میان  $f$  و  $h$  و  $\nabla f(x)^\top y = 0$  است.

$$\frac{d}{dt} f(x(t))|_{t=1} = 0 \Rightarrow \nabla f(x(1))^\top \dot{x}(1) = 0 \Rightarrow \text{هر دو ریون } f \text{ بر جای ریون } h \text{ در اینجا برابر.}$$

آنچه این ریون  $f$  بر جای ریون  $h$  است، میتواند مقدار  $y$  را که  $\nabla f(x)^\top y = 0$  باشد، داشته باشد.

$\nabla f(x)^\top y = 0$  را برای هر  $y \in \mathbb{R}^n$  در دو ریون  $h$  و  $f$  میتواند داشته باشد.

لیست، بین نشانههایی که میتوانند مقدار  $y$  را که  $\nabla h(x)^\top y = 0$  باشد، داشته باشند، بجز متریدن  $\nabla h(x)$ .

لیست، بین نشانههایی که میتوانند مقدار  $y$  را که  $\nabla f(x)^\top y = 0$  باشد، داشته باشند، بجز متریدن  $\nabla f(x)$ .

لیست، بین نشانههایی که میتوانند مقدار  $y$  را که  $\nabla h(x)^\top y = 0$  باشد، داشته باشند، بجز متریدن  $\nabla h(x)$ .

لیست، بین نشانههایی که میتوانند مقدار  $y$  را که  $\nabla f(x)^\top y = 0$  باشد، داشته باشند، بجز متریدن  $\nabla f(x)$ .

$$\nabla f(x^*) + \lambda^T \nabla h(x^*) = 0 \rightarrow \text{لطفاً جانشینی کنید: } \lambda \in \mathbb{R}^m \text{ بر} \\ \text{این: } [\nabla f(x^*)]_{1 \times n} + [\lambda_1, \dots, \lambda_m] \begin{bmatrix} \nabla h_1(x^*) \\ \vdots \\ \nabla h_m(x^*) \end{bmatrix}_{m \times n} = [\nabla f(x^*)] + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) = 0.$$

لیست، بین نشانههایی که میتوانند مقدار  $y$  را که  $\nabla f(x)^\top y = 0$  باشد، داشته باشند.

$$\frac{\partial L}{\partial x} = 0 \rightarrow \nabla f(x) + \lambda^T \nabla h(x) = 0 \rightarrow \text{لطفاً جانشینی کنید: } \lambda = \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_m \end{pmatrix} \in \mathbb{R}^{n+m}, \quad x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^{n+m} \\ \frac{\partial L}{\partial \lambda} = 0 \rightarrow h(x) = 0 \rightarrow \text{لطفاً جانشینی کنید: } x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n, \quad h(x) = 0 \in \mathbb{R}^m.$$

Batus

پیشنهاد شده است.

Subject :

Year . Month . Date .

$$\text{Ex. Maximize } x_1x_2 + x_2x_3 + x_1x_3 \quad \text{s.t. } x_1 + x_2 + x_3 = 3$$

$$\equiv \text{Minimize } -x_1x_2 - x_2x_3 - x_1x_3 \quad x_1 + x_2 + x_3 = 3$$

$f(x)$

$$\begin{cases} \nabla f(x) + \lambda^T \nabla h(x) = -(x_2 + x_3, x_1 + x_3, x_1 + x_2) + \lambda(1, 1, 1) = 0 \\ h(x) = 0 \Rightarrow x_2 + x_3 + x_1 = 3 \end{cases} \quad \left. \begin{array}{l} \lambda = 2 \\ x_1 = x_2 = x_3 = 1 \end{array} \right\}$$

$$\text{Ex. Maximize } xyz \quad \text{s.t. } xy + yz + zx = \frac{c}{2}, c > 0$$

$$\nabla f(x) + \lambda^T \nabla h(x) = \begin{pmatrix} -yz \\ -xz \\ -xy \end{pmatrix} + \lambda \begin{pmatrix} y+z \\ z+x \\ x+y \end{pmatrix} = 0$$

$$h(x) = 0 \rightarrow xy + yz + zx = \frac{c}{2}$$

$$x \times ① - y \times ② = \lambda(x-y)z = 0$$

$$\begin{aligned} y \times ② - z \times ③ = \lambda(y-z)x = 0 \\ z \times ③ - x \times ① = \lambda(z-x)y = 0 \end{aligned} \quad \left. \begin{array}{l} ④ \\ ① + ② + ③ = -(xy + yz + zx) + 2\lambda(x+y+z) = 0 \\ \Rightarrow 2\lambda(x+y+z) = \frac{c}{2} \end{array} \right\} \quad (1)$$

$$(I) \quad 2\lambda(x+y+z) = \frac{c}{2} \rightarrow \text{if } \lambda < 0 \rightarrow 0 = \frac{c}{2} > 0 \Rightarrow \text{X}$$

$$(II) \quad x=0 \rightarrow \lambda z = 0 \rightarrow z=0 \rightarrow \lambda y = 0 \rightarrow y=0 \rightarrow \text{مطلبانه } y=0, z=0 \text{ مطابق}\}$$

$$\lambda \neq 0, z \neq 0 \rightarrow y \neq 0 \rightarrow x \neq 0 \quad \text{مطلبانه}$$

$$④ \quad x=y=z = \pm \sqrt{\frac{c}{6}}$$

$$④ \quad \lambda = \pm \frac{1}{2} \sqrt{\frac{c}{6}}$$

لطفاً اینجا مذکور شود

$$M = \{y : \text{There } y \neq 0 \text{ such that } h(y) = 0 \text{ and } f(\alpha^*) \leq f(y)\} \quad (1)$$

برای  $M$  میتوان سنت ای

$$L(\alpha^*) = \nabla^2 f(\alpha^*) + \lambda^T \nabla^2 h(\alpha^*) = F(\alpha^*) + \lambda^T H(\alpha^*) \rightarrow \forall y \in M, y^T L(\alpha^*) y \geq 0$$

Subject :

Year . Month . Date .



$$\text{we know: } \frac{d^2 f}{dt^2} \Big|_{t=t^*} \geq 0$$

$$\textcircled{1} \quad \frac{d}{dt^2} \left( \nabla f(x(t)) \dot{x}(t) \right) = \ddot{x}(t)^T \nabla^2 f(x(t)) \dot{x}(t) + \nabla f(x(t))^T \ddot{x}(t) \geq 0$$

$$\begin{aligned} \nabla^T h(x) &= 0 \xrightarrow{\text{def}} \nabla^T \nabla h(x(t)) \dot{x}(t) = \sum_i \partial_i \nabla h_i(x(t)) \dot{x}(t) = 0 \\ &\xrightarrow{\text{def}} \dot{x}(t)^T \underbrace{\sum_{i=1}^m \partial_i \nabla^2 h_i(x(t)) \dot{x}(t)}_{\nabla^T \nabla^2 h(x(t))} + \sum_{i=1}^m \partial_i \nabla h_i(x(t)) \ddot{x}(t) = 0 \end{aligned}$$

$$\textcircled{2} \quad \dot{x}(t)^T \nabla^T \nabla^2 h(x(t)) \dot{x}(t) + \nabla^T \nabla h(x(t)) \ddot{x}(t) = 0$$

$$\rightarrow \textcircled{1} + \textcircled{2} \geq 0 \rightarrow \dot{x}(t) \left[ \nabla^2 f(x(t)) + \nabla^T \nabla^2 h(x(t)) \right] \dot{x}(t) + \left[ \nabla f(x(t)) + \nabla^T \nabla h(x(t)) \right] \ddot{x}(t) \geq 0$$

at  $t = t^* = 0$

$$\Rightarrow \dot{x}(t^*)^T \left[ \nabla^2 f(x^*) + \nabla^T \nabla^2 h(x^*) \right] \dot{x}(t^*) \geq 0$$

$$= \dot{x}(t^*)^T [F(x^*) + \nabla^T H(x^*)] \dot{x}(t^*) \geq 0 \rightarrow y^T [F(x^*) + \nabla^T H(x^*)] y \geq 0 \text{ for } \forall y \in M$$

$x^*$  is a minimum point

$$\Rightarrow \text{For all } y \in M : y^T L(x^*) y \geq 0$$

$\nabla^T \nabla h(x^*) = 0$  because  $\nabla h(x) = 0$  at  $x = x^*$  is sufficient

$$\text{Let } y \in M = \{y : \nabla h(x^*) y = 0\} \Rightarrow h(x^*)^T \nabla f(x^*) + \nabla^T \nabla h(x^*) = 0 \text{ and } y \in \mathbb{R}^m$$

$$\Rightarrow y^T L(x^*) y \geq 0, \forall y \in M \quad \text{so } h(x) = \nabla^T f(x) \text{ at } x = x^* \text{ is min}$$

$$\text{Ex. Max } x_1 x_2 + x_2 x_3 + x_1 x_3 \quad \text{s.t. } x_1 + x_2 + x_3 = 3$$

$$\text{Min } -x_1 x_2 - x_2 x_3 - x_1 x_3 = f(x) \rightarrow \nabla^T f = -\begin{pmatrix} x_2 + x_3 \\ x_1 + x_3 \\ x_1 + x_2 \end{pmatrix}, \nabla^2 f = -\begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

$$h(x) = x_1 + x_2 + x_3 - 3 = 0 \rightarrow \nabla^T h = \begin{pmatrix} 1 & 1 & 1 \end{pmatrix}, \nabla^2 h = 0$$

$$\nabla^2 f(x^*) + \nabla^T \nabla^2 h = -\begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \rightarrow \text{is PSD} \rightarrow \text{minimum}$$

(if  $\lambda_{\min} \geq 0$ )! NSD

! linearly independent PSD system  $- \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$  is not positive definite

! global minimum

**Subject :**

Year .      Month .      Date .

$$\left\{ \begin{array}{l} \nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) + \sum_{j=1}^p \mu_j \nabla g_j(x^*) = 0 \\ \sum_{j=1}^p \mu_j g_j(x^*) = 0 \\ h_i(x^*) = 0 \end{array} \right.$$

جوانِ نئے نہیں تھے اب تک بس کان لفٹا تو اپنے بیٹے کو بینچھے تیر دیا تھا جو اپنے بیٹے کو بینچھے تیر دیا تھا

مان یا یه راسته سرمهای (و می بس تینل جی دی عز منعه بر)

لایسنسی تدریخنال (لایسنسی در تاریخ ایران ظاهر شد) پایه طبقه بسته  $M_j = \{j \in \mathbb{N} : \text{ابعاد ریاضی معرفت}\}$

$$\left\{ \begin{array}{l} g_j(x^*) < 0 \rightarrow \mu_j = 0 \\ g_j(x^*) = 0 \rightarrow \mu_j > 0 \end{array} \right.$$

( $M \geq 0$ )  $\min_{\mathbf{x} \in \mathbb{R}^n} \frac{1}{2} \mathbf{x}^\top M \mathbf{x} + \mathbf{b}^\top \mathbf{x} = 0$

لـ  $\lambda$  دلیل انسانیت دل داشت و  $M_k(\alpha, g_k(\lambda)) = 0$  نیز داشت.

$$D: \{y : \nabla h(x^*)y = 0, \nabla g_j(x^*)y = 0, j \in J \}$$

$$\exists y \in D : x = a + \frac{dy}{2} \quad \text{as } d \ll 1 : g_k(x) < 0 \quad (\text{True})$$

(عہد)

$\alpha$   $\rightarrow J_{lc}(\alpha) = 0$

$\alpha'$   $\rightarrow$  سرمه، غمز

$$\Rightarrow g_k(x^* + \alpha y) = g_k(x^*) + \nabla g_k(x^*)(\alpha y) + o(\alpha) < 0$$

دین و فنون و علوم داشتند و بعد از آن میگردید

$$\Rightarrow \lim_{n \rightarrow \infty} g_n(x^*) = 0$$

$$\nabla f(x^*) + \alpha^T \nabla h(x^*) + \mu_k^T \nabla g_{-k}(x^*) + \lambda_k^T \nabla g_k(x^*) = 0$$

$$\rightarrow \underbrace{\nabla f(x^*) y}_{0} + \underbrace{\partial^T \nabla h(x^*) y}_{0} + \underbrace{\mu_{-k}^T \nabla g_{-k}(x^*) y}_{0} + \underbrace{\mu_k^T \nabla g_k(x^*) y}_{0} = 0 \Rightarrow \nabla f(x^*) y < 0$$

$$\text{Bafus} \xrightarrow{\text{استناد از بیانی}} f(x+uy) < f(x) \Rightarrow \exists \text{ مجموعه ای از } x^* \geq 0 \Rightarrow X \Rightarrow \mu_k \geq 0!$$

Subject :

Year . Month . Date .

Ex. Min  $2x_1^2 + 2x_1x_2 + x_2^2 - 10x_1 - 10x_2$  s.t.  $x_1^2 + x_2^2 \leq 5$   $\nabla g = \begin{pmatrix} \nabla g_1 \\ \nabla g_2 \end{pmatrix}$   
 $3x_1 + x_2 \leq 6$

$$\nabla f(x^*) + \lambda^T \nabla h(x^*) + \mu^T \nabla g(x^*) = (9x_1 + 2x_2 - 10, 2x_1 + 2x_2 - 10) + (\mu_1, \mu_2) \begin{pmatrix} 2x_1 & 2x_2 \\ 3 & 1 \end{pmatrix} = 0$$

$$9x_1 + 2x_2 - 10 + 2\mu_1 x_1 + 3\mu_2 = 0$$

$$2x_1 + 2x_2 - 10 + 2\mu_1 x_2 + \mu_2 = 0$$

$$\left. \begin{array}{l} \mu_1(x_1^2 + x_2^2 - 5) = 0 \quad \mu_1 > 0 \\ \mu_2(3x_1 + x_2 - 6) = 0 \quad \mu_2 > 0 \end{array} \right\} \rightarrow \mu_1(x_1^2 + x_2^2 - 5) + \mu_2(3x_1 + x_2 - 6) = 0 \equiv \mu^T g(x) = 0$$

بيانات بحثية : (1) مجموع المتغيرات مطلوب

$$\left. \begin{array}{l} \mu_1 = 0 = \mu_2 \Rightarrow 9x_1 + 2x_2 - 10 = 0 \\ 2x_1 + 2x_2 - 10 = 0 \end{array} \right\} \rightarrow \begin{array}{l} x_1 = 0 \\ x_2 = 5 \end{array} \Rightarrow g_1(0, 5) = 25 - 5 = 20 \neq 0 \Rightarrow \times.$$

الحل الثاني بـ (2)

$$\left. \begin{array}{l} \mu_2 = 0 \Rightarrow 9x_1 + 2x_2 - 10 + 2\mu_1 x_1 = 0 \\ 2x_1 + 2x_2 - 10 + 2\mu_1 x_2 = 0 \Rightarrow \begin{cases} x_1 = 1 \\ x_2 = 2 \end{cases} \\ x_1^2 + x_2^2 - 5 = 0 \end{array} \right\} \mu_1 = 1 > 0 \quad \checkmark$$

الحل الثالث بـ (3)

$$\left. \begin{array}{l} \mu_1 = 0 \Rightarrow 9x_1 + 2x_2 - 10 + 3\mu_2 = 0 \\ 2x_1 + 2x_2 - 10 + \mu_2 = 0 \Rightarrow \begin{cases} x_1 = 2/5 \\ x_2 = 6 - 6/5 \\ 3x_1 + x_2 = 6 \end{cases} \\ \mu_2 = -2/5 < 0 \Rightarrow \times. \end{array} \right.$$

الحل الرابع بـ (4)

$$\left. \begin{array}{l} 9x_1 + 2x_2 - 10 + 2\mu_1 x_1 + 3\mu_2 = 0 \\ 2x_1 + 2x_2 - 10 + 2\mu_1 x_2 + \mu_2 = 0 \\ x_1^2 + x_2^2 - 5 = 0 \\ 3x_1 + x_2 = 6 = 0 \end{array} \right\} \rightarrow \text{لا يتحقق الشرط}$$

لتحقيق شرط التفاضلية  $f, g, h \in C^2$  ومحضن  $\lambda$  من

لتحقيق شرط التفاضلية  $f, g, h \in C^2$  ومحضن  $\lambda$  من

برهان بـ (PSP) بـ (PSP) بـ (PSP)

$$L(x^*) = \nabla^2 f(x^*) + [\nabla^T \nabla^2 h(x^*)] + \mu^T [\nabla^2 g(x^*)]$$

$$M' = \{y : \nabla h(x^*) y = 0, \nabla g_j(x^*) y = 0 \quad \forall j \in J\} \rightarrow$$

$$y^T L(x^*) y \geq 0$$

Subject :

Year . Month . Date .

لما  $f, g, h \in C^2$  فـ  $L(x^*)$  امرأة

$\lambda \in R^P, \mu \in R^n$  ينطبق على  $L(x^*)$  (متضمنة في  $L(x^*)$ )

$$M > 0$$

$$M^T g(x^*) = 0$$

$$\nabla f(x^*) + \lambda^T \nabla h(x^*) + \mu^T \nabla g(x^*) = 0$$

$\forall y \in M' : y^T L(x^*) y > 0$  معنـى مـن  $M'$  بـ  $L(x^*)$

$$L(x^*) = \nabla^2 f(x^*) + \lambda^T \nabla^2 h(x^*) + \mu^T \nabla^2 g(x^*) = \begin{pmatrix} 4 & 2 \\ 2 & 2 \end{pmatrix} + (1, 0) \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} + (1, 1) \begin{pmatrix} 6 & 2 \\ 2 & 4 \end{pmatrix}$$

بـ  $\det L(x^*) > 0$  ،  $\Rightarrow$  مـن  $L(x^*)$  بـ  $L(x^*)$

Ex.  $\text{Min. } \frac{1}{2}(x_1^2 + x_2^2)$

$$\text{s.t. } x_1 + x_2 = 2 \Rightarrow x_1 + x_2 - 2 = 0 \quad \left\{ \begin{array}{l} \nabla f(x^*) + \lambda^T \nabla h(x^*) + \mu^T \nabla g(x^*) = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \lambda \begin{pmatrix} 1 \\ 1 \end{pmatrix} + (\mu_1, \mu_2) \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} \quad (I) \\ M_1(-x_1) = 0 \quad M_1 > 0 \\ M_2(-x_2) = 0 \quad M_2 > 0 \end{array} \right.$$

$$x_1 > 0, \quad x_2 > 0$$

$$-x_1 \leq 0, \quad -x_2 \leq 0$$

$$(I) : x_1 + \lambda - \mu_1 = 0 \quad -M_1 x_1 = 0$$

$$x_2 + \lambda - \mu_2 = 0 \quad -\mu_2 x_2 = 0$$

$$x_1 + x_2 - 2 = 0$$

جـ 1:  $x_1 = x_2 = 1$

$$\mu_1 = \mu_2 = 0 \rightarrow \begin{cases} x_1 + \lambda = 0 \\ x_2 + \lambda = 0 \\ x_1 + x_2 = 0 \end{cases} \rightarrow \lambda = -1 \quad x_1 = x_2 = 1$$

$$\text{جـ 1: } L(x^*) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + (-1) \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} > 0 \quad \checkmark$$

$$x_1 = 0 \Rightarrow \mu_1 = 0 \Rightarrow x_2 = 2 \Rightarrow \lambda = -2 \Rightarrow \mu_2 = -2 \quad \checkmark$$

$$x_2 = 0 \Rightarrow \mu_2 = 0 \Rightarrow x_1 = 2 \Rightarrow \lambda = -2 \Rightarrow \mu_1 = -2 \quad \checkmark$$

$$x_1 + x_2 = 0 \Rightarrow x_1 + x_2 - 2 = -2 = 0 \quad \checkmark$$

جـ 2:  $x_1 = 2$

جـ 3:  $x_1 = 0$

Batus

جـ 4:  $x_1 = 1$

**Subject :**

Year .      Month .      Date .

مکالمہ مخصوصاً اخراجی ترکیب بھروسے

در این سازی سه اسری محیط سفید است که تصور تبدیل شدن آنها در زمانی دستوری بجهه آنها می‌باشد

دیگر نیز می‌تواند در اینجا از دستورات مذکور در بینهایت ساده باشد.

$$\text{Min } f(\alpha) \quad \text{s.t. } g_j(\alpha) \leq 0, \quad j = 1, \dots, p \\ h_i(\alpha) = 0, \quad i = 1, \dots, m$$

اپنے مکان کا بذکر اپنے نئے بڑے سوسائٹی میں

نکه است که خوب نمی خواهد این سرمه های خوب را بخواهد این سرمه های خوب را بخواهد

تہذیب الراء

زیارتگاری زنگنه از اینجا آغاز شد؛ برای زنگنه حادثه‌ی

تعمیم امر  $\int$  برای اینجا برآورده است:  $\int g(x) dx = \{x : g(x) \leq \beta\}$

برای  $h_i$  میتوانیم  $a = h_i(x)$  را درست نماییم؛ بنابراین  $a \leq h_i(x) \leq b$  است.

نیز میں : }  $h_{12}$  پر محرب بیس =  $h_{12}$  حرباً بیس هم بیس سریاً !

$$\begin{aligned} \nabla^2 h(x) &\geq 0 \\ -\nabla^2 h(x) &\geq 0 \end{aligned} \quad \left\{ \Rightarrow \nabla^2 h(x) = 0 \Rightarrow h(x) = Ax + B \right. \quad \text{affine} \quad \left. \approx h(x) \right.$$

کتابخانه ملی افغانستان (KKT) (کتابخانه ملی افغانستان)

$$L(x, \vartheta, \mu) = f(x) + \vartheta^T h(x) + \mu^T g(x) = f(x) + \sum_{i=1}^m \vartheta_i h_i(x) + \sum_{j=1}^p \mu_j g_j(x) \rightarrow$$

مکانیزم این انتقال را می‌توان با استفاده از معادله (۲)، (۳) و (۴) بدستور

Subject :

Year . Month . Date .

- 1)  $h(x^*) = 0, g(x^*) \leq 0 \rightarrow \text{primal Feasibility}$
- 2)  $\mu^* > 0 \rightarrow \text{dual Feasibility}$
- 3)  $\nabla_x L(x, \lambda, \mu) = \nabla f(x^*) + \lambda^T \nabla h(x^*) + \mu^T \nabla g(x^*) = 0 \rightarrow \text{Lagrangian optimality}$
- 4)  $\mu^{*T} g(x^*) = 0 \rightarrow \text{Complementary slackness}$

Duality: Min  $f_0(x)$   $\rightarrow D = \bigcap_{i=1}^m \text{dom } f_i \bigcap_{i=1}^p \text{dom } h_i$   
s.t.  $f_i(x) \leq 0, i=1, \dots, m \quad \leftarrow x \in D \subseteq \mathbb{R}^m$   
 $h_i(x) = 0, i=1, \dots, p \quad \rightarrow \text{optimal value} = \mu^*$

convex optimization + linear programming  $\leftarrow$  (Primal)  $\rightarrow$  dual

Lagrangian:  $L(x, \lambda, \mu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \mu_i h_i(x)$  : primal

Lagrangian dual function:

$$g(\lambda, \mu) = \inf_{x \in D} L(x, \lambda, \mu) \quad \rightarrow \text{minimum of primal problem} \rightarrow \inf_{x \in D}$$

مقدار دوچرخه

$$= \inf_{x \in D} \left( f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \mu_i h_i(x) \right)$$

(Inequality)  $\lambda_i \geq 0, \mu_i \geq 0$   $\rightarrow$   $g(\lambda, \mu)$   $\leq f_0(x^*) + \sum_{i=1}^m \lambda_i f_i(x^*) + \sum_{i=1}^p \mu_i h_i(x^*)$   
جایزه دوچرخه ای  $\leq$  جایزه دوچرخه ای  $\leq$  جایزه دوچرخه ای

$L(x_1, \lambda)$   $\rightarrow L(x_1, \lambda)$



$\text{hyp}(f) = \{(x, r) \in D \times \mathbb{R} | f(x) \geq r\} \rightarrow f \text{ is concave iff } \text{hyp}(f) \text{ convex}$

$\rightarrow$  hypograph  $\rightarrow$  f is convex

$\rightarrow \text{hyp}(\inf_{x_1} L(x_1, \lambda)) = \text{hyp}(L(x_1, \lambda)) \cap \text{hyp}(L(x_2, \lambda))$

Batus

Subject :

Year . Month . Date .

Convexity of an affine op, & point wise superadditive

Concave function is subadditive

Convex:  $\text{epif} = \{(x, r) \in D \times R \mid f(x) \leq r\} \rightarrow f \text{ convex iff epif is convex}$

Concave dual:  $\text{epif}^* = \{(x, r) \in D \times R \mid g(x, p) \geq r\} \rightarrow g(x, p) \text{ concave iff epif}^* \text{ is convex}$

Lower bound property:

$g(\lambda, \mu) \leq P^*$  if  $\lambda \geq 0$

$$f_*(\tilde{x}) \geq L(\tilde{x}, \lambda, \mu) \stackrel{\lambda \geq 0}{\geq} f_*(\tilde{x}) + \sum_{i=1}^m \lambda_i f_i(\tilde{x}) + \sum_{j=1}^p \mu_j h_j(\tilde{x}) \leq f_*(\tilde{x})$$

We know,  $L(\tilde{x}, \lambda, \mu) \geq \inf L(x, \lambda, \mu) = g(\lambda, \mu)$

$x \in D$

$f_*(\tilde{x}) = P^* \geq g(\lambda, \mu)$

The dual problem (Lagrange dual problem): Max  $g(\mu, \lambda)$

s.t.  $\lambda \geq 0$

دual problem: Max  $g(\mu, \lambda)$  over  $\lambda \geq 0$  is convex

( $d^* = \text{dual minimum}$ ) over  $\lambda \geq 0$  is called  $P^*$  or strong d.

Duality gap:  $P^* - d^*$   $\rightarrow d^* \leq P^*$  weak duality

$\downarrow d^* = P^*$  strong duality  $\rightarrow$  called  $P^*$  is convex

Non-convex function is not strong d.

Converse of weak d.

Batus

Subject :

Year . Month . Date .

Slater's constraint qualification مُسْتَاد :  $\min f_1(x)$

(CQ)  $s.t. f_i(x) \leq 0, i=1, \dots, m$

$Ax=b$

if  $\exists \bar{x} \in \text{int } D : f_i(\bar{x}) < 0 \rightarrow$   $\bar{x}$  strictly feasible point convex in constraints  
 $i=1, \dots, m$   
 $A\bar{x}=b$

• CQ

$p^* = d^*$  Strong duality (Q)  $\bar{x}$  convex in extreme point

$x^*, \lambda^*, p^*$  via (N)  $d^* = p^*$  dual solution  $\lambda^*$  primal solution  $x^*$   $\leftarrow$

Weak KKT  $\bar{x}$  convex in extreme point  $\lambda^*$  dual solution  $\lambda^*$

Primal  $\bar{x}$ , dual  $\lambda^*$  weak KKT  $\bar{x}$  dual  $\lambda^*$  convex

Weak KKT  $\bar{x}$  extreme point  $\lambda^*$  dual solution  $\lambda^*$

2)  $g(\bar{x}, \bar{\mu}) = \inf \{ h(\bar{x}, \bar{x} + \bar{\mu}) \} \rightarrow \bar{x}^* \in \text{Argmin } L(x, \bar{x}^*, \bar{\mu}^*)$  (I)

NED

NED

Primal  $\bar{x}$ , dual  $\bar{\mu}$  CS, feasibility  $\bar{x}$  extreme point  $\bar{\mu}$  dual solution

Strictly convex in  $\bar{x}$  strictly convex in  $\bar{\mu}$  Primal  $\bar{x}$  extreme point  $\bar{\mu}$  dual solution

KKT  $\bar{x}$  extreme point strictly convex in  $\bar{\mu}$  Primal  $\bar{x}$  extreme point dual solution  $\bar{\mu}$

Not unique  $L(x^*, \bar{\mu})$  not  $\bar{x}$  extreme point,  $\bar{\mu}$  not dual solution  $\bar{\mu}$  not dual solution

values

Subject :

Strong duality

Year . Month . Date .

$$P^* = f_*(\bar{x}) \leq g(\bar{\lambda}, \bar{M}) = \inf_{\lambda} \left\{ f_*(\lambda) + \sum_{i=1}^m \bar{\lambda}_i^* f_i(\lambda) + \sum_{i=1}^p \bar{M}_i^* h_i(\lambda) \right\}$$

$$= \inf_{\lambda} f_*(\lambda) + \sum_{i=1}^m \bar{\lambda}_i^* f_i(\lambda) + \sum_{i=1}^p \bar{M}_i^* h_i(\lambda) \leq f_*(\bar{\lambda}) = f_*(\bar{x})$$

$\geq 0 \quad \leq 0 \quad = 0$

دالة مُقيّدة

(\*)  $f_*(\bar{x}) = f_*(\bar{\lambda})$  if feasible (جواب مُمكن)

$$\sum_{i=1}^m \bar{\lambda}_i^* = \alpha \in \text{int}(CS) \subset \mathbb{R}$$

لأنه

(Dual problem is strictly convex) ! therefore Primal is strictly convex (جواب)

Ex.  $\text{Min } \sum_{i=1}^n f_i(x_i)$

$$\text{s.t. } a^T x = b \rightarrow a = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix}, x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

$f_i(x_i) = \frac{1}{2} c_i x_i^2$  These are strictly convex  $\Rightarrow \sum f_i(x_i)$  is strictly convex  
and  $a^T x = b$  is convex

$$g(\mu) = \min_{\lambda} \left\{ \sum_{i=1}^n \frac{1}{2} c_i x_i^2 + \mu(b - a^T \lambda) \right\} = \mu b + \min_{\lambda} \left\{ \sum_{i=1}^n \frac{1}{2} c_i x_i^2 - \mu \sum_{i=1}^n a_i x_i \right\}$$

: primal dual separation

$$= \mu b + \min_{\lambda} \left\{ \sum_{i=1}^n \left\{ \frac{1}{2} c_i x_i^2 - \mu a_i x_i \right\} \right\} = \mu b + \underbrace{\min_{\lambda} \left\{ \frac{1}{2} c_i x_i^2 - \mu a_i x_i \right\}}_{x_i^* = a_i \mu}$$

$$g(\mu) = \mu b + \sum_{i=1}^n \left[ \frac{1}{2} \frac{a_i^2}{c_i} \mu^2 - \frac{a_i^2}{c_i} \mu^2 \right] = \mu b - \frac{\mu^2}{2} \sum_{i=1}^n \frac{a_i^2}{c_i} = b\mu - \frac{1}{2} \mu^2$$

$$\text{Max } g(\mu) = \text{Max } b\mu - \frac{1}{2} \mu^2 \rightarrow \mu^* = \frac{b}{t} \rightarrow x_i^* = \frac{a_i \mu^*}{c_i} = \frac{a_i b}{c_i t}$$

dual  $\rightarrow$  primal solution

min  $\varphi(x, z)$  is called the extended function

$$\varphi(x^*, z) \leq \varphi(x^*, z^*) \leq \varphi(x, z^*) \quad \forall x \in X, \forall z \in Z \rightarrow \varphi(x^*, z^*) = \varphi(x^*, z)$$

Batus

Subject :

Year . Month . Date .

بحدسال مکانیت اینستیتیو ایرانی از اینستیتیو ایرانی

$$\sup_{z \in Z} \varphi(x^*, z) = \varphi(x^*, z^*) = \inf_{x \in X} \varphi(x, z^*)$$

لبرمینمای (ز) اینستیتیو ایرانی

$$\sup_{z \in Z} \inf_{x \in X} \varphi(x, z) = \inf_{x \in X} \sup_{z \in Z} \varphi(x, z)$$

① Minimax inequality (کلیه اینستیتیو ایرانی) :  $\forall z \in Z \quad \varphi(x^*, z) \leq \sup_{z \in Z} \varphi(x, z)$

$$\inf_{x \in X} \varphi(x, z) \leq \sup_{z \in Z} \varphi(x, z)$$

$\Rightarrow \inf_{x \in X} \varphi(x, z) \leq \inf_{x \in X} \sup_{z \in Z} \varphi(x, z)$  for all  $z \in Z$

$$\sup_{z \in Z} \inf_{x \in X} \varphi(x, z) \leq \inf_{x \in X} \sup_{z \in Z} \varphi(x, z)$$

Ex.  $f(x, y) = x + y$ ,  $S = \{(x, y) | x=0, 1, 2, y=0, 1, 2, |x-y| < 2\}$

①  $\inf_x \sup_y f(x, y) = \inf_x \sup_{y \in S} (x + y) = \inf_x (x + 2) = 3$       ②  $\sup_y \inf_x f(x, y) = \sup_y \inf_{x \in S} (x + y) = \sup_y (y + 0) = 1 \Rightarrow \sup_y \inf_x f(x, y) \leq \inf_x \sup_y f(x, y)$

$\inf_{x \in X} \sup_{z \in Z} \varphi(x, z) \leq \sup_{z \in Z} \varphi(x^*, z) = \varphi(x^*, z^*) = \inf_x \varphi(x, z^*) \leq \sup_{x \in X} \inf_z \varphi(x, z)$

②  $\inf_{x \in X} \sup_{z \in Z} \varphi(x, z) \leq \sup_{z \in Z} \inf_{x \in X} \varphi(x, z)$

① and ② :  $\inf_{x \in X} \sup_{z \in Z} \varphi(x, z) = \sup_{z \in Z} \inf_{x \in X} \varphi(x, z)$  if  $(x^*, z^*)$  نظری

کلیه اینستیتیو ایرانی

$$x^* = \operatorname{Argmin}_x \sup_{z \in Z} \varphi(x, z)$$

$$z^* = \operatorname{Argmax}_z \inf_{x \in X} \varphi(x, z)$$

Batus

Subject :

Year . Month . Date .

$$\sup_{\mathcal{Z} \in \mathcal{X}} \varphi(x, z) = \inf_{z \in \mathcal{Z}} \varphi(x, z) \leq \varphi(x^*, z^*) \leq \sup_{z \in \mathcal{Z}} \varphi(x^*, z) = \inf_{x \in \mathcal{X}} \sup_{z \in \mathcal{Z}} \varphi(x, z)$$

عند تفاصيل المقدمة في الفصل السادس

برهان الـ (2) بحسب المقدمة

$\lambda$  يمثل المقدمة

برهان الـ (1) بحسب المقدمة

برهان الـ (3) بحسب المقدمة

$$L(x, \lambda, \mu) = f(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^m \mu_j h_j(x) \quad \sup_{x \in \mathcal{X}, \lambda \geq 0, \mu \geq 0} L(x, \lambda, \mu) = \begin{cases} f(x) & h_i(x) = 0 \\ \infty & f_i(x) \leq 0 \end{cases}$$

$\Rightarrow \inf_{x \in \mathcal{X}} \sup_{\lambda \geq 0, \mu \geq 0} L(x, \lambda, \mu) = p^* \Rightarrow x^* = \arg \min_{x \in \mathcal{X}} \sup_{\lambda \geq 0, \mu \geq 0} L(x, \lambda, \mu) \rightarrow$  البرهان

$$\sup_{x \in \mathcal{X}} \inf_{\lambda \geq 0, \mu \geq 0} L(x, \lambda, \mu) \leq p^* \Rightarrow (x^*, \lambda^*, \mu^*) \text{ هو解} \inf_{x \in \mathcal{X}} L(x, \lambda, \mu) \rightarrow \text{dual inequality}$$

$$\inf_{\lambda \geq 0, \mu \geq 0} \sup_{x \in \mathcal{X}} L(x, \lambda, \mu) = \sup_{\lambda \geq 0, \mu \geq 0} \inf_{x \in \mathcal{X}} L(x, \lambda, \mu) \quad \text{برهان الـ 1: strong duality}$$

Subject :

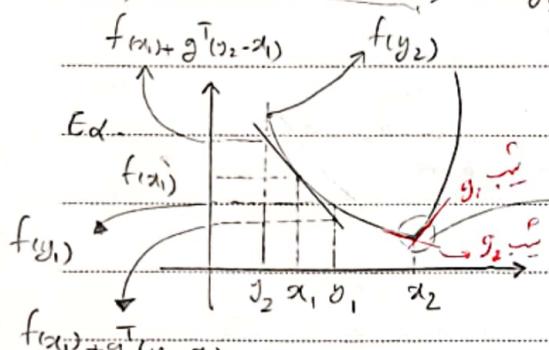
Year . Month . Date .

## Subgradient (زیرگرادیان)

درس سه بیرونی رسانیده باشند

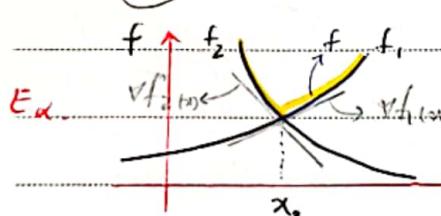
$$f(y) \geq f(x) + g^T(y-x)$$

$$f(y_2) \geq f(x_1) + g_1^T(y_2 - x_1)$$



این نتیجه حب بیرونی رسانیده باشند

این نتیجه حب بیرونی رسانیده باشند



$$f(y) \geq f(x_1) + g^T(y_1 - x_1) \rightarrow$$

$$\begin{cases} f_1(x) > f_2(x) \rightarrow g = \nabla f_1(x_1) \\ f_2(x) > f_1(x) \rightarrow g = \nabla f_2(x_1) \\ f_1(x_1) = f_2(x_1) \rightarrow g \in [\nabla f_2(x_1), \nabla f_1(x_1)] \end{cases}$$

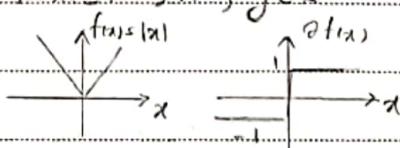
Subdifferential پیوسته باشند Subgradient همیشگی باشند

## Subdifferential (زیرگرادیان)

نهایی دلخواه باشند

$$\partial f(x) = \{g : f(z) \geq f(x) + g^T(z-x)\} \quad \text{Ex. } f: X \subseteq \mathbb{R}^n \rightarrow \mathbb{R}, g \in \mathbb{R}^m$$

$$\forall z \in X$$



زیرگرادیان دلخواه باشند

$$f(x): \mathbb{R}^n \rightarrow \mathbb{R} \rightarrow \text{Initial Min point} \rightarrow \text{initial } x_0 \rightarrow x_{k+1} = x_k - \alpha_k g_k$$

Step size  $\alpha_k$

کوچکترین دلخواه باشند

دسترسی دارند

Bonus

Subject : \_\_\_\_\_

Year . Month . Date .

$$f_k^{\text{best}} = \min_{i=1,2,\dots,k} f(x_i)$$

حال مخصوص ریاضی

متین دسته ای خوب در کارهای اول

step size نماینده احباب است

$$1) \alpha_k = d$$

$$2) \text{ طریق ریت } : \|x_{k+1} - x_k\| = \gamma, \alpha_k = \frac{\gamma}{\|g_k\|_2}$$

$$3) \sum_{k=1}^{\infty} \alpha_k^2 < \infty, \sum_{k=1}^{\infty} \alpha_k = \infty \Rightarrow \lim_{k \rightarrow \infty} \alpha_k = 0$$

$$\text{Ex. } \alpha_k = \frac{1}{k}$$

$$4) \sum_{k=1}^{\infty} \alpha_k^2 = \infty, \sum_{k=1}^{\infty} \alpha_k = \infty \Rightarrow \text{Ex. } \alpha_k = \frac{1}{k^{0.5}}$$

مثال کیا تئینی خواہی سبی کتابخ حلب ملکیت نویسین دیداری

مثال کیا کامپیوٹر بخدمات ایمنی خواهد

جیسا یعنی دلخواہی کے سوال کیسے فرمائے دارست

$$f(x^*) = f^* = \inf_x f(x) > -\infty \quad ①$$

$$\|g\|_2 \leq G \quad \forall g \in \partial f \quad ②$$
$$\forall x \in \mathbb{R}^n$$

نکاح نفع ایسی (سرابط ایسی) ای نفع ایسی (ای) خواهد

$$\|x_0 - x^*\| < R$$

لئے کام کی ایسی خود را خاب کر دیں کیونکہ دلخواہی

$$\|x_{k+1} - x^*\|_2^2 = \|x_k - \alpha_k g_k - x^*\|_2^2 = (x_k - \alpha_k g_k - x^*)^T (x_k - \alpha_k g_k - x^*) \quad \text{مثال خوبی ایسی نویسین دلخواہی}$$

$$= \|x_k - x^*\|_2^2 - 2\alpha_k g_k^T (x_k - x^*) + \alpha_k^2 \|g_k\|_2^2$$

(معادلہ)

atus

Subject :

Year . Month . Date .

$\rightarrow x^*$

$$f(y) \geq f(x) + g_k^T (y - x) \Rightarrow g_k^T (x^* - x_k) \leq f(x^*) - f(x_k)$$

$x^*$        $x_k$        $g_k^T$

$$\Rightarrow \|x_k - x^*\|^2 + 2\alpha_k g_k^T (x^* - x_k) + \alpha_k^2 \|g_k\|^2 \leq \|x_k - x^*\|^2 - 2\alpha_k (f(x_k) - f(x^*)) + \alpha_k^2 \|g_k\|^2$$

$$\Rightarrow \sum_{i=1}^k \|x_{i+1} - x^*\|^2 \leq \sum_{i=1}^k \|x_i - x^*\|^2 - 2 \sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2$$

$$\rightarrow \|x_{k+1} - x^*\|^2 \leq \|x_1 - x^*\|^2 - 2 \sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2$$

$$(1) \|x_{k+1} - x^*\|^2 \geq 0 \Rightarrow \|x_1 - x^*\|^2 - 2 \sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2 \geq 0$$

$$(2) \sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) \geq \sum_{i=1}^k \alpha_i^2 (f_k^{best} - f^*)$$

$$\Rightarrow \|x_1 - x^*\|^2 - 2 \sum_{i=1}^k \alpha_i (f_k^{best} - f^*) + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2 \geq 0$$

$\leq R^2$

$$\Rightarrow (2 \sum_{i=1}^k \alpha_i) (f_k^{best} - f^*) \leq R^2 + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2 \Rightarrow f_k^{best} - f^* \leq \frac{R^2 + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2}{2 \sum_{i=1}^k \alpha_i}$$

$$(1) \text{ if } \alpha = 1: f_k^{best} - f^* \leq \frac{R^2 + G^2 \sum_{i=1}^k \alpha_i^2}{2 \sum_{i=1}^k \alpha_i} = \frac{R^2 + kG^2 \alpha^2}{2k\alpha} \quad (\|g_i\|^2 \leq G)$$

$$\text{if } k \rightarrow \infty: f_k^{best} - f^* \leq \frac{G^2 \alpha}{2}$$

!  $f_k^{best} - f^*$  is minimum if  $\alpha = 1$  since  $f_k^{best}$  is decreasing in  $\alpha$  and  $G$  is constant.

$$(2) \text{ if } \alpha = \frac{\gamma}{\|g_k\|}: f_k^{best} - f^* \leq \frac{R^2 + \sum_{i=1}^k \frac{\gamma^2}{\|g_i\|^2} \|g_i\|^2}{2 \sum_{i=1}^k \frac{\gamma}{\|g_i\|}} \leq \frac{R^2 + \sum_{i=1}^k \gamma^2}{2 \frac{\gamma}{G} \sum_{i=1}^k \frac{1}{\|g_i\|}} = \frac{R^2 + k\gamma^2}{2k\gamma}$$

$$\text{if } k \rightarrow \infty: f_k^{best} - f^* \leq \frac{8G}{2}$$

Subject :

Year . Month . Date .

(3)  $\sum_{k=1}^{\infty} \alpha_k = \infty, \sum_{k=1}^{\infty} \alpha_k < \infty \rightarrow f_k^{\text{best}} - f^* \leq R^2 + C^2 \sum_{i=1}^n d_i^2, \text{ if } k \rightarrow \infty \text{ then } f_k^{\text{best}} \leq f^*$   
 $2 \sum d_i \Rightarrow f_k^{\text{best}} \leq f^*$   
 $f^*$  is The minimum

(4)  $\sum_{k=1}^{\infty} \alpha_k = \infty, \sum_{k=1}^{\infty} \alpha_k^2 = \infty, \lim_{k \rightarrow \infty} \alpha_k = 0 \rightarrow f_k^{\text{best}} = f^*$   
(This)

١) subgradient method

٢) بروش طیاره نیتیز (نیتیز)

٣) ایجاد مسیر

٤) طیاره

٥) تابع

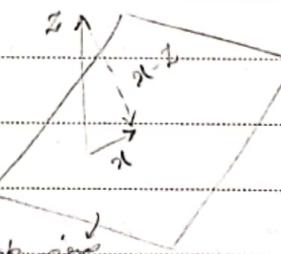
٦) مسیر

projected subgradient Method: (بروش طیاره نیتیز)

Min f(x)

s.t.  $x \in D, D \subseteq \mathbb{R}^n$  convex  $\rightarrow x_{k+1} = \text{Pr}_D(x_k - \alpha_k g_k)$

$\text{Pr}_D(x) = \text{argmin}_{\tilde{x} \in D} \|x - \tilde{x}\|$



Ex Min f(x)

s.t.  $Ax = b$   $x_k - \alpha_k g_k$

Min  $\|x - z\|^2 \rightarrow$   $\text{orthogonal}$   $\rightarrow$   $\text{perpendicular}$   $\rightarrow$   $\text{minimum}$

s.t.  $Ax = b$   $\sum a_i x_i = b$

$L(A, \lambda) = \|x - z\|^2 + \lambda^T (Ax - b)$

$\frac{\partial L}{\partial x} = 2(x - z) + A^T \lambda = 0 \times A \rightarrow 2(Ax - b) + A^T \lambda = 0 \rightarrow A^T \lambda = 2(b - Ax)$

$\therefore 2(b - Ax) + AA^T \lambda = 0 \rightarrow \lambda = 2(AA^T)^{-1}(A^T b - b)$

Batus

بروش طیاره نیتیز = بروش نیتیز

Subject :

Year . Month . Date .

$$z = z - A^T (AA^T)^{-1} (Az - b)$$

$$z \leftrightarrow z_{k+1}, z \leftrightarrow z_k - d_k g_k$$

$$z_{k+1} = z_k - \alpha_k g_k - A^T (AA^T)^{-1} (A(z_k - \alpha_k g_k) - b) = z_k - \alpha_k g_k - A^T (AA^T)^{-1} (b - Ad_k g_k - b)$$

$$= z_k - \alpha_k g_k - A^T (AA^T)^{-1} (-Ad_k g_k) = z_k - \alpha_k [I - A^T (AA^T)^{-1} A] g_k$$

$$\Rightarrow z_{k+1} = z_k - \alpha_k [I - A^T (AA^T)^{-1} A] g_k$$

$$\xrightarrow{\text{Pr}(g_k)} \xrightarrow{\text{N}(A)}$$

$$\xrightarrow{\text{Ad}_k}$$

برای آنکه  $g_k$  را می‌دانیم،  $\text{Ad}_k$  را بخواهیم داشت.

آنچه در پیشین مذکور شد!

(\*) We know,  $z = z - A^T (AA^T)^{-1} (Az - b)$  set  $\begin{cases} z \\ \downarrow \\ g_k \end{cases} \rightarrow Ax = b \rightarrow x = [I - A^T (AA^T)^{-1} A] g_k$

$$\Rightarrow z_{k+1} = z_k - \alpha_k \text{Pr}(g_k)$$

$$Ax = 0$$

پس (\*)

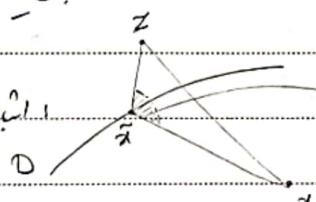
$$\begin{cases} z_{k+1} = z_k - \alpha_k g_k \\ x_{k+1} = \Pi_D(z_{k+1}) \end{cases}$$

بازگشتی، step size،  $\alpha_k$  را می‌دانیم.

ویژگی  $\Pi_D$  که  $\Pi_D$  Nonexpansive است (برای توضیح این نظریه را بخواهید).

$$\|\Pi_D(z) - x\| \leq \|z - x\|$$

$x \in D \rightarrow$  Convex



بین زوایا صاف است.

$$\|x_{k+1} - x^*\|^2 = \|\Pi_D(z_{k+1}) - x^*\|^2 \leq \|z_{k+1} - x^*\|^2$$

$x^* \in D$ .

نمایان از این متصویر است که این طبق این نظریه زیرا  $\Pi_D$  برای  $D$  خاص بود.

لذا  $\Pi_D$  بین  $D$  محدود است.

Batus

Subject :

Year .      Month .      Date .

Primal: Min  $f_0(x)$

وَمِنْ تَدْرِيْجٍ / dual stage

S.t.  $f_i(x) \leq 0$   $i = 1, \dots, m$

Dual: Max  $g(\mathbf{d})$  Min  $-g(\mathbf{d})$

$$\text{s.t. } \vartheta \geq 0 \quad \equiv \quad \frac{1}{\inf_{x \in X} L(x, \vartheta)} \quad (1), \quad g(\vartheta) = \inf_{x \in X} L(x, \vartheta)$$

$$L(x, \hat{y}) = f_0 + \sum_{i=1}^m \lambda_i f_i(x)$$

$\leftarrow$  Convex  $\rightarrow$   $-g(\theta)$   $\leftarrow$   $\rightarrow$  Concave  $\rightarrow$   $\leftarrow g(\theta)$   $\rightarrow$  مُنْتَجِزٌ

$\nabla f(x) \in g(\bar{x})$  at Subgradient w.r.t  $\bar{x}$

$$h_k \in \partial(-g(\vartheta_k)) \Rightarrow \vartheta_{k+1} = [\vartheta_k - \alpha_k h_k],$$

$$(x)_+ = \max(x, 0)$$

$$-g(\vartheta) = \inf_x L(x, \vartheta) = \sup_x -L(x, \vartheta) \Rightarrow -g(\vartheta) = \sup_x -(f_0(x) + \vartheta_1 f_1(x) + \dots + \vartheta_m f_m(x))$$

$$-L(x, \theta) \stackrel{\text{def}}{=} h(-L(x, \theta)) = -[f_1(x), \dots, f_m(x)] \quad \text{for}$$

$$\Rightarrow h_k = [f_1(\hat{x}(\omega_k)), \dots, f_m(\hat{x}(\omega_k))]^\top$$

## Decentralized optimization:

نحوه هستم بجهة ایجاد Node / یعنی حذف از جمله Node /

فی این رسیده و مانع از مبتداست. این رسیده از صرفاً خود رسیده نباشد.

$$\text{Min} \sum_{i=1}^n f_i(x_i; y)$$

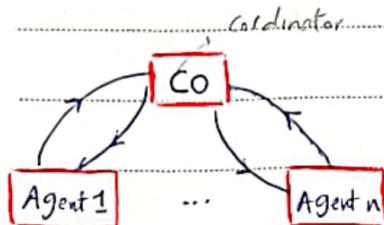
$$\text{② Min } \sum_{i=1}^n f_i(x_i) \quad \text{s.t. } \sum_{i=1}^n x_i \leq c$$

x<sub>1</sub>, x<sub>2</sub>, ..., x<sub>n</sub>

Subject :

Year . Month . Date .

- دور عمل ترتیب مزینه :
- ۱- سترس خطا نیز دعم اعلان قبل اطلاع در گیرنده
  - ۲- چم کاپس سند ترتیب دسته تعاویش پذیری
  - ۳- اعلان خدمت طبلان



: Resource Allocation : ② بررسی

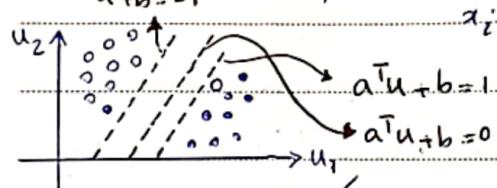
$x_i \rightarrow$  خارجی (مقدار) به عامل

$$\sum_{i=1}^n x_i \leq c \rightarrow \text{حدود میزان}$$

$$f_i(x)$$

$f_i \rightarrow$  Utility function

$a^T u + b = i \rightarrow$  محدودیت معرفی شده برای عامل  $i$



: SVM

①

هزینه ای ای را تأثیر می‌کند margin

data points :  $\{(x_j, y_j), j=1, \dots, p\}$

$x_j$  job feature  $\rightarrow$  label :  $o = y_j = 1$

$x_j \in \mathbb{R}^2 \rightarrow o = y_j = -1$

$$\min_{a, b} \frac{1}{2} \|a\|^2 + \sum_{j=1}^m \max(0, 1 - y_j(a^T x_j + b))$$

inde set  $\rightarrow \bigcup_{i=1}^m S_i = \{1, \dots, p\}$

$\{(x_e, y_e), e \in S_i\} \rightarrow$  مجموع داده های ای که محدودیت توزیع را نقض کرده اند

$$\min_{a, b} \sum_{i=1}^m \frac{1}{2} \|a\|^2 + \sum_{e \in S_i} [\max(0, 1 - y_e(a^T x_e + b))] \rightarrow f_i(x), x = (a, b)$$

$$= \min \sum_{i=1}^m f_i(x)$$

## Decomposition in Optimization

$$\min_{x_1, x_2} f_1(x_1) + f_2(x_2) \equiv \min_{x_1 \in C_1} f_1(x_1) + \min_{x_2 \in C_2} f_2(x_2)$$

S.6

سے خواہ اپر رجی (+) اون سسٹر کلیں سا سے اپر اور جھاکی غیر نریں لیں نہیں ممکن ہے نہیں۔

$$\min_{x_1 \in C_1} \psi(f_1(x_1), f_2(x_2)) = \psi(\min_{x_1 \in C_1} f_1(x_1), \min_{x_2 \in C_2} f_2(x_2))$$

$x_2 \in C_2$

$$\text{Ex. } \min(x_1^2 - x_2^2) = -1 \rightsquigarrow (\min x_1^2) - (\min x_2^2) = -1 \neq -4$$

$\bullet x_1 \leq 1$   
 $\bullet 0 \leq x_1 \leq 1$   
 $\bullet x_2 \leq 2$

1-2-51

(Complicating Compiling Variable) ~~is unique~~

$$f(x) = f_1(x_1, y) + f_2(x_2, y) \quad \text{Min}_y \quad f(x_1, x_2, y)$$

卷之三

Primal Decamp

ایو این ایک سلسلہ ایسے ہے تیرچاہی کھلا دیجی یا (یار / نوٹ) یا جسے گوئی

$$P_1: \underset{x_1}{\text{Min}} f_1(x_1, y) = \phi_1(y) \quad P_2: \underset{x_2}{\text{Min}} f_2(x_2, y) = \phi_2(y)$$

Min  $\phi_1(y) + \phi_2(y)$   
subject to  
 $y$  coordinator

التحليل المركب (Prime factorization) هو تحليل كل عدد صحيح موجب إلى حاصل ضرب في عوامل مركبة.

۴- تاریخ اسلام و اسلامیت در ایران

مودعی مادر مادر بزرگ پدر را خواسته  
Privacy

Subject:

Year.    Month.    Date.

الآن ندرس  $P_1$  و  $P_2$  معاً على جدول

$k=0$ ,  $y_0$  and  $\lambda_k$  are given by (1). Principal decomposition formula

$$g_1^k \in \partial \phi_1(y_k), g_2^k \in \partial \phi_2(y_k) \quad (1)$$

$$y_{k+1} = y_k - \alpha_k(g_1^k + g_2^k)$$

$$k = k + 1$$

۱۵) بازیست بیرونی مل (ایندرایت)

## Dual Decomposition

$$M_{\min} f(x) = f_1(x_1, y_1) + f_2(x_2, y_2) \equiv M_{\min} f_1(x_1, y_1) + f_2(x_2, y_2)$$

$$S.b \quad y_1 = y_2$$

$$f_1(x_1, y_1) + f_2(x_2, y_2) + \dots + f_n(x_n, y_n)$$

$$L_{\mu}(x_1,y_1,z_1) = \frac{1}{2} \left[ \frac{\partial^2 L}{\partial x^2} + \frac{\partial^2 L}{\partial y^2} + \frac{\partial^2 L}{\partial z^2} \right] \rightarrow L_2(x_2,y_2,z_2)$$

*مُؤْمِنٌ مُّسْتَقْبِلٌ مُّؤْمِنٌ مُّسْتَقْبِلٌ*

Dual Subproblems:  $\left\{ \begin{array}{l} g_1(\bar{\omega}) = \inf_{x_1, y_1} h_1(x_1, y_1, \bar{\omega}) \\ g_2(\bar{\omega}) = \inf_{x_2, y_2} h_2(x_2, y_2, \bar{\omega}) \end{array} \right. \Rightarrow$  Dual function:  $g(\bar{\omega}) = g_1(\bar{\omega}) + g_2(\bar{\omega})$

$$y_2(\delta) = \inf_{x_2, y_2} h_2(x_2, y_2, \delta)$$

Dual Problem: Max  $\bar{g}(\bar{x}) = \text{Max } g_1(x) + g_2(x)$

*Uroplatus*

حال براکی بحیره السیده اانی سینه (بست جندا حمل خود را تسریع ازینهاست) در عین زمان است

بررسی مسئله دو دلایلی از این

$$\stackrel{i=1}{\dots} \vdash -g_i(\tilde{\omega}) = -\inf_{x_0 y_1} (f_i(x_0 y_1) + \tilde{\omega}^T y_1)$$

$$= -f_i(x_i^*(\tilde{\omega}), y_i^*(\tilde{\omega})) - \tilde{\omega}^T y_i^*(\tilde{\omega}) > -f_i(x_i^*(\tilde{\omega}), y_i^*(\tilde{\omega})) - \tilde{\omega}^T y_i^*(\tilde{\omega}) + \tilde{\omega}^T y_i^*(\tilde{\omega}) - \tilde{\omega}^T y_i^*(\tilde{\omega})$$

$$= -f_i(x_i^*(\tilde{\omega}), y_i^*(\tilde{\omega})) - \tilde{\omega}^T y_i^*(\tilde{\omega}) + (-y_i^*(\tilde{\omega})) (\tilde{\omega} - \tilde{\omega})$$

$$\Rightarrow -g_i(\tilde{\omega}) \geq -g_i(\tilde{\omega}) + (-y_i^*(\tilde{\omega})) (\tilde{\omega} - \tilde{\omega}) \rightarrow \text{Subtraction}$$

$$y_i^*(\tilde{\omega}) \in \partial(-g_i(\tilde{\omega}))$$

دسته بندی  
Dual decomposition  
الدوال

کاری افسوس

$$(x_i^*(\tilde{\omega}), y_i^*(\tilde{\omega})) = \text{Argmin}_{x_0 y_1} (f_i(x_0 y_1) + \tilde{\omega}^T y_1)$$

$$(x_2^*(\tilde{\omega}), y_2^*(\tilde{\omega})) = \text{Argmin}_{x_2 y_2} (f_2(x_2 y_2) - \tilde{\omega}^T y_2)$$

$$\text{درست} (x_2^*(\tilde{\omega}), y_2^*(\tilde{\omega}))$$

$$g_{k+1} = [g_k - \alpha_i(y_2^*(\tilde{\omega}_k), \dots, y_i^*(\tilde{\omega}_k))]_+$$

$$k = k + 1$$

جواب دو دلایلی

پنجه داری

Subject :

Year . Month . Date .

$$g(\lambda) \leq f^*$$

دراخواں اسیم مابع خانہا بے راخواں لارے اسیم سارے طریقے مارچل طریقے مارچل

$$\hat{y} = \frac{y_1 + y_2}{2} \quad y_1 = y_2 = \text{not feasible}$$

$$f^* \leq f_1(x_1, \hat{y}) + f_2(x_2, \hat{y})$$

$$\hat{x}_i = \underset{x_i}{\text{Argmin}} f_i(x_i, \hat{y}), i=1,2$$

$$f^* \leq f_1(\hat{x}_1, \hat{y}) + f_2(\hat{x}_2, \hat{y}) \leq f_1(x_1, \hat{y}) + f_2(x_2, \hat{y})$$

Primal-dual dual decomposition

از این دو نتایج برای دو دوام این دو نتایج برای دو دوام

$$k \rightarrow \infty \Rightarrow \lambda_k \rightarrow \lambda^* \quad \text{! additional slackness}$$

دuality gaps over time

خوبی و نیازی برای دوام

$$\begin{cases} \{x_1^*(\lambda_k), y_1^*(\lambda_k)\} = \underset{x_1, y_1}{\text{Argmin}} f_1(x_1, y_1) + \lambda_k^T y_1 \\ \{x_2^*(\lambda_k), y_2^*(\lambda_k)\} = \underset{x_2, y_2}{\text{Argmin}} f_2(x_2, y_2) + \lambda_k^T y_2 \end{cases}$$

$$x_1^*(\lambda_k), y_1^*(\lambda_k)$$

کسکنی کسکنی مارچل مارچل

کسکنی کسکنی مارچل مارچل

Batus

Subject: \_\_\_\_\_

Year. Month. Date.

میں اپنے سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $x_1, x_2 \in \mathbb{R}^n$  نہیں

سکنیاٹریز

لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $x_1, x_2 \in \mathbb{R}^m$  نہیں  
لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $x_1, x_2 \in \mathbb{R}^n$  نہیں

2512

سینے پر صدر کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^m$  نہیں

Dual      Primal      DD-PC Decomposition

لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^m$  نہیں  
لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^n$  نہیں

لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^m$  نہیں  
لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^n$  نہیں

لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^m$  نہیں  
لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^n$  نہیں

لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^m$  نہیں  
لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^n$  نہیں

لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^m$  نہیں  
لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^n$  نہیں

لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^m$  نہیں  
لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^n$  نہیں

Decomposition with Constraints

Minimize  $f_1(x_1) + f_2(x_2)$

s.t.  $x_1 \in C_1, x_2 \in C_2$

$h_1(x_1) + h_2(x_2) \leq 0$  ( $h_1, R^n \rightarrow R^P$ )

لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^m$  نہیں  
لے کر اس سسٹم میں دو ہی کارکردگی ریجیٹ کردا ہے،  $y_1, y_2 \in \mathbb{R}^n$  نہیں

Basis \_\_\_\_\_

Subject :

Year . Month . Date .

### Primal decomposition

Minimize  $f_1(x_1) + f_2(x_2)$

s.t.  $x_1 \in C_1, x_2 \in C_2$

$h_1(x_1) \leq t, h_2(x_2) \leq t$

لهم اجزئ المهمة الى قسمين  $P_1, P_2$  ونحو ذلك

$$\begin{cases} P_1: \text{minimize } f_1(x_1) \\ \text{s.t. } h_1(x_1) \leq t \\ x_1 \in C_1 \end{cases} \quad \rightarrow \quad \begin{cases} P_2: \text{minimize } f_2(x_2) \\ \text{s.t. } h_2(x_2) \leq t \\ x_2 \in C_2 \end{cases}$$

لذلك  $\phi_1(t) = \text{min}_{x_1 \in C_1} f_1(x_1)$  و  $\phi_2(t) = \text{min}_{x_2 \in C_2} f_2(x_2)$

$$\text{Co كثرة, minimize } (\phi_1(t) + \phi_2(t))$$

لذلك  $\phi_1(t) = \text{min}_{x_1 \in C_1} f_1(x_1)$  و  $\phi_2(t) = \text{min}_{x_2 \in C_2} f_2(x_2)$

أو  $\phi_1(t) = \text{min}_{x_1 \in C_1} f_1(x_1)$  و  $\phi_2(t) = \text{min}_{x_2 \in C_2} f_2(x_2)$

$t_{k+1} = t_k - \alpha_k(d_k^1 + d_k^2) \quad \rightarrow \quad t_k \text{ كثرة} \quad \rightarrow \quad \text{Primal Decomposition point}$

$$d_k^1 = \frac{\partial \phi_1(t_k)}{\partial t}, d_k^2 = \frac{\partial \phi_2(t_k)}{\partial t} \quad \rightarrow \quad \text{Dual Decomposition point}$$

$$t_{k+1} = t_k - \alpha_k(d_k^1 + d_k^2) \quad \rightarrow \quad t_k \text{ كثرة} \quad \rightarrow \quad \text{Dual Decomposition point}$$

$$\phi_i^*(t) = \sup_{x_i \in C_i} \inf_{x_j \in C_j} (f_i(x_i) + \delta_i^\top(h_i(x_i) - t)) \quad \rightarrow \quad \begin{cases} d_k^1 = -\delta_1^*(t_k) \\ d_k^2 = \delta_2^*(t_k) \end{cases}$$

$$\alpha_k > 0, x_i \in C_i$$

Subject : \_\_\_\_\_

Year . Month . Date .

دراسته از دست رئیس پروفسور میرمیرانی برای این مقاله

برای این مقاله درست شده است که از تابع  $\phi_i(t)$  برای  $i=1, 2, \dots, n$  برای  $t \in [0, T]$  می باشد که  $\phi_i(t) = \sup_{x \in C_i} f_i(x) + \partial^*_i h_i(x)$  است.

برای  $i=1, 2, \dots, n$  داشته باشیم  $d_i^1 = -\partial_i^*(t_k)$  و  $d_i^2 = \partial_i^*(t_k)$  و  $\phi_i(t) = \sup_{x \in C_i} f_i(x) + \partial_i^*(t_k)$  است.

Dual function:  $\phi_1(\tilde{t}) = \sup_{x \in C_1} \inf_{t \in [0, T]} (f_1(x) + \partial_1^*(t_k)h_1(x_k) - \tilde{t}) \geq \inf_{x \in C_1} (f_1(x_k) + \partial_1^*(t_k)h_1(x_k) - \tilde{t})$

$= \inf_{x \in C_1} (f_1(x_k) + \partial_1^*(t_k)x_k(h_1(x_k) - \tilde{t}) + \partial_1^*(t_k)t_k - \partial_1^*(t_k)\tilde{t})$

$= \inf_{x \in C_1} (\underbrace{f_1(x_k) + \partial_1^*(t_k)(h_1(x_k) - t_k)}_{\phi_1(t_k)} + \partial_1^*(t_k)t_k - \partial_1^*(t_k)\tilde{t}) = \phi_1(t_k) + (\partial_1^*(t_k))(t_k - \tilde{t})$

$\phi_1(t_k) \geq \phi_1(t) + (\partial_1^*(t_k)(t_k - t)) \Rightarrow t \in \partial\phi_1(t)$

$\therefore t \in \partial\phi_1(t) \subseteq \partial_1^*(t_k) \subseteq \partial\phi_1(t_k)$

### Dual Decomposition:

Minimize  $f_1(x_1) + f_2(x_2) \rightarrow h_1(x_1) + h_2(x_2) = f_1(x_1) + f_2(x_2) + \partial_1^*(h_1(x_1)) + \partial_2^*(h_2(x_2))$   
s.t.  $x_1 \in C_1, x_2 \in C_2$   
 $h_1(x_1) + h_2(x_2) \leq 0$

$\begin{cases} P_1: \text{minimize } f_1(x_1) + \partial_1^* h_1(x_1) \\ \text{s.t. } x_1 \in C_1 \end{cases} \rightarrow g_1(\lambda)$   
 $P_2: \text{minimize } f_2(x_2) + \partial_2^* h_2(x_2) \rightarrow g_2(\lambda)$   
s.t.  $x_2 \in C_2$

1.  $\rightarrow$  Maximize  $g_1(\lambda)$   
 $\lambda > 0$

Batus

Subject :

Year.    Month.    Date.

$k=0, \dots, n$ , and  $\cos(k(1-\mu))$  dual decomposition point.

$$d_{k+1} \in \partial g_1(w_k), \quad d_{k+2} \in \partial g_2(w_k).$$

$$k = k+1 \quad (4) \quad g_{k+1} = [\Delta_k - \alpha_k (d_{k+1}^1 + d_{k+1}^2)]_+$$

$\Delta x^i = -h_i(x_i^*(\Delta x))$  for  $i=1,2$   
 $\Rightarrow$  Meaning is  $\Delta x^i(x_1^*, \dots, x_k^*) = h_i(x_i^*(\Delta x)) \in \mathcal{D}(-g(\Delta x))$

Give us neither impulsive nor individualistic primal energies.

Livid lungs were agent

Wetenschappelijke en praktische fragmenten over de  
staats- en bestuurlijke geschiedenis van Nederland.

$$t_i = \text{traffic on link } i \rightarrow \begin{pmatrix} t_1 \\ \vdots \\ t_m \end{pmatrix} = R_{\max} \times \begin{pmatrix} d_1 \\ \vdots \\ d_n \end{pmatrix}$$

$$[R]_{ij} = \begin{cases} 1 & \text{flow } j \text{ passes over link } i \\ 0 & \text{otherwise} \end{cases}$$

Consequently

$$R = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} = I_4 + f_j e_j e_j^T$$

7x3

$t \leq c \rightarrow$  برای اینجا برای اینجا برای اینجا

Maximize  $\sum_{j=1}^n w_j b_j y_j$

Subject :

Year . Month . Date .

$$\text{Dual Decomposition: } \text{Max}_{\mathbf{j}} \sum_{j=1}^n u_j(f_j) = \text{Min}_{\mathbf{c}} \sum_{j=1}^n u_j(f_j)$$

S.t. RSC

S.t. RSC

$$L(\mathbf{f}, \mathbf{d}) = \sum_{j=1}^n u_j(f_j) + \mathbf{d}^T (\mathbf{R}\mathbf{f} - \mathbf{c}) = \sum_{j=1}^n u_j(f_j) + \mathbf{d}^T \left( \sum_{i=1}^m r_i f_i - \mathbf{c} \right)$$

$$= \mathbf{d}^T \mathbf{c} + \sum_{j=1}^n (u_j(f_j) - \mathbf{d}^T r_j f_j) \rightarrow \text{Max}_{\mathbf{d}} \left[ \sum_{j=1}^n u_j(f_j) \right] - \sum_{j=1}^n \mathbf{d}^T r_j f_j$$

جواب مینیموم داشت که در اینجا مینیموم داشتند.

 $\bar{\mathbf{d}}$ 

$$\text{Subproblem } j: \quad g_j(\mathbf{d}) = \inf_{f_j} (\mathbf{d}^T r_j f_j - u_j(f_j))$$

$$\Rightarrow g_j(\mathbf{d}) = \mathbf{d}^T \mathbf{c} + \sum_{j=1}^n \inf_{f_j} (\mathbf{d}^T r_j f_j - u_j(f_j))$$

$$\text{Optimization} \Rightarrow \text{Max}_{f_j} g_j(\mathbf{d}) \Rightarrow d_j(\mathbf{d}) \in \mathcal{C}(-g_j(\mathbf{d})) \quad (\star)$$

$$(\star) \quad d = c - d^1 - d^2 - \dots - d^n, \quad d_j(\mathbf{d}) = r_j f_j(\mathbf{d})$$

این را می‌توانیم به صورت زیر نویسیم:

$$d_j = r_j f_j^*(d_k) \in \mathcal{C}(g_j(\mathbf{d}_k)) \quad \forall k = 0, 1, \dots, n-1$$

$$d_n = \mathcal{C}(c - \mathbf{d}_k - (c_m, r_1 f_1^*(d_k), r_2 f_2^*(d_k), \dots, r_n f_n^*(d_k))) : \text{کامپونتیون} \quad (3)$$

$$= \left[ d_n = (c - Rf^*(\mathbf{d}_k)) \right] + \text{برای هر کدامیک از بقایا}$$

$$k = k+1 \quad (4)$$

## Augmented Lagrangian

Substitution method in Aug Lagrangian problem

Minimize  $f(x)$

$$\text{S.t. } Ax = b \rightarrow f(x, y) + g^T(Ax - b)$$

$x \in \mathbb{R}^n$ ,  $A \in \mathbb{R}^{m,n}$

$f: \mathbb{R}^n \rightarrow \mathbb{R}$  and convex

Add  $\rho$  times primal objective function to get strictly convex minimization

dual form. Consider  $x$  not in domain of  $f$ . Minimize  $L_p(x, y)$

$$L_p(x, y) = f(x) + g^T(Ax - b) + \left(\frac{\rho}{2}\right)\|Ax - b\|_2^2$$

Penalty parameter  $\rho > 0$

Minimizing  $L_p(x, y)$  with respect to  $x$  gives

$$\text{minimize } f(x) + \left(\frac{\rho}{2}\right)\|Ax - b\|^2$$

s.t.  $Ax = b$

Convex and strictly monotonic in  $x$  and  $\|Ax - b\|^2$  is strictly convex so it has unique minimum. Hence  $x^*$  is unique.

Now consider  $y$  instead of  $x$  in  $L_p(x, y)$  and minimize with respect to  $y$ .

Now consider  $y$  instead of  $x$  in  $L_p(x, y)$  and minimize with respect to  $y$ .

Augmented Lagrangian method is a generalization of this.

METHOD OF MULTIPLIERS  $\begin{cases} x^{k+1} = \text{Argmin}_x L_p(x, y^k) \\ y^{k+1} = y^k + \rho(Ax^{k+1} - b) \end{cases}$

Step size

$$\partial L_p(x^{k+1}, y^k) = \partial f(x^{k+1}) + A^T y^k + \rho A(Ax^{k+1} - b) = 0$$

$$= \partial f(x^*) + A^T y^k + \rho(Ax^{k+1} - b) = 0$$

Bottom

$$= \partial f(x^{k+1}) + A^T y^{k+1} = 0 \quad \text{or} \quad L_p(x^{k+1}, y^{k+1}) \leq L_p(x^*, y^*)$$

Subject:

Year.      Month.      Date.

Max- $b^2$  has a min. Decompose into prime factors  
Date: \_\_\_\_\_ Month: \_\_\_\_\_ Year: \_\_\_\_\_

agent. Under these

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ (۱۱) مُصَانِعُ الْمُجْرِمِينَ

is limited to the Swiss (Aust.) feasibility studies in small cities.

ان در اینجا نمی تواند از اینجا نمی تواند

## Alternating Direction Method of Multipliers(ADMM) Lösungsmethoden

Min.  $f(x) + g(x)$   $\rightarrow$   $\alpha K^m$   
 $x \in R^m$

Bertram  
GERR

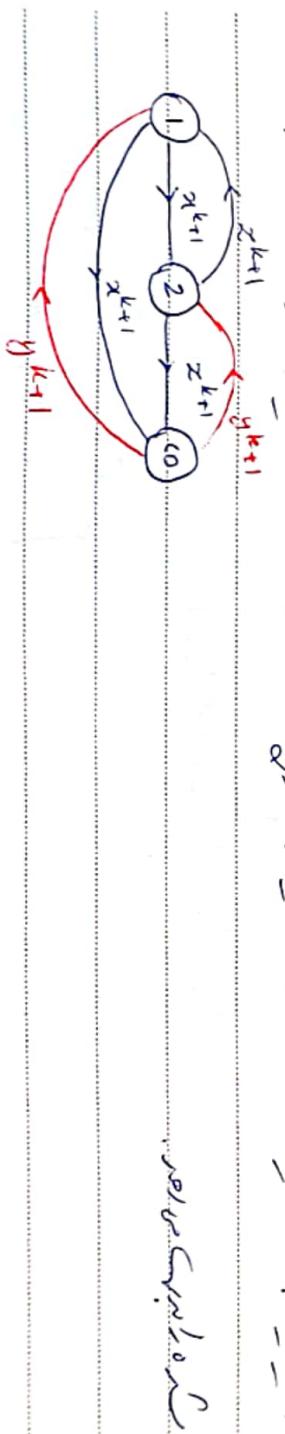
$$L_P(x, z, y) = f(x) + g(z) + y^T(Ax + Bz - c) + \left(\frac{P}{2}\right)\|Ax + Bz - c\|^2$$

$\mathbf{x}^{k+1} = \text{Argmin}_{\mathbf{x}} L_p(\mathbf{x}, \mathbf{z}_k, \mathbf{y}_k)$

$$z^{k+1} = \underset{z}{\operatorname{Arg\,min}} \, h_p(x_k, z, y_k)$$

$$y^{k+1} = y^k + p(Ax^{k+1} + Bz^{k+1} - c)$$

decompose. *Cylindrocyathus* is an Alternatingia, *Gymnopeltis* is a Crinoid.



Subject:

Year. Month. Date.

Scaled form  $\rightarrow$  ADMM primal-dual

$r = Ax + Bz - c \rightarrow$  residual  $u = (\frac{1}{\rho})y \rightarrow$  scaled dual variable  $\Rightarrow y = \mu u$

$$\textcircled{4} \quad \|y^T r + (\frac{\rho}{2})u\|^2 = (\frac{\rho}{2}) \|r + (\frac{1}{\rho})y\|^2 - (\frac{1}{2\rho}) \|uy\|^2$$

$$= \frac{\rho}{2} (r + (\frac{1}{\rho})y)^T (r + (\frac{1}{\rho})y) = \frac{\rho}{2} (r^T + \frac{1}{\rho} y^T)(r + (\frac{1}{\rho})y) = \frac{\rho}{2} (\|r\|^2 + \frac{2}{\rho} y^T r + \frac{1}{\rho^2} \|y\|^2)$$

$\rightarrow$  scaled ADMM primal-dual update

$$x^{k+1} = \underset{x}{\operatorname{Argmin}} (f(x) + \frac{\rho}{2} \|Ax + Bz^k - c + u^k\|^2)$$

$$z^{k+1} = \underset{z}{\operatorname{Argmin}} (g(z) + \frac{\rho}{2} \|Ax^{k+1} + Bz - c + u^k\|^2)$$

$$u^{k+1} = u^k + \rho x^{k+1} + Bz^{k+1} - c \quad (y^{k+1} = \mu u^{k+1} = y^k + \rho(Ax^{k+1} + Bz^{k+1} - c)) \\ \Rightarrow u^{k+1} = u^k + A x^{k+1} + B z^{k+1} - c$$

$$r^k = Ax^k + Bz^k - c$$

$$u^k = u^0 + \sum_{j=1}^k r^j \quad \begin{array}{l} \text{just sublevel set} \\ \text{nonexpansive mapping} \end{array}$$

$$\rightarrow \text{(closed) } \text{epi } f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{\infty\} \text{ a g. } \mathbb{R}^m \rightarrow \mathbb{R} \cup \{\infty\} \text{ is closed}$$

$\rightarrow$   $\text{epi}(f) = \{(x, y) \in \mathbb{R}^n \times \mathbb{R}^m \mid f(x) \leq y\}$   $\rightarrow$   $\text{epi}(f) \subset \mathbb{R}^n \times \mathbb{R}^m$

$\rightarrow$  closed nonempty closed epigraphical cone  $\rightarrow$  closed convex cone

$$\text{epi}(f) = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} \mid t \geq f(x)\}$$

$\rightarrow$  closed convex cone  $\rightarrow$  closed convex cone  $\rightarrow$  closed convex cone

object:

*zár.* Month. Date

①  $k \rightarrow 0$   $k \rightarrow \infty$

$$\textcircled{2} \quad y^k \rightarrow y^* \quad k \rightarrow \infty$$

نیا کر کے بہادر ہے جو اپنے دل  
(3) لکھا گیا

prost:  $\nu = A\lambda + BZ - C \rightarrow 0$ , if  $k \rightarrow 0$

Einzelne Autoren der Schule.

Convergence:  $f(x^k) + g(x^k) \rightarrow p^*$  if  $k \rightarrow \infty$

$\text{rank}(AB) \leq \min(\text{rank } A, \text{rank } B)$  (full rank)

Feasibility  $\rightarrow z^k$  Crosses  $\rightarrow z^{k+1}$  Surfaces

André Béguin n'a pas été nommé à la tête de l'Institut des hautes études en sciences humaines.

أَبْرَاهِيمُ الْمُسْلِمُونَ

حَسَدَهُ مَنْ نِزَّ بِهِ رَحْمَةً يَرَوُهُ لَهُ

f

Subject :

Year . Month . Date .

Consider ADMM for generic problems.  $\text{Min}_x f(x)$  bounded below, bounded Subgradient.

Subject to  $x \in C$

ADMM form take  $g$  to be the indicator of  $C$ ,  $\text{Min}_x f(x) + g(x) \rightarrow$  solve,  $\text{Min}_x f(x)$  bounded below, bounded Subgradient.

Subject to  $x, z = 0$

$$\text{Algorithm: } x^{k+1} := \underset{x}{\operatorname{argmin}}(f(x) + (\frac{\rho}{2}) \|x - z^k + u^k\|_2^2)$$

$$\left\{ \begin{array}{l} z^{k+1} = \underset{z}{\operatorname{argmin}}(\tilde{f}(z) + (\frac{\rho}{2}) \|z^{k+1} - u^k + x^{k+1}\|_2^2) \\ u^{k+1} = u^k + x^{k+1} - z^{k+1} \end{array} \right. \quad \text{④}$$

$$\text{Under iteration } \|\frac{1}{2} \|x^{k+1} - z^{k+1}\|^2 + \frac{1}{2} \|x^{k+1} - u^k\|^2 \rightarrow \text{Min}_x f(x) + g(x) \quad \text{⑤}$$

Optimization problem becomes a constrained Quadratic program with  $z^{k+1} = x^{k+1}$  to minimize over  $x^{k+1}$ .

$x^{k+1}$

$z^{k+1}$

$u^{k+1}$

$x^k$

Lasso least absolute shrinkage and selection operator

- Lasso problems  $\text{Min}_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$  ill-posed. Regularizer  $\|x\|_1$  is  $L_1$  norm. Response vector  $b$  is noisy. Parameter  $\lambda$  is regularization parameter. Generalization error increase with  $\lambda$ . Optimal  $\lambda$  is chosen under parameter estimation.  $\lambda = \text{Min}_{\lambda} \|Ax - b\|_2^2 + \lambda \|x\|_1$

$\Rightarrow \|x\|_1 \rightarrow$  Regularization for ill-posed problems and generalization

✓ Feature selection.

ADMM form:  $\text{Min}_{x,z} \frac{1}{2} \|Ax-b\|_2^2 + \vartheta \|z\|_1$

s.t.  $x-z=0$

$Ax=b, L_p(x,z,y) = \frac{1}{2} \|Ax-b\|_2^2 + \vartheta \|z\|_1 + y^\top (x-z) + \rho \|x-z\|_2 \rightarrow x = \text{int.}$

$$x^{k+1} = (A^\top A + \rho I)^{-1} (A^\top b + \rho z^k - y^k)$$

So we can see  $\|z\|_1$  is reduced.

$z^{k+1} := S_{\frac{\rho}{\vartheta}}(x^{k+1} + y^k / \rho) \rightarrow$  where the soft thresholding operator  $S$  is defined as below:

$$y^{k+1} := y^k + \rho(x^{k+1} - z^{k+1})$$

$$S_{\kappa,\vartheta} = \begin{cases} a - \kappa & a > \kappa \\ 0 & -\kappa < a < \kappa \\ a + \kappa & a < -\kappa \end{cases}$$

Consensus Optimization: want to solve problem with  $N$  objective terms:  $\text{Min}_{x,z} \sum_{i=1}^N f_i(x)$

e.g.,  $f_i$  is the loss function for  $i$ th block of training data

ADMM form:  $\text{Min}_{x,z} \sum_{i=1}^N f_i(x_i)$

s.t.  $x_i - z = 0$

$x_i$  are local variables.  $x_i - z = 0$  are consistency or consensus constraints

$z$  is the global variables. Can add regularization using a  $\|gz\|_2$  term

$$\text{ADMM: } L_p(x,z,y) = \sum_{i=1}^N (f_i(x_i) + y_i^\top (x_i - z) + \frac{\rho}{2} \|x_i - z\|_2^2)$$

$$x_i^{k+1} := \text{argmin}_{x_i} (f_i(x_i) + y_i^\top (x_i - z^k) + \frac{\rho}{2} \|x_i - z^k\|_2^2)$$

$z^{k+1} := \frac{1}{N} \sum_{i=1}^N (x_i^{k+1} + \frac{1}{\rho} y_i^k)$

$$y_i^{k+1} := y_i^k + \rho(x_i^{k+1} - z^{k+1})$$

## Federated Learning

- Training a machine learning algorithm (e.g.: DNN), on multiple local datasets.
  - Without explicitly exchanging data samples (privacy, communication cost).
  - Training local models on local data samples.
  - Sending parameters (e.g.: the weights and biases of a DNN) from the local nodes to a server.
  - Server aggregates parameters and generate a global model and share it by all nodes.

卷之三

- ### • Expansive Communication

Systems Heterogeneity  $\rightarrow$  ~~different individuals~~ different types of cells

Statistical Heterogeneity → Statistical heterogeneity leads to Privacy Concerns → Surveyors will not be able to trust the data.

卷之三

**Problem Formulation**: Number of data points → Data point  
 $\min_{w \in \mathbb{R}^d} f(w), f(w) = \frac{1}{n} \sum_{i=1}^n f_i(w), f_i(w) = \text{dist}(x_i, y_i; w), F_k(w) = \frac{1}{k} \sum_{i \in P_k} f_i(w)$   
 Number of data points →  $\sum_{i \in P_k}$  Dataset of client k → Client k  
 $\Rightarrow f_{\text{avg}} = \sum_{k=1}^K \frac{n_k}{n} F_k(w)$

Advantage of Primal Decomposition in Federated Learning

- Non-Convex problem → distributed and asynchronous dual decomposition.
  - No personal variable. Makes the update easy at the agent's level.
  - Large optimization problems with large constraints → primal decomposition → primal-Fisher and Fisher dual decomposition with Federated Learning with partitioned
  - Flexible local updating
  - Low client participation

— 1 —

Subject : \_\_\_\_\_

Year . Month . Date . \_\_\_\_\_

**Algorithm.** The  $K$  clients are indexed by  $k$ ;  $B$  is the local minibatch size,  $E$  is the number of local epochs, and  $\eta$  is the learning rate.

Server execute :

Client Update ( $k, w$ ), // Run on client  $k$

```

initialization:  $w_0$ 
for each round  $t=1, 2, \dots$  do
     $m \leftarrow \text{max}(C_k, k+1)$ 
     $S_t \leftarrow (\text{random set of } m \text{ clients})$ 
    for each client  $k \in S_t$  in parallel do
         $w_{t+1}^k \leftarrow \sum_{k=1}^K \frac{\eta e}{n} w_{t+1}^k$ 
        ClientUpdate( $k, w_t$ )
    for each local epoch  $i$  from 1 to  $E$  do
        for batch  $b \in B$  do
             $w \leftarrow w - \eta P(w, b)$ 
    return  $w$  to server.
}

```

(\*) Number of local updates per round is  $M_E = E \frac{n_e}{B}$

**Dcentralized Non-cooperative optimization:**

What happens with decomposition solution if the agents are not cooperative?

Let's start with an example:  $\text{min}_x (x_1 - \frac{1}{8}x_1^2) + (x_2 - \frac{1}{8}x_2^2)$

s.t.  $x_1 + x_2 \leq 7$

The functions are increasing in form, the constraint is active at the optimal solution, the solution obtained by primal-dual methods must satisfy the following KKT conditions:

$$\begin{aligned} & \text{Lag} = x_1 + \frac{1}{8}x_1^2 - x_2 + \frac{1}{8}x_2^2 + \lambda(x_1 + x_2 - 7) \\ \Rightarrow \quad & \frac{\partial \text{L}}{\partial x_1} = -(1 - \frac{1}{4}x_1) + \lambda = 0, \quad \frac{\partial \text{L}}{\partial x_2} = x_1 + x_2 - 7 = 0 \Rightarrow x_1 + x_2 = 7 \end{aligned}$$

The resulting solution:  $x_1^* = 3.5, x_2^* = 3.5, \lambda^* = \frac{1}{8}$

Let's consider the dual variable  $\lambda$  associated with coupling constraint as the "real price" and " $\lambda x_i$ " as the corresponding "real payment". Then the payoff of agent  $i$  is given by

$$U_2(x_2, \eta) = x_2 - \frac{1}{8}x_2^2 - \lambda x_2$$

Pragmatical optimization of  $U_2$  is given by

Subject : \_\_\_\_\_

Year . Month . Date .

At optimal solution we have :  $U_i(x_i^*, \bar{x}^*) = x_i^* - \frac{1}{8}x_i^{*2} - \bar{x}^*x_i^* = 1.53125$   
Consider agent 1 deviates from  $\hat{x}_1^* = 3.5$  to  $\hat{x}_1 = 3$  while the strategy of agent 2 is fixed to  $\hat{x}_2^* = 3.5$ . Since the constraint is not active anymore, we have  $\bar{x}^* = 0$ ,  
Let's recompute the payoff value of agent 1:

$$U_1(\hat{x}_1, \bar{x}^*) = U_1(3, 0) = \hat{x}_1 - \frac{1}{8}\hat{x}_1^2 - \bar{x}^*\hat{x}_1 = 1.875 > U_1(\hat{x}_1^*, \bar{x}^*) = 1.53125$$

The same situation always happens if the value functions are increasing and the constraint is active and then, one of the agents slightly decrease its value to make its payment equal to zero and earns more profit.

**Result.** A selfish agent may have incentive to deviate from optimal solution or

global optimization.

→ Game Theory Mechanism Design

→ Optimal Mechanism Design

→ Nash Equilibrium → Non-cooperative Game Theory → Mechanism Design

→ Non-cooperative multi-agent decision making

→ Each selfish agent only aims to maximizing its own payoff function.

→ The global optimality (social optimality) may be lost in this case.

→ John Nash proposed the concept of Nash Equilibrium to analyze non-cooperative games.

1) we start with a rather general formulation of game

2) We define the Nash equilibrium.

3) And then, we propose a decentralized solution to obtain the Nash equilibrium

**Game components :**

• Set of players (agents),  $N = \{1, 2, \dots, N\}$  → number of players

• Strategy Sets :  $A_n \in \mathcal{X}_N$ ,  $n \in N$

• Objective functions :  $J_n(x_n, x_{-n}) \quad \forall n \in N$ ,  $x_n = [x_1^T \ x_2^T \ \dots \ x_{n-1}^T \ x_n^T]^T$

→  $\sum J_n$  is the social welfare function

Subject : \_\_\_\_\_

Year . Month . Date . \_\_\_\_\_

### Best Response Function:

Each agent wants to minimize its own objective function.

$$B.R_n(x_{-n}) = \underset{x_n \in \mathcal{X}_n}{\operatorname{argmin}} J_n(x_n, x_{-n}) \quad \text{for } n \in N$$

However, the result depends on the strategy of other players.

→ Player's best response.

- 1) How can an agent evaluate best response function to make a decision?
- 2) What would be the outcome of the game if all the agents follow their best response? (we need to analyze the behavior of players)

### Information and Learning Game:

- Naturally, the agents do not have any information neither on other agent's objective function nor their current strategies (non-cooperative nature). decision Each agent needs at least historical information on other agents' strategies to make a!
- Such information is available when:

The game is repeated for some iterations, say  $t \in \{1, 2, \dots\}$ .  
The agents can see others' decisions after each round.

Or a coordinator broadcasts some information on the historical data of the game. The agents can make an estimate from other agents' strategies using historical data. The most commonly used and realistic estimation is the simplest one, since people usually think simply (again, we are only analyzing the player's behavior). It is called Naïve estimation (Naïve expectation),  
$$\hat{x}_i(t) = x_{-i}(t-1) \quad (\text{if it's a agent's best response})$$
  
**Nash Equilibrium** →  $\hat{x}_i(t) = \underset{x_i \in \mathcal{X}_i}{\operatorname{argmax}} J_i(x_i, x_{-i})$   
What is the expected final outcome of the game? The Nash Equilibrium(NE) point.  
What is the property of NE? No player can better off by unilaterally changing its strategy given the other players' strategies are fixed.

$$(x_1^*, x_2^*, \dots, x_n^*) \text{ is an NE if } \forall i \in N, \forall x_i \in \mathcal{X}_i: J_i(x_i^*, x_{-i}^*) \leq J_i(x_i, x_{-i}^*)$$

## Simple example: prisoner's Dilemma

		Prisoner 2	
		Coperative	Defect
Prisoner 1	Coperative	3, 3	0, 5
	Defect	1, 1	5, 0

- If we minimize over strategies, it will result in a Nash equilibrium
- It is a minimax strategy for Prisoner 1 to choose defect
- It is a minimax strategy for Prisoner 2 to choose defect
- Both players choose defect

agent's strategy

! or NE best

## Aggregation / Mean Field game

• Objective Function :  $J_n(x_{\text{agg}}, \sigma_N)$  Then  $N$  subagents, i.e. in social price

structure from consumer behavior

Optimality

- Aggregative term:  $\delta(x_N) = \frac{1}{N} \sum_{n \in N} x_n \rightarrow$  interacting between all agents

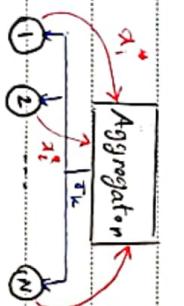
$$\cdot \text{Best Response: } x_n^* = \underset{y \in X_n}{\operatorname{argmin}} J_n(y, \frac{1}{N} y + \frac{1}{N} \sum_{j \neq n} x_j) \quad \forall n$$

→ Each agent doesn't have direct access to other agent's historical data

→ There is an aggregator who knows the historical decisions of the agents (more realistic: e.g. smart grid, transport or wireless networks, ...)

- The agents may do not have even information on the structure of aggregative term
- The aggregator broadcast some numerical information on the aggregative term to all the agents

Game procedure:



Algorithm:

initialization: randomly initialize  $\sigma_0, k \leftarrow 0$

iteration: for  $n \in N$

$x_n^*(\sigma_k) \leftarrow \underset{y \in X_n}{\operatorname{argmin}} J_n(y, \sigma_k)$

end

$\sigma_{k+1} \leftarrow (1-\alpha_k)\sigma_k + \alpha_k x_n^*(\sigma_k)$

Batch

$\Delta(\sigma_k) \leftarrow \sum_{n \in N} \frac{1}{n} x_n^*(\sigma_k)$

$\alpha_k \leftarrow b_{11}$

Subject: \_\_\_\_\_

Year. \_\_\_\_\_ Month. \_\_\_\_\_ Date. \_\_\_\_\_

we don't expect to reach exactly to NE since each agent neglects its effect in the mean-field term.

$\arg\min_{y \in X_n} J_n(y, \sigma)$  is called the best-response function of agent  $n$ .

The  $\epsilon$ -Nash Equilibrium!

$$J_n(x_n, \frac{1}{N} \sum_{j \neq n} x_j^*) \leq \min_{x_n \in X_n} J_n(x_n, \frac{1}{N} \sum_{j \neq n} x_j^*) + \epsilon \quad \text{Nash}$$

$\Rightarrow$  whenever  $\frac{1}{N} \sum_{j \neq n} x_j^*$  is agent  $n$ 's best-response, then  $x_n^*$  is Nash

if  $\epsilon$  is small enough, then  $\frac{1}{N} \sum_{j \neq n} x_j^*$  is close to some NE

Convergence of the best-response function to NE

Convergence of the best-response function to NE

Convergence assumptions:

Assumption on Learning rate:  $\alpha_k$  non-increasing, non-summable  $\sum_{k=1}^{\infty} \alpha_k = \infty$ , square-summable  $\sum_{k=1}^{\infty} \alpha_k^2 < \infty$

Assumptions on the objective functions:  $J_i(y, \sigma)$  is uniformly Lipschitz continuous

$$|J_i(y, \sigma) - J_i(\tilde{y}, \sigma)| \leq L(\|y - \tilde{y}\| + \|\sigma - \tilde{\sigma}\|)$$

The best-response mappings are non-expansive:  $|x_i^*(\sigma) - x_i^*(\tilde{\sigma})| \leq \|\sigma - \tilde{\sigma}\|$

Convergence results:

$\sigma_{k+1} = (1 - \alpha_k)\sigma_k + \alpha_k \tilde{\sigma} = \sigma$

$\rightarrow$  Algorithm converges to a fixed point of the aggregation mapping. A:  $A(\sigma) = \frac{1}{N} \sum_{i=1}^N x_i^*(\sigma) = \sigma$

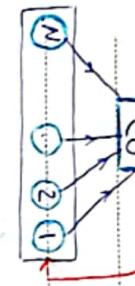
$\rightarrow$  The collective set of best-response strategies is an EN-Nash equilibrium

$\rightarrow$   $E_N$  is inversely proportional to  $N$ !

Batus

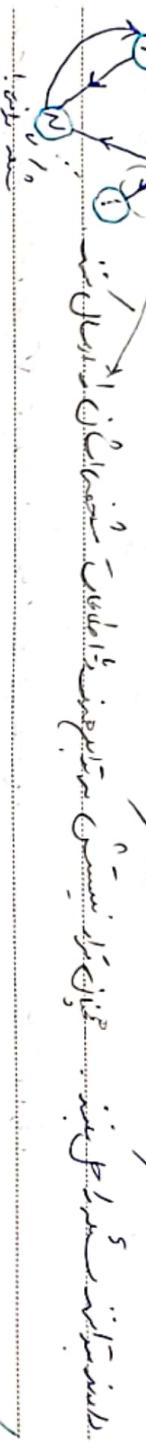
# Distributed Optimization

## Decentralized optimization



Coordinator! Coordinator! Coordinator! Coordinator!

Coordinator is present. Distributed optimization 2



اجماع (Consensus) / اجماع معاشر مسند ایجاد کننده راستایار

ساقی نے گل (والج) مانی اسکے جنی نے اور اسکے  
ordinates کا نام بھی اسی نام سے دیا ہے

مَنْ يَرْجُوا لِتَّهْبِيَةً فَلْيَعْلُمْ أَنَّهُ مَنْ يَرْجُوا  
لِتَّهْبِيَةً فَلْيَعْلُمْ أَنَّهُ مَنْ يَرْجُوا

$G(\pi, E, A)$  →  $\text{Morphism}$

directed weighted graph

(node set)  $V$ ,  $V = \{v_1, v_2, \dots, v_n\}$ ; (edge set)  $E$ ,  $E \subseteq V \times V$ ,  $\{(i, j) \in E\}$ .

(i,i)  $\notin E$ , Viele V

(Adjacency Matrix), i.e. consider  $A = [a_{ij}] \in \mathbb{R}^{n \times n}$ ,  $\forall (i,j) \in V \times V$ .  $a_{ij} \geq 0$ .

Bafus

Subject:

Year \_\_\_\_\_ Month \_\_\_\_\_ Date : \_\_\_\_\_

مسار (Path) کیجیے میرے اندر ہا اسی سطح پر صرف سے سے الی اپنے دل میں تکویر میں آئے۔

گراف مرتبط (Connected graph) یعنی در این گراف هر دو راس را با یک یا چند پیوند می‌بینیم.

(ج) (ب) (أ) (ز) (ع) (م) (ل) (د) (ر) (ص) (ط) (ن) (س) (ه) (ي) (ف) (ك) (ج) (ب) (أ) (ز) (ع) (م) (ل) (د) (ر) (ص) (ط) (ن) (س) (ه) (ي) (ف) (ك)

### Strongly Connected graph

fully connected graph.

$(i,j) \in E$  if  $i \neq j$  and  $i, j \in V$

Hij  $\in E \Rightarrow (j,i) \in E$ ,  $j = i$  is a self-loop undirected  $G$  is

A.s [ ]  $\rightarrow$  Strongly connected. *Ex.*

*definition of graph*

Die Choleren ist höchstens nicht schwach und unbeständig.

in  $\mathcal{C}$  also  $\mathcal{O}^{\circ}$  in  $N_i(t)$  ist kein Punkt mehr zu  
finden.

$\vec{q}_i = 1$  numbers  $\vec{q}_{i,0}$  called **stochastic vector** since  $\sum_i \vec{q}_{i,0} = 1$

Vie.V  
Aminobenzoic acid

ماتریس تصادفی (Stochastic Matrix) نام دارد.

مکاری میں اسی طرح A<sub>1</sub>, A<sub>2</sub> اور A<sub>3</sub> (double stochastic) میں سے ایک ایسا مجموعہ ملکے کا تھا جو اسی طرح A<sub>1</sub>, A<sub>2</sub> اور A<sub>3</sub> کا مجموعہ میں ملکے کا تھا۔



Subject: \_\_\_\_\_

Year: \_\_\_\_\_ Month: \_\_\_\_\_ Date: \_\_\_\_\_

## Weighted Averaging Algorithm (Algorithm)

دالن اسیم حوال بولی مسما زدن باره سدا نهاد (کن) خرد بنداند

$$x_i(k+1) = \sum_{j \in N_i(k)} a_{ij}(k) x_j(k)$$

برای درج اسرار،  $x_i(k+1)$  را برای  $i=1, 2, \dots, m$  بخوان سه ایده یعنی تابع

و  $a_{ij}(k)$  را در اینجا بخواهیم اینها را برای  $i=1, 2, \dots, m$  می خواهیم مسایل معمولی می دانیم.

برای مسایل معمولی مفهوم رسانید که  $a_{ij}(k)$  (مسایل معمولی)  $\rightarrow$   $a_{ij}(k) = 1$  (مسایل معمولی)

و  $a_{ii}(k) = 1$  (مسایل معمولی)  $\rightarrow$   $a_{ii}(k) = 1$  (مسایل معمولی)

$$a_{ij} \geq 0, \quad a_{ij} > 0 \quad \text{and} \quad \sum_{j \in N_i(k)} a_{ij}(k) = 1 \quad \forall i, k$$

for  $j \in N_i(k)$

و  $G_k = (\mathcal{V}, E(k))$  را نیز می نویسیم

$$A(k) = [a_{ij}(k)], \quad a_{ij}(k) = \begin{cases} a_{ij}(k) > 0 & (i, j) \in E(k) \text{ or } j = i \\ 0 & \text{Otherwise} \end{cases}$$

و  $A(k)$  را می نویسیم

پرداختی شرطی  $\rightarrow$  این را می نویسیم

و  $G_k = (\mathcal{V}, E(k))$  را می نویسیم

و  $G_k$  را می نویسیم

و  $G_k$  را می نویسیم

و  $G_k$  را می نویسیم

Batus \_\_\_\_\_

Subject :

Year . Month . Date .

الفصل السادس خوارزمية Node (١٤)

$$x(k+1) = A(k)x(k), \quad x(k) = \begin{pmatrix} x_1(k) \\ x_2(k) \\ \vdots \\ x_m(k) \end{pmatrix}, \quad x_i(k) = \sum_{j \in N(k)} a_{ij}(k)x_j(k) \quad \forall i$$

$$A(k) \text{ عمارات لـ } a_{ij}(k) \geq 0, \quad \sum_{j \in N(k)} a_{ij}(k) = 1$$

$\hat{j} \in N(k)$

الخطوة الأولى: تحديد العقدة المترتبة على العقدة المدخلية  $A(k)$

الخطوة الثانية: تحديد العقدة المدخلية  $x(k)$  من خلال العدد المعرف بالخطوة الأولى

$$\lim_{k \rightarrow \infty} x_i(k) = \alpha \quad \forall i \rightarrow \alpha = \sum_{j=1}^m T_{ij} x_j(0), \quad \left\{ \begin{array}{l} T_{ij} > 0 \\ \sum_{j=1}^m T_{ij} = 1 \end{array} \right.$$

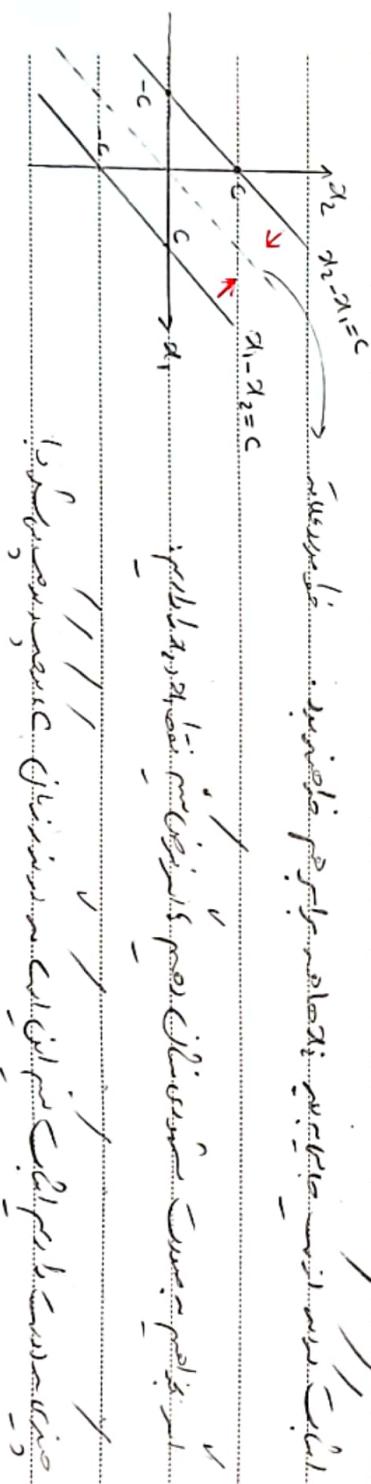
الخطوة الثالثة: الاتصال

$$T_{ik} = \max_{j \in N(k)} x_j(k) - \min_{j \in N(k)} x_j(k)$$

الخطوة الرابعة: تحديد العقدة المدخلية  $V(k)$



الخطوة الخامسة: تحديد العقدة المدخلية  $V(k)$



الخطوة السادسة: تحديد العقدة المدخلية  $V(k)$

$$V(k+1) = \max_{i \in N(k+1)} \min_{j \in N(i)} x_j(k+1)$$

$$X(k+1) = A(k)X(k)$$

$$x_i^{*} = \text{Argmax}_{j \in N(i)} (a_{ij}^T X(k)) \quad j^{*} = \text{Argmin}_{j \in N(i)} (a_{ij}^T X(k))$$

Batus

$$A(k) = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{pmatrix}$$

Subject : \_\_\_\_\_

Year . Month . Date .

② اسما نمبریں ملے۔ New Year Number  
کے مقابلے میں اس کا نمبر ہے۔  $\frac{A(k)}{x(k)}$   $\frac{x(k+1)}{A(k+1)}$

$$x(k+1) = A(k)x(k) + A(k)A(k+1)\underbrace{A(k+1)x(k)}_{x(k+1)} = P(k, s)x(s)$$

$$P(k, s) = A(k)A(k-1) \cdots A(s+1)A(s)$$

وہیں پہنچا کر پہنچا کر کے مقابلے میں اس کا نمبر ہے۔  $\frac{A(k)}{x(k)}$   $\frac{x(k+1)}{A(k+1)}$

$$x(k+1) = P(k, s)x(s) \quad \text{کے مقابلے میں اس کا نمبر ہے} \quad \frac{A(k+1)}{x(k+1)} \quad \frac{x(k)}{A(k)}$$

پہنچا کر پہنچا کر کے مقابلے میں اس کا نمبر ہے۔  $\frac{A(k+1)}{x(k+1)} \quad \frac{x(k)}{A(k)}$

پہنچا کر پہنچا کر کے مقابلے میں اس کا نمبر ہے۔  $\frac{A(k+1)}{x(k+1)} \quad \frac{x(k)}{A(k)}$

پہنچا کر پہنچا کر کے مقابلے میں اس کا نمبر ہے۔  $\frac{A(k+1)}{x(k+1)} \quad \frac{x(k)}{A(k)}$

پہنچا کر پہنچا کر کے مقابلے میں اس کا نمبر ہے۔  $\frac{A(k+1)}{x(k+1)} \quad \frac{x(k)}{A(k)}$

پہنچا کر پہنچا کر کے مقابلے میں اس کا نمبر ہے۔  $\frac{A(k+1)}{x(k+1)} \quad \frac{x(k)}{A(k)}$

پہنچا کر پہنچا کر کے مقابلے میں اس کا نمبر ہے۔  $\frac{A(k+1)}{x(k+1)} \quad \frac{x(k)}{A(k)}$

$$A^T \cdot [a_i^T]_j [a_j^T]_i = [.] \quad a_{ij} = a_i^T a_j \geq 0$$

$$A^T \cdot [a_i^T]_j [a_j^T]_i = [.] \quad a_{ij} = a_i^T a_j \geq 0$$

Subject : \_\_\_\_\_

Year . Month . Date . \_\_\_\_\_

الحمد لله رب العالمين . At(i,j) . Year (i,j) . Month (i,j) . Date (i,j) .  
Subject : \_\_\_\_\_

Sister Yousra

$$\left[ \begin{array}{c|c} [ij] & [ij] \\ \hline [ij] & [ij] \end{array} \right] = \left[ \begin{array}{c|c} ij & ij \\ \hline ij & ij \end{array} \right]$$

$$\left[ \begin{array}{c|c} i & j \\ \hline i & j \end{array} \right] = \left[ \begin{array}{c|c} ij & ij \\ \hline ij & ij \end{array} \right]$$

لأن إدخال إدخال i في Node j يعطى  $\left[ \begin{array}{c|c} ij & ij \\ \hline ij & ij \end{array} \right]$  .

لأن إدخال إدخال i في Node j يعطى  $\left[ \begin{array}{c|c} ij & ij \\ \hline ij & ij \end{array} \right]$  .

الثانية

( strongly connected ) : سلام

$$[P(k-(m-1)+1, k)]_{ij} \geq \eta^{m-1}$$

لأن  $P(k-(m-1)+1, k)$  هو periodically strongly connected لـ  $P(k, k+1)$  .

$$E_B = \bigcup_{k \in K} E_k \equiv (i, j) \in E_k \vee E_{k+1} \cup \dots \cup E_{k+B-1} = E_B$$

حالياً ماضي

(iteration)  $B=10$  .

حالياً ماضي

حالياً ماضي  $m-1$  iteration

(iteration)  $m-1$  .

حالياً ماضي  $m-1$  .

Batus

Subject :

Year . Month . Date .

سیارک نوک از کهکشان راه شیر

، Periodically S.C is observed

$$[\varphi(\underline{k+(m-1)\beta}-\underline{l),k)]_{ij} \geq \eta^{(m-1)\beta}$$

$\beta_0$

این دلیل است که این مجموعه از مجموعه های ممکن است در این مجموعه از مجموعه های ممکن باشد

$$\begin{aligned} x((k+1)\beta_0) &= \varphi((k+1)\beta_0-1, k\beta_0) x(k\beta_0) \\ \Rightarrow S = k\beta_0 & \quad \left. \begin{array}{l} \text{to} \\ \text{Node} \end{array} \right\} \text{Number of combination} \\ k = (k+1)\beta_0 - 1 & \Rightarrow k - S + 1 = \beta_0 = (m-1)\beta \end{aligned}$$

$$x(t_{s+1}) = \varphi(t_s, t_s) x(t_s)$$

این دلیل است که این مجموعه از مجموعه های ممکن باشد

$$\begin{aligned} A_{nm}, B_{nm} &\rightarrow \text{given by} \\ 1 = \begin{pmatrix} 1 \\ 1 \end{pmatrix} & \quad \text{choose one of them} \end{aligned}$$

$$\text{Proof : } A1 = 1 \quad \left. \begin{array}{l} \text{for} \\ B1 = 1 \end{array} \right\} \Rightarrow (AB)1 = A(B1) = A1 = 1 \Rightarrow AB = 1$$

این دلیل است که این مجموعه از مجموعه های ممکن باشد

$$M(t) = \max_i x_i(t) - \min_j x_j(t)$$

$$M(t+1) = \max_i x_i(t+1) - \min_j x_j(t+1) \rightarrow M(t+1) \leq M(t)$$

این دلیل است که این مجموعه از مجموعه های ممکن باشد

Batus

Subject : \_\_\_\_\_

Year . Month . Date . \_\_\_\_\_

$$\hat{x}_i^{(t+1)} = \operatorname{Argmax}_i \hat{\varphi}_i^T \boldsymbol{\alpha}(t_0), \quad j^{(t+1)} = \operatorname{Argmin}_j \hat{\varphi}_j^T \boldsymbol{\alpha}(t_0)$$

$$\hat{\varphi}_i^T \boldsymbol{\alpha}(t_0) = \sum_{j=1}^m \hat{x}_j^{(t+1)} \cdot \alpha_j^{(t+1)}$$

$$\mathcal{N}(t+1) = \hat{\varphi}_{j^{(t)}}^T \boldsymbol{\alpha}(t_0) - \hat{\varphi}_i^T \boldsymbol{\alpha}(t_0) = \hat{\varphi}_{j^{(t)}}^T [1_{\max} x_i(t_0) - 1_{\min} x_i(t_0)]$$

$$-\hat{\varphi}_{j^{(t)}}^T [1_{\min} x_j(t_0) - 1_{\max} x_j(t_0)] \quad \text{(1)}$$

$$\textcircled{1} \quad \hat{\varphi}_{j^{(t)}}^T 1_{\max} x_i(t_0) - \hat{\varphi}_{j^{(t)}}^T 1_{\min} x_j(t_0) = \min x_j(t_0) - \max x_i(t_0) = \mathcal{N}(t_0)$$

$$\Rightarrow \mathcal{N}(t+1) = \mathcal{N}(t_0) + \hat{\varphi}_{j^{(t)}}^T [\max x_i(t_0) - \min x_i(t_0)] + \hat{\varphi}_{j^{(t)}}^T [\min x_j(t_0) - \max x_j(t_0)]$$

$\mathcal{N}(t_0) = \boxed{1_{\max} x_i(t_0) - 1_{\min} x_i(t_0)}$   $\rightarrow$   $\mathcal{N}(t_0)$   $\leftarrow$  مقدار کنونی در مجموعه

$\hat{\varphi}_{j^{(t)}}^T [\min x_j(t_0) - \max x_j(t_0)]$   $\rightarrow$  مقدار کنونی در مجموعه

$$\mathcal{N}(t+1) \leq \mathcal{N}(t_0) \rightarrow \text{سکون تبدیل شد} \rightarrow \text{مقدار کنونی در مجموعه} \rightarrow \text{مقدار کنونی در مجموعه}$$

این مقدار  $\mathcal{N}(t+1)$  را می‌گیریم

$$\mathcal{N}(t+1) \leq \mathcal{N}(t_0) + (1-\eta^\beta)^T [x_i(t_0) - 1_{\max} x_i(t_0) + 1_{\min} x_i(t_0) - x_i(t_0)]$$

$\downarrow \mathcal{N}(t_0)$

$$= \mathcal{N}(t_0) - (1-\eta^\beta)^T [1_{\max} x_i(t_0) - 1_{\min} x_i(t_0)] = \mathcal{N}(t_0) - (1-\eta^\beta)^T \mathcal{N}(t_0) = (1-\eta^\beta)^T \mathcal{N}(t_0)$$

$$\Rightarrow 0 \leq \mathcal{N}(t+1) \leq (1-\eta^\beta) \mathcal{N}(t_0)$$

این مقدار را می‌گیریم و از مجموعه  $\mathcal{N}(t+1)$  و  $\mathcal{N}(t_0)$  برداشت می‌کنیم

Subject :

Year . Month . Date .

$$\gamma = 1 - m\gamma^{B_0} \rightarrow N(B_0) \leq N_{(0)} \quad k=D$$

$$N(2B_0) \leq \gamma N(B_0) \leq \gamma^2 N_{(0)} \quad k=1$$

⋮

$$N(kB_0) \leq \gamma N((k-1)B_0) \dots \leq \gamma^k N_{(0)} \quad k=D$$

$$N(kB_0) \leq (1 - m\gamma^{B_0})^k N_{(0)}$$

$$\text{Case } \gamma < 1$$

$$\gamma < 1 \rightarrow \gamma^{B_0} < 1$$

$$T \rightarrow \infty \Rightarrow N(T) \rightarrow 0 \rightarrow \text{Max } x_i(T) \rightarrow \text{Min } x_j(T)$$

$$\text{Geometric series: } \gamma^T \rightarrow \text{Converges} \rightarrow \lim_{T \rightarrow \infty} \frac{a}{\gamma^T} = \frac{a}{\gamma}$$

$$\text{and } \lim_{T \rightarrow \infty} \bar{P}(T,0) \text{ since } \lim_{T \rightarrow \infty} T \rightarrow \infty \text{ and } A(T) = \bar{P}(T,0) \text{ for all } T$$

$$\lim_{T \rightarrow \infty} x(T) = 1d \rightarrow \sum_{i=1}^D x_i = 1 \quad \text{by definition of a probability vector}$$

$$\text{we know, } x(T+1) = \bar{P}(T,0)x(0) \Rightarrow \text{if } T \rightarrow \infty, \quad \boxed{\lim_{T \rightarrow \infty} x(T,0) = \bar{P}(T,0)x(0) \quad \forall x(0)}$$

$$\text{and } \lim_{T \rightarrow \infty} \bar{P}(T,0) = \bar{P}(T+1,0) \quad \text{by definition of a probability vector}$$

$$\Delta \quad \lim_{T \rightarrow \infty} \bar{P}(T,0)x(0) = \bar{P}_2^T(T,0)x(0) \quad \text{by definition of a probability vector}$$

$\therefore$

$$\lim_{T \rightarrow \infty} \bar{P}(T,0)x(0) = \lim_{T \rightarrow \infty} \bar{P}_2^T(T,0)x(0) \quad \text{by definition of a probability vector}$$

$$\text{Hence, we have } \lim_{T \rightarrow \infty} \bar{P}(T,0)x(0) = \lim_{T \rightarrow \infty} \bar{P}_2^T(T,0)x(0) \quad \text{by definition of a probability vector}$$

$$\lim_{T \rightarrow \infty} \bar{P}(T,0) = \bar{P}_2^T(T,0) \quad \text{by definition of a probability vector}$$

Bonus

Subject :

Year . Month . Date .

$$\int_{T_0}^{\infty} \rho_i(t) dt = \lim_{T \rightarrow \infty} \rho_i(T) = \bar{\rho}_i(0) \Rightarrow 1_d = \bar{\rho}_i(0)x^{(0)}.$$

$$\left\{ \begin{array}{l} \alpha = \bar{\rho}_i^T(0)x^{(0)} \Rightarrow (\bar{\rho}_i^T(0) - \bar{\rho}_j^T(0))x^{(0)} = 0 \\ \alpha = \bar{\rho}_j^T(0)x^{(0)} \end{array} \right. \quad \forall x^{(0)} \in \mathbb{R}^m \Rightarrow \bar{\rho}_i^T(0) = \bar{\rho}_j^T(0) \quad \forall i, j$$

$$\bar{\rho}(0) = 1 \quad \Pi^T = \begin{bmatrix} \pi_1 & \dots & \pi_m \\ \vdots & \ddots & \vdots \\ \pi_1 & \dots & \pi_m \end{bmatrix} \quad \text{nonnegative convex combination}$$

$$1_d = \bar{\rho}(0)x^{(0)} \Rightarrow \alpha = \Pi^T x^{(0)} = \sum_{i=1}^m \Pi_i x_i^{(0)} \quad (\sum_{i=1}^m \Pi_i = 1, \quad \Pi_i \geq 0)$$

A. Nedić, A. Ozdaglar, "Distributed subgradient Methods for Multi-agent optimization"

الخطوة الأولى: توزيع القيمة المحددة من قبل كل عميل على جميع العمالء الآخرين

$$\left\{ [\bar{\rho}(k, s)]_j - \Pi_{j(s)} \right\} \leq c q \xrightarrow{\frac{(k-s)}{6}} q \in (0, 1)$$

الخطوة الثانية: توزيع القيمة المحددة من قبل كل عميل على جميع العمالء الآخرين

الخطوة الثالثة: توزيع القيمة المحددة من قبل كل عميل على جميع العمالء الآخرين

الخطوة الرابعة: توزيع القيمة المحددة من قبل كل عميل على جميع العمالء الآخرين

الخطوة الخامسة: توزيع القيمة المحددة من قبل كل عميل على جميع العمالء الآخرين

$$A^T 1 = 1 \quad \text{and} \quad 1^T A(u) = 1^T$$

$$\frac{1}{m} \sum_{i=1}^m \pi_i(k+1) = \frac{1}{m} 1^T A(k+1)u = \frac{1}{m} 1^T x^{(k+1)} = \frac{1}{m} \sum_{i=1}^m x_i^{(k)}$$

Batus

Subject: \_\_\_\_\_

Year. Month. Date. \_\_\_\_\_

$$\alpha = \frac{1}{m} \sum_{i=1}^m x_i(0) \rightarrow \text{Average Consensus} \quad \text{and} \quad \lim_{k \rightarrow \infty} x_i(k) = \alpha \\ = \lim_{k \rightarrow \infty} \frac{1}{m} \sum_{i=1}^m x_i(k) \quad \text{or} \quad \lim_{k \rightarrow \infty} \bar{x}_i(k) = \alpha$$

$$\bar{P}^{(0)} = 1\bar{\Pi}^T = \begin{bmatrix} \frac{n_1}{n} & \dots & \frac{n_m}{n} \\ \vdots & & \vdots \end{bmatrix}$$

$$\begin{cases} A\bar{B} = A1 = 1 \\ 1^T A\bar{B} = 1^T B = 1^T \end{cases} \quad \text{Lyapunov function for } \dot{x}_i = x_i - \bar{x}_i \\ \text{Lyapunov function for } \dot{\bar{x}}_i = \bar{x}_i - \bar{x}_i$$

$$\Rightarrow \sum_{i=1}^m \bar{x}_i = 1 \Rightarrow m\bar{x}_i = 1 \Rightarrow \bar{x}_i = \frac{1}{m} \quad i=1,2,\dots,m \Rightarrow \bar{P}(0) = \frac{1}{m} 11^T$$

$$|[\bar{P}(k,s)]_{ij} - \frac{1}{m}| \leq c_9 \frac{(k-s)^{\beta_0}}{\beta_0} \rightarrow \begin{cases} k-s = kB_0 \\ c>0 \end{cases}$$

## Consensus: Applications and Extensions

### 1) Opinion Dynamics in Social Network:

$$\text{The French-DeGroot model of opinion formation: } \tilde{x}_i(k+1) = \sum_{j=1}^n w_{ij} x_j(k), \quad \forall i, \quad k=0,1,\dots$$

Influence weights: is the contribution of agent  $j$ 's opinion to the opinion of agent  $i$  at its next step.

The self-influence weight  $w_{ii}$  indicates the agent's openness to the assimilation of the other's opinion

$\rightarrow w_{ii}=1 \equiv \text{Fully Stubborn}$

$w_{ii}=0 \equiv \text{Non-Stubborn}$

$w_{ii} \in [0,1] \equiv \text{Partially Stubborn}$

1. Initial state:  $x_1(0) = 1, x_2(0) = 0, \dots, x_n(0) = 0$

Subject:

Year:      Month:      Date:

2) Hey selmann-Kaue (HK) Model of opinion Formation:

Neighbors are defined in terms of a confidence interval:  $N_i(t) = \{j \in [m] \mid \|x_i(t) - x_j(t)\|_1 \leq \epsilon\}$

Each agent updates his opinion by averaging the opinions of all his neighbors.

$$x_i(t+1) = \frac{1}{2} (x_i(t) + x_{i+1}(t)) \quad \text{for } t=0, 1, 2, \dots$$

*Convergence:* For any initial profile and any confidence interval  $\epsilon$ , the agents' opinions

$x_i(t)$  converge to some limiting opinion  $x_i^*$  in a finite time, i.e., for each agent  $i$ , there exists time  $T_i > 0$  such that  $x_i(t) = x_i^*$  for all  $t \geq T_i$ .

The fragmentation of opinion may occur i.e., we may have agents  $i$  and  $j$  such that:

$$x_i \neq x_j$$

3) Multi-Vehicle Formation Control: Set of Autonomous Robots

Chiteng (2007) proposed a new method based on the Chirp-Z transform to estimate the parameters of a linear system.

$$u_{ij} = \sum_{k \in N_i} \frac{a_{ij}(x_j - x_k)}{1 + |x_j - x_k|}$$

weighted avg  
Minimized Consensus -  
- all

$$\Phi_G(x) = \frac{1}{2} \sum_{i,j=1}^n a_{ij} (x_j - x_i)^2 \rightarrow$$

مینیموم سیویل ایجاد کنید

Replacing  $u_i$ 's in the local dynamics we have:  $\dot{x}_i(t) = -L x_i(t)$ . Laplacian Matrix:

$$J_{ij} = \sum_{k=1, k \neq i}^n a_{ik}, j = 1, \dots, n$$

$a_{ij}$  for  $j \neq i$

$L(G) = L = \Delta - A$  weight matrix

$$\Delta = \text{diag}\left\{\sum_{i=1}^n a_{ij}\right\}_{j=1}^n$$

Subject :

Year . Month . Date .

Every row sum of the Laplacian matrix is zero. Therefore, the Laplacian matrix always has a zero eigenvalue corresponding to a right eigenvector.

L has a zero eigenvalue, hence it is singular.

$$L \mathbf{1} = \mathbf{0} \Rightarrow (\mathbf{A}\mathbf{1})^T = \mathbf{1}^T = (1, 1, \dots, 1)^T, \text{ Rank}(L) \leq n-1$$

Therefore,  $\text{rank}(L) \leq n-1$ . Since  $\text{rank}(L) < n$ ,  $L$  is full rank.  $L$  is full rank.

**Theorem 1:** Let  $G = (N, E, A)$  be a weighted digraph with Laplacian  $L$ . If  $G$  is strongly connected, then  $\text{rank}(L) = n$ .

Proof: By contradiction. Assume  $L$  is not strongly connected. Then  $L$  is not full rank.

**Convergence:** The protocol  $u_i = \sum_{j \in N_i} a_{ij} (x_j - x_i)$  globally asymptotically solves a consensus problem.

Sketch of proof:

1)  $\text{rank}(L) = n$

2)  $L$  has an eigenvalue at zero, the rest of eigenvalues have positive real parts. Cause:  $x^T L x = \frac{1}{2} \sum_{ij} a_{ij} (x_j - x_i)^2 \geq 0$

Since  $L$  is full rank,  $L$  is semi-positive definite. Therefore,  $L$  is invertible.

3) Therefore the linear system is stable:  $\dot{x}(t) = -Lx(t)$

Since  $L$  is semi-positive definite,  $L$  is symmetric and  $L$  is invertible.

$x = -Lx$

4) Equilibrium:  $Lx^* = 0 \Rightarrow x^* \in \text{Null}(L) \Rightarrow x^* = \mathbf{0}$

Since  $L$  is full rank,  $\text{Null}(L) = \{\mathbf{0}\}$ . Therefore,  $x^* = \mathbf{0}$ .

Therefore,  $x_i = x_j$  for all  $i, j \in N$ .

Protocol converges to a unique solution.

Subject :

Year . Month . Date .

### 1) Flocking

$$\begin{cases} \dot{q}_i = p_i \\ \dot{p}_i = \varphi_i \end{cases}$$

$q_i \in \mathbb{R}^m$  denote the position of node  $i$ .

what we want is  $\|q_i - q_j\| = d$   $\forall j \in N_i(q)$ .  
In other words agent  $i$  agent  $j$  have to agree.

### Variants/Extensions of Consensus:

1) Constrained Consensus:  $x_i(t+1) = P_{X_i} \left[ \sum_{j=1}^m A_{ij}(t)x_j(t) \right]$ ,  $X \triangleq \bigcap_{i=1}^m X_i$

$X \neq \emptyset$

Assumption: The sets  $X_i \subseteq \mathbb{R}^n$  are nonempty, closed, and convex, and their interaction is nonempty.

2) Noisy Links:  $x_i(k+1) = x_i(k) + \sum_{j \in \mathcal{N}_i} w_{ij}(k)(x_j(k) - x_j(k) - s_{ij}(k))$

So  $w_{ij}$  is noisy channel weight

minimizing

The term  $s_{ij}(k) + s_{ji}(k)$  represents a noisy estimate that agent  $i$  receives from its neighboring agent  $j$ , with  $s_{ij}(k)$  being the random noise on direct link  $(i,j)$  at time  $k$ .

3) Delay:  $x_i^i(k+1) = \sum_{j=1}^m a_j^i(k)x_j^i(k-t_j^i(k))$  for  $k=0,1,2,\dots$

The scalar  $t_j^i(k)$  represents the delay of a message from agent  $j$  to agent  $i$ .

### a) Random Graphs

Our general deterministic assumption can be extended to random graphs. In fact, if all agents receive information from a subset of agents, then each agent  $i$  will receive information from a random subset of agents.

Set of stochastic matrices of order  $n$  with entries  $p_{ij}$  where agent  $j$  has a strictly positive diagonal entries.  $p_{ii} = 1$ . Distribution of  $p_{ij}$  is infinite dimensional vector of i.i.d. random variables.

$\pi = \{\pi_1, \pi_2, \dots, \pi_n\}$   $\pi_i \sim \pi$ : distribution  $\pi = (\pi_1, \pi_2, \dots)$  is a stochastic matrix with  $\pi = (\pi_1, \pi_2, \dots, \pi_n, \pi_{n+1})$

Batus

$$x(k) = W_k(\omega)x(k-1), \quad W_k: \Omega \rightarrow \mathbb{R}^n, \quad W_k(\omega) = W_k$$

### 5) Asynchronous updating

Drawbacks of synchronous updates:

- Agents see the same time (imagine that each has its own clock and it updates at each tick)
- Preceding algorithm requires that all nodes have synchronized clocks
- Links have to be perfectly activated to transmit and receive information
- Communication protocols require receiving "ack-s"
- Communications can be costly

#### Asynchronous Gossip Scheme

- Given a static undirected graph  $G = (V, E)$
- Each node may wake up with equal probability  $(\frac{1}{m})$

Upon waking up, a node chooses one of its neighbors at random.

It contacts its neighbor  $j$  with probability  $P_{ij}$ .

Upon agent  $i$  establishing connection with agent  $j$ , the agent "talk"

Their exchange their information (say at time  $t_j$ )  $i$  talks to  $j$ :  $i$  sends  $x_{it_j}$  to  $j$  and  $j$  sends  $x_{jt_j}$  to  $i$

They perform some local update

Upon completing the update: Both agents go to "sleep"

The nodes  $I_k$  and  $J_k$  exchange their current values  $x_{ik(k)}$  and  $x_{jk(k)}$

Both nodes update as follows:  $x_{Ik}(k+1) = \gamma x_{Ik}(k) + (1-\gamma) x_{Jk}(k)$

$$x_{Jk}(k+1) = \gamma x_{Jk}(k) + (1-\gamma) x_{Ik}(k)$$

#### Distributed Optimization:

Given  $m$  linear functions  $f_i(x)$  to be minimized over  $\mathbb{R}^n$  and  $m$  agents  $i$  ( $i=1, 2, \dots, m$ )

$$\min_{\mathbf{x}} \sum_{i=1}^m f_i(\mathbf{x})$$

$$\mathbf{x} \in X = \prod_{i=1}^m X_i$$

Subject :

Year \_\_\_\_\_ Month. \_\_\_\_\_ Date. \_\_\_\_\_

$X^*$  لیکن  $x^*$  میں کوئی محدودیت نہیں اور  $x^*$  کو  $x_i \in \mathbb{R}^n$  کے  $n$  میں اور  $x^* = \sum_{i=1}^n x_i$  کے میں تصور کریں گے۔

$f(x)$  کو  $\mathbb{R}^n$  کے  $n$  میں کوئی محدودیت نہیں اور  $f(x) \leq f(x^*)$  کو  $x^*$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$S_{f_i}(\bar{x}) \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$f_i(\bar{x}) - f_i(x^*) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x \in \mathbb{R}^n$  کو  $x^*$  کے میں تصور کریں گے۔

$\text{کو } k+1$

$\text{کو } k+1$

$x^* = \sum_{i=1}^n x_i$  کو  $x^*$  کے میں تصور کریں گے۔



لـ  $\min_{x \in X} f(x)$  ،  $f(x)$   $\rightarrow$   $\min_{x \in X}$   $\sum_{i=1}^n f_i(x_i)$  ،  $f_i(x_i)$   $\rightarrow$   $\min_{x_i \in X_i}$   $f_i(x_i)$  ،  $X = \prod_{i=1}^n X_i$

### Convergence of Distributed Optimization Algorithm

$$P_x(\bar{x}) = \underset{x \in X}{\operatorname{Argmin}} \| \bar{x} - x \|$$



1)  $\| P_x(x) - P_x(y) \| \leq \| x - y \|$  ، Non-expansivity

$$2) \| P_x(x) - y \|^2 \leq \| x - y \|^2 - \| P_x(x) - x \|^2 \quad \forall x \in X$$

3) Weight rule: if  $a_i^j > 0$  then  $a_i^j \geq 1$  ،  $a_i^j \geq 1$

2) Doubly stochasticity of  $A(w)$ :  $A(w) = [a_{ij}^i]_{w \in W}$  ،  $1^T A(w) = 1^T$  ،  $A(w) 1 \geq 1$

3)  $G(V, E)$  is strongly connected:  $E_d = \{(j, i) | (j, i), i \in E_k\}$  for infinitely many times  $k \geq 1$

after  
،  $G$  is strongly connected if it goes infinitely often through some node after

$B \geq 1$  ،  $i, j \in V$  ،  $i \neq j$  ،  $(i, j) \in E_d$  ،  $(j, i) \in E_d$

3 + 4 = periodically strongly connected

→ closed and convex

$\hat{\Omega}_{i_1} X_{i_1} = X$  ،  $\hat{\Omega}_{i_1} \Omega_{i_1} = I$  ،  $\Omega_{i_1} \Omega_{i_1}^T = I$  ،  $\Omega_{i_1} \Omega_{i_1}^{-1} = I$  ،  $\Omega_{i_1}^{-1} \Omega_{i_1} = I$

Bottom  $\| d \| < L > 0$  ،  $\nabla f(x)$

$\subseteq X$

Subject : \_\_\_\_\_

Year . Month . Date . \_\_\_\_\_

$$V^i(\omega) = \sum_{j=1}^m a_j^i(\omega) x^j(\omega)$$

$$\chi^i_{(k+1)} = V^i_{(k)} - \alpha_k d_{ik}(\omega) \quad (\mu^i_{(k)}) \rightarrow \chi^i_{(k)}$$

$$\rho^i_{(k)} = P_X [V^i(\omega) - \alpha_k d_{ik}(\omega)] = (V^i_{(k)} - \alpha_k d_{ik}(\omega))$$

بيان سرهم حالي ينبع على حسابه

بيان ايجي لار ديار سارك تارك بيمس سادس رسيل ترسير مولس انتظاره

بريد ايجي لار ديار سارك تارك بيمس سادس رسيل ترسير مولس انتظاره

$$y^{(k+1)} = \frac{1}{m} \sum_{j=1}^m x^j_{(k+1)} = \frac{1}{m} \sum_{j=1}^m (V^j_{(k)} - \frac{1}{m} \sum_{i=1}^m d_{ik}(\omega) + \frac{1}{m} \mu^j_{(k)})$$

$$\frac{1}{m} \sum_{i=1}^m \sum_{j=1}^m a_j^i x^j_{(k)} = \frac{1}{m} \sum_{j=1}^m x^j_{(k)} \sum_{i=1}^m a_j^i = y^{(k)}$$

$$\Rightarrow y^{(k+1)} = y^{(k)} - \frac{1}{m} \sum_{i=1}^m d_{ik}(\omega) + \frac{1}{m} \sum_{i=1}^m \mu^i_{(k)}$$

بيان رسيل نرس ٣٠ (٦٤) ارسنبل (٦٥) ترسير المتم ترسير دى مولس انتظاره (PSG)

بيان رسيل دى مولس انتظاره (٦٦) بيمونس رسيل دى مولس انتظارها ايجي

$$1) \lim_{k \rightarrow \infty} \|x^i_{(k)} - y^{(k)}\| = 0, \text{ if } \lim_{k \rightarrow \infty} \alpha_k = 0$$

$$2) \sum_{k=1}^{\infty} \alpha_k \|x^i_{(k)} - y^{(k)}\| < \infty \quad \forall i, \text{ if } \sum_{k=1}^{\infty} \alpha_k^2 < \infty$$

Bonus : \_\_\_\_\_

Subject: \_\_\_\_\_

Year. Month. Date. \_\_\_\_\_

ابد - راجع :  $\lambda(k+1) = A(k)x(k) - d_k d(k) + \rho(k)$

$$\phi(k,s) = A(k)A(k-1)\dots A(s)$$

$$\lambda(k+1) = \overbrace{\phi(k,s)}^{(I)} + \underbrace{[-d_k d(k) + \rho(k)]}_{(II)}$$

$$+ \phi(k,k+1) [-d_{k+1} d(k+1) + \rho(k+1)] + \dots + \phi(k,s+1) [-d_s d(s) + \rho(s)]$$

$$A(k)A(k+1)$$

لأن  $\lambda(k+1)$  يعتمد على  $x(k)$  و  $d(k)$  و  $\rho(k)$  فقط، فإن  $\lambda(k+1)$  يعتمد على  $\lambda(k)$  فقط.

$$\lambda^i(k+1) = \sum_{j=1}^m [\phi(k,s_j)]_j^i x_j(s) \xrightarrow{\frac{1}{m} \sum_{i=1}^m d_i(k)} y(k+1) = \frac{1}{m} \sum_{j=1}^m \phi^j(k) d_j(k)$$

$$+ \sum_{r=s}^{k-1} \sum_{j=1}^m [\phi(k,r+1)]_j^i \rho^j(r) \xrightarrow{-d_i(k+1)} \frac{d_k}{m} \sum_{i=1}^m d_i(k) + \frac{1}{m} \sum_{r=s}^k \sum_{j=1}^m \phi^j(r) \rho^i(r)$$

لذلك  $y(k+1)$  يعتمد على  $y(k)$  و  $\rho(k)$  فقط.

إذن  $y(k)$  يعتمد على  $y(k-1), \dots, y(0)$  و  $\rho(k)$ .

$$\|y(k)\| \leq \sum_{j=1}^m \|[\phi(k-1,0)]_j^i\| \frac{1}{m} \|x_j(0)\| \xrightarrow{k+1 \rightarrow k, s=0} y(k) = \frac{1}{m} \sum_{j=1}^m x_j(0)$$

$$+ \sum_{r=0}^{k-2} \sum_{j=1}^m \|\phi(k-1,r+1)\|_j^i \frac{1}{m} \|d_j(r)\| \xrightarrow{k-1 \rightarrow k, r=0} \text{لذلك } y(k) \text{ يعتمد على } y(k-1), \dots, y(0).$$

$$+ d_{k-1} \|\phi(k-1,0)\| + \frac{1}{m} \sum_{j=1}^m \|d_j(k)\| \xrightarrow{k-1 \rightarrow k, r=0} \|\phi(k)\| \leq C_P \cdot \|\rho(k)\|$$

$$+ \sum_{r=0}^{k-2} \sum_{j=1}^m \|\phi(k-1,r+1)\|_j^i \frac{1}{m} \|\rho^j(r)\| \xrightarrow{0 < \beta < 1}$$

$$+ \|\rho^i(k)\| + \frac{1}{m} \sum_{i=1}^m \|\rho^i(k)\|$$

Batus \_\_\_\_\_

Subject :

Year . Month . Date .

$$\|x^i(u) - y(u)\| \leq c\beta^{k-1} \sum_{j=1}^m \|x^j_{(t_0)}\| + mcL \sum_{r=0}^{k-1} \beta^{k-r-2} dr$$

$$+ 2\alpha_{k-1}L + c \sum_{r=0}^{k-2} \beta^{k-r-2} \sum_{j=1}^m \|\rho^j(u)\| + \frac{1}{m} \sum_{j=1}^m \|\rho^j(u)\|$$

نیز معمولی روش برای اینجا استفاده نموده اند که اینجا روشی است که در اینجا معمولی است.

$$\|P_k(x) - y\|^2 \leq \|x - y\|^2 \|P_k(x) - y\|^2 \quad \forall x \in X \quad (\text{کوکس-کوکس})$$

$x \in X \Rightarrow y \in X$   $\Delta$  گامی کامبینیشن از  $x^i$   $\rightarrow$   $\rho^i$

$$\begin{aligned} \|x^i_{(k+1)} - y_{(k)}\|^2 &\leq \|y_{(k)} - \rho^i_{(k)}\|^2 + \|x^i_{(k+1)} - y_{(k)} - \rho^i_{(k)}\|^2 \\ &= \alpha_{k+1}^2 L^2 + \rho^i_{(k)} \\ &= \alpha_{k+1}^2 L^2 + \|\rho^i_{(k)}\|^2 \end{aligned}$$

$$\Rightarrow \alpha_{k+1}^2 L^2 + \|\rho^i_{(k)}\|^2 \Rightarrow \|\rho^i_{(k)}\|^2$$

$$\Rightarrow \|\rho^i_{(k)}\|^2 \leq \alpha_{k+1}^2 L^2 \Rightarrow \|\rho^i_{(k)}\| \leq \alpha_{k+1} L$$

$$\|x^i_{(k+1)} - y_{(k+1)}\| \leq c \sum_{j=1}^{k-1} \|x^j_{(t_0)}\| + mcL \sum_{r=0}^{k-2} \beta^{k-r-2} dr$$

برای اینجا اینجا معمولی است.

$$\alpha_{k+1} \rightarrow \alpha_{k+1} \rightarrow \alpha_{k+1} \rightarrow \dots \rightarrow \alpha_{k+1} \rightarrow 0$$

$$\Rightarrow \lim_{k \rightarrow \infty} \|x^i(u) - y(u)\| \leq 2mcL\beta^{-2} \lim_{k \rightarrow \infty} \sum_{r=0}^{k-2} \beta^{k-r}$$

حالا معمولی این جای اینجا است.

$$\sum_{r=0}^k \beta^{k-r} \leq \frac{N}{K} \sum_{r=0}^k \beta^{k-r} = \frac{N}{K} \frac{\beta^k - 1}{1 - \beta} = \frac{N}{K} \frac{1}{1 - \beta}$$

ما داریم  $\max_{r=0}^k \alpha_r$

$$0 \leq r \leq K$$

Subject :

Year . Month . Date .

جبر خطی و تجزیه و ترکیب

$$\rightarrow \frac{\beta^k - \beta^{-(k+1)}}{1 - \beta^{-1}} = \frac{\beta^k - \beta^{\frac{k}{2}-1}}{1 - \beta^{-1}} \quad \text{if } k > 0, \beta^k \neq 0, \beta^{\frac{k}{2}-1} \neq 0.$$

$$\rightarrow \frac{\beta^k - \beta^{-(k+1)}}{1 - \beta^{-1}} = \frac{\beta^k - \beta^{k-1}}{1 - \beta^{-1}}$$

اگر  $\beta^k = 0$  میگیریم  
اگر  $\beta^k \neq 0$  میگیریم

Therefore :  $\lim_{k \rightarrow \infty} \|x^i(k) - y(k)\| = 0$ .  $\forall i$ .

این بدان معنی است که  $x^i(k)$  به  $y(k)$  نزدیک شده است.

$$\alpha_k \|x^i(k) - y(k)\| \leq C \alpha_k \beta^{k-1} \sum_{j=1}^m \|x^j(0)\| + 2mC \sum_{r=0}^{k-1} \beta^{k-r-2}$$

$$\alpha_k \|x^i(k) - y(k)\| \leq C \alpha_k \beta^{2(k-1)} \sum_{j=1}^m \|x^j(0)\| + 2mC \sum_{r=0}^{k-1} \beta^{k-r-2}$$

$$2mC \leq \alpha_k^2 + \alpha_k^2$$

$$\Rightarrow \alpha_k \|x^i(k) - y(k)\| \leq C \beta^{2(k-1)} \sum_{j=1}^m \|x^j(0)\| + C \alpha_k^2 \sum_{j=1}^m \|x^j(0)\|$$

$$\text{برایم که } 1 + m C \alpha_k^2 L \sum_{r=0}^{k-1} \beta^{k-r-2} \leq \alpha_k^2 + \alpha_k^2 L \text{ باشد}$$

$$\leq \frac{1}{1-\beta} \text{ باشد}$$

$$\Rightarrow \alpha_k \|x^i(k) - y(k)\| \leq C \beta^{2(k-1)} \sum_{j=1}^m \|x^j(0)\| + m C L \sum_{r=0}^{k-1} \beta^{k-r-2} + 2L(\alpha_k^2 + \alpha_{k-1}^2) + m C A \alpha_k^2$$

$$A = \frac{1}{m} \sum_{j=1}^m \|x^j(0)\| + \frac{L}{1-\beta}$$

$$\sum_{k=1}^{\infty} \alpha_k \|x^i(k) - y(k)\| \leq C \sum_{k=1}^{\infty} \beta^k \|x^i(0)\| + \sum_{k=1}^{\infty} (m C A \alpha_k^2 + 2L(\alpha_k^2 + \alpha_{k-1}^2)) + m C A \sum_{k=1}^{\infty} \alpha_k^2$$

$$+ m C L \sum_{k=1}^{\infty} \sum_{r=0}^{k-1} \beta^{k-r-2}$$

Batus

T<sub>3</sub>

Subject: \_\_\_\_\_  
Year. \_\_\_\_\_ Month. \_\_\_\_\_ Date. \_\_\_\_\_

$$\sum_{k=1}^{\infty} \beta^{2(k-1)} / \text{Mordukar } T_1$$

$$\sum_{k=1}^{\infty} \alpha_k^2 < \infty \Rightarrow \text{Mordukar } T_2$$

$$\sum_{k=1}^{\infty} \sum_{r=0}^k \beta^{k-r} = \sum_{r=0}^{\infty} (\alpha_r)^2 \sum_{k=r}^{\infty} \beta^{k-r} \leq \frac{1}{1-\beta} \sum_{r=0}^{\infty} (\alpha_r)^2 < \infty$$

if  $\alpha_k > 1$

$$\sum_{k=1}^{\infty} \alpha_k \|x^i(k)\| \rightarrow \infty$$

Optimality condition  
 $\nabla f(x^*) = 0$

$$\nabla^i(k) = \sum_{j=1}^m \alpha_j^i (w_j x^i_w), \quad x^i(k+1) = P_x[\nabla^i(k) - \delta k d_i(k)]$$

$x^i \in X$  and  $\lim_{k \rightarrow \infty} \|x^i(k) - x^*\| = 0$

Proof by contradiction: Assume  $\lim_{k \rightarrow \infty} \|x^i(k) - x^*\| \neq 0$

Since  $x^i$  is bounded, there exists a subsequence  $x^{i,j}$  such that  $\lim_{j \rightarrow \infty} \|x^{i,j}(k) - x^*\| = 0$

$$\sum_{i=1}^m \|x^{i,j}(k) - x^*\|^2 = \sum_{i=1}^m \|P_x[\nabla^i(k) - \delta k d_i(k)] - x^*\|^2$$

$$\|\nabla^i(k) - \delta k d_i(k)\| \leq \|x^i(k) - x^*\| \Rightarrow \|\nabla^i(k) - \delta k d_i(k)\| \leq \|\nabla^i(k) - x^*\|$$

$$\Rightarrow \sum_{i=1}^m \|x^i(k) - x^*\|^2 \leq \sum_{i=1}^m \|\nabla^i(k) - \delta k d_i(k) - x^*\|^2 = \sum_{i=1}^m (\nabla^i(k) - \delta k d_i(k))^T (\nabla^i(k) - \delta k d_i(k))$$

$$= \sum_{i=1}^m \|\nabla^i(k) - x^*\|^2 + \sum_{i=1}^m \alpha_i^2 \|\delta k d_i(k)\|^2 - 2\alpha_k \sum_{i=1}^m d_i^T(k) (\nabla^i(k) - x^*)$$

$d_i^T(k) (\nabla^i(k) - x^*) \geq f_i(\nabla^i(k)) - f_i(x^*)$  subgradient

Batus

## Subject:

Year . Month . Date .

$$\Rightarrow \sum_{i=1}^m \|x_{(k)}^i - x^*\|^2 \leq \max_{k \in K} \sum_{i=1}^m \|f_i(x_{(k)}) - f_i(x^*)\|$$

$\sum_{j=1}^m a_j^i x_{(k)}$

$$\Rightarrow \sum_{i=1}^m \left\| \sum_{j=1}^m a_j^i x_{(k)}(x_{(k+1)}^i - x^*) \right\|^2 \leq \sum_{i=1}^m \|x_{(k)}^i - x^*\|^2 + m \alpha_k^2 L^2 - 2 \alpha_k \sum_{i=1}^m \|f_i(x_{(k)}) - f_i(x^*)\|^2$$

$$\Rightarrow \sum_{i=1}^m \|x_{(k+1)}^i - x^*\|^2 \leq \sum_{i=1}^m \|x_{(k)}^i - x^*\|^2 + m \alpha_k^2 L^2 - 2 \alpha_k \sum_{i=1}^m \left[ f_i(x_{(k)}^i) - f_i(x^*) \right] \cdot \left[ f_i(x_{(k+1)}^i) - f_i(x^*) \right]$$

$$\sum_{i=1}^m \|f_i(x_{(k+1)}^i) - f_i(x^*)\|^2 \leq \sum_{i=1}^m \left\| \sum_{j=1}^m a_j^i (x_{(k+1)}^j - x^*) \right\|^2 + \sum_{i=1}^m \left\| \sum_{j=1}^m a_j^i (x_{(k)}^j - x_{(k+1)}^j) \right\|^2 + \sum_{i=1}^m \left\| \sum_{j=1}^m a_j^i (x_{(k)}^j - x^*) \right\|^2$$

$$\sum_{i=1}^m \|x_{(k+1)}^i - x^*\|^2 \leq \sum_{i=1}^m \|x_{(k)}^i - x^*\|^2 + m \alpha_k^2 L^2 - 2 \alpha_k \sum_{i=1}^m \left[ f_i(y_{(k)}) - f_i(x^*) \right]$$

$$\sum_{j=1}^m a_j^i x_{(k)}^j = \sum_{j=1}^m a_j^i y_{(k)}^j$$

$$\sum_{i=1}^m \|x_{(k+1)}^i - x^*\|^2 \leq \sum_{i=1}^m \|x_{(k)}^i - x^*\|^2 + m \alpha_k^2 L^2 - 2 \alpha_k \sum_{i=1}^m \left[ f_i(y_{(k)}) - f_i(x^*) \right]$$

$$f = \sum_{i=1}^m f_i \sum_{j=1}^N \|x_{(k)}^j - y_{(k)}^j\| + 2 \alpha_k \sum_{i=1}^m \|x_{(k)}^i - y_{(k)}^i\|$$

$$f = \sum_{i=1}^m f_i \sum_{k \in K} \|x_{(k)}^i - y_{(k)}^i\| + N \epsilon_k \sum_{k \in K} \|x_{(k)}^i - y_{(k)}^i\|$$

$$\Rightarrow \sum_{i=1}^m \|x_{(k+1)}^i - x^*\|^2 \leq \sum_{i=1}^m \|x_{(k)}^i - x^*\|^2 + m \alpha_k^2 L^2 - 2 \sum_{k \in K} \alpha_k \|x_{(k)}^i - y_{(k)}^i\|$$

$$+ 2L \sum_{k \in K} \sum_{i=1}^m \|x_{(k)}^i - y_{(k)}^i\| + 2L \sum_{k \in K} \sum_{i=1}^m \alpha_k \|x_{(k)}^i - y_{(k)}^i\|$$

$$\Rightarrow \sum_{i=1}^m \|x_{(k+1)}^i - x^*\|^2 \leq \sum_{i=1}^m \|x_{(k)}^i - x^*\|^2 + 2L \sum_{k \in K} \alpha_k \|x_{(k)}^i - y_{(k)}^i\|$$

$$0 \leq \sum_{k \in K} \|x_{(k)}^i - x^*\|^2 \leq \sum_{i=1}^m \|x_{(k+1)}^i - x^*\|^2 + m \alpha_k^2 L^2 - 2 \sum_{k \in K} \alpha_k \|x_{(k)}^i - y_{(k)}^i\|$$

$$\sum_{i=1}^m \|x_{(k+1)}^i - x^*\|^2 \leq \sum_{i=1}^m \|x_{(k)}^i - x^*\|^2 + 2L \sum_{k \in K} \alpha_k \|x_{(k)}^i - y_{(k)}^i\|$$

Batus

جول اس بی ن مانسٹر کا وہ سلسلہ درستیں: میرا درس مکالمہ:

حال مخصوص سیم کو دربرین  $(x^*, f(x^*))$  بجهودی مفهودی

$$\text{fact: } \sum_{k=0}^{\infty} d_k(f(y(w)), f(x^*)) < \epsilon \quad , \quad \sum_{k=1}^{\infty} d_k = \infty \rightarrow y(k) \in X \rightarrow f(y(w)) - f^* \rightarrow 0$$

اگر  $\sum_{k=0}^{\infty} d_k(f(y(w)), f(x^*)) < \epsilon$  سپس  $\liminf_{k \rightarrow \infty} [f(y(w)) - f^*] = 0$

$$\liminf_{k \rightarrow \infty} [f(y(w)) - f^*] = 0$$

حال مخصوص بایرانی کو نبینی عرب نیرالطباطبائی

$$\sum_{i=1}^m \|x^i(N+1) - x^*\|^2 \leq \sum_{i=1}^m \|x^i(K) - x^*\|^2 + mL^2 \sum_{k=K}^N d_k^2 - 2 \sum_{k=K}^N d_k(f(y(w)), f(x^*))$$

$$+ 2L \sum_{k=1}^N \sum_{i=1}^m \|x^i(k) - x^i(N+1)\|$$

→ روش حمل کو N مرتبہ بخوبی معرفت کرو ویکاریت صفر است

$$\lim_{N \rightarrow \infty} \sum_{i=1}^m \|x^i(N+1) - x^*\|^2 \leq \lim_{K \rightarrow \infty} \sum_{i=1}^m \|x^i(K) - x^*\|^2$$

(ا) اس کا مطلب اس

$$\lim_{K \rightarrow \infty} \sum_{i=1}^m \|x^i(K) - x^*\|^2 = 0 \quad \text{کو محدودیت کر دے} \quad \sum_{i=1}^m \lim_{K \rightarrow \infty} \|x^i(K) - y(w)\|^2 = 0$$

حال مخصوص کو نبینی کو محدودیت کر دے

$$\text{دنبالہ } f^* = \liminf_{k \rightarrow \infty} f(y(w)) \rightarrow \liminf_{k \rightarrow \infty} f(y(w)) = f^*$$

$$\lim_{k \rightarrow \infty} x^i(k) = x^* \quad \forall i \quad \text{کو محدودیت کر دے} \quad \lim_{k \rightarrow \infty} x^i(k) = f^*$$

مڈی پریسز ریکارڈنگز میڈیا سوسائٹی کے نام پر ایک ریجسٹریشن سٹور

سروسز سٹور میڈیا سوسائٹی کے نام پر ایک ریجسٹریشن سٹور

$$\text{Convex } \min_{i=1}^N f_i(x) \quad f_i : \mathbb{R}^n \rightarrow \mathbb{R} \text{ (private info of agent } i) \\ X : \text{Compact and Convex}$$

s.t.  $g(x) \leq 0 ; h(x) = 0 ; x \in X$  : global decision variable

Convex optimization problem :  $g : \mathbb{R}^n \rightarrow \mathbb{R}^m$   $g(x)$  is a vector  $\Rightarrow g \leq 0$  left hand side

Convex

$$\text{Convex } \min_{i=1}^N f_i(x) \quad f_i(x) = Ax_i b , A \in \mathbb{R}^{m \times n} \\ s.t. \quad N g(x) \leq 0 , N h(x) = 0 ; x \in X \\ \text{Convex function decomposition}$$

$N g(x) \leq 0$   $\Rightarrow$   $N h(x) = 0$   $\Rightarrow$   $N g(x) \leq 0$   $\Rightarrow$   $N h(x) = 0$   $\Rightarrow$   $N g(x) \leq 0$   $\Rightarrow$   $N h(x) = 0$

$$\text{Convex } \min_{i=1}^N f_i(x) \quad f_i(x) = f(x) + \underbrace{N^T [g(x)]_+}_{(I)} + \underbrace{N^T [h(x)]_+}_{(II)} \\ H(x, \mu, \lambda) = f(x) + \lambda^T g(x)_+ + \mu^T h(x)_+$$

Convex optimization problem :  $x \in \mathbb{R}^m \geq 0$   $\lambda \in \mathbb{R}^m \geq 0$   $\mu \in \mathbb{R}^n \geq 0$   $H(x, \mu, \lambda)$   $\inf_{x \in X} q_p = \inf_{x \in X} H(x, \mu, \lambda)$

$$\text{Max } q_p(\mu, \lambda) \\ \mu \in \mathbb{R}^m \geq 0 \quad \lambda \in \mathbb{R}^n \geq 0 \\ \text{Convex } \max_{\mu \in \mathbb{R}^m \geq 0} \min_{\lambda \in \mathbb{R}^n \geq 0} q_p(\mu, \lambda)$$

Convex optimization problem :  $\lambda \in \mathbb{R}^n \geq 0$   $\mu \in \mathbb{R}^m \geq 0$   $\inf_{\lambda \in \mathbb{R}^n \geq 0} \max_{\mu \in \mathbb{R}^m \geq 0} q_p(\mu, \lambda)$

$$d^*_{\text{L}} = q_{\mu}(\mu^*, \lambda^*) = \inf_{x \in X} \{ f(x) + N \mu^T g(x) + N g^{*T} h(x) \}$$

$$\leq \inf_{x \in X} \{ f(x) + N \mu^T [g(x)]^+ + N l_2^T [h(x)]^+ \}$$

$$\text{dual constraint} = q_p(\mu^*, \lambda^*) \leq \max_{\mu \geq 0} q_p(\mu, \lambda, \lambda) = d_p^* \quad (4, 9 > 0)$$

$$(I, II) \Rightarrow d^* \leq d_p^* \quad \text{dual gap inequality}$$

$$\forall x^* \in X^*, [g(x^*)]^+ = 0, |h(x^*)| = 0$$

(1)

$$q_p(\mu, \lambda) = \inf_x H(x, \mu, \lambda) \leq H(x^*, \mu, \lambda) = f(x^*) = p^*$$

$$\Rightarrow \max_{\mu \geq 0, \lambda \geq 0} q_p(\mu, \lambda, \lambda) = d_p^* \leq p^* \quad (2)$$

$$(1), (2) \Rightarrow d^* \leq d_p^* \leq p^*$$

لما  $x^*$  ممكنة فـ  $x^*$  ممكنة  
لما  $x^*$  ممكنة فـ  $x^*$  ممكنة  
لما  $x^*$  ممكنة فـ  $x^*$  ممكنة

$$d_p^* = p^* \quad \text{dual gap = zero} \rightarrow \text{penalty dual gap} = 0$$

$$p^* \leq d_p^* \leq p^* \quad \text{dual gap = zero} \rightarrow \text{penalty dual gap} = 0$$

$$p^* \leq d_p^* \leq p^* \quad \text{dual gap = zero} \rightarrow \text{penalty dual gap} = 0$$

$$\text{برهان اول: مفهوم مبرهن نسبتاً بسيأراً} \rightarrow \text{برهان اول: مفهوم مبرهن نسبتاً بسيأراً}$$

تھے نتائجی بدلی کا نام نہیں بلکہ اس نے اس کا نام تھا۔ جو اس کا نام تھا اس کا نام تھا۔

مذکورہ اس نے اس کا نام تھا۔ جو اس کا نام تھا اس کا نام تھا۔

$$\sup_{\substack{\alpha \in X \\ \mu \geq 0 \\ \vartheta \geq 0}} H(\alpha, \mu, \vartheta) = \inf_{\substack{x \in X \\ \alpha \geq 0}} L(x, \mu, \vartheta)$$

Penalty dual جو نہیں

بھاوس سے مکاری نہیں بلکہ اس نے اس کا نام تھا۔

$$H_i(\alpha, \mu, \vartheta) = f_i(\alpha) + \mu^T [g(\alpha)]^+ + \vartheta^T h(\alpha) \Rightarrow H(\alpha, \mu, \vartheta) = \sum_{i=1}^N H_i(\alpha, \mu, \vartheta)$$

$\Delta$   $H_i(\alpha, \mu, \vartheta)$  :  $\alpha$  is fixed  $\rightarrow$  convex in  $\alpha$

$\Delta$   $H_i(\alpha, \mu, \vartheta)$  :  $\omega = (\mu, \vartheta)$  fixed  $\rightarrow$  concave in  $\alpha$

جو نہیں مکاری نہیں بلکہ اس کا نام تھا۔

بھاوس سے مکاری نہیں بلکہ اس کا نام تھا۔

$\Delta$   $H_i(\alpha, \mu, \vartheta)$  :  $\mu$  is fixed  $\rightarrow$  convex in  $\alpha$

(1) Initialization:  $\vartheta_{(0)}^i \in R^N \geq 0$ ,  $\mu_{(0)}^i \in R^m \geq 0$ ,  $x_{(0)}^i \in X$

2) Information fusion:  $V_{\alpha}^i(k) = \sum_{j=1}^N \alpha_j^i(k) \alpha_j^i(k) \rightarrow V_{\alpha}^i(k) = N f_i(\alpha^i(k))$

$$V_{\alpha}^i(u) = \sum_{j=1}^N \alpha_j^i(u) \mu_j^i(u)$$

$$V_{\alpha}^i(u) = \sum_{j=1}^N \alpha_j^i(u) g_j^i(u)$$

$$V_{\alpha}^i(u) = \sum_{j=1}^N \alpha_j^i(u) g_j^i(u)$$

Subject :

Year . Month . Date .

Step size

$$(3) \text{ Optimization: } x^i_{(k+1)} = P_\chi [N_x^i(u) - \alpha(u) D_x^{i(u)}]$$

$x = N_x^i(u)$  نتیجہ کے لئے  $H_i(x, N_x^i(u), N_g^i(u))$  کو  
نیکی دینے کے لئے

$$D_x^i(u) = Df_i(N_x^i(u)) + \sum_{l=1}^m [N_l^i(u)]_x D[g_e^i(N_x^i(u))]^\dagger + \sum_{l=1}^n [N_l^i(u)]_g D[h_e(N_x^i(u))]$$

(Classical gradient)  $\rightarrow$   $g_e^i(N_x^i(u))$  کو  
نیکی دینے کے لئے  $N_x^i(u)$  کو  
نیکی دینے کے لئے  $N_g^i(u)$  کو  
نیکی دینے کے لئے

برنامہ کا ایک ممکنہ مقدار کو  
نیکی دینے کے لئے  $N_x^i(u)$  کو  
نیکی دینے کے لئے  $N_g^i(u)$  کو  
نیکی دینے کے لئے

$$\mu^i_{(k+1)} = N_y^i(u) + \alpha(u) [g(N_x^i(u))]^\dagger \rightarrow \text{supergradient of } H_i \text{ w.r.t. } p_i \text{ at } (N_x^i(u), N_g^i(u))$$

$$\delta^i_{(k+1)} = N_y^i(u) + \alpha(u) [h(N_x^i(u))] \rightarrow \text{supergradient of } H_i \text{ w.r.t. } q_i \text{ at } u$$

لگانے سے  
Subgradient of Supergradient

$$y^i_{(k+1)} = N_y^i(u) + N(f_i(N_x^i(u)), f_i(N_x^i(u))) \rightarrow \text{minimum value of } H_i$$

بڑی بیان کے لئے

$$1) \lim_{k \rightarrow \infty} \alpha(k) = 0 \quad 2) \lim_{k \rightarrow \infty} \alpha(k+1).S(k) = 0 \quad S(k) = \sum_{l=0}^K \alpha(l)$$

$$3) \sum_{k=0}^{\infty} \alpha(k) = \infty \quad 4) \sum_{k=0}^{\infty} \alpha^2(k) < \infty \quad 5) \sum_{k=0}^{\infty} \alpha^2(k+1).S(k) < \infty \quad 6) \sum_{k=0}^{\infty} \alpha(k+1).S(k) < \infty$$

$$\text{Ex. } \alpha(k) = \frac{1}{k+1}$$

پرولڈ - پرولڈ - penalty - primal - dual - constraint  
نیکی دینے کے لئے  
نیکی دینے کے لئے

نیکی دینے کے لئے  
نیکی دینے کے لئے  
نیکی دینے کے لئے

Batus

$\alpha(k)$  a step size  $\rightarrow$  DPP (Dual Subgradient)  $\rightarrow$   $\lim_{k \rightarrow \infty} \|x^i(k) - \tilde{x}\| = 0 \quad \forall i \in V$

$$\lim_{k \rightarrow \infty} \|g^i(k) - p\| = 0 \quad \forall i \in V$$

## Distributed Optimization Extension and Applications:

Stochastic consensus-based subgradient methods:

$$x_i(t+1) = P_x [w_i(t) - \alpha(t)(\tilde{\nabla} f_i(w_i(t+1)) + e_i(t+1))]$$

Stochastic error in computing Subgradient  $\nabla f_i$ , measurement etc.

Uniformly bounded in mean square

Provide an estimate for the algorithm's performance in mean

Consensus-based subgradient method for noisy links:

$$w_i(t+1) = x_j(t) - \eta(t) \sum_{j=1}^J r_{ij}(x_j(t) + \epsilon_j(t)) \rightarrow \text{Noise: random zero-mean noise on the link}$$

$\eta(t) > 0$  is a noise-damping  $\leq \frac{1}{N} \eta_j(t)$  when  $j \neq N_i$  from  $j$  to  $i$ .

Stepsize

$$x_i(t+1) = w_i(t+1) - \alpha(t) g_i(w_i(t+1))$$

$\rightarrow$  Noise-damping stepsize  $\eta(t)$  has to be coordinated with sub-gradient related stepsize  $\alpha(t)$ :

$$\begin{aligned} \sum_t x_i(t) < \infty, & \rightarrow \sum_t \alpha^2(t) < \infty \\ \sum_t \eta(t) < \infty, & \rightarrow \sum_t \eta^2(t) < \infty \\ \sum_t \alpha w_i(t) < \infty, & \rightarrow \sum_t \frac{\alpha^2(t)}{\eta(t)} < \infty \end{aligned}$$

Consensus-based subgradient methods for distributed sets:

The set  $X$  can be given as intersection set  $X = \bigcap_{i=1}^n X_i$  where each  $X_i$  is a private information of agent  $i$ .

In this case the projection-based update of algorithm is modified as follows:

$$x_i^{(t+1)} = P_{X_i} [w_i^{(t+1)} - \alpha(t) \tilde{\nabla} f_i(w_i^{(t+1)})]$$

### Distributed Random Projection (DRP) Algorithm

A version of the algorithm where  $X_i$  is itself an intersection of a collection of sets, and a random set from the collection is used in the projection-based update.

Initialize  $x_{i(0)}$  for  $i \in \mathcal{N}$ . For  $k \geq 0$ , each agent  $i$  performs the following steps:

$$1. \text{ Mixing: } v_{i(k)} = \sum_{j=1}^m a_{ij}(k) x_j(k)$$

$$2. \text{ Gradient update: } \tilde{v}_{i(k)} = v_{i(k)} - \alpha_i(k) \nabla f_i(v_{i(k)})$$

3. Projection: A random variable  $\Omega_i(k) \in \mathcal{T}_i$  is drawn, and a component  $X_i$  of  $X_i = \bigcap_{j=1}^m X_j$  is used for projection:  $x_{i(k+1)} = \prod_{j \neq \Omega_i(k)} [v_{i(k)}]$

$\Omega_i$  is chosen such that  $\Omega_i(k) \neq \Omega_i(l)$ ,  $\forall l \neq k$ . Example:  $\Omega_i(k) = \{x_1\}$

### Distributed Mini-Batch Random Projection (DMRP)

What if  $X_i$  consists of  $10^4$  hyperplanes?

Then one sample will render a poor approximation of the true set  $X_i$ .

100 samples will provide a better approximation of the set.

Initialize  $x_{i(0)}$  for  $i \in \mathcal{N}$ . For  $k \geq 0$ , each agent  $i$  does the following:

$$1. \text{ Mixing: } v_{i(k)} = \sum_{j=1}^m a_{ij}(k) x_j(k)$$

$$2. \text{ Gradient update: } \psi_i^0(k) = v_{i(k)} - \alpha_i(k) \nabla f_i(v_{i(k)})$$

3. Projection: A batch of  $b$  independent random variables  $\Omega_i^{r+1}(k), r = 1, \dots, R$  is drawn. The components  $X_i^{a_1(k)}, X_i^{a_2(k)}, \dots, X_i^{a_b(k)}$  of  $X_i = \bigcap_{j=1}^m X_j$  are used for sequential projections.

$$\psi_i^r(k) = \prod_{j=1}^m [\psi_i^{r-1}(k)]_{j \neq \Omega_i^{r+1}(k)}, \text{ for } r = 1, \dots, b$$

$$X_i^{a_b(k)} = \psi_i^b(k)$$

$$\psi_i^0(k) = v_{i(k)} - \alpha_i(k) \nabla f_i(v_{i(k)})$$

### Asynchronous consensus-based subgradient methods:

$$x_i(k) = \left( x_{I_k}(k-1) + x_{J_k}(k-1) \right) / 2 \quad i \in \{I_k, J_k\}$$

$$\text{Gossip: } x_i(k) = \prod_{j \neq i} [y_j(k) - x_j(k)] f_i(y_i(k))$$

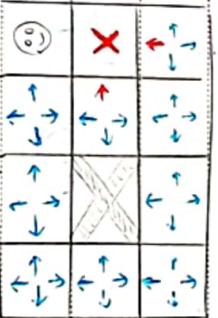
$$x_i(k) = x_i(k-1) \quad \text{for all } i \notin \{I_k, J_k\}$$

### Dynamic Optimization

بررسی

A. two-state state model  
 بررسی  
 "Transition from optimization to RL"

Optimization in a Grid World:



برای این شرکت فرآیند را کنترل کنید :

- We do not have an explicit model of cost function to minimize.

- We have a Multi-Stage decision-making problem (otherwise we face curve of dimensionality)  
 این مسأله بحث و تحقیق در مورد این روش است که چگونه با هم چندین حالت را در یک رشته ای داشتیم

برای این شرکت فرآیند را کنترل کنید :

Making

- We may not know where the goal is

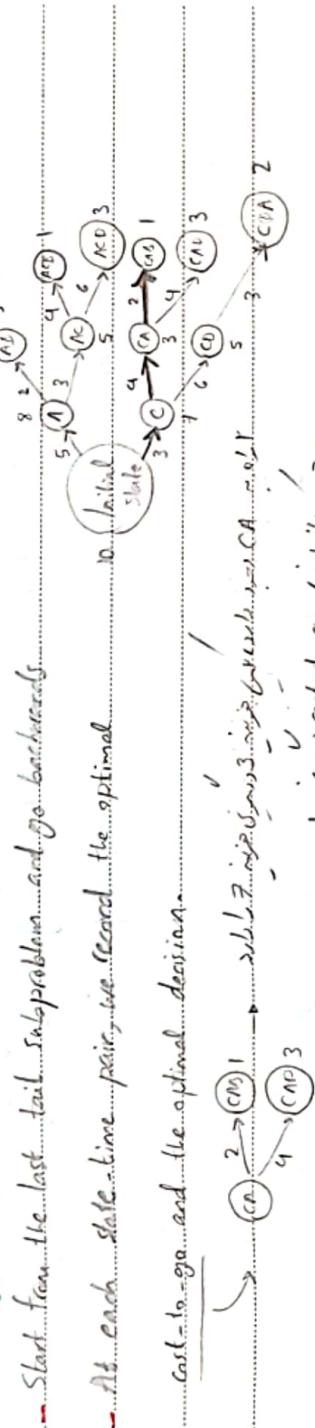
### Dynamic Optimization: Multi-Stage Decision Making

- We have a new variable at each stage which is named **STATE**.
- A decision at an state can lead to specific set of states.
- The state can also affect the cost function.
- The transition between states in two consecutive stages depend on the previous state(s) and corresponding decision.

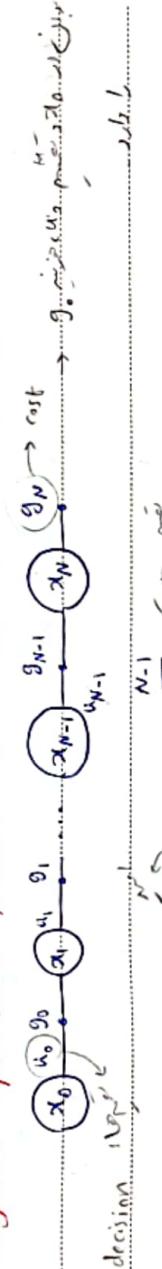
حال سیل از dynamic optimization میگذرد.

Scheduling Example: Find optimal sequence of operations A, B, C, D.

- Start from the last tail subproblem and go backwards
  - At each state-time pair, we record the optimal cost-to-go and the optimal decision.



### Formulating Dynamic Optimization Problems



$$\min_{\mathbf{w}} E \left\{ g_N(\mathbf{z}_N) + \sum_{k \leq 0} g_k^*(\widehat{\mathbf{x}}_k | \mathbf{w}_k, \mathbf{w}_k) \right\}$$

- حال می خواهد مورد مسکن / معاشری تبدیل شود :  $x_{k+1} = f_k(x_k, u_k, w_k)$   $k=0, \dots, N-1$

- Central constraints:  $u_k \in U_k(x_k)$
  - Probability distribution  $P_k(x_{k+1})$  of  $u_k$
  - Policies:  $\Pi = \{ \pi_0, \dots, \pi_{N-1} \}$ , where  $\pi_k$  maps states  $x_k$  into controls  $u_k = \pi_k(x_k)$  and is such that  $\pi_k(x_k) \in U_k(x_k)$  for all  $x_k$ .

Expected cost of  $\pi$  starting at  $x_0$  is,  $J_{\pi}(x_0) = E \left\{ g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, p_k(x_k), u_k) \right\}$

Optimal cost function,  $J^*(x_0) = \min_{\pi} J_\pi(x_0)$

## Algorithm DP

- Start with:  $J_N(x_0) = g_N(x_0)$
- Go backwards using:  $J_k(x_0) = \min_{x_k \in \mathcal{X}_k} E\{g_k(x_k, u_k) + J_{k+1}\{f_k(u_k)\}\}$ ,  $k=0, 1, \dots, N-1$

Subject :

Year . Month . Date .

## Reinforcement Learning :

Subject : DP & RL

جذبیتی مینیمیم و مکسیمی برداشتگری دارای این تعریف را این بیان میکند

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

$$\pi_a(s) = \text{prob}(a_t = a \text{ when } s_t = s)$$

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

$$R_t = r_{t+1} + \gamma r_{t+2} + \dots + \gamma^{k-1} r_{t+k}$$

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

نهاده نماینده استوچری رفتار را که در آن میتواند میزان جذبیت را در چندین مرحله

## مقدمة في علم الحاسوب

### التعلم الآلي

▪ مفهوم  $\pi$ -Policy /  $\pi$ -Policy هو حالات بحثية حيث يختار المدخلات كلها بحسب قيم ال報酬.

$$\mathcal{V}_{\pi}(s) = E_{\pi}\{R_t | S_t = s\} = E_{\pi}\left\{\sum_{k=0}^{\infty} \gamma^k r_{t+k} | S_t = s\right\} = E_{\pi}\left\{\sum_{k=0}^{\infty} \gamma^k P_a^k [R_{t+k}]\right\}$$

▪ مفهوم  $\pi$ -Action /  $\pi$ -Action هو انتخاب المدخلات كلها بحسب قيم ال報酬.

$$Q_{\pi}(s, a) = E_{\pi}\{R_t | R_t = a\} = E_{\pi}\left\{\sum_{k=0}^{\infty} \gamma^k r_{t+k} | S_t = s, a_t = a\right\} = \sum_a P_a^s [R_{t+1}^a + \gamma \mathcal{V}_{\pi}(s)]$$

$$E_{\pi}\{r_{t+1} | S_t = s, a_t = a\} = E_{\pi}\{r_{t+1} | S_t = s, a_t = a\}$$

▪  $\pi$ -Policy Evaluation /  $\pi$ -Policy Evaluation هو إيجاد القيمة المُنافقة  $\mathcal{V}_{\pi}(s)$  لـ  $s$ .

▪  $\pi$ -Policy Improvement /  $\pi$ -Policy Improvement هو إيجاد المدخلات المُنافقة  $a^*$  لـ  $s$ .

▪  $\pi^*$  /  $\pi^*$  هو المدخلات المُنافقة لـ  $s$ ، حيث يختار المدخلات كلها بحسب قيم ال報酬.

▪  $\pi^*$  /  $\pi^*$  هو المدخلات المُنافقة لـ  $s$ ، حيث يختار المدخلات كلها بحسب قيم ال報酬.

▪  $\pi^*$  /  $\pi^*$  هو المدخلات المُنافقة لـ  $s$ ، حيث يختار المدخلات كلها بحسب قيم ال報酬.

$$\pi^*(s) = \max_a Q_{\pi}(s, a) = \arg \max_a Q_{\pi}(s, a)$$

▪  $\pi^*$  /  $\pi^*$  هو المدخلات المُنافقة لـ  $s$ ، حيث يختار المدخلات كلها بحسب قيم ال報酬.

$$\pi^*(s) = \max_a E_{\pi}\{r_{t+1} + \gamma \cdot \mathcal{V}_{\pi}(s') | S_{t+1} = s'\, a_t = a\} = \max_a \sum_s P_{ss'}^a [R_{s'}^a + \gamma \cdot \mathcal{V}_{\pi}(s')]$$

$$= \max_a Q_{\pi}(s, a)$$

پروگرامی مدل سازی برای تخمین مقدار  $V^*$  با استفاده از روش  $\pi$ -لرنینگ (Policy Iteration) است.

### (policy iteration)

بررسی پیشنهادی میکنند که این روش چگونه کار میکند و چرا که این روش میتواند به درستی تخمین مقدار  $V^*$  را بدهد.

$$V_{k+1}(s) = \mathbb{E}_\pi \{ r_{t+1} + \gamma V_k(s_{t+1}) | s_t = s \} = \sum_a \pi(s,a) \mathbb{E}_\pi [R_{ss'}^a + \gamma V_k(s')]$$

ابتدا  $\pi$  را از صفر میکنیم.

با این روش از زیرین شروع میکنیم، پس از اینکه نتایج حاصل شوند میتوانیم آنها را بروز کنیم.

برای اینکه  $\pi$  را بروز کنیم باید  $V$  را بروز کنیم.

با این روش از زیرین شروع میکنیم، پس از اینکه نتایج حاصل شوند میتوانیم آنها را بروز کنیم.

$$\pi_k(s) = \arg \max_a \mathbb{E}_\pi [R_{ss'}^a + \gamma V_k(s')]$$

Policy Iteration (using iterative policy evaluation) for estimating  $\pi \approx \pi^*$

1. Initialization:  $V(s) \in \mathbb{R}$  and  $\pi(s,a)$  arbitrarily for all  $s \in S$ ;  $V(\text{Terminal}) = 0$

2. Policy Evaluation: Loop:

$$\Delta \leftarrow 0$$

Loop for each  $s \in S$ ,

$$V \leftarrow V(s)$$

$$V(s) \leftarrow \sum_a \pi(s,a) \mathbb{E}_\pi [R_{ss'}^a + \gamma V(s')]$$

$\Delta \leftarrow \max(\Delta, |V(s) - V_{old}(s)|)$

until  $\Delta < \theta$ . (a small positive number determining the accuracy of estimation.)

3. Policy Improvement: policy\_stable  $\leftarrow$  True

For each  $s \in S$ :

$$\text{old\_action} \leftarrow \pi(s)$$

$$\pi(s) \leftarrow \arg \max_a \sum_s \pi(s,a) [R_{ss'}^a + \gamma V(s')]$$

If old\\_action  $\neq \pi(s)$ , then Policy\\_stable  $\leftarrow$  False

If policy-stable, then stop and return  $V \approx V^*$  and  $\pi \approx \pi^*$

Batus

Subject :

Year . Month . Date .

Value Iteration

$$1) V_{t+1}(s) = \max_a E_{\pi} \left\{ r_{t+1} + \gamma V_t(s_{t+1}) \mid s_t = s, a_t = a \right\}$$

$$= \max_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V_t(s') ] = \max_a Q_{t+1}(s, a)$$

$$2) \pi^*(s) = \arg \max_a Q_s(s, a)$$

Value Iteration, for estimation  $\pi \leq \pi^*$ :

Algorithm parameter: a small threshold  $\theta > 0$  determining accuracy of estimation. Initialize  $V(s)$ , for all  $s \in S^t$ , arbitrarily except that  $V(\text{terminal}) = 0$ .

Loop:

$\Delta \leftarrow 0$   
Loop for each  $s \in S^t$ :

$V \leftarrow V(s)$

$$V(s) \leftarrow \max_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V(s')]$$

$$\Delta \leftarrow \max(D, |\Delta - V(s)|)$$

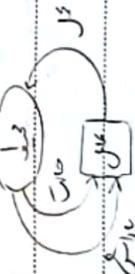
until  $\Delta < \theta$

Output a deterministic policy,  $\pi \leq \pi^*$ , such that  $\pi(s) = \arg \max_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V(s')]$

بررسی تقریبی نتیجه عمل می‌گیریم

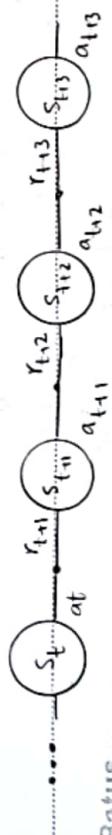
عملیاتی در سمت  $(P_{ss'}^a, R_{ss'}^a)$

اعمالیاتی در عمل باید و داشت اما هر کسی می‌داند که برای این سند خود خواهد است.



درس سمت معلم:

درست درس پایه را در حالت صادر می‌داند (Q(s,a)). در این:



→ لحر اندروز ناپلریکو از بحث در مسائل مولن دست یافت. تمریج یا اسی همی رسانی کی سبک است.

→ در این سبک هر کارکرد را در چهار قسم دانست. Returni → خواهد بود.

Return<sub>i</sub> =  $r_1 + \gamma r_2 + \gamma^2 r_3 + \dots + \gamma^{k-1} r_k$

→ مانندیزی داریکی داشت. در این سبک هر کارکرد را در چهار قسم دانست. Returni → خواهد بود.

→ مانندیزی داریکی داشت. در این سبک هر کارکرد را در چهار قسم دانست. علی‌جان (Q(a)) در این سبک به عنوان

$Q(s,a) \leftarrow \text{Average}(\text{Return}_i)$

→ مانندیزی داریکی داشت. در این سبک هر کارکرد را در چهار قسم دانست. علی‌جان (Q(a)) در این سبک به عنوان

**Exploration-Exploitation Balances:**

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ سیاست عملیاتی خود را در برداشتن آغاز می‌کند.

→ لدھر لپڑوں نے اپنے پروگرامز میں دنہالی میں بولنے سے پہلے تکمیل کیا ہے۔

Return<sub>i</sub> =  $r_1 + \gamma r_2 + \gamma^2 r_3 + \dots + \gamma^{k-1} r_k + \text{task reward}$

۴- مانند  $\frac{1}{n}$  مارکسی حاکمیت سرمه را از خود کنی محظی میگیرد که این حقیقت کاملاً حاصل (این) در مارکسیسم نیز نیست.

**Q15(a) ← Average (Ratum:)**

وَالْمُؤْمِنُونَ الْمُؤْمِنَاتُ لِلرَّحْمَةِ الْمُؤْمِنَاتُ لِلرَّحْمَةِ

Exploration-Exploitation Balance

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ وَاللَّهُ أَكْبَرُ وَبِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

→ سطح سطحی حمایت می‌شوند تا نیز رسم بعنوان عالی باشد  $\rightarrow$  **Softmed**

$$\Pi(s,a) = \frac{e^{\overline{\pi}(s,a)}}{\sum_{a' \in A(s)} e^{\overline{\pi}(s,a')}}$$

۴ راسماً حدّد میر، اینجا ناصلی است. ترتیب خود را باعث تغییر می‌کند. action این رسمیت را نمایم. آنها نهایت حجم

البرازيلis epoch) وتحتها سلسلة من الأدلة وفرضياتها، اعتماداً على action reaction، وهي تشير إلى مفهوم المعاشر والمتضاد، حيث يتحقق التغيير في المفهوم المعاشر (أي المعاصر) بفضل المفهوم المتضاد (أي المعاكس)، مما يفتح المجال لـ "المعنى" (meaning)، الذي يمثل المفهوم المعاكس للمفهوم المعاشر.

ابن رازی طبسته شد (رسک صحن) و از  
آن پس مادرش را نیز بگذشت

The diagram illustrates a Q-learning agent architecture. It starts with a **Slate** at the bottom left, which feeds into a **State** circle. From the **State** circle, an arrow labeled  $a_0$  points to a **Q<sub>00</sub>** circle. From **Q<sub>00</sub>**, an arrow labeled  $a_1$  points to a **Q<sub>11</sub>** circle. From **Q<sub>11</sub>**, an arrow labeled  $a_2$  points to a **Q<sub>22</sub>** circle. From **Q<sub>22</sub>**, an arrow labeled  $a_3$  points to an **Action** circle. Finally, an arrow labeled  $r$  points from the **Action** circle back to the **Slate**.

51.  $\sum_{i=1}^n$   $\frac{1}{i}$   $\geq \ln n + 1$

$s_2$   $Q_{20}$   $Q_{21}$   $Q_{22}$   $Q_{23}$   $Q_{24}$   $Q_{25}$

### A Monte Carlo algorithm

Algorithm parameter : small  $\varepsilon > 0$

Initialize :

$\pi \leftarrow$  an arbitrary  $\varepsilon$ -soft policy  
 $Q(s,a) \in R$  arbitrarily, for all  $s \in S, a \in A(s)$

Returns<sub>t</sub>(s,a)  $\leftarrow$  empty list for all  $s \in S, a \in A(s)$

Repeat forever (for each episode) :

Generate an episode following  $\pi$ :  $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Loop for each step of episode,  $t = T-1, T-2, \dots, 0$ :

$G \leftarrow \gamma G + R_{t+1}$

Unless the pair  $S_t, A_t$  appears in  $S_0, A_0, S_1, A_1, \dots, S_{t-1}, A_{t-1}$ :

Append  $G$  to Returns<sub>t</sub>(S<sub>t</sub>, A<sub>t</sub>)

$Q(S_t, A_t) \leftarrow$  average(Returns<sub>t</sub>(S<sub>t</sub>, A<sub>t</sub>))

$A^* \leftarrow \arg\max Q(S_t, a)$

For all  $a \in A(S_t)$ :

$$\Pi(a|S_t) \leftarrow \begin{cases} 1 - \varepsilon & \text{if } a = A^* \\ \frac{\varepsilon}{|A(S_t)|} & \text{if } a \neq A^* \end{cases}$$

Monte Carlo (DP)

لین دریں باقی مسکم باقی عمر نہ دو جائی سرمه از کھڑک رہنے رہ

سادھرنی سلسلانی وسیبازی

اپن سبب ۰ تر بخوبی مسکم ایجاد کاروں پر کمی کھڑک رکھنے کی حکایت

۴- کمی کی حرکت سکھ لئا جائی سرمه بخوبی مسکم ایجاد کاروں پر کمی کھڑک رکھنے کی حکایت

مدرسون روکن ساند روکن سونت / مدرسون تاون مدرسون داستن اصحاب ک زنجه های توپ بازی های پارک رانی کارد

می خواهی را نمودیں / من هم طبق شناسنامه / رسیدن سیالک نمایی برای بقدر مخفی نمایی کرد / همچنان که برگ از این

حَلَالٌ مُنْهَى حَلَالٌ مُنْهَى حَلَالٌ مُنْهَى

$$V(S_t) = E \left\{ \sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | S_t = s \right\} = E \left\{ r_{t+1} + \gamma V(S_{t+1}) | S_t = s \right\} \rightarrow \text{partial dynamic programming}$$

$$N_{t+1}(S_t) = N_t(S_t) + \alpha \cdot \underbrace{[r_{t+1} + \gamma d_t(S_{t+1}) - N_t(S_t)]}_{\text{Reward}} \quad 0 \leq \alpha \leq 1$$

لذلک رسن جا  $\left\{ \begin{array}{l} \text{رسن ۱۱} \\ \text{رسن ۱۲} \end{array} \right.$  SARSA  $\left\{ \begin{array}{l} \text{رسن ۱۳} \\ \text{رسن ۱۴} \end{array} \right.$  Q  $\left\{ \begin{array}{l} \text{رسن ۱۵} \\ \text{رسن ۱۶} \end{array} \right.$  ایونیک ایونیک

میں میور دی رہنگے۔ لیکن اس کی سیکھ خدمت اُڑا کیا جائے۔ کوئی انسان پر اچھا نام نہیں چلے (Q)۔

$\{s,a\} \leftarrow Q(s,a) + \alpha [r + \gamma \cdot Q(s',a') - Q(s,a)]$

## Sarsa: An on-policy TD control algorithm

Algorithm parameters: step size  $\alpha \in [0, 1]$  ; small  $\epsilon > 0$   
 Initialize  $Q(S, A)$ , forall  $s \in S^t$ ,  $a \in A(s)$ , arbitrarily expect that  $Q(s, a)_{initial} = 0$

Loop for each episode:

Initialize  $S$

- Choose  $A$  from  $S$  using policy derived from  $Q$  (e.g.,  $\epsilon$ -greedy)
- Loop for each step of episode:
  - Take action  $A$ , observe  $R, S'$
  - Choose  $A'$  from  $S'$  using policy derived from  $Q$  (e.g.,  $\epsilon$ -greedy)
  - $Q(S, A) \leftarrow Q(S, A) + \alpha [R + \gamma Q(S', A') - Q(S, A)]$
  - $S \leftarrow S'$ ;  $A \leftarrow A'$ ;
- until  $S$  is terminal

سازه سارسا برخلاف رسکی سریع تر از آنچه معرفتی ( $\delta$ ) را بخواهد.

$$Q(S, A) \leftarrow Q(S, A) + \alpha [R + \max_a Q(S', a) - Q(S, A)]$$

## Q-learning: An off-policy TD algorithm

(\*)

- Loop for each episode:
  - Initialize  $S$
  - Loop for each step for episode:
    - Choose  $A$  from  $S$  using policy derived from  $Q$  (e.g.,  $\epsilon$ -greedy)
    - Take action  $A$ , observe  $R, S'$
    - $Q(S, A) \leftarrow Q(S, A) + \alpha [R + \max_a Q(S', a) - Q(S, A)]$
    - $S \leftarrow S'$
  - until  $S$  is terminal

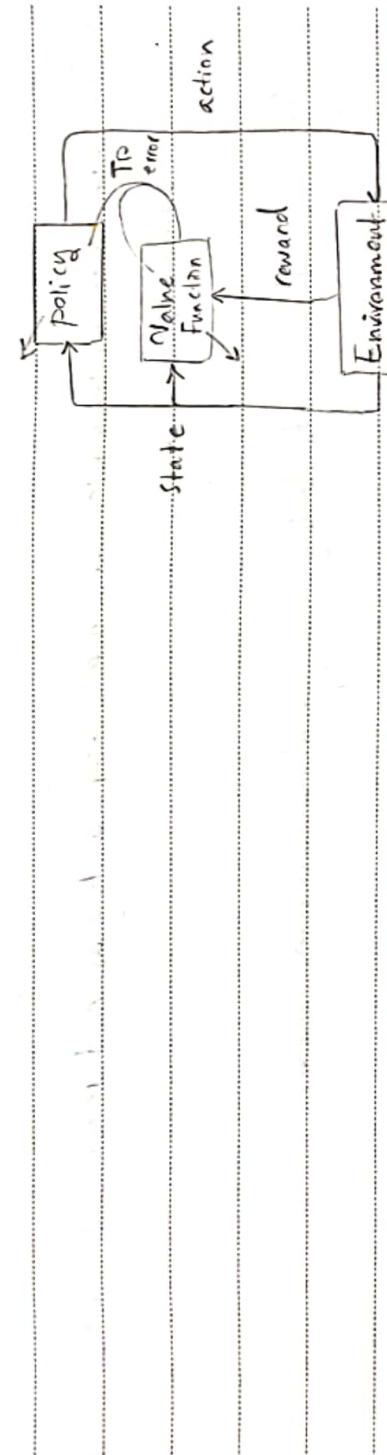
$$\delta_t = r_{t+1} + \gamma (V(s_{t+1}) - V(s_t))$$

Actor-Critic / دریں جسے سارے

The value of the next state may give more insight about how the last action was good rather than blending this value to the action taken in the next step.

$$\pi_t(s, a) = \Pr\{a_t = a | s_t = s\} = \frac{e}{\sum_a p(s_t)}$$

$$V_{t+1}(s_t) = V_t(s_t) + \alpha \delta_t = V_t(s_t) + \alpha \cdot [r_{t+1} + \gamma V_t(s_{t+1}) - V_t(s_t)]$$



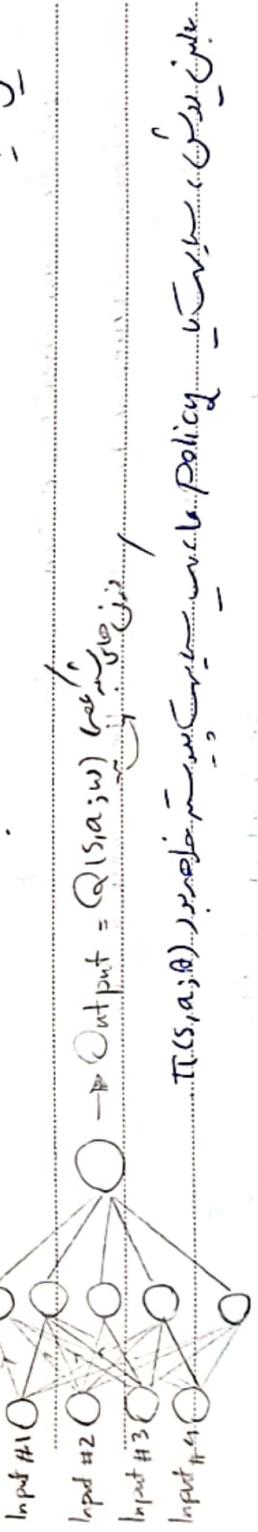
### Continuous RL:

المرتبط حالات و احتمالات اخواتها بحسب طبقات حظوظها خاصه بـ  $\pi$  function approximation.

کوچکا مقدارها بـ  $\pi$  احتمال مناسباً مناسب طبقات حظوظها خاصه بـ  $\pi$  function approximation.

لذا  $\pi$  "state-action" مخفف ترتيم در لامع من مقدارها (متغير ترتيمها) سے تابع مخفف رہے۔

لذا  $\pi$  "state-action" مخفف ترتيم در لامع من مقدارها (متغير ترتيمها) سے تابع مخفف رہے۔



جس کو مخفف کر کے پارامتریز کر کر خلاصہ کر دیں۔

Subject :

Year . Month . Date .

## Advantages of continuous policy parameterization.

- The action probabilities change smoothly as a function of the learned parameter, whereas in epsilon-greedy selection the action probabilities may change dramatically for an arbitrarily small change in the estimated action values.
- This is a good way of injecting prior knowledge about the desired form of the policy into reinforcement learning system.
- The policy can be parameterized in any way, as long as is differentiable with respect to its parameters.
- Offers useful ways of dealing with continuous action spaces.
- Although, the temperature or Epsilon could be reduced over time to approach determinism, but in practice it would be difficult to choose the reduction schedule, or even the initial temperature.

## Policy Gradient: policy Objective Function

- Goal: given policy  $\pi_{\theta}(s, a)$  with parameters  $\theta$ , find best  $\theta$ .
- But how do we measure the quality of a policy  $\pi_{\theta}$ ?

In episodic environments we can use the start value:  $J_1(\theta) = V^{\pi_{\theta}}(s_1) = E_{\pi_{\theta}}[r]$

In continuing environments we can use the average value:

$$J_{av}(\theta) = \sum_a d^{\pi_{\theta}}(s) \overline{V^{\pi_{\theta}}(s)}$$

Distribution of Markov chain for  $\pi_{\theta}$

Or the average reward per time-step.

$$J_{av}^R(\theta) = \sum_s d^{\pi_{\theta}}(s) \sum_a \pi_{\theta}(s, a) R_s^a$$

Status \_\_\_\_\_

Subject : \_\_\_\_\_

Year . Month . Date . \_\_\_\_\_

## policy Gradient : Score Function

The score function is  $\nabla_{\theta} \log \pi_{\theta}(s, a)$

$$\nabla_{\theta} \pi_{\theta}(s, a) = \pi_{\theta}(s, a) \frac{\nabla_{\theta} \pi_{\theta}(s, a)}{\pi_{\theta}(s, a)} = \pi_{\theta}(s, a) \nabla_{\theta} \log \{\pi_{\theta}(s, a)\}$$

We will use a softmax policy as a running example.

Weight actions using linear combination of features  $\phi(s, a)^T \theta$

Probability of action is proportional to exponentiated weights:

$$\pi_{\theta}(s, a) \propto e^{\phi(s, a)^T \theta}$$

The score function is:  $\nabla_{\theta} \log \pi_{\theta}(s, a) = \phi(s, a) - E_{\pi_{\theta}}[\phi(s, a)]$

## Compute the policy gradients.

Consider a simple class of one-step MDPs.

Starting in state  $s$  and  $a$   $\rightarrow$   $s'$   $\xrightarrow{\text{action } a}$   $s'$   $\xrightarrow{\text{reward } r}$

Terminating after one time-step with reward  $r = R_{s, a}$

$$\begin{aligned} J(\theta) &= E_{\pi_{\theta}}[r] \\ &= \sum_{s \in S} \sum_{a \in A} \pi_{\theta}(s, a) R_{s, a} \end{aligned}$$
$$\begin{aligned} \nabla_{\theta} J(\theta) &= \sum_{s \in S} \sum_{a \in A} \pi_{\theta}(s, a) \nabla_{\theta} \log \pi_{\theta}(s, a) R_{s, a} \\ &= E_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(s, a) r] \end{aligned}$$

## Policy Gradient Theorem:

The policy gradient theorem generalizes the approach to multi-step MDPs.

Replaces instantaneous reward  $r$  with long-term value  $Q^{\pi_{\theta}}(s, a)$ .

### Theorem:

For any differentiable policy  $\pi_{\theta}(s, a)$ , for any of the policy objective function  $J = J_r$ ,

$J_{av R}$ , or  $\frac{1}{1-\gamma} J_{av V}$ , the policy gradient is:

$$\nabla_{\theta} J(\theta) = E_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(s, a) Q^{\pi_{\theta}}(s, a)]$$

Status \_\_\_\_\_

Subject :

Year . Month . Date .

## Monte Carlo Policy Gradient

- Update parameters by stochastic gradient ascent
- Using policy gradient theorem
- Using return  $r_t$  as an unbiased sample of  $Q^{\pi_\theta}(s_t, a_t)$   
reward ↴  
$$\Delta \theta_t = \alpha \nabla_\theta \log \pi_\theta(s_t, a_t) r_t$$

function REINFORCE

Initialize  $\theta$  arbitrarily

for each episode  $\{s_1, a_1, r_2, \dots, s_{T-1}, a_{T-1}, r_T\} \sim \pi_\theta$  do

for  $t=1$  to  $T-1$  do

$$\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(s_t, a_t) r_t$$

end for

end for

return  $\theta$

end function

Monte-Carlo policy gradient still has high variance

We use a **critic** to estimate the action-value function,  $Q_w(s, a) \approx Q^{\pi_\theta}(s, a)$

Actor-critic algorithms maintain two sets of parameters

Critic Updates action-value function parameters  $w$

Actor Updates policy parameters  $\theta$ , in direction suggested by critic

Actor-critic algorithm follow an approximate policy gradient

$$\nabla_\theta J(\theta) \approx E_{\pi_\theta} [\nabla_\theta \log \pi_\theta(s, a) Q_w(s, a)]$$

$$\nabla_\theta = \alpha \nabla_\theta \log \pi_\theta(s, a) Q_w(s, a)$$

Action-Value Function approximation.

Approximate the action-value function  $\rightarrow \sum_{\pi_\theta} Q_\pi(s, a) : \hat{q}(s, a; w) \approx q_\pi(s, a)$

Minimise mean-squared error between approximate action-value fn  $\hat{q}(s, a; w)$  and true action-value fn  $q_\pi(s, a)$

$$J(w) = E_\pi [(q_\pi(s, a) - \hat{q}(s, a; w))^2]$$

Batus

Subject :

Year . Month . Date .

## Monte Carlo Policy Gradient

→ Update parameters by stochastic gradient ascent

→ Using policy gradient theorem

→ Using return  $\gamma_t$  as an unbiased sample of  $Q^{\pi_\theta}(s_t, a_t)$   
reward ✓

$$\Delta \theta_t = \alpha \nabla_\theta \log \pi_\theta(s_t, a_t) \gamma_t$$

### function REINFORCE

Initialize  $\theta$  arbitrarily

for each episode  $\{s_1, a_1, r_2, \dots, s_{T-1}, a_{T-1}, r_T\} \sim \pi_\theta$  do

for  $t=1$  to  $T-1$  do

$$\theta \leftarrow \theta + \alpha \nabla_\theta \log \pi_\theta(s_t, a_t) \gamma_t$$

end for

end for

return  $\theta$

end function

Monte-Carlo policy gradient still has high variance

We use a **critic** to estimate the action-value function,  $Q_w(s, a) \approx Q^{\pi_\theta}(s, a)$

Actor-critic algorithms maintain two sets of parameters

Critic Updates action-value function parameters  $w$

Actor Updates policy parameters  $\theta$ , in direction suggested by critic

Actor-critic algorithm follow an approximate policy gradient

$$\nabla_\theta J(\theta) \approx E_{\pi_\theta} [\nabla_\theta \log \pi_\theta(s, a) Q_w(s, a)]$$

$$\nabla_\theta = \alpha \nabla_\theta \log \pi_\theta(s, a) Q_w(s, a)$$

### Action-Value Function approximation

Approximate the action-value function  $\rightarrow \hat{q}_\pi \approx q_\pi : \hat{q}_\pi(s, a, w) \approx q_\pi(s, a)$

Minimise mean-squared error between approximate action-value fn  $\hat{q}_\pi(s, a, w)$  and true action-value fn  $q_\pi(s, a)$

$$J(w) = E_\pi [(q_\pi(s, a) - \hat{q}_\pi(s, a, w))^2]$$

Batus

Subject :

Year . Month . Date .

Use stochastic gradient descent to find a local minimum:

$$\frac{1}{2} \nabla_w J(w) = (q_{\pi}(s, a) - \hat{q}(s, a, w)) \nabla_w \hat{q}(s, a, w)$$

$$\Delta w = \alpha (q_{\pi}(s, a) - \hat{q}(s, a, w)) \nabla_w \hat{q}(s, a, w)$$

Like prediction, we must substitute a target to  $q_{\pi}(s, a)$ .

→ For MC, the target is the return  $G_t$ :

$$\nabla_w = \alpha (G_t - \hat{q}(s_t, a_t, w)) \nabla_w \hat{q}(s_t, a_t, w)$$

→ For TD(0), the target is the TD target  $R_{t+1} + \gamma Q(s_{t+1}, a_{t+1})$

$$\nabla_w = \alpha (R_{t+1} + \gamma \hat{q}(s_{t+1}, a_{t+1}, w) - \hat{q}(s_t, a_t, w)) \nabla_w \hat{q}(s_t, a_t, w)$$

### Actor-Critic Policy Gradient

→ Simple actor-critic algorithm based on action-value critic

→ Using linear value fn approx.  $Q_w(s, a) = \phi(s, a)^T w$

Critic Updates  $w$  by TD(0)

Actor Updates  $\theta$  by policy gradient

function QAC:

Initialise  $s, \theta, w$

Sample  $a \sim \pi_\theta$

for each step do

    Sample reward  $r = R_s^a$ ; Sample transition  $s' \sim p_s^a$

    Sample action  $a' \sim \pi_\theta(s', a')$

$$\delta = r + \gamma Q_w(s', a') - Q_w(s, a)$$

$$\theta = \theta + \alpha \nabla_\theta \log \pi_\theta(s, a) Q_w(s, a)$$

$$w \leftarrow w + \beta \delta \phi(s, a)$$

$$a \leftarrow a', s \leftarrow s'$$

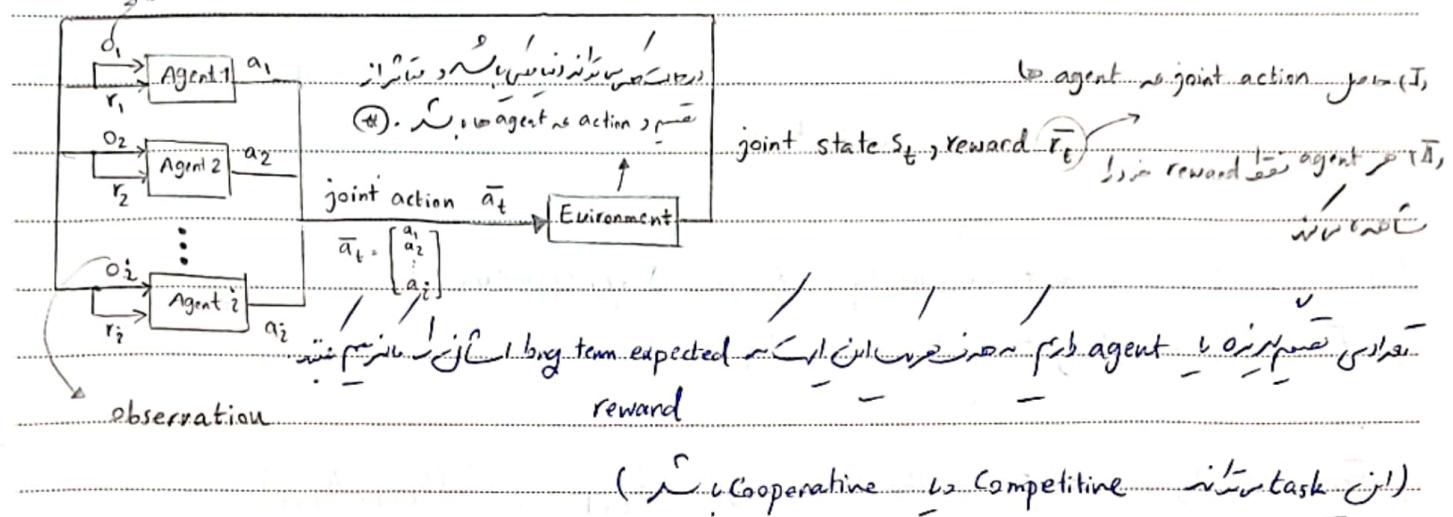
Bonus end for

end function

**Subject :**

Year .      Month .      Date .

# Multi-Agent Reinforcement Learning (S-S) - 1



## Multi-Agent MDP

ابن این مدل در میان مجموعه ای از این انتقالات می تواند یک انتقال را انتخاب کرده و این انتقال را در مقابل مدل معرفی کند.

Set of agents  $1, \dots, n$

$$(N, S, \vec{A}, \vec{R}, T)$$

Stochastic transition function, specifying

$$\vec{A} = A_1 \cup A_2 \cup \dots \cup A_n$$

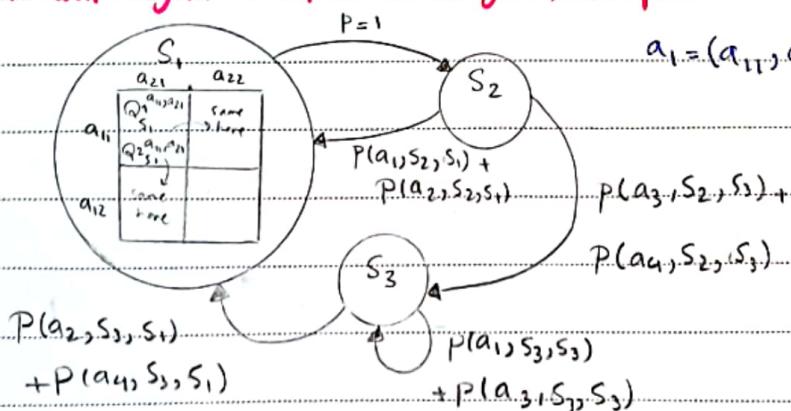
$$\vec{R} = R_1 \times R_2 \times \dots \times R_n$$

$A_i$ : set of actions of agent  $i$

$$j \circ \mu: S \times \tilde{A} \rightarrow R$$

immediate reward function of agent  $i$ :

## Multi-Agent MDP (Markov game) example:



Batus.

Subject :

Year . Month . Date .

## Learning in Multi-agent MDPs: The simplest way to extend MDPs to the multi-agent

- MDP is just to add a subscript to Q function of each agent:

$$\Delta Q_i(s, a_i) \leftarrow (1-\alpha)Q_i(s, a_i) + \alpha[R_i(s, \vec{a}) + \gamma V_i(s')]$$

$$\text{e.g. } Q \text{ learning update: } V_i(s) \leftarrow \max_{a_i \in A_i} Q_i(s, a_i)$$

- That is, to have the learning agent pretend that the environment is passive; ignores the fact that the Q value is a function of the actions selected by the other agents.

- Assuming each agent can observe the joint action of agents, the first idea is to simply

define the Q-values as a function of agents' joint action.

$$\Delta Q_i(s, \vec{a}) \leftarrow (1-\alpha)Q_i(s, \vec{a}) + \alpha[R_i(s, \vec{a}) + \gamma V_i(s')]$$

Question: How to evaluate  $V_i(s')$ ?

- An agent can use On-policy methods like SARSA to update  $V_i(s')$  based on real joint

actions in  $s'$ :

$$\Delta V_i(s') \leftarrow Q_i(s', \vec{a})$$

- However, for off-policy methods we need to have an estimate/expectation from the action of other agents.

- In any case, we need such estimation/expectation for action selection based on a policy (e.g. greedy)

Batus

Subject :

Year . Month . Date .

minimax Q-learning algorithm: For selfish agents, Littman suggests the minimax-Q learning algorithm, in which  $V$  is updated with the minimax of Q-values:

$$V_i(s) \leftarrow \max_{P_i \in \Pi(A_i)} \min_{a_2 \in A_2} \sum_{a_1 \in A_1} P_i(a_1) Q_i(s, (a_1, a_2))$$

Maximizes agent  $i$ 's reward given other agents' policies.

Minimizes agent  $i$ 's reward given other agents' policies.

$$\min_{a_1 \in A_1} \sum_{a_2 \in A_2} P_i(a_1) Q_i(s, (a_1, a_2))$$

The policy can be updated in the same way.

Belief-based algorithm: One alternative is to explicitly maintain a belief regarding the

likelihood of the other agents' policies, and update  $V$  based on the induced expectation of

the Q-values

$$V_i(s) \leftarrow \max \sum_{a_1} P_i(s, a_1) Q_i(s, (a_1, a_{-i}))$$

$a_{-i}$ : other agent's action  $\rightarrow$  pdf estimator  $\rightarrow$  Histogram, kernel density (frequency)

Friend-or-Foe (FOF) algorithm:

$$\text{Friend: } V_i(s) \leftarrow \max_{a_1 \in A_1} Q_i(s, (a_1, a_2))$$

$$a_2 \in A_2$$

$$\text{Foe: } V_i(s) \leftarrow \max_{P_i \in \Pi(A_i)} \min_{a_2 \in A_2} \sum_{a_1 \in A_1} P_i(a_1) Q_i(s, (a_1, a_2))$$

The idea is simply that i's friends are assumed to work together to maximise i's value

Batus

Subject :

Year . Month . Date .

while its foes are working together to minimize its value.

$$V_i(s) \leftarrow \max_{x \in \Pi(x_1, \dots, x_k)} \min_{y_1, \dots, y_k \in Y_1, x_1, \dots, x_k} \sum_{\pi_1, \dots, \pi_k \in X_1, \dots, X_k} \Pi(x_1, \dots, \Pi(x_k)) Q_i[s, x_1, \dots, x_k, y_1, \dots, y_k]$$

Fully Cooperative Tasks: → bring reward without competition

The agents have the same reward function and the learning goal is maximize

the common discount return. state joint action

$$Q_{k+1}(x_{k+1}, u_{k+1}) = Q_k(x_k, u_k) + \alpha [r_{k+1} + \gamma \max_{u_{k+1}} Q_k(x_{k+1}, u') - Q_k(x_k, u_k)]$$

reward  $\uparrow$   $u'$ , joint action

→ consider  $R$  w.r.t. joint action, to state  $x_{k+1}$  &  $r_{k+1}$  w.r.t. reward function  
(Curse of dimensionality.)

Greedy policy:  $\bar{h}_i^*(x) = \arg \max_{u_i, u_{i+1}, \dots, u_n} Q^*(x, u)$

→ It breaks ties randomly; different agents may break ties in different ways; Resulting joint action may be suboptimal.

	Agent 1	2, 2	3, 3
Agent 2	3, 3	2, 2	

The Distributed Q-learning algorithm: works in deterministic problems:

↓ no global reward function

$$Q_{i,k+1}(x_k, u_{i,k}) = \max \{ Q_{i,k}(x_k, u_{i,k}), r_{k+1} + \gamma \max_{u_i} Q_{i,k}(x_{k+1}, u_i) \}$$

↓ each agent has local Q-table and ignore other agents' reward

$$(u_{i,k})_{k=1}^{\infty} \text{ is fixed (action) } \rightarrow (x_k)_{k=1}^{\infty}$$

The local Q-values are updated only when the update leads to an increase in the Q-value

Status

Subject :

Year . Month . Date .

The local policy is updated only if the update leads to an improvement in the Q-values

$$T_{i,k+1}(x_k) = \begin{cases} u_{i,k} & \text{if } \max_{u_i} Q_{i,k+1}(x_k, u_i) > \max_{u_i} Q_{i,k}(x_k, u_i) \\ T_{i,k}(x_k) & \text{otherwise} \end{cases}$$

↑ Greedy update  
↓ Policy

↑ Greedy Policy

Under the conditions that the reward function is positive and  $Q_{i,0} = 0$   $\forall i$ , the local policies

of the agents probably converge to an optimal joint policy wrt global Q

↑ Greedy local Q-function of ↑ Optimal joint action  $a^*$  wrt  $Q_{i,k}$   
↓ Policy

↑ Greedy local Q-function of ↑ Optimal joint action  $a^*$  wrt  $Q_{i,k+1}$

### Indirect Coordination Methods:

Bias action selection toward actions that are likely to result in good rewards or returns

↑ Probability of reward  $r$  wrt  $a$  used for joint-action-selection

This steers the agents toward coordinated action selections

is the overreward of more coordinated action selection → Cooperative individual Bias  $\rightarrow$  models

The likelihood of good values is evaluated using, e.g., method of the other agents' estimated

→ inferring strategy of action

by the learner, or action statistics of the values observed in the past.

### (I) Joint Action Learns (JAL) (static tasks)

↑  $Q_i(s)$  (over certain state  $s$ )

$$(I) \quad Q_i(u_i, u_{-i}) = (1-\gamma)Q_i(u_i, u_{-i}) + \gamma r(u_i, u_{-i})$$

Action of agent  $i$

Employ empirical models of the other agents' strategies: Joint based

Status

Subject :

Year . Month . Date .

agent  $j$  as action ; agent  $i$   $\hat{Q}_j^i(u_j) = \frac{C_j^i(u_j)}{\sum_{\tilde{u}_{j \neq i}} C_j^i(\tilde{u}_{j \neq i})}$  # times agent  $i$  observed

agent  $j$  taking action  $u_j$

total # of agent  $j$  taking action  $u_j$

$$\tilde{Q}_i(u_i) = \sum_{u_{-i}} Q_i(u_i, u_{-i}) \prod_{j \neq i} \frac{\hat{Q}_j^i(u_j)}{\sum_{\tilde{u}_{j \neq i}} \hat{Q}_j^i(\tilde{u}_{j \neq i})} \quad \text{action } (i \in \mathcal{A})$$
$$\tilde{Q}_i(u_i) = (1-\gamma)\tilde{Q}_i(u_i) + \gamma r(u_i) \quad (\text{II})$$

$$C_i(u_i) \in \{0, 1\} \quad \tilde{Q}_i(u_i) = \sum_i (\text{I}) \quad \text{or} \quad (\text{II})$$

### (II), Frequency Maximum Q-value (FMQ) (static tasks)

agent  $i$  takes action  $u_i$  ;  $\tilde{Q}_i(u_i) = (1-\gamma)\tilde{Q}_i(u_i) + \gamma r(u_i, u_{-i})$

variable frequency counts

$$\tilde{Q}_i(u_i) = \tilde{Q}_i(u_i) + \nu \frac{C_{\max}^i(u_i)}{C_i(u_i)} r_{\max}(u_i)$$

$r_{\max}(u_i)$  is the maximum reward observed after taking action  $u_i$ ,

$C_{\max}^i(u_i)$  counts how many times this reward has been observed.

works for deterministic tasks, where variance in the rewards resulting from the agent's actions can only be the result of the other agent's actions