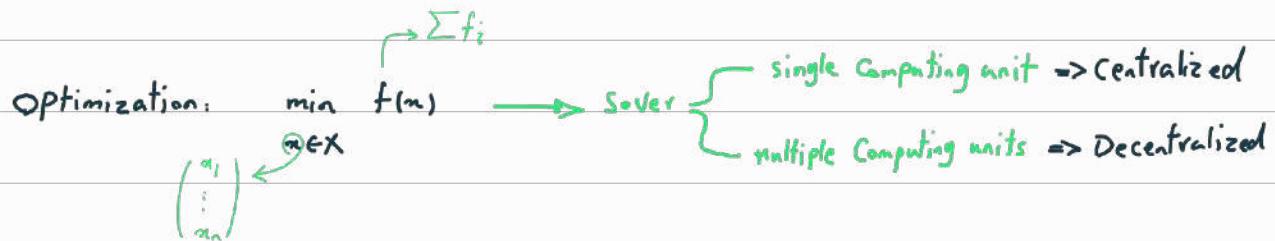


Distributed Optimization and Learning

3/1/2023

Topics

* Classification of optimization problems



Computational مُقدّمات 1 : Decentralized (الجزء الأول)

Parallel محاسبات

\leftarrow عدد بین زال و محاسبات

\leftarrow محاسباتی مادہ دیسیئری محاسباتی

بنگت نہ بُلے ها local ، جواب هاکی local است چاہیے

دل ہے زیل جواب global و نہ همیں

Structural مُقدّمات 2

\leftarrow مُختیّرین ناہ ہاد نابغ تفہ

\leftarrow تابع ایسا طور پر بنی نابغ تفہ

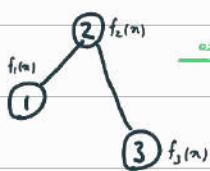
$$\min_{\mathbf{x}_1, \mathbf{x}_2} f_1(\mathbf{x}_1) + f_2(\mathbf{x}_2) \longrightarrow \text{Trivially Decomposable}$$

where $\mathbf{x}_1 \in \mathbb{R}^{n_1}$, $\mathbf{x}_2 \in \mathbb{R}^{n_2}$

$$\min_{\mathbf{x}_1, \mathbf{x}_2, \mathbf{y}} f_1(\mathbf{x}_1, \mathbf{y}) + f_2(\mathbf{x}_2, \mathbf{y}) \longrightarrow \text{Complicating Variable}$$

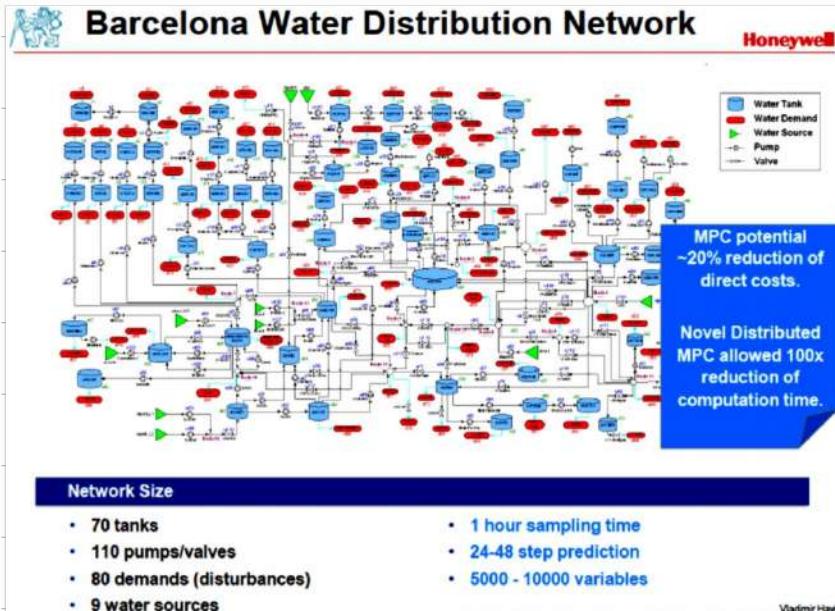
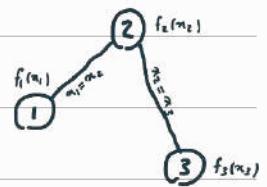
where $\mathbf{x}_1 \in \mathbb{R}^{n_1}$, $\mathbf{x}_2 \in \mathbb{R}^{n_2}$, $\mathbf{y} \in \mathbb{R}^{n_3}$

$$\min_x f_1(x) + f_2(x) + f_3(x)$$



$$\min_{x_1, x_2, x_3} f_1(x_1) + f_2(x_2) + f_3(x_3)$$

$$\text{s.t. } x_1 = x_2 \text{ and } x_2 = x_3$$



تکمیل سازی شبکه آب شهر بردا:

* مثل های از یارگیر کارمزین شده

Markov Random Fields

ترانسیستور به هر Node یک تغیر تعدادی را دارد شده
تغیر تعدادی هر Node مرتبط باشید است به هر دیگری های همایه دنبت به سایر Node ها متعلّم است

کاربرد مارکوف میدی ندیم : Image Denoising ←

پوشش های آندرین میدی ندیم + تاریخی سلتیون دیشن = آنچه هفت
→ \min_u smoothness

QFDMA Resource - Allocation

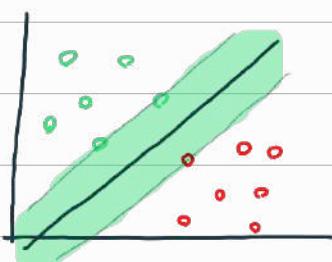
تخصیص باند در متغیرهای فاسیلی

مجموع Rate هر کاربر : تابع هدف \rightarrow شدن می باشد

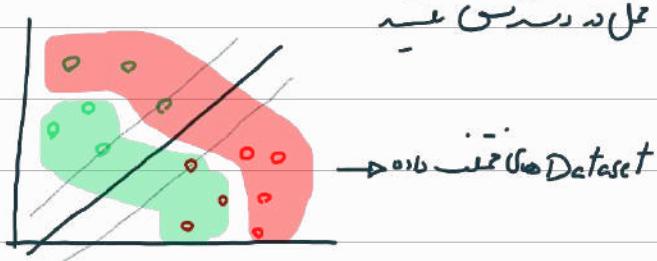
↓
متغیر \rightarrow از مرکز کاربری توان استفاده کنند
هر کاربر از صد٪ بینه باشد \rightarrow
توان ارسالی محدود است \rightarrow

تغییرهای تغییری : Rate انتقال داده و توان ارسالی

Support Vector Machine



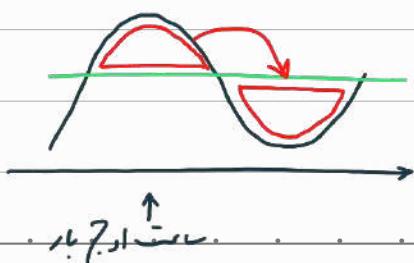
جی خاصیم خط جداگانه را پیدا نمی کنیم
بینه Margin داشته باشیم



نمودار : هر یاده های یک عمل دستی نیست

\rightarrow چند داده Dataset

Demand Side management in smart grids



نیت دهنده به مسافت آنرا نزدیک چوبار \rightarrow
در سمت های مختلف تغییر نزد

ساعت اوج بار

هزینه تولید + مجموع رفایت کاربران دفعه سایت : نابغه صرف

s.t. $\text{تولید} \rightarrow \text{مجموع صرف} \rightarrow \text{نابغه}$

Opinion Dynamics in Social Networks

$$\alpha_i(t+1) = \frac{1}{d_i+k_i} \sum_{j \in \text{edi}} \alpha_j(t) + \frac{k_i}{d_i+k_i} \alpha_i(t)$$

کلی از الگوریتم های اجماع است

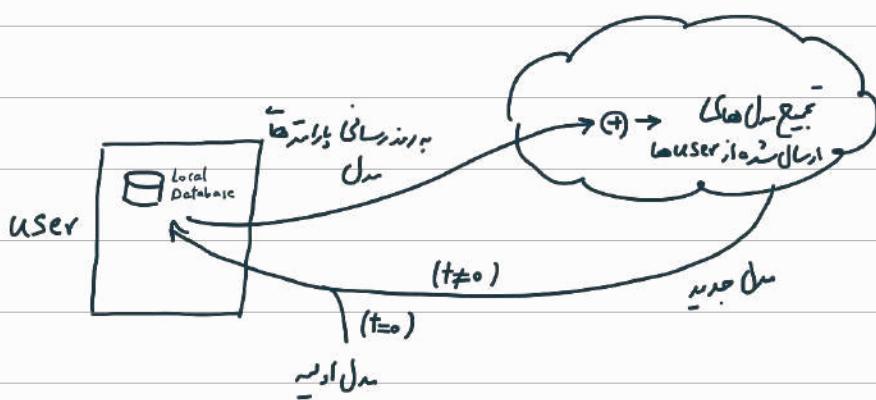
α_i (t+1) \downarrow opinion
 \downarrow stubbornness \downarrow مجموع افرادیان

میزان میزان نظرات به ست نظرات هرچندی شر

لهم بانسل این Agent ها حق توان کن
 کننده دانسل کرد!

Distributed Deep Learning / Federated Learning

دانه های توزیع شده هست \rightarrow داده های لذتی ها هست \rightarrow
 دانه های با سوچ ها ترتیب چی شوند داده بانه ای برداشته \leftarrow
 Crowd Sourcing \leftarrow



(optimization) (Silvia)

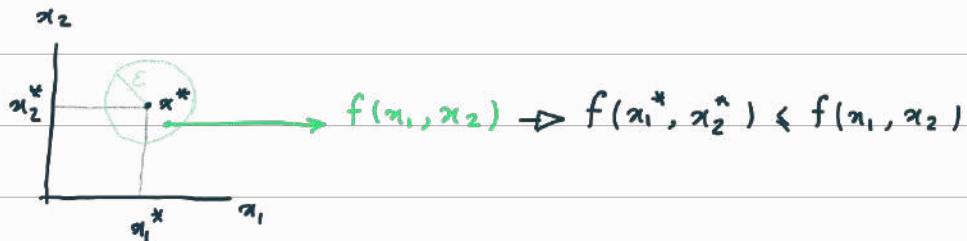
تعریف سلسی*

$$f: \mathbb{R}^n \rightarrow \mathbb{R} \quad \leftarrow \text{هندسه ریاضیات}$$

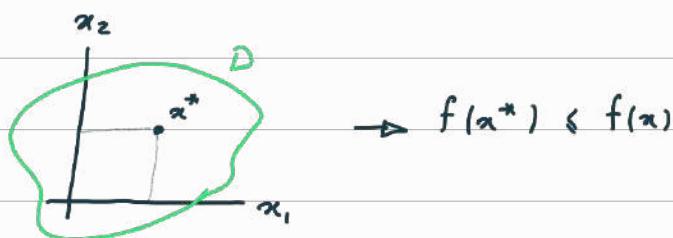
Feasible: $D \subseteq \mathbb{R}^n$, $x^* \in D$

x^* را بجزی معین D باشد که $f(x^*)$ کمترین مقدار (local min):

$$\exists \epsilon > 0 : \forall x \in D \text{ with } \|x - x^*\| < \epsilon : f(x^*) \leq f(x)$$



آنکه x^* مقدار کمینه محلی (Global min) برای f در D باشد.



آنکه x^* مقدار کمینه محلی (Strict local min) برای f باشد. دو هریک از دو حالت آنکه $f(x^*) < f(x)$ خواهد بود.

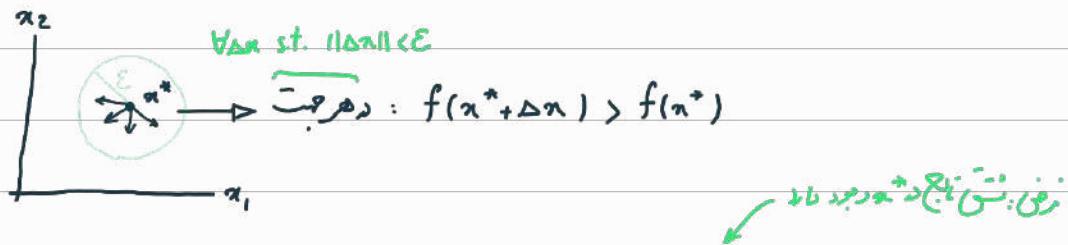
بنابراین f کمینه محلی است.



شُرُطِيَّاتِي

$$\text{لما } f(\mathbf{x}^* + \Delta \mathbf{x}) = f(\mathbf{x}^*) + \left(\frac{\partial f}{\partial \mathbf{x}} \Big|_{\mathbf{x}=\mathbf{x}^*} \right)^T \Delta \mathbf{x} + \frac{1}{2} \Delta \mathbf{x}^T \left(\frac{\partial^2 f}{\partial \mathbf{x}^2} \Big|_{\mathbf{x}=\mathbf{x}^*} \right) \Delta \mathbf{x} + \text{HOT}$$

جی فرضیه برای کمینه‌ی ترجیحی ایجاد کنیم: \mathbf{x}^* (کمینه‌ی ترجیحی) بسط نهادنی را بهتر می‌داند



$$\rightarrow \Delta \mathbf{x}: \Delta \mathbf{x} = -\eta \left(\frac{\partial f}{\partial \mathbf{x}} \Big|_{\mathbf{x}=\mathbf{x}^*} \right) \quad 0 < \eta \ll 1$$

|| $\Delta \mathbf{x}$ || تپی

$$\Rightarrow f(\mathbf{x}^* + \Delta \mathbf{x}) = f(\mathbf{x}^*) - \eta \left(\frac{\partial f}{\partial \mathbf{x}} \Big|_{\mathbf{x}=\mathbf{x}^*} \right)^T \left(\frac{\partial f}{\partial \mathbf{x}} \Big|_{\mathbf{x}=\mathbf{x}^*} \right) + O(\eta)$$

$$\begin{aligned} &\text{اجمل ماتل}^2 \text{ در } \\ &\lim_{\eta \rightarrow 0} \frac{O(\eta)}{\eta} = 0 \end{aligned}$$

که عبارت مرتب بالاتر در تابع بقیه عبارات دستی ایجاد می‌شود تقریباً

$$\mathbf{y}^T \mathbf{y} = [y_1 \dots y_n] \begin{pmatrix} y_1 \\ \vdots \\ y_n \end{pmatrix} = y_1^2 + \dots + y_n^2 = \|\mathbf{y}\|^2$$

$$\Rightarrow f(\mathbf{x}^* + \Delta \mathbf{x}) = f(\mathbf{x}^*) - \eta \left\| \frac{\partial f}{\partial \mathbf{x}} \Big|_{\mathbf{x}=\mathbf{x}^*} \right\|^2 + O(\eta)$$

$$\exists \varepsilon > 0: \eta < \varepsilon \rightarrow -\eta \left\| \frac{\partial f}{\partial \mathbf{x}} \Big|_{\mathbf{x}=\mathbf{x}^*} \right\|^2 + O(\eta) < 0 \Rightarrow f(\mathbf{x}^* + \Delta \mathbf{x}) < f(\mathbf{x}^*)$$

$\Delta x = 0 \Leftrightarrow$ مکمل نشانه تابع تعریف نیست

شرط لازم مرتبه اول برای لینگی

$$\frac{\partial f}{\partial x} \Big|_{x=x^*} = 0$$

\Leftrightarrow آنچه x^* یک کریمه علی برای f بشد داشته باشد f در x^* نزیر است. آنها :

→ تعریف

به طور متسابقی توان اثان دار که این شرط برای نقطه بینیه و زینی (Saddle) نیز برقرار است

↓
بر عقیقی راستهای کنید
عقیقی راستهای بینیه

$$\Rightarrow f(x^* + \Delta x) = f(x^*) + 0 + \frac{1}{2} \Delta x^T \frac{\partial^2 f(x^*)}{\partial x^2} \Delta x + O(\|\Delta x\|^2)$$

$$H(x^*) < 0 \Rightarrow \exists \varepsilon : \|\Delta x\| < \varepsilon : \frac{1}{2} \Delta x^T H(x^*) \Delta x + O(\|\Delta x\|^2) < 0 \Rightarrow f(x^* + \Delta x) < f(x^*)$$

↑
ND

$$\rightarrow \text{شرط لازم مرتبه دوم برای لینگی} : \frac{\partial^2 f}{\partial x^2} \Big|_{x=x^*} = H(x^*) > 0$$

↑
PSD

آنچه $H(x^*)$ غیر عقیقی باشد باز هم به
تاریخی سر جواه در آن حالت به
آنکه بخشی راستهای Δx داشته باشند
تفصیل خواهد بود

چون داین حالت $H \neq 0$ ، عبارت اول - عبارت دوم

نمایه گذشت

شرط کافی مرتبه دوم : $\frac{\partial^2 f}{\partial x^2} \Big|_{x=x^*} = H(x^*) > 0$

↑
PSD

$$f(x^* + \Delta x) - f(x^*) = \underbrace{\frac{1}{2} \Delta x^T H(x^*) \Delta x}_{> 0} + O(\|\Delta x\|^2) > 0 \Rightarrow f(x^*) < f(x^* + \Delta x) \rightarrow \text{Local min}$$

$\exists \varepsilon : \|\Delta x\| < \varepsilon$

شرط کافی برای f - شرایط بینیه را به دست می رده.

بردار سرتی



$$f(\alpha^* + \Delta\alpha) = f(\alpha^*) + \nabla f(\alpha^*) \Delta\alpha + \Delta\alpha^T H(\alpha^*) \Delta\alpha + \text{HOT}$$

$$\alpha^* \rightarrow \text{کنتم} \Rightarrow \nabla f(\alpha^*) = 0 \Rightarrow f(\alpha^* + \Delta\alpha) = f(\alpha^*) + \Delta\alpha^T H(\alpha^*) \Delta\alpha + \text{HOT}$$

$$H(\alpha^*) > 0 \rightarrow \text{eig}(H(\alpha^*)) > 0$$

$\Delta\alpha$ را به صفت تریب فلی بردار درجه های سلسه H می نویسیم
: فرضی بردار درجه های سلسه H

$$\left(\sum_{i=1}^n \alpha_i v_i \right)^T H(\alpha^*) \left(\sum_{i=1}^n \alpha_i v_i \right) = \left(\sum_{i=1}^n \alpha_i v_i \right)^T \left(\sum_{i=1}^n \alpha_i \lambda_i v_i \right) = \sum_{i=1}^n \alpha_i^2 \lambda_i \|v_i\|^2 > 0$$

$Hv_i = \lambda_i v_i \quad v_i^T v_j = 0 \quad i \neq j$

$\Delta\alpha$ را با استفاده از این اثبات می خواهیم

دجرد سازی داشته باشی $\Delta\alpha^T H \Delta\alpha$ \rightarrow بسته به اندازه تغییر $\Delta\alpha$ در v_i های سطحی، λ_i های سطحی را داشتیم \rightarrow دجرد سازی داشته باشی $\Delta\alpha^T H \Delta\alpha$ \rightarrow دجرد سازی داشته باشی $\Delta\alpha$

دجرد سازی داشته باشی $\Delta\alpha$ \rightarrow $\lambda_i = 0 \Rightarrow \alpha_i \neq 0, \alpha_j = 0, j \neq i$ \rightarrow $\Delta\alpha^T H \Delta\alpha = 0$ \rightarrow $\Delta\alpha = \text{Min}_{\Delta\alpha} L$ \rightarrow $\Delta\alpha = \text{HOT}$

Example

نمایه ایت دفعه آن را بگیری و بحذف آن دست

$$f(\alpha) = \alpha_1^2 + \alpha_2^2 + 3\alpha_1\alpha_2 + 2\alpha_2 - \alpha_1 + 3$$

$$\frac{\partial f}{\partial \alpha} = \begin{pmatrix} 2\alpha_1 + 3\alpha_2 - 1 \\ 2\alpha_2 + 3\alpha_1 + 2 \end{pmatrix} = 0 \Rightarrow \alpha^* = \begin{pmatrix} -\frac{2}{5} \\ \frac{7}{5} \end{pmatrix}$$

$$H(x) = \frac{\partial^2 f}{\partial x^2} = \begin{pmatrix} 2 & 3 \\ 3 & 2 \end{pmatrix} \quad \text{eig}(H) : \det(\lambda I - H) = 0$$

$$\Rightarrow (\lambda - 2)^2 - 9 = 0 \Rightarrow \lambda - 2 = \pm 3 \Rightarrow \begin{cases} \lambda = 5 \\ \lambda = -1 \end{cases} \Rightarrow \text{یک سطح زنی است} \xrightarrow{\text{مکانیزم}} x^*$$

End example

$$f(x) = x^T A x + b^T x + c$$

$$\Rightarrow \frac{\partial f}{\partial x} = (A + A^T)x + b = 0 \quad \leftarrow \text{خط لامبرت} \xrightarrow{\text{لطف لامبرت}} x = -(A + A^T)^{-1}b$$

$$\Rightarrow \frac{\partial^2 f}{\partial x^2} = A + A^T$$

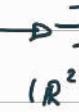
PD: 
 ND: 
 غير معرف: 

End example

$$f(x) = \frac{1}{2} x_2^2 + x_1 + x_2 = x^T \begin{pmatrix} 0 & 0 \\ 0 & \frac{1}{2} \end{pmatrix} x + (1, 1)^T x, \quad x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

$$\Rightarrow A + A^T = \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} \rightarrow \lambda = 0 \quad \lambda = 1$$

$$\frac{\partial f}{\partial x} = 0 \Rightarrow \begin{pmatrix} 0 & 0 \\ 0 & 1 \end{pmatrix} x + (1, 1)^T = 0 \Rightarrow \begin{pmatrix} 1 \\ x_2+1 \end{pmatrix} = 0 \Rightarrow \begin{cases} 1 = 0 \\ x_2 + 1 = 0 \end{cases} \rightarrow$$

شرط لامبرت برداریت 
 (علیغ اتفاق نمیزد R^2)

این رابطه مارک نهاد 

End example

$$f(x) = \frac{1}{2} x_1^2 + \frac{1}{2} x_2^2 + x_1 x_2 + x_1 + x_2$$

$$= \alpha^T \begin{bmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{bmatrix} \alpha + (1-1)\alpha, \quad \alpha = \begin{pmatrix} \alpha_1 \\ \alpha_2 \end{pmatrix}$$

$$A + A^T = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \rightarrow (\lambda - 1)^2 - 1 = 0 \Rightarrow \lambda - 1 = \pm 1 \Rightarrow \begin{cases} \lambda = 0 \\ \lambda = 2 \end{cases} \rightarrow \text{PSD}$$

$$\frac{\partial f}{\partial \alpha} = 0 \Rightarrow \begin{pmatrix} \alpha_1 + \alpha_2 + 1 \\ \alpha_2 + \alpha_1 + 1 \end{pmatrix} = 0 \Rightarrow \alpha_1 + \alpha_2 + 1 = 0 \quad \checkmark$$

شرط لازم برتبه اول در تابع دلخواه است و شرط کافی برقرار نیست

$$f(\alpha) = \frac{1}{2} (\alpha_1 + \alpha_2 + 1)^2 \geq 0, \quad \text{شرط لازم: } \alpha_1 + \alpha_2 + 1 = 0 \Rightarrow \min f$$

$$f = 0 \text{ میانگین } \alpha_1 + \alpha_2 + 1 = 0, \quad \min f$$

تراجی (Convex, Concave)

تعریف: تابع f بر مجموعه محض Ω محب ناسیه می‌شود اگر به ازای هر $\alpha_1, \alpha_2 \in \Omega$ و $\alpha \in [0, 1]$ داشته باشد:

$$f(\alpha \alpha_1 + (1-\alpha) \alpha_2) \leq \alpha f(\alpha_1) + (1-\alpha) f(\alpha_2)$$

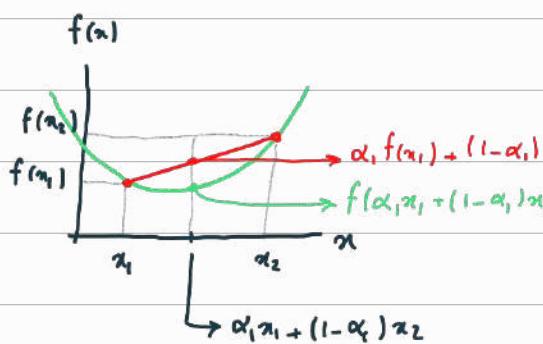
برای این شرط داخل
هر دو نقطه وجود را داشته باشد

Ω : مجموعه محض $\Omega \ni \alpha_1, \alpha_2 \in \Omega \Rightarrow \alpha \alpha_1 + (1-\alpha) \alpha_2 \in \Omega$

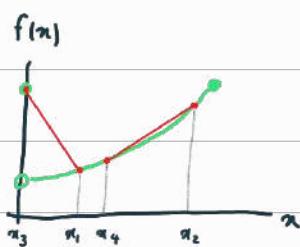
$$f(\alpha \alpha_1 + (1-\alpha) \alpha_2) < \alpha f(\alpha_1) + (1-\alpha) f(\alpha_2) \quad \text{به ازای } \alpha \in (0, 1), \quad \alpha_1 \neq \alpha_2$$

شرط داخل

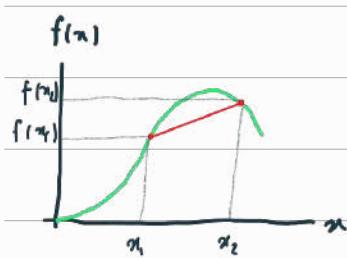
آنچه این محب ناسیه شود



مأْلَعُوكَ اللَّهُ :



آنچه قدر بناستی:



: (Non Convex) مُعَلِّجٌ عَنْ مُحَاجَةٍ

→ هر کجا عجب بدن یک نایع، فقط ماضی سین هر دسته باید بلاتر از سخنی قرار نماید

تعريف: آنچه f را مجذبه مدبب یا سور (Concave) است اگر و $y = f(x)$

تعريف: تابع f بـ معرفهٔ خوب (Strictly Concave) است اگر $y = -f(x)$ معرفهٔ خوب باشد.

نواص تابع محب و f_1, \dots, f_n اگر $\sum_{i=1}^n a_i f_i$ همیشه بزرگ باشد، $a_i > 0$ $i = 1, \dots, n$: Convex

$$\text{مُعِذَّب} f_1 \Rightarrow f_1(\alpha x_1 + (1-\alpha) x_2) < \alpha f_1(x_1) + (1-\alpha) f_1(x_2) \quad x_1, x_2$$

$$f_0(x_1) \geq f_0(\alpha x_1 + (1-\alpha)x_2) \leq \alpha f_0(x_1) + (1-\alpha)f_0(x_2) \quad \forall \alpha \in [0,1]$$

$$\textcircled{+} \Rightarrow \sum_i a_i f_i(\alpha x_1 + (1-\alpha)x_2) \leq \alpha \sum_i a_i f_i(x_1) + (1-\alpha) \sum_i a_i f_i(x_2) \quad \checkmark$$

ابنطیجی تابع

2 اگر f تابعی محدب بر مجموعه محدب Ω باشد آنگاه $\Gamma_C = \{x : x \in \Omega, f(x) \leq c\}$ همچویه محدب است

$$x_1 \in \Gamma_C \Rightarrow f(x_1) \leq c$$

ابتدا:

$$x_2 \in \Gamma_C \Rightarrow f(x_2) \leq c$$

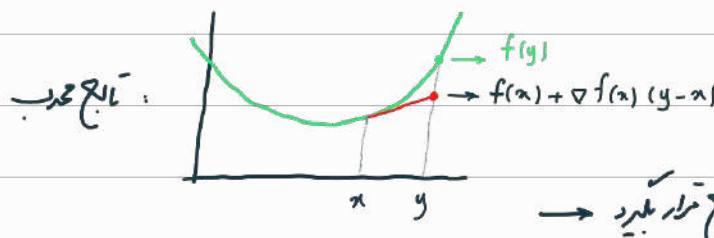
$$\alpha f(x_1) + (1-\alpha) f(x_2) \leq c$$

$$\Rightarrow f(\alpha x_1 + (1-\alpha) x_2) \leq \alpha f(x_1) + (1-\alpha) f(x_2) \leq c$$

$$\Rightarrow \alpha x_1 + (1-\alpha) x_2 \in \Gamma_C \quad \checkmark$$

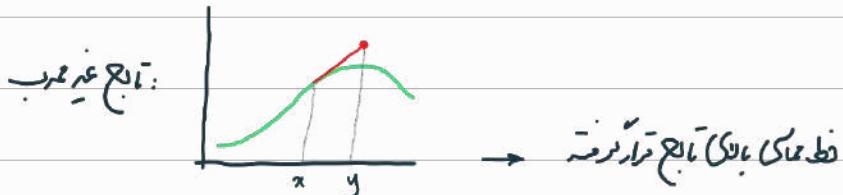
تشکیل

3 اگر $f \in C^1$ و f بر Ω حوب است اگر دسته اگر $\nabla f(x)$ بر Ω حوب است آنگاه $f \in \Gamma_C$ (حوب کنید)



ابتدا:

ابتدا را فیلم کنید



این تابع عیوب است.



این تابع شیخ نزدیک است.

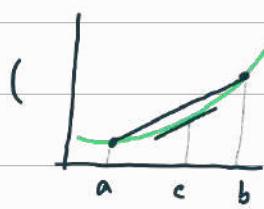
4 اگر $f \in C^2$ و f تابعی محدب بر مجموعه محدب Ω باشد آنگاه ماتریس صیغه f نیز مینهیست
برهان است (در عکس) ← سطر لازم را کافی

ابتدا: بر اساس تعریف تابع - تعریف مقدار میانگین مترقب درم:

$$f(y) = f(x) + \nabla f(x)(y-x) + \frac{1}{2}(y-x)^T H_f(x+\alpha(y-x))(y-x)$$

$$y = x + (y-x) = x + \Delta x$$

\uparrow
 $\exists 0 < \alpha < 1$ ← ماتریس میانگین بده
برهان است



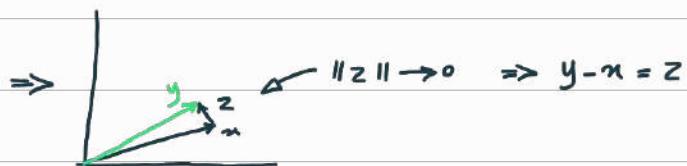
(یاددا ریکا تفہی مقدار یا میں مرتب اول): $f'(c) = \frac{f(b) - f(a)}{b - a}$

$$H_f > 0 \Rightarrow (y-x)^T H_f (x + \alpha(y-x)) (y-x) > 0 \quad \text{اثبات رہت:}$$

$$\stackrel{\text{خط اصلی}}{\Rightarrow} f(y) > f(x) + \nabla f(x) (y-x) \Rightarrow \text{محب} \leftarrow f$$

$$H_f > 0 \Rightarrow \exists z, \alpha: z^T H_f (x) z < 0 \quad \text{اثبات برہت:}$$

$$\rightarrow (y-x) : \begin{cases} \text{در اسے ز بند} \\ \text{با نازدیکی کر جوک باشد} \end{cases} \rightarrow x + \alpha(y-x) \approx x$$



$$z^T H_f (x) z < 0 \stackrel{\text{سوچنی ہریں}}{\Rightarrow} z^T H_f (x + \varepsilon) z < 0, \|\varepsilon\| \rightarrow 0$$

$$\stackrel{\|z\| \rightarrow 0}{\Rightarrow} \frac{1}{2} z^T H_f (x + \alpha z) z < 0 \Rightarrow f(y) < f(x) + \nabla f(x) (y-x)$$

اگر ہریں ہیں معنی بنت بند (H_f) تب محب اکیدت $\Rightarrow H_f > 0$
وابہ برہت برقراریت

5 اگر تابع f رجوعی محب ہو محب بند، آنکہ ہر لینہ ملی (local) یا کہہ فلکی (global) است

فرمیا
 $f(x^*) \leq f(x) \forall x \in \Omega \Rightarrow \exists y \in \Omega : f(y) < f(x^*)$

(غیر فلکی)

اثبات:

/ /

$$\alpha f(x^*) + (1-\alpha) f(x^*) = f(x^*)$$

$$\Rightarrow f(\alpha y + (1-\alpha)x^*) \leq \alpha f(y) + (1-\alpha) f(x^*) < f(x^*) , \quad 0 < \alpha < 1$$

$\alpha \rightarrow 0 \Rightarrow \text{نکته می‌شود } \alpha y + (1-\alpha)x^*$

$\hookrightarrow f(\alpha y + (1-\alpha)x^*) < f(x^*) \Rightarrow \text{حقیقتی می‌شود}$

مجموعه شاطئ تابع f بر مجموعه محض S محض است 6

$$x, y \in S \Rightarrow \alpha x + (1-\alpha)y \in S \quad \begin{matrix} \text{محض} \\ \text{محض} \end{matrix} \quad \text{هر کدام } f \text{ محض است}$$

$$\Rightarrow f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha) f(y) = f(x) = f(y)$$

می‌توانیم $f(\dots) < f(x) = f(y)$ نباشد برای اینکه $f(\dots)$ می‌تواند برابر باشد

کنیت

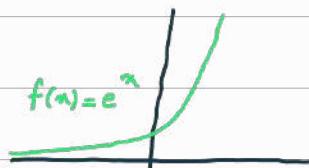
$$\Rightarrow \alpha x + (1-\alpha)y \in S \quad \checkmark$$

تابع محض است اگر و تنها آن که دارای پیمانست 7

$x, y \in S \Rightarrow \alpha x + (1-\alpha)y \in S$ دارای پیمانست

$$\Rightarrow f(x) = f(\alpha x + (1-\alpha)y) \leq \alpha f(x) + (1-\alpha) f(y) = f(x) \quad \times$$

تابع محض است اگر و تنها آن که دارای پیمانست $H_f = e^x > 0$



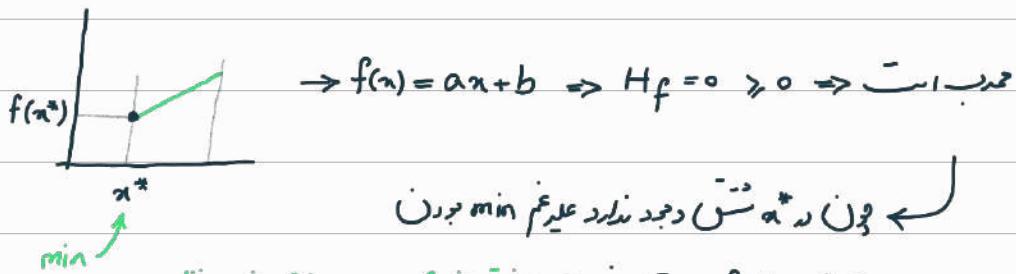
8) مرضیه نایاب محدب و متقارن f را محبوعه محدب و مرحد است. شرط لازم رکافی برای این که $\nabla f(x^*) = 0$ باشد این است که: $\nabla f(x^*) = 0$ باشد این است که: دو قطبی بسیار منیکی برای این سازی است

ابتدا: شرط لازم برای بینگی ملائمه شده است

شرط کافی بردن:

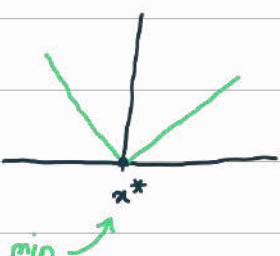
$$\forall y \in \mathbb{R} \quad f(y) \geq f(x) + \nabla f(x)(y-x)$$

$$\nabla f(x^*) = 0 \Rightarrow f(y) \geq f(x^*) \checkmark$$



$$f(y) \geq f(x^*) + \nabla f(x^*)(y - x^*) \xrightarrow{\substack{f(y) \geq f(x^*) \\ a > 0}} \nabla f(x^*)(y - x^*) \geq 0 \rightarrow$$

باکتسنست که $\nabla f(x^*)$ برقرار است



شرط Convex
نیز برقرار است

$$\begin{cases} y > x^* \Rightarrow \nabla f(x^*) > 0 \Rightarrow \nabla f(x^*)(y - x^*) > 0 \\ y < x^* \Rightarrow \nabla f(x^*) < 0 \Rightarrow \nabla f(x^*)(y - x^*) > 0 \end{cases}$$



د. تابع Convex، یعنی حی تماسنده سطح زیر سطح غیرمتقارن نیز برشد

Example

تابع مربعی:

$$f(x) = \frac{1}{2} x^T P x + q^T x + r$$

$P = P^T$ \leftarrow متغیر مداران P همیشگی شود

$$\Rightarrow \nabla f^T = \frac{1}{2} (P + P^T)x + q = Px + q = 0 \Rightarrow Px = -q$$

$$\nabla^2 f = H = P$$

$$\Rightarrow \begin{cases} P \succ 0 & \Rightarrow \text{حذب است} \Rightarrow \text{Full Rank}, P \Rightarrow \text{جواب ندارد} \\ P \succ 0 & \Rightarrow \text{حذب الگی است} \Rightarrow x^* = -P^{-1}q \end{cases}$$

Counterexample

$$f(x) = x^4$$



$$\Rightarrow f'(x) = 4x^3 \Rightarrow f''(x) = 12x^2 \Rightarrow f''(0) = 0 \Rightarrow H_f \geq 0$$

→ دو این نشان می‌کنند که ازین همین نهی معنی نیست است تابع f حذب الگی است.

$$\Rightarrow \begin{cases} H_f > 0 & \Rightarrow \text{حذب الگی} \\ H_f > 0 & \Rightarrow \text{حذب الگی} \end{cases}$$

Endre Example

$$f(x, y) = \frac{x^2}{y} \quad y > 0$$

$$\nabla^T f(x, y) = \begin{pmatrix} \frac{2x}{y} \\ -\frac{x^2}{y^2} \end{pmatrix} \Rightarrow \nabla^2 f(x, y) = \begin{pmatrix} \frac{2}{y} & \frac{-2x}{y^2} \\ -\frac{2x}{y^2} & \frac{2x^2}{y^3} \end{pmatrix} = H(x, y) = \frac{2}{y^3} \begin{pmatrix} y & -xy \\ -xy & x^2 \end{pmatrix}$$

$y > 0 \Rightarrow \frac{2}{y^3} > 0, \quad y^2 > 0, \quad \det(H) = x^2 y^2 - x^2 y^2 = 0 \Rightarrow H \geq 0 \rightarrow$ محدب (PSD)

$$\nabla^T f(x, y) = \begin{pmatrix} \frac{2x}{y} \\ -\frac{x^2}{y^2} \end{pmatrix} = 0 \Rightarrow x=0, \quad y>0 \rightarrow$$

نقطهٔ بُعدی تابع $f(x, y)$ می‌باشد

* الگوریتم‌های بینه‌سازی

بردست آمدن حل بُتے مبای سُد بینه‌سازی همیه ممکن نیست \Leftrightarrow از الگوریتم‌های iterative استفاده می‌شود

$$\min_x f(x) \rightarrow x_0 \rightarrow x_1 \rightarrow x_2 \rightarrow \dots \rightarrow x^* = \operatorname{Argmin}_x f(x)$$

* هدف رسیدن به نقطهٔ بُعدی تابع f به حریت تکریی است

: (Steepest Descent / SD)

← از ترتیب مرتب اول بخط تیرا استفاده می‌شود

$$f(x + \Delta x) = f(x) + f_x^T \Delta x + \frac{1}{2} \Delta x^T H(x) \Delta x + \text{HOT}$$

ترتیب مرتب اول

$$\rightarrow \text{funktsjoner: } f(x_k + \Delta x_k) \approx f(x_k) + f'_n(x_k) \Delta x_k \quad \rightarrow \text{ترتیب متبال f در مرحله k}$$

$$\left\{ \begin{array}{l} \Delta x_k = x_{k+1} - x_k \\ x_{k+1} = x_k + \Delta x_k \end{array} \right. \rightarrow \text{اعتراضی شود} \quad x_{k+1} = x_k + \Delta x_k$$

$$\underbrace{f(x_k + \Delta x_k)}_{\approx f_k} \approx f(x_k) + \underbrace{f_n^T(x_k) \Delta x_k}_{\ll 0} \xrightarrow{\text{if } f_n^T(x_k) \Delta x_k < 0} f(x_{k+1}) < f(x_k)$$

اشارہ دوست ۲۵ بابی طریقے
یعنی شور کے اپنی موارد برقرار شود

$$\rightarrow \Delta x_k = \lambda_k u_k$$

$$\Rightarrow \text{سریع} \Rightarrow \text{در} 180^\circ, f_n(x_k), \Delta x_k \text{ ناچیز} \Rightarrow u_k = \frac{-f_n(x_k)}{\|f_n(x_k)\|} \Rightarrow f_n^T(x_k) \Delta x_k < 0$$

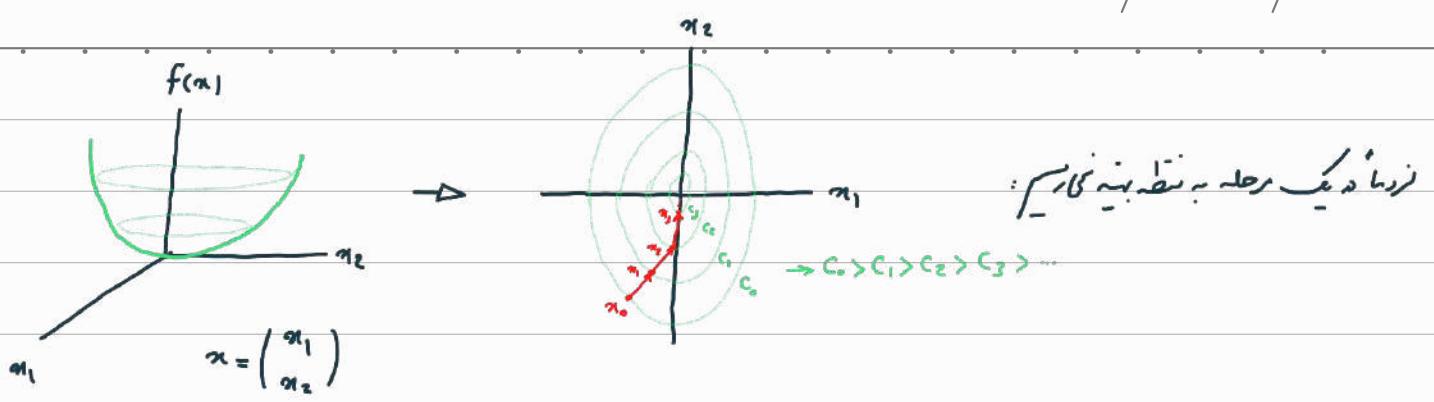
می توان λ_k را که مک انتساب نموده $f_n^T(\alpha_k) \Delta \alpha_k$ بنت به H.O.T. عالی سود داشت در $f(\alpha_{k+1})$ بر تراو شود.
ده صفت ایجاد می توان λ_k را - صرفت بهش - دست آورد:

$$\lambda_k^* = \underset{\lambda_k}{\operatorname{Argmin}} \ f(\pi_k + \lambda_k u_k)$$

بری حل یعنی سازی^{*} گام (Backtracking Line Search) از الگوریتم ها (Line Search) هم استفاده کرد
 (یعنی سازی) اسکالر است و ساده تر است

$$\Rightarrow x_{k+1} = x_k + \lambda_k u_k$$

در استانی آندریتر ۸۰ نیز لک اتکاب می‌شود با تردیک سُلَن به تنظیمیه ۶۰ لک حک اتکاب می‌شود تا به تنظیمیه همان شرم



مئریزی هست SD : برای تراکم محب دشمنی بایتماب نسبت ۳۰ به میانگین (۲۷) الگوریتم SD بمتدازگینه
تایم ۱۰۰ میلی ثانی

$$\lambda_k = \frac{\|f_n(x_n)\|}{L} \rightarrow \text{دنبت مستقر} \Rightarrow \|f(x) - f(y)\| < L \|x-y\|$$

لے می ترانہ حد بالا میں استاب شود

- Backtracking Line Search

دسترسی به آنها کمتر محدود است و خواهیم بینایی
iteration شرطیت

نت خانم عابد: اگر رسم تصرف می شود آن صفاتی که از معادله های زیر برآورده شود:

$$1 \quad \| \nabla f(x_k) \| \leq \epsilon_\sigma$$

راهنمایی شرط برقراریاند

$$2 \quad |f(x_i) - f(x_{i-1})| < C_f \quad i = k, k-1, \dots, k-m$$

$$||x_i - x_{i-1}|| < \epsilon_n \quad i = k, k-1, \dots, k-m$$

$$4 \quad \lambda_k < k\lambda_1, \quad 0 < k < 1$$

5 $a = \text{Number of iterations}$ \rightarrow عدد التكرارات

Example

\hat{x}_k

$\begin{matrix} \uparrow \\ A > 0 \\ \downarrow \\ \text{PD} \end{matrix}$

$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

اشیع SD برای تابع می:

$$f_n(x) = Ax + b \Rightarrow x_{k+1} = x_k - \lambda_k \left(\frac{Ax_k + b}{\|Ax_k + b\|} \right)$$

$$f(x_k + \lambda_k u_k) = \frac{1}{2} (x_k + \lambda_k u_k)^T A (x_k + \lambda_k u_k) + b^T (x_k + \lambda_k u_k) + c$$

$$\Rightarrow \frac{\partial f}{\partial \lambda_k} = \left(\frac{\partial f}{\partial (x_k + \lambda_k u_k)} \right)^T \frac{\partial (x_k + \lambda_k u_k)}{\partial \lambda_k} = [A(x_k + \lambda_k u_k) + b]^T u_k = 0$$

$$\Rightarrow \underbrace{x_k^T A u_k + \lambda_k u_k^T A u_k + b^T u_k}_{= u_k^T A x_k} = 0, H_k = u_k^T A u_k > 0 \rightarrow \overline{\lambda_k} = \overline{u_k^T A x_k}$$

$$\Rightarrow \lambda_k = \frac{-u_k^T (Ax_k + b)}{u_k^T A u_k} = \frac{-u_k^T f_n(x_k)}{u_k^T A u_k} = \frac{f_n^T(x_k) f_n(x_k)}{\underbrace{f_n^T(x_k) A f_n(x_k)}_{\parallel f_n(x_k) \parallel}}$$

$$\Rightarrow x_{k+1} = x_k + \Delta x_k = x_k + \lambda_k u_k = x_k - \frac{f_n^T(x_k) f_n(x_k)}{f_n^T(x_k) A f_n(x_k)} f_n(x_k)$$

Another Example

$$f(x) = x_1^2 + 25x_2^2 = \frac{1}{2} x^T \begin{pmatrix} 2 & 0 \\ 0 & 50 \end{pmatrix} x \quad x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$$

$$\Rightarrow f_n(x) = \begin{pmatrix} 2x_1 \\ 50x_2 \end{pmatrix}, H = A > 0$$

$$x_0 = \begin{pmatrix} 2 \\ 2 \\ 2 \end{pmatrix} \Rightarrow f(x_0) = 104 , f_n(x_0) = \begin{pmatrix} 4 \\ 100 \\ 100 \end{pmatrix}$$

$$x_1 = x_0 - \frac{(4 \ 100) \ (4)}{(4 \ 100) \ (2 \ 2) \ (2 \ 100)} \begin{pmatrix} 4 \\ 100 \\ 100 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \\ 2 \end{pmatrix} - 0.02003 \begin{pmatrix} 4 \\ 100 \\ 100 \end{pmatrix} = \begin{pmatrix} 1.92 \\ -0.003 \\ 1.92 \end{pmatrix} \Rightarrow f(x_1) = 3.69$$

iteration 3.69 < 104 if 3rd

Example

$$\begin{cases} 3x_1 - \cos(x_2 x_3) - \frac{3}{2} = 0 \\ 4x_1^2 - 625x_2^2 + 2x_2 - 1 = 0 \\ \exp(-x_1 x_2) + 20x_3 + \frac{10\pi - 3}{3} = 0 \end{cases} \quad \text{حل درستگاه معادلات:}$$

$$\Rightarrow \text{خط}: \begin{cases} e_1(x) = 3x_1 - \cos(x_2 x_3) - \frac{3}{2} \\ e_2(x) = 4x_1^2 - 625x_2^2 + 2x_2 - 1 \\ e_3(x) = \exp(-x_1 x_2) + 20x_3 + \frac{10\pi - 3}{3} \end{cases} \quad x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

$$\Rightarrow F(x) = \frac{1}{2} (e_1^2(x) + e_2^2(x) + e_3^2(x))$$

حل ریشه $F(x) = 0$

حل تقریبی ریشه $F(x) \rightarrow 0$

آنچه می‌شود حل کنیم، بازشن شرط لازم مرتب اول به دستگاه معادلات اینه که مابین حل بینت

که از الگوریتم iterative استفاده شود

$$x_0 = \begin{pmatrix} 0 \\ 0 \\ 0 \end{pmatrix} \Rightarrow F(x_0) = \frac{1}{2} ((-2.5)^2 + (-1)^2 + (10.472)^2) = 58.456 , F_n(x_0) = \begin{pmatrix} -7.5 \\ -2 \\ 209.44 \end{pmatrix}$$

فیزیکاً متغیر شدن نداشت

$$x_1 = x_0 - \lambda_0 F_n(x_0) \quad \rightarrow x_1 = x_0 - \lambda_0 \begin{pmatrix} -7.5 \\ -2 \\ 209.44 \end{pmatrix}$$

$$\lambda_0 \text{ انتساب: } F(x_1) < F(x_0) \Rightarrow \lambda_0 = 0.001$$

$$\Rightarrow \alpha_1 = \begin{pmatrix} 0.0075 \\ 0.002 \\ -0.20944 \end{pmatrix} \rightarrow F(\alpha_1) = 23.306 < 58.456 = F(\alpha_*) \checkmark$$

رسن SD : مزیت : سرچ به جای تردی می شود
 ایجاد : هدایت کننده از تردی نشدن به جای تردی مکمل نشستن
 استفاده کرد

رسن مرتب دهنده‌ی نتایج :

$$f(x_k + \Delta x_k) \approx f(x_k) + \nabla f(x_k) \Delta x_k + \frac{1}{2} \Delta x_k^T H(x_k) \Delta x_k \rightarrow \text{پاتاب} \quad \text{نسبتی برآورد} \rightarrow \text{Quadratic}$$

$$\frac{\partial f(x_k + \Delta x_k)}{\partial \Delta x_k} = \nabla^T f(x_k) + H(x_k) \Delta x_k = 0 \quad \text{معنی: } H(x_k) > 0 \rightarrow \text{نمایش} \quad \rightarrow \text{حدیده در} \quad H$$

$$\Rightarrow \Delta x_k = -H^{-1}(x_k) \nabla^T f(x_k) \quad \Rightarrow x_{k+1} = x_k - H^{-1}(x_k) \nabla^T f(x_k)$$

لایه بطری ریکی از H_k باز است زیاد

شرطی هدایتی رسن نتیجی محدود (Bounded) H به نظر نگذارد. α^* به α

Example

$$f(x) = \frac{1}{2} x^T A x + b^T x + c$$

$$\Rightarrow \nabla f(x) = Ax + b, \quad H(x) = A, \quad \text{نمایه } x,$$

$$x_1 = x_0 - A^{-1}(Ax_0 + b) = x_0 - x_0 - A^{-1}b = -A^{-1}b = x^* \rightarrow$$

پنجه های بیخ بیخ

← بدل آجع ربعی الگوریتم نیزی دلیل مرحله به سند کنیه آجع می شد SD بینه است

پس ازه برآ استفاده از نتایج روش های SD نیزی ، استفاده از SD در مراحل اولیه دشوار نیست - باید کنیه دسی استاده از دسی نیزی جت ترجیح دهد و در اینجا به منظمه کنیه

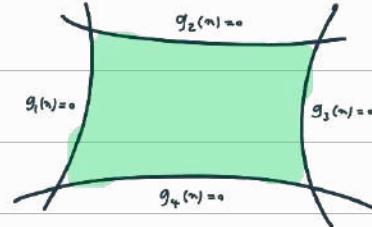
← در مرحله اولیه جاب کنیه مثل آجع - آجع Quadratic نزدیکی نزد

* بهینه سازی معنی

minimize $f(x)$

$x \in \Omega \subseteq \mathbb{R}^n$ → زخمی کنیم نقطه داخلی Ω است

$$\begin{array}{ll} \text{محدوده ای را نایار کنیم} & h_i(x) = 0 \\ \text{اما نمی کنیم} & g_i(x) \leq 0 \\ \vdots & \vdots \\ h_n(x) = 0 & g_p(x) \leq 0 \end{array}$$



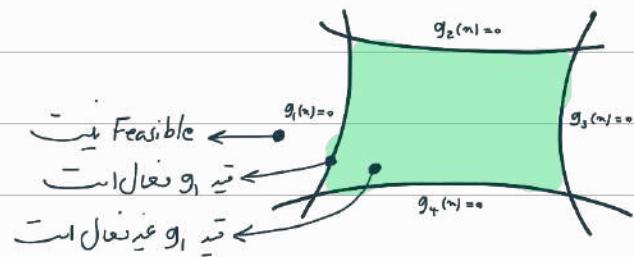
↑ با قید نایار کی ای توان نمی Feasible را سنجو کرد

تعداد قید نایار کی از تعداد تغییرات است (در فضای \mathbb{R}^3 دو بعدی ۳ قید یک نقطه را سنجو کنید !) $\Leftrightarrow m \leq n$

زخمی : f و g_i و h_i ها بیست و دوست بزرگ از مرتبه دارند ($i = 1, \dots, m$ و $j = 1, \dots, p$)

استراحت قید نایار کی را بزرگ می کنیم (اعیت قید نایار کی هم در حالت تایدیان است)

$g_j(x^*) = 0$: قید غیرفعال $\rightarrow x^*(j) = 0$ ← قید فعال : $g_j(x^*) < 0$



تعریف: به مجموعی از محدودهای محدود صریح که می‌تواند محدود مسأله باشد Feasible می‌گویند.

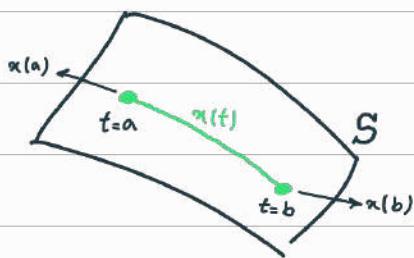
تید تاری: با فرض استقلال تصور تاری، مجموعه قابل پذیری ابر صفحه با بعد $n-m$ را تحلیل می‌دهند

$$R^3, \quad x_1 + x_2 + x_3 = 0 \Rightarrow 3-1=2 \rightarrow R^3 \text{ صفحه منطبق}$$

با این تدبیر یک مابگشایی دارید:
 ماتریس هر دو تبعیض از x_1, x_2, x_3
 سعی بر دست می‌آید

- صفحه (ابر صفحه) سمعن شده با تید را ب ماتریس می‌دهم \leftarrow جواب بینه داخل S است

یک مسیر بر صفحه S را با مجموعه نقاط $\alpha(t) \in S$ نامی دهم که در بازه $a \leq t \leq b$ با پایانی t یا انتهای S نهاد است.

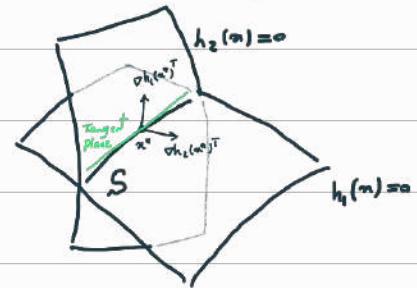
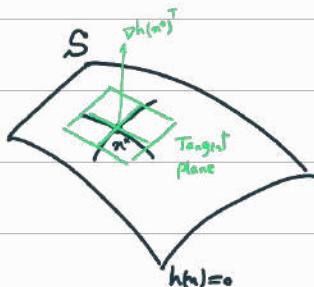
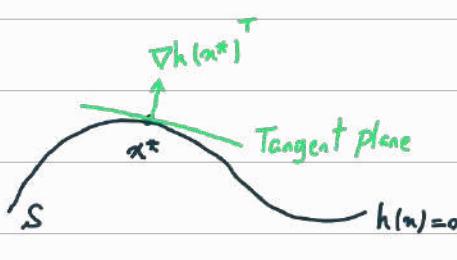


یک مسیر نقطه‌زنی است اگر $\frac{dx}{dt} = \dot{x}$ در حد ذاته باشد و مشتق پنجم از مرتبه دوم است اگر $(\alpha(t))$ در حد ذاته پنده

مسیر $\alpha(t)$ از نقطه α^* بر S عبور می‌کند اگر در حد ذاته باشد $\dot{x}(t^*) \in \{t: a \leq t \leq b\}$

صفه‌هایی که از α^* عبارت استند نظر نمایم، صفحه‌هایی در α^* به مجموعه هستق‌ها

هسته‌های α^* لامه‌ی شود



تعریف: به نقطه α^* که $h(\alpha^*) = 0$ برای سه‌ی که رکنیه بوده‌اند این بردارهای α^* را بردارهای α^* می‌نامند.

تفصیل: دسته‌ی رکنیه α^* بر صفحه S که $h(\alpha^*) = 0$ شناخته شده است صفحه‌هایی به صفت زیر تعریف می‌گردند:

$$M = \{y : \nabla h(\alpha^*)^T y = 0\} \rightarrow \text{پوچی بردارهای برآمده اند}$$

ابتدا کامل در تابع $h(\alpha)$

$$S \ni x(t) \Rightarrow h(x(t)) = 0 \Rightarrow \nabla h(x(t))^T \dot{x}(t) \Big|_{t=t^*} = 0 \quad \text{ثبت: اثبات}$$

$$\left\{ \begin{array}{l} h_1 = 0 \\ \vdots \\ h_m = 0 \end{array} \right.$$

$$\nabla h(x) = \begin{bmatrix} \nabla h_1(x) \\ \vdots \\ \nabla h_m(x) \end{bmatrix}_{m \times n}$$

هسته‌های α^* را درینجا
برصمه‌های α^* (نمایه)

در نتیجه بر صفحه S کی اعمورند

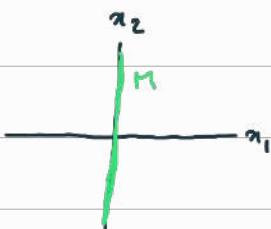
$$\nabla h_i(\alpha^*) \Rightarrow \text{Rank}(\nabla h(\alpha^*)) = m \Rightarrow n - m = \text{بعد نصفکی برجی}$$

لطفاً دو نصفکی اعمورند

⇒ صفحه‌هایی که نصفکی تعداد بر سطحهای α^* را درینجا می‌نمایند

Example

$$h(x_1, x_2) = x_1 = 0$$



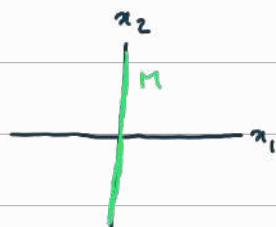
صفحہ ۱۰۷ مکمل بررسی دلایا (۰،۲،۳) = \bar{x}^* محرر ۲۰۱۸ فراہم برور

$$\nabla h(x_1, x_2) = (1 \ 0) \Rightarrow (1 \ 0)y = 0$$

$$\Rightarrow (1+0) \begin{pmatrix} y_1 \\ y_2 \end{pmatrix} = 0 \Rightarrow y_1 = 0 \Rightarrow M = \{y : (1+0)y = 0\} = \sigma_2, \text{ erg}$$

Endröhre

$$h(x_1, x_2) = x_1^2 = 0$$



$$\nabla h(x^*) = (2x_1^* - \alpha)$$

$$x^* \in h \Rightarrow n_i^* = 0 \Rightarrow \nabla h(x^*) = (0 \ 0) \rightarrow \text{بهاء لطوان سلبي}$$

$$\forall y \in \mathbb{R}^n \Rightarrow \nabla h(x^*) y = 0 \Rightarrow M = \mathbb{R}^n \cdot x^*$$

بین ربط صفر و کا با بودت آمد

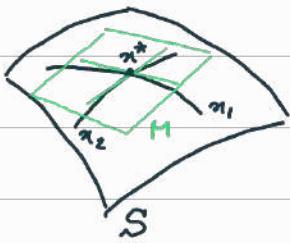
م: اگر α^* نقطه رُزلاردی قید $h(\alpha) = 0$ باشد و همچنین مطه عبارتی مغلی برای f با توجه به قید باشد، آنگاه به ازای کوچکترین $y \in \mathbb{R}$ داریم $\nabla f(\alpha^*)y = 0$ و $\nabla h(\alpha^*)y = 0$.

لے گا ہر صنعتی محاذات

صفحہ ۵

$$\text{إذا تمكنت من} \quad \alpha^* \Rightarrow \frac{d}{dt} f(\alpha(t)) \Big|_{t=t^*} = 0 \Rightarrow \nabla f(\alpha(t^*)) \cdot \dot{\alpha}(t^*) = 0$$

صفه‌های



\Rightarrow بردار $\nabla f(x^*)$ را هشتگرای می‌سینه از x^*
در آن عمد است

\Leftarrow $\nabla f(x^*)$ را هشتگرای و که دعیرت $= \nabla h(x^*)$ صدق می‌کند
که همان صفحه‌هایی می‌باشد عمد است

$\nabla f(x^*) \in \{ \nabla h_1(x^*), \dots, \nabla h_m(x^*) \} \Rightarrow$ صفحه‌های :
بردارهای سارایان $\{ \nabla h_1, \dots, \nabla h_m \}$: یک زیرفضا با عده m دارد بر صفحه‌های
راست است

از نظر عمد بر صفحه‌هایی را
span می‌کند

شرط لازم بگشته

تصییغ: اگر x^* یک کینه ملی f با توجه به قید $h(x) = 0$ باشد و x^* یک نقطه رکن‌لار برای این تقدیر باشد، آنگاه
بردار $\lambda \in \mathbb{R}^m$ وجود دارد به طوری که،

$$\nabla f(x^*) + \lambda^T \nabla h(x^*) = 0$$

شرط $\nabla f(x^*) + \sum_{i=1}^m \lambda_i \nabla h_i(x^*) = 0$ را دارای است و ب
شرط ترتیب فطی آن هاتا بیان است

می‌توانیم شرط لازم بگشته را بثابت بخواهیم که لامارزین کنه می‌شود بیان کسر:

$$L(x, \lambda) = f(x) + \lambda^T h(x) \Rightarrow \begin{cases} \frac{\partial L}{\partial x} = 0 \Rightarrow \nabla f(x) + \lambda^T \nabla h(x) = 0 \\ \frac{\partial L}{\partial \lambda} = 0 \Rightarrow h(x) = 0 \end{cases} \rightarrow \text{شرط لازم بگشته}$$

ضراس لامارز

تعیین $x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$ و $\lambda = \begin{pmatrix} \lambda_1 \\ \vdots \\ \lambda_m \end{pmatrix}$

معادله $n+m =$ معادله $n+m$ \leftarrow حل معجل \leftarrow بروزت می‌آید

دیگر میتوانیم بگوییم که شرط لازم (مقداری که باید داشت) همانند مقداری که باید داشت باشد.

Example

$$\begin{aligned} \text{Maximize } & x_1x_2 + x_2x_3 + x_1x_3 \\ \text{s.t. } & x_1 + x_2 + x_3 = 3 \end{aligned} \quad \equiv \quad \begin{aligned} \text{minimize } & -x_1x_2 - x_2x_3 - x_1x_3 = f(x) \\ \text{s.t. } & x_1 + x_2 + x_3 = 3 \end{aligned}$$

$$\Rightarrow \begin{cases} -(x_2 + x_3, x_1 + x_3, x_1 + x_2) + \lambda(1 \ 1 \ 1) = 0 \\ x_1 + x_2 + x_3 = 3 \end{cases}$$

$$\Rightarrow \begin{cases} x_2 + x_3 = \lambda \\ x_1 + x_3 = \lambda \\ x_1 + x_2 = \lambda \end{cases} \quad \begin{array}{l} \text{①} \\ \text{②} \\ \text{③} \end{array} \rightarrow \begin{array}{l} x_1 + x_2 + x_3 = 3\lambda \rightarrow 3\lambda = 6 \rightarrow \lambda = 2 \\ x_1 = x_2 = x_3 \Rightarrow x_1 = x_2 = x_3 = 1 \end{array}$$

Another Example

$$\text{Maximize } xyz$$

$$\Rightarrow \text{minimize } f = -xyz$$

$$\text{s.t. } xy + yz + zx = \frac{c}{2} \quad c > 0$$

$$\nabla^T f + \lambda \nabla^T h = 0 \Rightarrow \begin{cases} \text{①} \begin{pmatrix} -yz \\ -xz \\ -xy \end{pmatrix} + \lambda \begin{pmatrix} y+z \\ x+z \\ x+y \end{pmatrix} = 0 \\ \text{② } xy + yz + zx = \frac{c}{2} \end{cases} \Rightarrow \begin{cases} x\text{①} - y\text{②} \rightarrow \lambda(x-y)z = 0 \\ y\text{②} - z\text{③} \rightarrow \lambda(y-z)x = 0 \\ z\text{③} - x\text{①} \rightarrow \lambda(z-x)y = 0 \end{cases} \quad (*)$$

$$\text{①} + \text{②} + \text{③} \Rightarrow -(xy + yz + zx) + 2\lambda(x + y + z) = 0 \rightarrow 2\lambda(x + y + z) = \frac{c}{2} \rightarrow \lambda \neq 0$$

**

$$\text{منطق: } x=0 \xrightarrow{\textcircled{2}} \lambda z = 0 \xrightarrow{\lambda \neq 0} z = 0 \xrightarrow{\textcircled{1}} \lambda y = 0 \xrightarrow{\lambda \neq 0} y = 0$$

$$\begin{aligned} \text{منطق: } & \begin{cases} y = 0 \Rightarrow x = z = 0 \\ z = 0 \Rightarrow x = y = 0 \end{cases} \\ & \xrightarrow{\lambda y_1 + y_2 + z = \frac{c}{2} \neq 0} x \neq 0, y \neq 0, z \neq 0 \end{aligned}$$

$$\Rightarrow \textcircled{3} \Rightarrow x = y = z \Rightarrow \text{منطق: } x^2 + y^2 + z^2 = \frac{c}{2} \Rightarrow x = \pm \sqrt{\frac{c}{6}}$$

$$\textcircled{4} \Rightarrow \lambda = \pm \frac{1}{2} \sqrt{\frac{c}{6}} \Rightarrow \begin{cases} x = y = z = \pm \sqrt{\frac{c}{6}} \\ \lambda = \pm \frac{1}{2} \sqrt{\frac{c}{6}} \end{cases} \leftarrow \begin{array}{l} \text{ح. م. رسم) ح. م.} \\ \text{ح. م. رسم} \end{array}$$

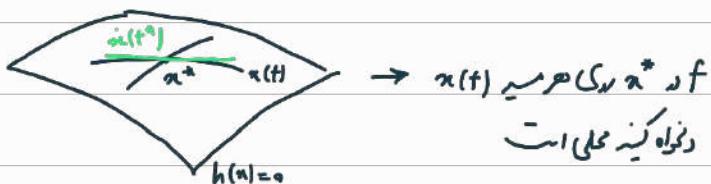
شرط لازم کافی مرتبه دوم: شرط لازم مرتبه دوم: α^* که نباید f تبدیل به تردی باشد.

$M = \{y : \nabla h(\alpha^*) y = 0\}$

$$M \text{ بر } L(\alpha^*) = \nabla^2 f(\alpha^*) + \lambda^T \nabla^2 h(\alpha^*) = F(\alpha^*) + \lambda^T H(\alpha^*)$$

نیست معنی است

$$\forall y \in M : y^T L(\alpha^*) y \geq 0$$



ابتدا:

در α^* هر کسی

روزگار کننده محلی است

$$\Rightarrow \frac{d^2 f}{dt^2} \Big|_{t=t^*} \geq 0 \Rightarrow \frac{d}{dt} (\nabla f(\alpha(t)) \cdot \dot{\alpha}(t)) \geq 0$$

$$\Rightarrow \ddot{\alpha}(t)^T \nabla^2 f(\alpha(t)) \dot{\alpha}(t) + \nabla f(\alpha(t))^T \ddot{\alpha}(t) \geq 0 \quad \text{(I)}$$

$$h(\alpha) = 0 \Rightarrow \lambda^T h(\alpha) = 0 \xrightarrow{\text{منطق}} \lambda^T \nabla h(\alpha(t)) \dot{\alpha}(t) = 0$$

$$\Rightarrow \sum_{i=1}^m \lambda_i \nabla h_i(\alpha(t)) \dot{\alpha}(t) = 0$$

$$\overbrace{\dot{\alpha}^T(t) \sum_{i=1}^m \lambda_i \nabla^2 h_i(\alpha(t)) \dot{\alpha}(t)}^{\lambda^T \nabla^2 h(\alpha(t))} + \sum \lambda_i \nabla h_i(\alpha(t)) \ddot{\alpha}(t) = 0$$

$\lambda^T \nabla^2 h(\alpha(t))$: notation

$$\Rightarrow \dot{\alpha}^T \lambda^T \nabla^2 h(\alpha(t)) \dot{\alpha}(t) + \lambda^T \nabla h(\alpha(t)) \ddot{\alpha}(t) = 0 \quad \textcircled{I}$$

$$\Rightarrow \textcircled{I} + \textcircled{I} \geq 0 \Rightarrow \dot{\alpha}^T(t) \left[\nabla^2 f(\alpha(t)) + \lambda^T \nabla^2 h(\alpha(t)) \right] \dot{\alpha}(t) + \left[\nabla f(\alpha(t)) + \lambda^T \nabla h(\alpha(t)) \right] \ddot{\alpha}(t) \Big|_{t=t^*} \geq 0$$

(شرط لامساية)

$$\Rightarrow \dot{\alpha}^T(t^*) \left[\underbrace{\nabla^2 f(\alpha^*)}_{F} + \underbrace{\lambda^T \nabla^2 h(\alpha^*)}_{H} \right] \dot{\alpha}(t^*) \geq 0$$

$$\Rightarrow \dot{\alpha}^T(t^*) \left[F(\alpha^*) + \lambda^T H(\alpha^*) \right] \dot{\alpha}(t^*) \geq 0 \rightarrow$$

برای این معنی سیرها باید
برتاییدن \Leftrightarrow کل معنی های داشتایی خود

$$\Rightarrow y^T [F(\alpha^*) + \lambda^T H(\alpha^*)] y \geq 0 \quad \forall y \in M \Rightarrow y^T L(\alpha^*) y \geq 0 \quad \forall y \in M$$

شرط کافی تر برآورده: اگر α^* یک نقطه رکورد بر قدر $y^T h(y) = 0$ باشد به طوری که $h(y) = 0$ در محدوده ای از M

$L(\alpha^*) = \nabla^2 f(\alpha^*) + \lambda^T \nabla h(\alpha^*)$ که $\sim \lambda \in R^n$

آنکه $y^T L(\alpha^*) y > 0 \quad \forall y \in M - \{y: \nabla h(\alpha^*) y = 0\}$
که معملاً کمتر از یک تابع f شرایطی باشد.

Example

$$\begin{aligned} \text{Maximize } & \alpha_1 \alpha_2 + \alpha_2 \alpha_3 + \alpha_1 \alpha_3 \\ \text{s.t. } & \alpha_1 + \alpha_2 + \alpha_3 = 3 \end{aligned} \Rightarrow \text{minimize } f = -\alpha_1 \alpha_2 - \alpha_2 \alpha_3 - \alpha_1 \alpha_3$$

به شرط لانگریزه اول ره نشان های آنل بروست آمد

$$\nabla^T f = \begin{pmatrix} x_1 + x_3 \\ x_1 + x_3 \\ x_1 + x_2 \end{pmatrix} \Rightarrow \nabla^2 f = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix}$$

$$\nabla^T h = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \Rightarrow \nabla^2 h = 0$$

$$\Rightarrow \nabla^2 f(x^*) + \lambda^T \nabla^2 h = - \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix}$$

$$0 : \text{درینان} \quad \lambda^T \nabla^2 h \text{ اعماق سم} \rightarrow \text{ناعی} \Rightarrow 0 - (1+1) = -2$$

باشه علاست (x^*) را بر معرفه خواهی ببری کنیم

$$M = \{y : (1 \ 1 \ 1)y = 0\} = \{y : y_1 + y_2 + y_3 = 0\}$$

$$y^T L(x^*)y = -[y_1 \ y_2 \ y_3] \begin{pmatrix} 0 & 1 & 1 \\ 1 & 0 & 1 \\ 1 & 1 & 0 \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ y_3 \end{pmatrix} = -[y_1(y_2 + y_3) + y_2(y_1 + y_3) + y_3(y_1 + y_2)]$$

$$= -[-y_1^2 - y_2^2 - y_3^2] = y_1^2 + y_2^2 + y_3^2 > 0 \quad \forall y \in M$$

$y \neq 0$

به عطف برست آنده از شرط لانگریزه اول کنیه f (بنیه تابع فاسمه نده) را به برست خواهد

قدرت ناتاری

Minimize $f(x)$

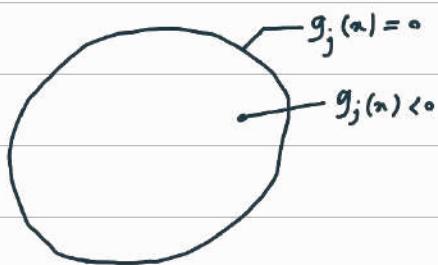
$$\text{s.t. } \underset{m=1}{h_m(x)} = 0 \quad \underset{p=1}{g_p(x)} \leq 0 \quad f, g, h \in C'$$

دیسته دستگذیری

نمکیتیاری با آن برخورد می شود

نمکیتیاری با آن برخورد می شود

نمکیتیاری با آن برخورد می شود



آرسطو بینه خارج من بشن Feasible نیست
آرسطو بینه دی من بشن باشید قید تاری برخورد نمود
آرسطو بینه داخل من بشن، من محدودیتی برک آن اعمال نمایند

Example

$$\min (x-1)^2$$

$$x \geq 1$$

نمایند ناولد نیست \Rightarrow شرطیت: $x^* = 1$
بهریقه داخل من بشن ای کوچکتر
نمایند ناولد \leftarrow بین فقره من وجد قید لقی نمایند

$$\min x^2$$

$$x \leq 1$$

نمایند داشت آهل حساب $\Rightarrow x^* = 0$
نمایند داشت Feasible بین یابند باخ
داشته باشی لذت

$$\min x^2$$

$$x \geq 1$$

نمایند داشت آسن $\rightarrow x^* = 1$ \rightarrow حاب قش نمایند

به این قید ناتاری آنی سنه با به صفت عادی حل می کنیم در نهایت Feasible بین حاب هارا با آن حل می کنیم

تعیین: فرض x^* نه از نظر ای است که $g_i(x^*) = 0$ و $g_i(x^*) > 0$ را برآورده می کند (سُنبی است) دل جموعه اندیشه های از زبانه که داشت x^* و می بند (نمایند فعل) آنگاه x^* نیت به تیرهای فرق تبلد است اگر $\nabla h_i(x^*) = 0$ باز هر $m \in \mathbb{N}$ دل $\nabla h_i(x^*)$ متصل فطی باشد.

تغییرات کاروچ-کون-تاکر (Karush-Kuhn-Tucker)

Minimize $f(x)$

$$\text{s.t. } h(x) = 0, g(x) \leq 0$$

باشد و مینیموم x^* یک نقطه ریاضی برای تمرین شده آنها $\mu \geq 0, \mu \in \mathbb{R}^m, \lambda \in \mathbb{R}^n$ باشد آنها را دوست دارند به طوری که:

$$\begin{cases} \underset{i \in \mathcal{N}}{\nabla f(x^*)} + \lambda^T \underset{i \in \mathcal{M}}{\nabla h_i(x^*)} + \mu^T \underset{i \in \mathcal{P}}{\nabla g_i(x^*)} = 0 \\ \mu^T g(x^*) = 0 \\ h(x^*) = 0 \end{cases}$$

شرط لامبرتی متسابل ←

اثبات: تمرینات اولیه تصور تاری با خاصیت لامبرتی متسابل لامبرتی می شوند
تمرینات اولیه غیرفعال ضریب معزی کنند و متسابل لامبرتی می شوند

$$\mu^T g(x^*) = \sum_{j=1}^p \mu_j g_j(x^*) = 0 \quad \text{تمرینات اولیه غیرفعال} \rightarrow$$

$$0 \geq \mu_j > 0, \forall j \Rightarrow \mu_j = 0 \quad \text{تمرینات اولیه غیرفعال} \rightarrow$$

\Rightarrow می x^* که نسبی تابع f بر قبیل تمرینات می توان نسبت که که نسبی f با توجه به تمرینات اولیه غیرفعال می باشد. بنابراین برای تمرینات اولیه غیرفعال همان رابطه لامبرتی برقرار است ($\Rightarrow \mu_j$ برای تمرینات اولیه غیرفعال زéro و λ_j خالص بود)
برای سایر تمرینات غیرفعال (که نسبی دارای رابطه لامبرتی ظاهر شوند) باید داشته باشیم $\mu_j = 0$ (λ_j خالص برای همه تمرینات اولیه غیرفعال می باشد)

$$\begin{cases} g_j(x^*) < 0 \Rightarrow \mu_j = 0 \\ g_j(x^*) = 0 \Rightarrow \mu_j > 0 \end{cases}$$

که دلخواه $\mu_j = 0$ (همان این خاصیت را برآورد می کند ($\mu_j > 0$))

آنرا تمرینات اولیه غیرفعال و تمرینات اولیه حساب

آن است که مقدم باید برقرار باشد اما اینکه λ شرطی و مجرد نماید

ابتدا: فرضیه $g_k(x^*) = 0$

D : مجموعی حاصل از سایر محدودهای x^*

$$\Rightarrow D = \{y : \nabla h(x^*)y = 0, \nabla g_j y = 0, j \in J, j \neq k\}$$

$y \in D$

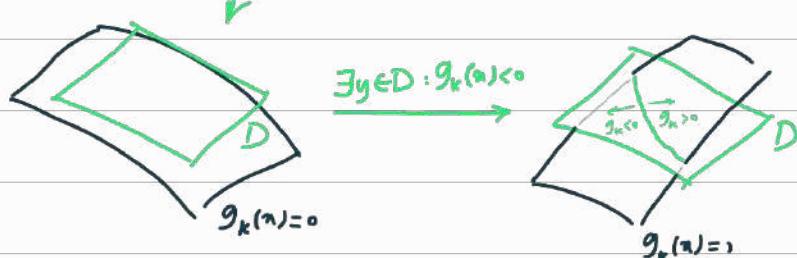
$$\rightarrow x = x^* + \alpha y \quad 0 < \alpha < 1 \Rightarrow \exists y \in D : g_k(x) < 0$$

آخرین و درد نداشت باشد، در هر جای در D مثل x^* $g_k(x) = 0$ نباشد که داشت

این صرفا ∇g_k تغیر بر مفعول عوایق عمرانی است ($= 0$) $g_k(x^*) = 0$ است اما

بسیار ∇g_k دسیر محدودهای محدودهای سازنده D را به قطعی گشود

داین حدت α دیگر نقطه پردازه نمی‌باشد



$$\Rightarrow g_k(x^* + \alpha y) < 0 \Rightarrow g_k(x^*) + \underbrace{\nabla^T g_k(x^*) (\alpha y)}_{\text{این عبارت علاوه بر}} + O(\alpha) < 0$$

ماتنی می‌کند
 $\alpha \ll 1 \Rightarrow$

$$\Rightarrow \nabla g_k^T \alpha y < 0 \xrightarrow{\alpha > 0} \nabla g_k^T(x^*) y < 0$$

$$\nabla f(x^*) + \lambda^T \nabla h(x^*) + \underbrace{\mu_k^T \nabla g_k(x^*)}_{\text{همانند مذکور}} + \underbrace{\mu_k^T \nabla g_k(x^*)}_{k \neq j} = 0$$

$$\xrightarrow{y \in D \Rightarrow 0} \underbrace{\nabla f(x^*) y}_{y \in D \Rightarrow 0} + \underbrace{\lambda^T \nabla h(x^*) y}_{y \in D \Rightarrow 0} + \underbrace{\mu_k^T \nabla g_k(x^*) y}_{\mu_k^T = 0} + \underbrace{\mu_k^T \nabla g_k(x^*) y}_{\mu_k^T = 0} = 0$$

$\Rightarrow \nabla f(x^*) y < 0$ $\xrightarrow{\text{بطابق}} f(x^* + \alpha y) < f(x^*) \Rightarrow x^* + \alpha y \text{ نیزی باره} \Rightarrow$
 به تیرینیت باشد
 $g_x(x) < 0$ است و
 دسترسی است Feasible

$$\mu_k > 0 \leftarrow$$

Example

$$\text{Minimize } 2x_1^2 + 2x_1x_2 + x_2^2 - 10x_1 - 10x_2$$

$$\text{s.t. } x_1^2 + x_2^2 \leq 5$$

$$3x_1 + x_2 \leq 6$$

$$\Rightarrow (4x_1 + 2x_2 - 10 \quad 2x_1 + 2x_2 - 10) + \begin{pmatrix} 1 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} 2x_1 & 2x_2 \\ 3 & 1 \end{pmatrix} = 0$$

$$\Rightarrow \begin{cases} 4x_1 + 2x_2 - 10 + 2\mu_1 x_1 + 3\mu_2 = 0 \\ 2x_1 + 2x_2 - 10 + 2\mu_1 x_2 + \mu_2 = 0 \end{cases}$$

$$\begin{cases} \mu_1(x_1^2 + x_2^2 - 5) = 0 & \mu_1 \geq 0 \\ \mu_2(3x_1 + x_2 - 6) = 0 & \mu_2 \geq 0 \end{cases} \quad \Rightarrow \quad \mu_1(x_1^2 + x_2^2 - 5) + \mu_2(3x_1 + x_2 - 6) = \mu^T g(x) = 0$$

۱- همیشہ از قدر ممکن اتفاق نمایند.

$$f_1 = f_2 = 0 \Rightarrow \begin{cases} 4x_1 + 2x_2 - 10 = 0 \\ 2x_1 + 2x_2 - 10 = 0 \end{cases} \Rightarrow \begin{cases} x_1 = 0 \\ x_2 = 5 \end{cases} \Rightarrow g_1(0, 5) = 25 - 5 = 20 \quad \text{✓}$$

2 قید اول فعال باشد و تیه در فعال نباشد

$$\mu_2 = 0 \Rightarrow \begin{cases} 4x_1 + 2x_2 - 10 + 2\mu_1 x_1 = 0 \\ 2x_1 + 2x_2 - 10 + 2\mu_1 x_2 = 0 \\ x_1^2 + x_2^2 - 5 = 0 \end{cases} \Rightarrow x_1 = 1, x_2 = 2, \mu_1 = 1 \quad \checkmark$$

$$g_2(1, 2) = 3 + 2 - 6 \leq 0 \quad \checkmark$$

3 تقدیر مفعل رضیاً علی غیر مفعال باشد

$$\mu_1 = 0 \Rightarrow \begin{cases} 4x_1 + 2x_2 - 10 + 3\mu_2 = 0 \\ 2x_1 + 2x_2 - 10 + \mu_2 = 0 \\ 3x_1 + x_2 = 6 \end{cases} \Rightarrow x_1 = \frac{2}{5}, \mu_2 = \frac{-2}{5} < 0, x_2 = 6 - \frac{6}{5} \quad X$$

4 هر دو تقدیر مفعال باشند

$$\begin{cases} 4x_1 + 2x_2 - 10 + 2\mu_1 x_1 + 3\mu_2 = 0 \\ 2x_1 + 2x_2 - 10 + 2\mu_1 x_2 + \mu_2 = 0 \\ x_1^2 + x_2^2 - 5 = 0 \\ 3x_1 + x_2 = 6 \end{cases} \rightarrow \mu_1, \mu_2 < 0 \quad X$$

میک سلسله می تواند چند تابع محلي داشته باشد (دسته حالت مفعال / غیر مفعال بودن قيمتها جواب داشته باشند)

شرط لازم مرتبه دهم:

اگر روابع $f, g, h \in C^2$ باشند و x^* نقطه رکوردار تقدیر (مفعال) باشد و همچنان x^* یک کینه نبی $\lambda \in R^n$, $\mu \in R^P$, $\nu \in R^Q$ داشته باشد. آنگاه ضوابط دو دارند به طبقی که

$$L(x^*) = \nabla^2 f(x^*) + \lambda^T \nabla^2 h(x^*) + \mu^T \nabla^2 g(x^*) \rightarrow \text{notation: } \lambda^T \nabla^2 h = \sum_{i=1}^m \lambda_i \nabla^2 h_i, \mu^T \nabla^2 g = \sum_{j=1}^p \mu_j \nabla^2 g_j$$

بر عده هر کسی مربوط به تقدیر مفعل داشته باشد نیزه بنت معنی (PSD) است:

$$\forall y \in M' \quad y^T L(x^*) y \geq 0$$

$$M' = \{y : \nabla h(x^*) y = 0, \nabla g_j(x^*) y = 0 \quad \forall j \in J\}$$

لے جو همه تقدیر ناتای مفعال

پیش‌نیاز مرتبه 2

شرط کافی ریتم: آگر تابع $f, g, h \in C^2$ داشته باشد و مقدار میرد باشد، شرط کافی برای این که x^* یک نقطه نسبی اکید برای $\mu \in \mathbb{R}^P$, $\lambda \in \mathbb{R}^m$ باشد این است که در دو حالت پسندیدگی و غایبی از:

$$\mu > 0$$

$$\mu^T g(x^*) > 0$$

$$\nabla f(x^*) + \lambda^T \nabla h(x^*) + \mu^T \nabla g(x^*) = 0$$

و $L(x^*)$ می‌باشد بحسب عبارتی:

$$\forall y \in M' \quad y^T L(x^*) y > 0$$

Example

ادامه مدل:

$$\begin{cases} x_1^* = 1 \\ x_2^* = 2 \end{cases} \quad \begin{cases} \mu_1 = 1 \\ \mu_2 = 0 \end{cases}$$

$$L(x^*) = \begin{bmatrix} 4 & 2 \\ 2 & 2 \end{bmatrix} + 1 \times \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix} = \begin{bmatrix} 6 & 2 \\ 2 & 4 \end{bmatrix} \rightarrow \text{نمایش اصلی سمت}: 6, 24$$

$$\Rightarrow L(x^*) > 0 \Rightarrow \text{نقطه نسبی است} \Rightarrow x^*$$

Example

$$\text{Minimize } \frac{1}{2} (x_1^2 + x_2^2)$$

$$\text{s.t. } x_1 + x_2 - 2 = 0$$

$$x_1 \geq 0 \rightarrow -x_1 \leq 0$$

$$x_2 \geq 0 \rightarrow -x_2 \leq 0$$

$$\Rightarrow \begin{cases} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \lambda \begin{pmatrix} 1 \\ 1 \end{pmatrix} + (\mu_1 \ \mu_2) \begin{pmatrix} -1 & 0 \\ 0 & -1 \end{pmatrix} = 0 \Rightarrow \begin{cases} x_1 + \lambda - \mu_1 = 0 \\ x_2 + \lambda - \mu_2 = 0 \end{cases} \\ \mu_1(-x_1) + \mu_2(-x_2) = 0 \\ \mu_1, \mu_2 \geq 0 \end{cases}$$

$$\begin{cases} -\mu_1 x_1 = 0 \\ -\mu_2 x_2 = 0 \\ x_1 + x_2 - 2 = 0 \end{cases}$$

1 هر دو قیمت ناتاری غیرفعال

$$\mu_1 = \mu_2 = 0 \Rightarrow \begin{cases} x_1 + \lambda = 0 \\ x_2 + \lambda = 0 \\ x_1 + x_2 = 2 \end{cases} \quad \left| \begin{array}{l} \oplus \\ 2 \end{array} \right. \Rightarrow x_1 + x_2 + 2\lambda = 0 \Rightarrow \lambda = -1 \Rightarrow x_1 = x_2 = 1 > 0 \quad \checkmark$$

$$L(x^*) = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} + (-1) \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} > 0 \Rightarrow \text{که است } x^* = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$$

2 قید اول فعل و قید دوم غیرفعال

$$x_1 = 0, \mu_2 = 0 \quad \xrightarrow{x_1 + x_2 = 2} x_2 = 2 \quad \xrightarrow{x_2 + \lambda = 0} \lambda = -2 \quad \xrightarrow{x_1 + \lambda - \mu_1 = 0} \mu_1 = -2 < 0 \quad \times$$

3 قید اول غیرفعال و قید دوم فعل

$$x_2 = 0, \mu_1 = 0 \quad \xrightarrow{x_1 + x_2 = 2} x_1 = 2 \quad \xrightarrow{x_1 + \lambda = 0} \lambda = -2 \quad \xrightarrow{x_1 + \lambda - \mu_1 = 0} \mu_1 = -2 < 0 \quad \times$$

4 هر دو قید فعل

$$x_1 = x_2 = 0 \Rightarrow x_1 + x_2 = 0 \neq 2 \quad \times$$

end

بهینه‌سازی محاسبه $\min f(x)$

$x \in \Omega \rightarrow$ محاسبه: $x_1, x_2 \in \Omega \Rightarrow \alpha x_1 + (1-\alpha) x_2 \in \Omega$

$$\Leftrightarrow f(\alpha x_1 + (1-\alpha) x_2) \leq \alpha f(x_1) + (1-\alpha) f(x_2)$$

نتیجه: در بهینه‌سازی متعاقباً اگر مجموعه شعاع نماینده ترتیب تیرید تاری دناتاری را داشتیم، آنگاه مجموعه همچو محاسبه باشد و همچو همچو تابع $f(x)$ محاسبه باشد، درستگی های بیان شده در بهینه‌سازی محاسبه نه حالت دو بعدی تیرید تاری دناتاری نیز برقراری باشد.

Minimize $f(x)$

$$\begin{cases} g_j(x) \leq 0 & j=1, \dots, p \\ h_i(x) = 0 & i=1, \dots, m \end{cases}$$

اگر f فیض مجموعه محاسبه، یک مجموعه محاسبه است \Rightarrow آنگاه قدر محاسبه باشد همچو مجموعه سور

راستگار $\Gamma = \{x : g_j(x) \leq 0\}$ محاسبه است آنگاه $g_j(x)$ همچو تابع محاسبه باشد

$$h_i(x) = 0 \quad \begin{cases} h_i(x) \leq 0 \Rightarrow h_i(x) \text{ همچو محاسبه باشد} \\ -h_i(x) \leq 0 \Rightarrow -h_i(x) \text{ همچو سور باشد} \end{cases} \quad \left. \begin{array}{l} h_i(x) \text{ همچو محاسبه باشد} \\ h_i(x) \text{ همچو سور باشد} \end{array} \right\} \Rightarrow h_i(x) \text{ همچو محاسبه باشد}$$

$$\begin{array}{c} \text{محاسبه } h_i \Rightarrow \nabla^2 h_i(x) \geq 0 \\ \rightarrow \text{محاسبه } -h_i \Rightarrow -\nabla^2 h_i(x) \geq 0 \end{array} \quad \left. \begin{array}{l} \Rightarrow \nabla^2 h_i(x) = 0 \\ \Rightarrow \text{affine} \quad h_i(x) \end{array} \right\} \Rightarrow h_i(x) = Ax + B$$

$$\begin{aligned} L(x, \lambda, \mu) &= f(x) + \lambda^T h(x) + \mu^T g(x) \\ &= f(x) + \sum_{i=1}^m \lambda_i h_i(x) + \sum_{j=1}^p \mu_j g_j(x) \end{aligned}$$

شرط لازم و کافی برآوری (KKT) برای بهینه‌سازی محاسبه:

برطراد (x^*, λ^*, μ^*) باشند و خواص لائزاورث برآوری شوند بهینه‌سازی محاسبه می‌باشد آن‌ها آن را شرط لازم و کافی برآوری می‌دانند:

$$\left\{ \begin{array}{l} h(x^*) = 0, g(x^*) \leq 0 \rightarrow \text{Primal Feasibility} \quad (x: \text{Primal}) \\ \mu^* > 0 \rightarrow \text{dual Feasibility} \quad (\mu, \lambda: \text{dual}) \\ \nabla_x L(x^*, \lambda^*, \mu^*) = \nabla f(x^*) + \lambda^{*T} \nabla h(x^*) + \mu^{*T} \nabla g(x^*) = 0 \rightarrow \text{Lagrangian optimality} \\ \mu^{*T} g(x^*) = 0 \rightarrow \text{Complementary Slackness} \end{array} \right.$$

کنیج جاب در سائل Strictly Convex درین حالت هم برقرار است (با این باره جاب می خواهد) global است
دیگر برخی حالات دیگر نیست

(Duality) کلی

Minimize $f_0(x)$

st. $f_i(x) \leq 0 \quad i=1, \dots, m \rightarrow f_0 \text{ مقداری (optimal value)}: P^*$

$h_i(x) = 0 \quad i=1, \dots, p$

$D = \left(\bigcap_{i=0}^m \text{dom } f_i \right) \cap \left(\bigcap_{i=1}^p \text{dom } h_i \right) \rightarrow$ اشتراک ماده تراویح $\rightarrow x \in D \subseteq \mathbb{R}^n$

(دیلینه سازی) نتی ناد

دیلینه جد شد جاب در D بشد

سندکان (Dual) : سنه اصلی (Primal) \leftarrow سنه بینه سازی بدن قید + سنه بینه سازی

\leftarrow آن سنه اصلی non-Convex و متغیر باشه می تمل آن را به یک سنه بدن تبدیل کرد
تمام ساده تر بشد

\leftarrow حتی برای سائل Convex این تبدیل می تاند نزدیت محاسباتی داشته باشد

\leftarrow این تبدیل می تاند ب حل توزیع شده سندکان کند

$$\text{Lagrangian: } L(x, \lambda, \mu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \mu_i h_i(x)$$

مکن است \min -حدت حری دارد مانند (نیزه‌ترین حدیان) infimum

→ Lagrange dual function: $g(\lambda, \mu) = \inf_{x \in D} L(x, \lambda, \mu)$

$$\min x^2 \rightarrow \text{min} \rightarrow$$

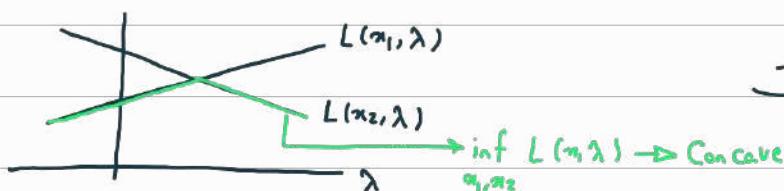
$$\inf_{x>0} x^2 = 0 \rightarrow \text{حاجب طرد غير منتهي}$$

$$\liminf_{n \rightarrow \infty} e^{-n} = 0 \quad \Rightarrow \quad n \rightarrow \infty$$

$$\Rightarrow g(\lambda, \mu) = \inf_{\alpha \in D} L(\alpha, \lambda, \mu) = \inf_{\alpha \in D} \left(f_\alpha(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{i=1}^p \mu_i h_i(x) \right)$$

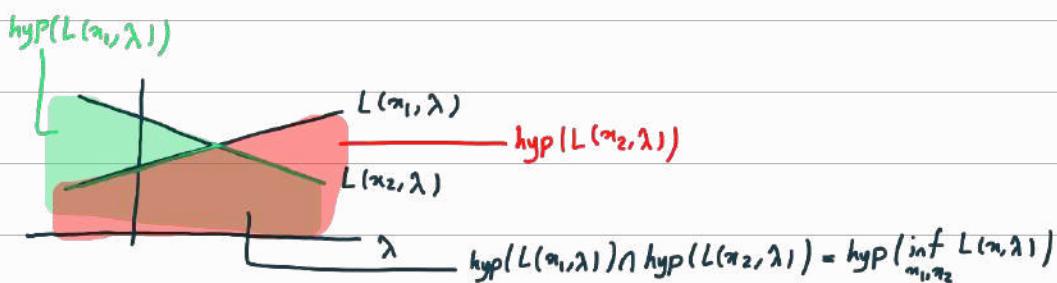
مغلق است این زیر محدود بوده و ممکن جواب نداشته باشد. دایره صرفت
نمی شناسد از این درست استفاده کرد.

-Concave $\Rightarrow g(\lambda, \mu)$ -



است (affine) $\lambda \in \mathbb{R}$ μ دفعی (g(λμ))

مُعِيَّنٌ تَابِعٌ : Hypograph $\rightarrow \text{hyp}(f) = \{(x, r) \in D \times \mathbb{R} \mid f(x) \geq r\}$

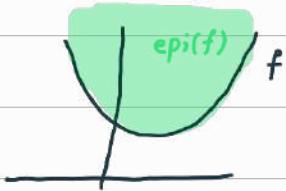


f is Concave iff $\text{hyp}(f)$ is Convex

ناتج \inf_{hyp} معتبر است \Rightarrow استاذ \inf_{hyp} معتبر است \Rightarrow استاذ \inf_{hyp} معتبر است

تعريف Epigraph : $\text{مُعْرَفَة سَاقِب الْوَلَى} \rightarrow \text{epi}(f) = \{(x, r) \in D \times \mathbb{R} \mid f(x) \leq r\}$

f is Conven iff $\text{epi}(f)$ is Conven



- Lower bound property : $g(\lambda, \mu) < P^*$ if $\lambda >$.

$$f_*(\tilde{x}) \geq L(\tilde{x}, \lambda, \mu) = f_*(\tilde{x}) + \sum_{i=1}^m \lambda_i f_i(\tilde{x}) + \sum_{i=1}^p \mu_i h_i(\tilde{x}) \leftarrow \text{دالة بدل لـ } f_* \text{ يأخذ مدخل } \tilde{x} \text{ ويعطي ناتج } L(\tilde{x}, \lambda, \mu)$$

$$L(\tilde{\alpha}, \lambda, \mu) > \inf_{\alpha \in D} L(\alpha, \lambda, \mu) = g(\lambda, \mu) \Rightarrow g(\lambda, \mu) < f_*(\tilde{\alpha})$$

از آنجایی که رابطه برابر با اینکی هر آنچه شنبی برقرار است بنا بر این شامل *^۲ شنبی دستوراتی که در آن f. تبریزی نسخه

$$\Rightarrow g(\lambda, p) \leq f_*(\pi^*) = p^*$$

The (Lagrange) dual Problem: Minimize $g(\mu, \lambda)$

s.t. $\lambda > 0$

و سفر نظر دو عدالت \Rightarrow نه dual محاسبات \Rightarrow $g(\lambda, \mu) = 0$ تاحد ممکن ترتیب می شود

→ مُلْهَمَتْ Conven است دحل آن بُهْرَى هدِیَى بَرَى مُمْ رَا بَ دَسْتْ مَى رَهْرَ

$$d^*: \text{dual minimum} \Rightarrow \text{duality gap} = P^* - d^* \quad \begin{cases} d^* < P^* & : \text{weak duality} \\ d^* = P^* & : \text{strong duality} \end{cases}$$

عکس سایه weak duality (حالت خاص) strong duality (عکس سایه برقرار است) weak duality
 ماده ای برقرار است و همچنین برای بخشنده non-Conven تواند برقرار باشد.

Slater's constraint qualification Constraint qualification (CQ)

minimize $f_0(x)$

s.t. $f_i(x) \leq 0 \quad i=1, \dots, m$

$$Ax = b$$

داخلی (غیر مرزی): interior

$$\exists \tilde{x} \in \text{int } D : f_i(\tilde{x}) < 0 \quad i=1, \dots, m, \quad A\tilde{x} = b$$

و این صفت مطلقاً Conven است و Strictly Feasible است.

شرط CQ برقرار است.

با این حال سایه Strong duality، CQ برقرار خواهد بود Conven شاید.

لایه دناب بود

λ^*, μ^* برقرار KKT شاید x^*, λ^*, μ^* برقرار Strong duality و dual منتهی λ^*, μ^* بودت آنها Conven بودند.

$\lambda^* \geq 0$ ✓ Dual Feasibility

$$g(\lambda, \mu) = \inf_{x \in D} \{L(x, \lambda, \mu)\} \rightarrow x^* = \operatorname{Argmin}_{x \in D} L(x, \lambda^*, \mu^*) \quad \checkmark \text{ Lagrange optimality}$$

λ^*, μ^* برقرار

x^* برقرار است آنرا باید بدانیم. این حالت ممکن است های ریگری هم برداشت باید که مربوط به Primal Feasibility باشد Complementarity slackness.

اگر x^* بودت آسه از رابطه فوق Complementary Slackness و Feasibility شرایطی کند که این صفت باعث بینه سنه Primal خواهد بود.

یک حالت خاصی این است که مسنه Primal جواب بینه کننده باشد Strictly Convex بوده. در این صفت حل مسنه dual باعث بینه سنه Primal خواهد دارد. در غیر این صفت فتناً باید شرایط KKT احراز شود.

Primal بینه سنه

$$P^* = f_0(x^*) - g(\lambda^*, \mu^*) = \inf_{\alpha} \left\{ f_0(\alpha) + \sum_{i=1}^m \lambda_i^* f_i(\alpha) + \sum_{i=1}^p \mu_i^* h_i(\alpha) \right\}$$

↑
strong duality

$$= f_0(\tilde{\alpha}) + \sum_{i=1}^m \lambda_i^* f_i(\tilde{\alpha}) + \sum_{i=1}^p \mu_i^* h_i(\tilde{\alpha}) \rightarrow \text{بردست آسه نزد } x^* \text{ میشود}$$

$$\text{بردست } \tilde{\alpha} \Rightarrow f_0(\tilde{\alpha}) + \underbrace{\sum_{i=1}^m \lambda_i^* f_i(\tilde{\alpha})}_{\geq 0} + \underbrace{\sum_{i=1}^p \mu_i^* h_i(\tilde{\alpha})}_{\leq 0} \leq f_0(\tilde{\alpha})$$

Feasibility $\Rightarrow 0$

$$\text{آنچه که باعث میشود: } f(x^*) = f_0(x^*) = f_0(\tilde{\alpha}) = f_0(\tilde{\alpha}) + \underbrace{\sum_{i=1}^m \lambda_i^* f_i(\tilde{\alpha})}_{\geq 0} + \underbrace{\sum_{i=1}^p \mu_i^* h_i(\tilde{\alpha})}_{\leq 0} \Rightarrow \text{Complementary slackness} \checkmark$$

بنه بینه سنه Primal خواهد بود

آخرین بینه سنه که میتواند باشد آسه از رابطه فوق Complementary Slackness و Feasibility شرایطی کند Primal بینه سنه

داین حالت شرطی دری تغییرهای Dual (μ^*, λ^*) هم داشت شرود نتیجه این تغییرها برابر خواهی لازماً بینه سنه Primal هست.

Complex

$$\min \sum_{i=1}^n f_i(x_i)$$

s.t. $a^T x = b$

$$f_i(x_i) = \frac{1}{2} c_i x_i^2$$

$$x = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

$$g(\mu) = \min_{\alpha} \left\{ \sum_{i=1}^n \frac{1}{2} c_i \alpha_i^2 + \mu(b - a^T \alpha) \right\} = \mu b + \min_{\alpha} \left\{ \sum_{i=1}^n \frac{1}{2} c_i \alpha_i^2 - \mu \sum_{i=1}^n a_i \alpha_i \right\}$$

$$= \mu b + \min_{\alpha} \left\{ \sum_{i=1}^n \left(\frac{1}{2} c_i \alpha_i^2 - \mu a_i \alpha_i \right) \right\} = \mu b + \sum_{i=1}^n \min_{\alpha_i} \left\{ \frac{1}{2} c_i \alpha_i^2 - \mu a_i \alpha_i \right\}$$

$$\Rightarrow \alpha_i^* = \frac{a_i \mu}{c_i} \Rightarrow g(\mu) = \mu b + \sum_{i=1}^n \left[\frac{1}{2} \frac{a_i^2}{c_i} \mu^2 - \frac{a_i^2}{c_i} \mu^2 \right] = \mu b - \frac{\mu^2}{2} \underbrace{\sum_{i=1}^n \frac{a_i^2}{c_i}}_t = b\mu - \frac{1}{2} t \mu^2$$

$$\underset{\mu}{\operatorname{Max}} \quad b\mu - \frac{1}{2} t \mu^2 \Rightarrow \mu^* = \frac{b}{t} \Rightarrow \alpha_i^* = \frac{a_i \mu^*}{c_i} = \frac{a_i b}{c_i t}$$

بروی این نزدیکی حل بته مارکینه عمدتاً از دشمن سیر استفاده می شود. دشمن اینکه حل اصلی نیاز باشد یا نباید از زیرگردیان استفاده نماید کاری برای

ارتباط بین تابع لامارک و ساده بینه داشت Dual, Primal

نحوی: دست بردار آسن مقداری از اسنهای دیگر از اسنهای دیگر
نحوی: دست بردار آسن مقداری از اسنهای دیگر از اسنهای دیگر

$\alpha^*, z \in \text{Man}$

$$\varphi(x^*, z) \leq \varphi(x^*, z^*) \leq \varphi(x, z^*) \quad \forall x \in X, \forall z \in Z$$

$z^* \in \text{min}_{z \in Z} \varphi$

بلطفاً می توانست $x^* \in X, z^* \in Z$ یک نظریه برای تابع φ است اگر منطق است:

$$\sup_{z \in Z} \varphi(x^*, z) = \varphi(x^*, z^*) = \inf_{x \in X} \varphi(x, z^*) \rightarrow \text{نظریه باریست}$$

ل: اگر بخت (x^*, z^*) یک نظریه‌بازی آجع فیزیک تاری برتر است:

$$\sup_{z \in Z} \inf_{x \in X} \psi(x, z) = \inf_{x \in X} \sup_{z \in Z} \psi(x, z) \rightarrow \text{تربیت اعلی}$$

ابت:

$$\text{minimax inequality: } \forall \bar{z} \in Z \quad \psi(x, \bar{z}) \leq \sup_{z \in Z} \psi(x, z)$$

$$\Rightarrow \forall \bar{z} \in Z \quad \inf_{x \in X} \psi(x, \bar{z}) \leq \inf_{x \in X} \sup_{z \in Z} \psi(x, z)$$

برای کنتمبر $\Rightarrow \sup_{\bar{z} \in Z} \inf_{x \in X} \psi(x, \bar{z}) \leq \inf_{x \in X} \sup_{z \in Z} \psi(x, z)$ ①
است

هر شرطی برتر است \leftarrow minimax inequality

Example

$$f(x, y) = x + y \quad S = \{(x, y) \mid x=0, 1, 2, y=0, 1, 2, |x-y| < 2\}$$

$$|x-y| < 2$$

$$\sup_y \rightarrow y=2 \rightarrow \inf_x \downarrow \rightarrow x=1 \rightarrow \inf_x \sup_y f = 1+2=3$$



$$\inf_x \rightarrow x=0 \rightarrow \sup_y \rightarrow y=1 \rightarrow \sup_y \inf_x f = 0+1=1$$

$$\sup_z \psi(x^*, z) = \psi(x^*, z^*) = \inf_x \psi(x, z^*) \quad \text{اگر نظریه‌بازی } (x^*, z^*) \text{ اعلی}$$

$$\Rightarrow \inf_x \sup_z \psi(x, z) \leq \sup_z \psi(x^*, z) = \psi(x^*, z^*) = \inf_x \psi(x, z^*) \leq \sup_z \inf_x \psi(x, z)$$

$$\Rightarrow \inf_n \sup_z \varphi(n, z) \leq \sup_z \inf_n \varphi(n, z) \quad \text{②}$$

$$\text{①, ②} \Rightarrow \inf_n \sup_z \varphi(n, z) = \sup_z \inf_n \varphi(n, z) \quad \square$$

نتیجه: (x^*, z^*) نقطه زیستی باعث φ است اگر روش تاریک \min_{\max} برقرار بشد و x^* , z^* به ترتیب یعنی مسئله رشته زیستی برقرار شوند:

$$\begin{cases} x^* = \operatorname{Argmin}_n \sup_z \varphi(n, z) \\ z^* = \operatorname{Argmax}_z \inf_n \varphi(n, z) \end{cases}$$

نات: آنکه x^* , z^* یعنی مسئله زیستی مسئله \min_{\max} بشدند.

$$z^* = \operatorname{Argmax}_z \dots$$

$$x^* = \operatorname{Argmin}_n \dots$$

$$\sup_z \inf_n \varphi(n, z) = \inf_n (\sup_z \varphi(n, z)) \leq \varphi(x^*, z^*) \leq \sup_z \varphi(x^*, z) = \inf_n \sup_z \varphi(n, z) \quad \text{③}$$

حل روش تاریک \min_{\max} برقرار بشد، تاریک در مسأله نفعاً عادلات مفق برقرار است

$$\Rightarrow \inf_n (\sup_z \varphi(n, z)) = \varphi(x^*, z^*) = \sup_z \varphi(x^*, z) \rightarrow \varphi \text{ باعث } (x^*, z^*) \text{ می‌شود}$$

نات: عکی: اگر (x^*, z^*) نقطه زیستی باعث φ باشد، بهم فواید نات: \min_{\max} برقرار است. یعنی برای این نفعاً عادله \star تاریک در مسأله نفعاً عادله برقرار مفاهمش که در نتیجه آن x^* , z^* یعنی مسئله زیستی مفق خواهند بود:

$$\Rightarrow \sup_z \inf_n \varphi(n, z) = \inf_n (\sup_z \varphi(n, z)) = \varphi(x^*, z^*) = \sup_z \varphi(x^*, z) = \inf_n \sup_z \varphi(n, z)$$

$$\rightarrow x^* = \operatorname{Argmin}_n \sup_z \varphi$$

$$\rightarrow z^* = \operatorname{Argmax}_z \inf_n \varphi$$

تفیه فیتی (٢,٣,٤) میں نظر نہیں برداشت لارا شدی (٢,٣,٤) است اور نقطہ اگر x^*, λ^*, μ^* دوں (٢,٣,٤)

بترتیب باعینہ سنه Dual، Primal بُنندھیں برداشت بہتر ہے

Dual \rightarrow Primal (٢,٣,٤) بہت آئندہ نہیں پسندی خیس x^*, λ^*, μ^* باعینہ سالنے
میں برداشت Strong duality ہے

$$L(x, \lambda, \mu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \mu_j h_j(x)$$

$$\Rightarrow \sup_{\lambda \geq 0, \mu} L(x, \lambda, \mu) = \begin{cases} f_0(x) & \rightarrow \text{Feasible } x: \begin{cases} h_i(x) = 0 \\ f_i(x) \leq 0, \lambda \geq 0 \end{cases} \\ \infty & \rightarrow \text{تفوکرانہیں} \end{cases}$$

$\Rightarrow \inf_x \sup_{\lambda \geq 0, \mu} L(x, \lambda, \mu) = P^* \rightarrow$ جواب فیلڈ میں انتسابی
حدت اینے مدار ∞ میں تعدد دیجیے حل اینی
سنه سمجھیے حل سنه Primal میں تعدد

$$\Rightarrow x^* = \operatorname{Argmin}_x \sup_{\lambda \geq 0, \mu} L(x, \lambda, \mu) \rightarrow \text{Primal جواب سُنے}$$

$$\text{Dual سُنے: } \sup_{\lambda \geq 0, \mu} \inf_x L(x, \lambda, \mu) = d^*$$

$$\Rightarrow (\lambda^*, \mu^*) = \operatorname{Argmax}_{\lambda \geq 0, \mu} \inf_x L(x, \lambda, \mu) \rightarrow \text{Dual جواب سُنے}$$

اُسراز Strong duality برداشت تے آنکہ $P^* = d^*$ دامن مابطہ نہیں

$$\inf_x \sup_{\lambda \geq 0, \mu} L(x, \lambda, \mu) = \sup_{\lambda \geq 0, \mu} \inf_x L(x, \lambda, \mu) \rightarrow \text{minimum تے} \rightarrow \text{minimum تے} = \text{Strong duality}$$

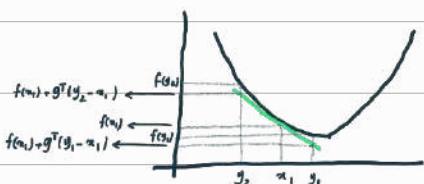
دنیاں (٢,٣,٤) میں نظر نہیں برداشت لارا شدی (٢,٣,٤) است اور (٢,٣,٤) سط نہیں پسند تے
کہ معامل strong duality است برداشت

زیرگرادیان (subgradient)

نوعی تفاضل است به مسئله زیرگرادیان (عموماً برای بینه‌سازی تفاضل) انتساب دارد که می‌تواند در همه نقاط
برای تفاضلConvex تابعConvex تابع است.

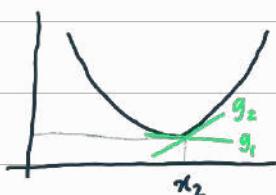
تعریف: مجدداً و یک زیرگرادیان را برای تفاضل داریم که این است که:

$$f(y) \geq f(x) + g^T(y - x) \quad \forall y \in X$$



نیش فقط ($g = g^T$) اعمال زیرگرادیان است
(در تفاضل Convex)

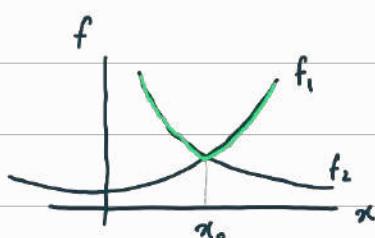
super gradient : نیش بزرگتر از نیش Concave



هر شیوه‌ی g_1 و g_2 مترانه \rightarrow تفاضل f در نقطه x_2 پذیرنیست \rightarrow
پس g_1 و g_2 subgradient

Example

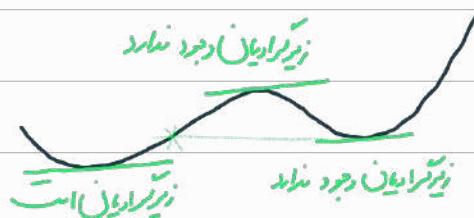
$$f = \max(f_1, f_2)$$



زیرگرادیان تفاضل f :

$$\begin{cases} f_1(x) > f_2(x) \Rightarrow g = \nabla f_1(x) \\ f_2(x) > f_1(x) \Rightarrow g = \nabla f_2(x) \\ f_1(x) = f_2(x) \Rightarrow g \in [\nabla f_2(x_0), \nabla f_1(x_0)] \end{cases}$$

end

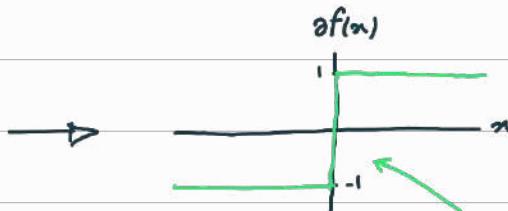


برای تابع Convex زیرگرادیان دارای ساخت
جود دارد که هر تابع محدب دارای ساخت زیر آن است

زیردیفرانسیل (subdifferential) : به مجموعه زیرگرادیان های تابع f در x نیز دینامیکی $\partial f(x)$ نویش می دهند

$$\partial f(x) = \{g : f(z) \geq f(x) + g^T(z-x) \quad \forall z \in X\}$$

$$f: X \subseteq \mathbb{R}^n \rightarrow \mathbb{R} \quad g \in \mathbb{R}^n$$



کل جزو $[1, -1]$ را صفت خواهد زیردیفرانسیل است

با استفاده از مسئله زیرگرادیان $\left\{ \begin{array}{l} \text{تابع غیردستی زیرگرادیان} \\ \text{هدایی آساق می امده} \end{array} \right.$
مانند است در هر iteration ستد تابع هدف کم شود وی در نسبت قدرای سود

Distributed & Decomposition & Compatible

د فضه تابع به فضی علی می کند Projected Subgradient

نیاز نداریم زیرگرادیان دارای ماده تابع دارد و داشته باشد

آنرا زیرگرادیان برای بینه سازی سائل محدب:

مذکور

$$f(x) : \mathbb{R}^n \rightarrow \mathbb{R} \rightarrow \text{حداصلت بین تصور انتظاری این}$$

$$\Rightarrow \text{initial } x_0 \in \mathbb{R}^n$$

$$x_{k+1} = x_k - \alpha_k g_k$$

step size α_k of مرحله k \rightarrow یک زیرگرادیان تابع f در نقطه (x_k, α_k)

بر دلیل ساده سوی این امر در دو مرتبه
زیرا رایان را تواند نشانه نهاد

دستگاه دستگاه f حرکتی کسر ایجاد می‌شود زیرا رایان استقرانیست

$$f_k^{\text{best}} = \min_{i=1, \dots, k} f(x_i) \rightarrow \text{نرخ} f(x_k)$$

Step size: 1 نسبت: $\alpha_k = \alpha$

$$2 \text{ طول} \frac{\gamma}{\|g_k\|} \Rightarrow \alpha_k = \frac{\gamma}{\|g_k\|}$$

$$\|x_{k+1} - x_k\| = \left\| \frac{\gamma}{\|g_k\|} g_k \right\| = \gamma$$

$$3 \text{ مجموع مربعات تعداد} \sum_{k=1}^{\infty} \alpha_k^2 < \infty \quad \sum_{k=1}^{\infty} \alpha_k = \infty$$

$$\lim_{k \rightarrow \infty} \alpha_k = 0 \quad \text{non summable} \quad \text{squared summable}$$

$$4 \alpha_k = \frac{1}{k} \quad \text{نسبت} \alpha_k \text{ بین مکمل باستهایی} \rightarrow \text{بینهایی شود}$$

$$4 \text{ مجموع مربعات تعداد} \lim_{k \rightarrow \infty} \alpha_k = 0 \quad \sum_{k=1}^{\infty} \alpha_k^2 = \infty \quad \sum_{k=1}^{\infty} \alpha_k = \infty$$

$$\alpha_k = \frac{1}{k^{0.5}}$$

تفصیل هدایی و هدایی به متداولی برای این الگوریتم را بررسی می‌کنیم

$$f(x^*) = f^* = \inf_x f(x) > -\infty \quad \text{نحوه این} \alpha^* \text{ وجود دارد به طوری که:} \quad 1 \text{ نفرهای (هدایی):}$$

$$2 \quad \|g\|_2 \leq G \quad \forall g \in \partial f \quad \forall x \in \mathbb{R}^n$$

نامه رسمی ارسی (سرایط ارسی این مقدار بین (x^*) محدود باشد: 3

آنکه سرایط ارسی محدود انتساب شدن x^* بین محدود باشد

عمل همایی الگوریتم زیر را دانلود:

$$\|x_{k+1} - x^*\|_2^2 = \|x_k - \alpha_k g_k - x^*\|_2^2 = (\underbrace{x_k - \alpha_k g_k - x^*}_\text{ })^\top (\underbrace{x_k - \alpha_k g_k - x^*}_\text{ })$$

$$= \|x_k - x^*\|_2^2 - 2\alpha_k g_k^\top (x_k - x^*) + \alpha_k \|g_k\|_2^2$$

$\uparrow \alpha_k g_k^\top (x_k - x^*) = \alpha_k (x_k - x^*)^\top g_k$

تعیین زیر مراحل: $f(y) \geq f(x) + g^\top (y - x) \rightarrow y \rightarrow x^*, x \rightarrow x_k$

$$\Rightarrow g_k^\top (x^* - x_k) \leq f(x^*) - f(x_k)$$

$$\Rightarrow \|x_{k+1} - x^*\|_2^2 \leq \|x_k - x^*\|_2^2 - 2\alpha_k (f(x_k) - f(x^*)) + \alpha_k^2 \|g_k\|_2^2$$

عملیاتی کسری: $\sum_{i=1}^k \alpha_i$

$$\Rightarrow \sum_{i=1}^k \|x_{i+1} - x^*\|_2^2 \leq \sum_{i=1}^k \|x_i - x^*\|_2^2 - 2 \sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) + \sum_{i=1}^k \alpha_i^2 \|g_i\|_2^2$$

$$\Rightarrow \|x_{k+1} - x^*\|_2^2 \leq \|x_1 - x^*\|_2^2 - 2 \sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) + \sum_{i=1}^k \alpha_i^2 \|g_i\|_2^2$$

$$\Rightarrow \|x_{k+1} - x^*\|_2^2 \geq \|x_1 - x^*\|_2^2 - 2 \sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) + \sum_{i=1}^k \alpha_i^2 \|g_i\|_2^2 \geq 0$$

$$\Rightarrow \sum_{i=1}^k \alpha_i (f(x_i) - f(x^*)) \geq \sum_{i=1}^k \alpha_i (f_k^{\text{best}} - f^*)$$

(فرضیه: $\langle R^2 \rangle$)

$$\Rightarrow \|\alpha_i - \alpha^*\|^2 - 2 \sum_{i=1}^k \alpha_i (f_k^{best} - f^*) + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2 \geq 0$$

$$\Rightarrow (2 \sum_{i=1}^k \alpha_i) (f_k^{best} - f^*) \leq R^2 + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2$$

$$\Rightarrow f_k^{best} - f^* \leq \frac{R^2 + \sum_{i=1}^k \alpha_i^2 \|g_i\|^2}{2 \sum_{i=1}^k \alpha_i}$$

(فرضیه: $\|g_i\| \in G$)

1 تابع α : $f_k^{best} - f^* \leq \frac{R^2 + G^2 \sum_{i=1}^k \alpha_i^2}{2 \sum_{i=1}^k \alpha_i} = \frac{R^2 + kG^2 \alpha^2}{2k\alpha}$

$$k \rightarrow \infty \Rightarrow f_k^{best} - f^* \leq \frac{G^2 \alpha}{2}$$

آنچه هنرای شد را در بازدیدی ساده از این نتیجه می بینیم

جواب باتوجهی مانند

لئے α کو حکم این حد را در حلقہ فی آنہ باعثیت پیدا نمی کند

2 طبقه بندی: $f_k^{best} - f^* \leq \frac{R^2 + \sum_{i=1}^k \frac{\gamma^2}{\|g_i\|^2} \|g_i\|^2}{\frac{2}{G} \sum_{i=1}^k \gamma} \leq \frac{R^2 + \sum_{i=1}^k \gamma^2}{\frac{2}{G} \sum_{i=1}^k \gamma} = \frac{R^2 + k\gamma^2}{\frac{2k\gamma}{G}}$

$$k \rightarrow \infty \Rightarrow f_k^{best} - f^* \leq \frac{\gamma G}{2} \rightarrow \text{با کوچکترین ترتیب ترتیب شده ای} \\ \text{بخطهای کوچکتری بین اجرا کر}$$

3 $\sum_{i=1}^k \alpha_i = \infty$, $\sum_{i=1}^k \alpha_i^2 < \infty$: $f_k^{best} - f^* \leq \frac{R^2 + G^2 \sum_{i=1}^k \alpha_i^2}{2 \sum_{i=1}^k \alpha_i}$

$$k \rightarrow \infty \Rightarrow f_k^{best} - f^* \leq 0 \quad \underline{f_k^{best} > f^*} \Rightarrow f_k^{best} = f^*$$

لئے استنباط جواب بنیه هنرای شود

4 $\sum_{i=1}^k \alpha_i = \infty$, $\sum_{i=1}^k \alpha_i^2 = \infty$, $\lim_{k \rightarrow \infty} \alpha_i = 0$

→ انتہا لیکچر نوت

$$\frac{d}{k} \rightarrow \alpha_k = \frac{1}{k^{0.5}} \Rightarrow \lim_{T \rightarrow \infty} \frac{\sum_{k=1}^T \frac{1}{k}}{\sum_{k=1}^T \frac{1}{k^{0.5}}} = 0 \rightarrow \text{بازگشت این عبارت در } T+1 \text{ مرحله} \rightarrow \text{تلخ بدن آن نماید}$$

$$k \rightarrow \infty \rightarrow f_k^{\text{best}} \rightarrow f^* \rightarrow \text{نه این حالت هم بجزایر بینه درست}$$

- ← دیگری هایی : subgradient +
- 1 نسخه اول
 - 2 نسبت به نسخه هایی ماتده ترین (مرتبه دهم) کنتراست
 - 3 مثلاً : 1. مطالعه برای تراویح شروع نماید
 - 4 مطالعه ساده
 - 5 مطالعه نسبت برای استفاده در الگوریتم های توزیع شده غیرمتراز
 - 6 مطالعه استفاده در حالت معده

: (Projected subgradient method)

$$\min f(x)$$

$$\text{s.t. } x \in D \quad D \subseteq \mathbb{R}^n, \text{ Convex} \rightarrow \text{داری Convex}$$

$$\rightarrow x_{k+1} = \text{Pr}_D(x_k - \alpha_k g_k) \rightarrow x_k - \alpha_k g_k$$

دارد انتساب چیزی

نحوه ایجاد مجموعه D که محدودیت نامحدود را از بردارهای x برداشته باشد

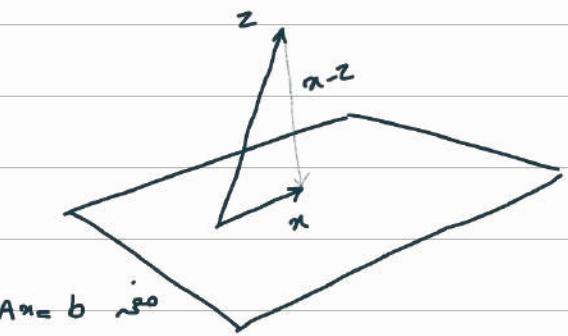
$$\Pi_D(x) = \text{Pr}_D(x) = \underset{\tilde{x} \in D}{\text{Arg min}} \|x - \tilde{x}\| \quad : \text{projection}$$

Example

$$\min f(x)$$

$$\text{s.t. } Ax = b$$

$$\Rightarrow \alpha_{k+1} = P_{A\alpha=b} \underbrace{(\alpha_k - \alpha_k g_k)}_{z} \quad z$$



$\min \|x - z\|^2 \rightarrow z$ بردار x به طوری است که مینیموم $\|x - z\|^2$ باشد
 s.t. $Ax = b$ که x متعین - معمولی است $Ax = b$

(زیرا بزرگتر از آن است) $L(x, \lambda) = \|x - z\|^2 + \lambda^T (Ax - b)$

$$\frac{\partial L}{\partial x} = 2(x - z) + A^T \lambda = 0 \xrightarrow{Ax} 2(Ax - Az) + AA^T \lambda = 0 \Rightarrow \lambda = 2(AA^T)^{-1}(Az - b)$$

برای مatrیس A بزرگ باشد \leftarrow ته داشت A متمم رکابی به ماتریس است \leftarrow

جایگزینی λ با α $\xrightarrow{\text{جایگزینی}} x = z - A^T (AA^T)^{-1}(Az - b)$ $\xrightarrow{\text{منتهی است}} \text{منتهی است}$ \leftarrow شرط مستقل (آن) \leftarrow دلخواست

$$\Rightarrow x_{k+1} = x_k - \alpha_k g_k - A^T (AA^T)^{-1}(A(x_k - \alpha_k g_k) - b) = x_k - \alpha_k g_k - A^T (AA^T)^{-1}(b - A\alpha_k g_k - b)$$

$$= x_k - \alpha_k g_k - A^T (AA^T)^{-1}(-A\alpha_k g_k)$$

این ترتیب بزمول اصلی اضافه نشود

$$\Rightarrow x_{k+1} = x_k - \alpha_k \underbrace{[I - A^T (AA^T)^{-1} A]}_{P_{N(A)}(g_k)} g_k$$

$$\frac{P_{N(A)}(g_k)}{A\alpha=0}$$

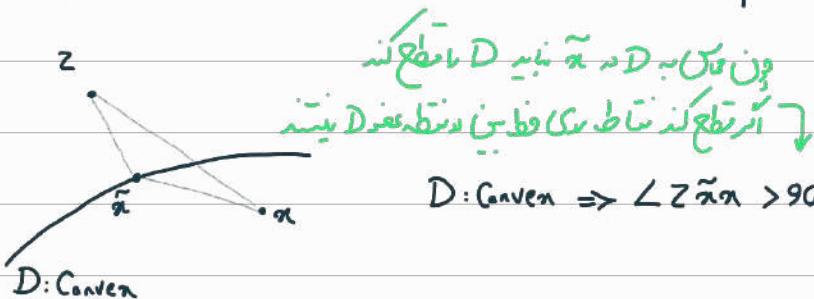
$$\xrightarrow{z \leftarrow g_k, b \leftarrow 0} P_{N(A)}(g_k) = g_k - A^T (AA^T)^{-1}(Ag_k - 0) = (I - A^T (AA^T)^{-1} A)g_k$$

end

هر دوی الگوریتم زیر را دیالن تقدیر نموده: بازدهیات مثبت و stepsize نیز

$$\begin{aligned} \text{دالة الخط الابعد} \\ \left\{ \begin{array}{l} Z_{k+1} = x_k - \alpha_k g_k \\ x_{k+1} = \Pi_b(Z_{k+1}) \end{array} \right. \end{aligned}$$

$$\|\Pi_D(z) - x\| \leq \|z - x\| \quad \forall x \in D \quad : \text{ـ ابرابر Non expansive} \quad \text{ـ} \quad \Pi_D(z)$$



$x^* \in D$: Convex

$$\|x_{k+1} - x^*\|^2 = \|P_D(z_{k+1}) - x^*\|^2 \leq \|z_{k+1} - x^*\|^2 \rightarrow \text{نماین این مرحله بعده ابتدا همیزی شاید}$$

حالت اللهم زر ملائیکاً بین آسم فراہد بحدود

شامل شاہزادی مرضیہ Conven برلن جمیعہ تحریر

الدستور نیز ایساں تصریح کر دے ہے اس کا فائدہ

— — — — —

* حل سنه dual به تدگ رسن ترايان تغويير شده

$$\text{Primal : } \min f_0(x) \quad \rightarrow \quad \text{dual Max } g(\lambda)$$

$$\text{s.t. } f_i(x) \leq 0 \quad i=1, \dots, m \quad \text{s.t. } \lambda \geq 0$$

$$L(\alpha, \lambda) = f_0 + \sum_{i=1}^m \lambda_i f_i(\alpha) \Rightarrow g(\lambda) = \inf_{\alpha} L(\alpha, \lambda) \Rightarrow \begin{cases} \text{Max } g(\lambda) & \Rightarrow \min -g(\lambda) \\ \text{s.t. } \lambda \geq 0 & \text{s.t. } \lambda \geq 0 \end{cases}$$

مُلاشَّان دارم $g'(x) < 0$ است و نسبت به x Concave ، دنباران $(g(x))$ -تایی است

ازین زیرمکان اسعادیتی می‌گزینیم \leftarrow Current optimization

تقریب (4) ممکن است ساده باشد و دسته تعمیرسازی برای آنها نیز ساده باشد. بین الگوریتم زیربرایان (تعمیرشده) و ریشه dual که تقریب affine در اعمال می‌گیریم از زیر حل شده dual نسبت به Primal در نظر است.

الگوریتم زیربرایان تعمیرشده

$$h_k \in \partial(-g(\lambda_k))$$

$\lambda_{k+1} = [\lambda_k - \alpha_k h_k]_+$, $(\alpha)_+ = \max(\alpha, 0)$ است \rightarrow تعمیرسازی برای اسادیر + باینی معنی است
که آن متغیر بودست آنها نسبت بر خود آن متغیر
در غیراین صورت متغیر غیرلایظ ظاهر شد

که تعمیرسازی برای هلا ساخت

$$-g(\lambda) = \sup_n - (f_0(n) + \lambda_1 f_1(n) + \dots + \lambda_n f_n(n))$$

$$-g(\lambda) = -\inf_n L(n, \lambda) = \sup_n -L(n, \lambda)$$

$$\Rightarrow \lambda^* : h(-L(n, \lambda)) = -[f_1(n), \dots, f_n(n)]^\top \forall n$$

$$\sup_n -L(n, \lambda) \rightarrow \lambda^* \Rightarrow h_k = -[f_1(\alpha^*(\lambda_k)), \dots, f_n(\alpha^*(\lambda_k))]^\top$$

که درین قطی بین (n, λ) نسبت به λ زیربرایان هم به سانچی می‌شود

بهینه سازی غیر متمرکله (Decentralized Optimization)

فرض کنیم مجموعه ای از n عامل / Node ها دارای تابع هدف $N = \{1, \dots, n\}$ که هر یک از عامل / Node ها دارای تابع هدف f_i است، $i = 1, \dots, n$ و متغیر قسمگری x_i دارد. هدف حل مسئله های بهینه سازی با انتقال ذیل می باشد:

$$\underset{x_1, \dots, x_n, y}{\text{Minimize}} \quad \sum_{i=1}^n f_i(x_i, y)$$

و (تغییر) Primal مربوط به مجموع f_i از Agent ها نیست → تغییراتی (Complicating Variable)

$$\underset{\text{st. } \sum_{i=1}^n x_i \leq c}{\text{Minimize}} \quad \sum_{i=1}^n f_i(x_i)$$

متغیر تبادل ایجاد می کند → Decompose

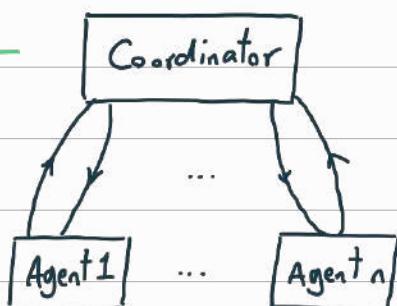
:

با استفاده از این فرایند لامارش، λ (تغییر Dual) مربوط به مجموع f_i از Agent ها نیست

دلالت عمل سرگرمانی نیز: ۱. کسری محاسباتی دعم اطلاعات تبادل اطلاعات و عم رترن (یعنی ارسال اطلاعات تابع) (Agent) ها

- 2. جم محاسباتی مسئله سرگرمانی تبادل اطلاعات (اتاسی) تعداد Agent ها در نظر نمی گیرد
- 3. بردار قسمگری (Dual) حل سرگرمانی را مستقیماً کنایه می کند
- 4. اطلاعات خصوصی کاربران (Agent) ها ممکن است مخواهد اطلاعات ان را در اختیار Agent بلاذی تراو دهد

چون تغییر میدهند تداخلی دارند (جبر) Coordinator
نیاز است می ارتباط Agent ها باشند
با کسری کنیم (راهنمایی اینجا این Agent هاست)



بنای کنی حل مسئله بهینه سازی غیر متمرکله:

Resource Allocation

Example

x_i : مقدار عیوب (کار/بران/...) به عمل کرد

$$\sum_{i=1}^n x_i \leq c : \text{محدودیت نابغ}$$

f_i : میزان ترجیح/ضرایب (Utility) عامل x_i از دریافت x_i :

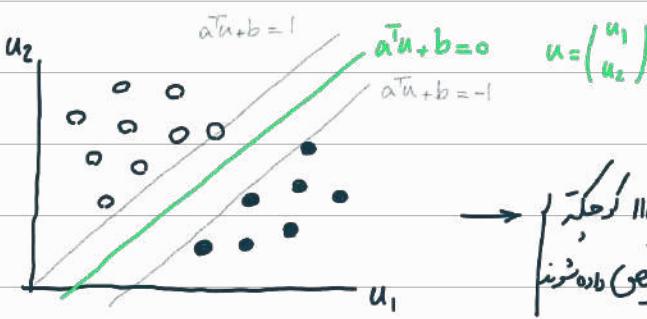


کسی Agent درست دارد مثلاً بین کار x_i داشته باشد

$$\Rightarrow \text{Minimize} \sum_{i=1}^n f_i(x_i)$$

$$\text{s.t. } \sum_{i=1}^n x_i \leq c$$

Another Example



: SVM حل فشرنگی

Margin $\|u\|$ بزرگتر \rightarrow generalization
نه خاکی $\|u\|$ بین از حد کر جدید نزد کر Data point های بینهای است به توجه داشتن

Data points: $\{(z_j, y_j), j=1, \dots, p\}$

\rightarrow z_j Feature

\rightarrow y_j Label: $\circ y_j = -1, \bullet y_j = 1$

\rightarrow $z_j \in \mathbb{R}^2$

$$\Rightarrow \underset{a,b}{\text{minimize}} \quad \frac{\lambda}{2} \|a\|^2 + \sum_{j=1}^p \max(0, 1 - y_j(a^T z_j + b))$$

↓ Margin > 0 Margin < 0 or violate
 ↓ Minimize Margin

Hard Constraint: $y_j(a^T z_j + b) \geq 1 \Rightarrow \begin{cases} y_j = 1 \rightarrow a^T z_j + b \geq 1 \\ y_j = -1 \rightarrow a^T z_j + b \leq -1 \end{cases}$

Soft Constraint

نیز classify داده های کرست $\rightarrow y_j(a^T z_j + b) \geq 1 \Rightarrow \max(0, 1 - y_j(a^T z_j + b)) = 0$

نیز classify داده های که نیست $\rightarrow y_j(a^T z_j + b) < 1 \Rightarrow \max(0, 1 - y_j(a^T z_j + b)) = 1 - y_j(a^T z_j + b)$

نه بینه سازی تعداد داده هایی که اشتباه شوند را مینمی کند

فرض کنید مجموعه داده هادر m محل خلاص توزیع شده اند

$$\{ (z_i, y_i), i \in S_i \} : \text{مجموعه داده های محل } i \rightarrow \bigcup_{i=1}^m S_i = \{1, \dots, m\}, \bigcap_{i=1}^m S_i = \emptyset$$

↓ index set

(مجموعه اندیس داده های محل i)

$$\Rightarrow \underset{a,b}{\text{minimize}} \quad \sum_{i=1}^m \left(\frac{\lambda}{2m} \|a\|^2 + \sum_{l \in S_i} \max(0, 1 - y_l(a^T z_l + b)) \right)$$

$f_i(x), x = (a, b)$

$$\Rightarrow \underset{x}{\text{minimize}} \quad \sum_{i=1}^m f_i(x) \rightarrow x: \text{تغیر تابعی}, f_i: i(\text{Node}) \text{ or Private} \text{ حادثه ای اطلاعات}$$

هدف: به محل مسائل ارتباط بین Coordinator سه اصلی حل شود

* Decomposition in Optimization

→ Convex Optimization 2 - Boyd

مثال جوابی بزرگ:

$$\begin{array}{l} \text{Minimize } f_1(x_1) + f_2(x_2) \\ \text{s.t. } x_1 \in C_1, x_2 \in C_2 \end{array} \equiv \left(\begin{array}{l} \text{Minimize } f_1(x_1) \\ x_1 \in C_1 \end{array} \right) + \left(\begin{array}{l} \text{Minimize } f_2(x_2) \\ x_2 \in C_2 \end{array} \right)$$

لے ساخت دو تغیراتی مسکنی یا تغیراتی دو دسوار \leftrightarrow بحثت بزرگی جوابی بزرگ است

ب فرآوریهای (جع) این ساختهای سایر ابرآوردهای غیر تزویی نیز جوابی بزرگ است
غیر تزویی مسکن ب حکایت آنها

Min \leq Max: ابرآوری ساخت

$$\rightarrow \underset{\substack{x_1 \in C_1 \\ x_2 \in C_2}}{\text{minimize}} \Psi(f_1(x_1), f_2(x_2)) \equiv \Psi\left(\underset{x_1 \in C_1}{\text{minimize}} f_1(x_1), \underset{x_2 \in C_2}{\text{minimize}} f_2(x_2)\right)$$

ملا این قیمت بزرگ ابرآور (تنقیح) بر مدار نیست

Example

$$\min x_1^2 - x_2^2$$

$$0 \leq x_1 \leq 1$$

$$0 \leq x_2 \leq 2$$

$$\Rightarrow x_1 \rightarrow \min, x_2 \rightarrow \max \Rightarrow \min x_1^2 - x_2^2 = -4$$

$$0 \leq x_1 \leq 1$$

$$0 \leq x_2 \leq 2$$

$$\left(\min_{x_1 \in A} x_1^2 \right) - \left(\min_{1 \leq x_2 \leq 2} x_2^2 \right) = -1 \neq -4$$

• مسئلہ با تعییر تداخلی (Complicating/Coupling Variable)

برای مسئلہ حل میں دو تعییرہ ادا نظر میں ہیں، بہ جالت دو تعییرہ
قابل تعمیم است

$$\underset{\mathbf{x}=(x_1, x_2, y)}{\text{minimize}} f(\mathbf{x}) = f_1(x_1, y) + f_2(x_2, y)$$

سلسلہ حسابی پیور نسبت بین x_2 و x_1

$$\Rightarrow \underset{x_1, x_2, y}{\text{minimize}} f(x_1, x_2, y) = \min_y \underbrace{\min_{x_1, x_2} f(x_1, x_2, y)}$$

کائن سازی کر کر y را اعتمادی دہنے

ایہ این است کہ ابتدائی کائن سازی نہ تھی و مطلع ہیں (نالہ / Node) اعتمادی سودہ سس حاصل بیٹھ بالاتر (کاونڈینیٹر / Coordinator) ایسا لمحہ تعدد آ کائن سازی نہ تھی تداخلی اعتماد سودہ درستیت f کی تردید.

: Primal Decomposition

Problem 1

$$P_1: \underset{x_1}{\text{minimize}} f_1(x_1, y) = \varphi_1(y)$$

$$P_2: \underset{x_2}{\text{minimize}} f_2(x_2, y) = \varphi_2(y)$$

$$\left. \begin{array}{l} \text{حل سلسلہ مطلع بالاتر} \\ \text{حلی شد} \end{array} \right\} \rightarrow \underset{y}{\text{minimize}} \varphi_1(y) + \varphi_2(y)$$

باین فرع حسابی (Primal Decomposition) کی ترتیب چاکرہ co کے تعییر Coordinator کرنے

نیاز است Agent ها آنچه بیشتر (Privacy) ~ CO ارسال کند

مکن است ارسال عامل y_i ، Privacy عامل نادیده شغل کند (دستگاه که تقدیر شخصی دارد نه باشد عامل ها به خود را ارسال کند)

برای این که سنه ارساطی بین عامل ها در بین y_i و CO تبادل شود می تراویم ϕ_1 و ϕ_2 برای عذری بین عامل ها و CO تبادل شود و معین Privacy تابع هفت عامل ها حفظ شود.

فرض کنیم زیرساز P و Q تابع عامل ها حال شده است.

1 : Primal Decomposition الگوریتم

زیر میراثی

$$g^k \in \partial \psi_1(y_k), g^k \in \partial \psi_2(y_k)$$

برای اینکه Conven باشد متن زیر را بخواهیم

تعیین هدایتی طبق

$$y_{k+1} = y_k - \alpha_k(g_1^k + g_2^k)$$

به منظمه تغییرات داخلی ترطیب CO به ریس زیر میراثیان: (α_k) به ریس (های) استاندار بیان شده انتقام می شود

CO باشد که زیر میراثیان آنچه که

$$k = k+1$$

باشد با مرحله 1 تا شرط توقف

باشد $\left. \begin{array}{l} \text{باشد} \\ \text{باشد} \end{array} \right\}$ حل باشد $\left. \begin{array}{l} \text{باشد} \\ \text{باشد} \end{array} \right\}$

: Dual Decomposition (این اصلی بعد) سازی شده با تعیین تغییرات جدید را احراز کرد (Consensus / اجماع)

$$\text{minimize } f(x) = f_1(x_1, y) + f_2(x_2, y)$$

$$\text{s.t. } y_1 = y_2 \rightarrow \text{تغییرات Dual} \Rightarrow \text{تغییرات شده شد}$$

لامارزین سند معامل $L(x_1, y_1, x_2, y_2, \lambda) = f_1(x_1, y_1) + f_2(x_2, y_2) + \lambda^T(y_1 - y_2)$

$$= \underbrace{[f_1(x_1, y_1) + \lambda^T y_1]}_{L_1(x_1, y_1, \lambda)} + \underbrace{[f_2(x_2, y_2) - \lambda^T y_2]}_{L_2(x_2, y_2, \lambda)}$$

سند قابل جهانی نه

بنابراین سبکی بدست آوردن تابع dual کافی است زیر مبانی زیرا حل غایب

dual subproblems $\begin{cases} g_1(\lambda) = \inf_{x_1, y_1} L_1(x_1, y_1, \lambda) = \inf_{x_1, y_1} f_1(x_1, y_1) + \lambda^T y_1 \\ g_2(\lambda) = \inf_{x_2, y_2} L_2(x_2, y_2, \lambda) = \inf_{x_2, y_2} f_2(x_2, y_2) - \lambda^T y_2 \end{cases}$

dual تابع: $g(\lambda) = g_1(\lambda) + g_2(\lambda)$

dual problem: Maximize $\underset{\lambda}{\text{Maximize}} \quad g(\lambda) \equiv \underset{\lambda}{\text{Maximize}} \quad g_1(\lambda) + g_2(\lambda) \rightarrow$ ترطیب CO و مطلع بالا سرچل می شود

تبه حالت تبلیغی مطلع CO دستیاری می باشد. کاهش حفظ اطلاعات ارسالی از ارسال تابع خود را کی نمی

برای حل الگوریتم سند اجتنب مطحوم مخصوص عامل ها دستیاری ارتباطات (هر عامل لامارزین است یک زیر مزادیان از تابع $g(\lambda)$) و داده کننده CO ارسال کند. همچنین لامارزین است CO در هر مرحله آفرین مقدار به زیر مسانی سند λ را محاسبه و باری عامل ها ارسال کند.

$g_i : \text{Concave} \rightarrow -g_i : \text{Convex} \rightarrow$ زیر مزادیان دارد

$-g_i(\lambda)$

$$i=1 \Rightarrow -g_1(\tilde{\lambda}) = -\inf_{x_1, y_1} [f_1(x_1, y_1) + \tilde{\lambda}^T y_1] = -f_1(x_1^*(\tilde{\lambda}), y_1^*(\tilde{\lambda})) - \tilde{\lambda}^T y_1^*(\tilde{\lambda})$$

تفییخ λ

↑ علی از x_1^* و y_1^* باست بزرگ شدن عیوب را کم کنند

تغییب عیوب (محض) می شود

$$= -f_1(x_1^*(\lambda), y_1^*(\lambda)) - \lambda^T y_1^*(\lambda) + (-y_1^*(\lambda))(\tilde{\lambda} - \lambda)$$

$-g_1(\lambda)$

$\Rightarrow -g_1(\tilde{\lambda}) > -g_1(\lambda) + (-y_1^*(\lambda))(\tilde{\lambda} - \lambda)$ ↑ تعریف نیزه را داین

متوالیت $\Rightarrow -y_1^*(\lambda) \in \partial(-g_1(\lambda))$

به این طریق $i=2 \Rightarrow \dots \Rightarrow y_2^*(\lambda) \in \partial(-g_2(\lambda))$

لـ Agent های مخابیر را برای CO ارسال کن

$$\Rightarrow (y_2^*(\lambda) - y_1^*(\lambda)) \in \partial(-g(\lambda))$$

1 : Dual Decomposition اللوریت

2 : حل نیزه های عاملها

$$(x_1^*(\lambda_k), y_1^*(\lambda_k)) = \underset{x_1, y_1}{\operatorname{Argmin}} (f_1(x_1, y_1) + \lambda_k^T y_1)$$

$$(x_2^*(\lambda_k), y_2^*(\lambda_k)) = \underset{x_2, y_2}{\operatorname{Argmin}} (f_2(x_2, y_2) - \lambda_k^T y_2)$$

CO $\approx y_2^*(\lambda_k) - y_1^*(\lambda_k)$ ، ارسال

$$\lambda_{k+1} = \lambda_k - \alpha_1 (y_2^*(\lambda_k) - y_1^*(\lambda_k))$$

سازمانی تغییرات CO در طبقه Dual

3 $k = k+1$

برای مرحله 2 آشنا شو

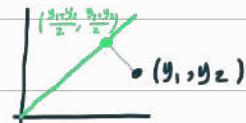
د این پس عامل ها بینه سازی نهاده (که مخواسته باشی) را به دست بایرسن (Dual) می توانیم که میتوانیم همین تفاضل هندسی تیر و بعد دارد

د هر مرحله یک حد میانی از جواب بینه را خواهیم داشت $\leftarrow g(\lambda) < f^*$

د مداخل الگوریتم باخ ها زیرا Feasible بیشتر $y_1 \neq y_2$ \leftarrow

اگر عوایض در مداخل میانی تا درست شدن از تغییرهاکی وجود نداشت بایس

$$y_1 = y_2 \rightarrow \hat{y} = \frac{y_1 + y_2}{2}$$



د این صرت دارم $f^* < f_1(x_1, \hat{y}) + f_2(x_2, \hat{y})$ \leftarrow با تغییر الگوریتمی از بینی این سیمی درد

می توان متدار x_1, x_2 و هم توطیع بینه سازی را بحسب \hat{y} بینز کرد $\leftarrow \hat{x}_i = \operatorname{Argmin}_{x_i} f_i(x_i, \hat{y})$ $i=1,2$

که باعث بودن باخ دیاعم تغییر آن فناهه شده داریم $\leftarrow (\hat{y}, \hat{y})$ $f^* < f_1(\hat{x}_1, \hat{y}) + f_2(\hat{x}_2, \hat{y}) \leq f_1(x_1, \hat{y}) + f_2(x_2, \hat{y})$

\hookrightarrow sub optimal باخ

هندسی الگوریتم Dual decomposition و بزرگی تغییرهاکی Primal

از آنجاکه سنه dual نسبت به λ محدب می باشد، اگر به دوین زیرمادیان بینکل نسبت انتخاب شود
د این صرت فراهم داشت

$$\lambda \xrightarrow{k \rightarrow \infty} \lambda_k \rightarrow \lambda^*$$

حال اگر سنه بینه سازی محدب باشد و سوابط CQ برقرار باشد در این صرت duality gap برابر صفر خواهد بود و λ^* همان خوبی لازماز بینه سنه خواهد بود.

$$(x_1^*(\lambda_k), y_1^*(\lambda_k)) = \underset{x_1, y_1}{\operatorname{Argmin}} f_1(x_1, y_1) + \lambda_k^T y_1$$

$$(x_2^*(\lambda_k), y_2^*(\lambda_k)) = \underset{x_2, y_2}{\operatorname{Argmin}} f_2(x_2, y_2) - \lambda_k^T y_2$$

از آنچه که λ_k باید λ هدایت شود، تا دیر x_1^* و x_2^* و y_1^* و y_2^* هدایت خواهد شد.

اگر سلسله بینه سازی Conven باشد و این صرت از آنچه که تغییرات $i=1,2$ نماید یکتا مانته باشند
الگوریتم از دو بستره بینه دندنی x_1 و x_2 هدایت خواهد شد و به تعیین سرط $y_1 = y_2 = 0$ نهادن نهادن
شرط $x_1 = x_2$ برقراریت حا

اما اگر سلسله بینه سازی strictly Conven باشد، آنگاه یافح $i=1,2$ یکتا مانته باشند و این صرت الگوریتم
با این تغییرات شرط $y_1 = y_2 = 0$ نهادن نهادن برقرار خواهد شد.

لے جاب است دنی $y_1 = y_2 = 0$ را برقرار کنند

: DD ، PD (ساده و سخت)

dual

محاسبه (y_k) از حل بینه سازی با امکان حل عددی ✓

Primal

$y_i^k \in \partial \Psi_i(y_k)$ محاسبه y_k دسی

✓ سنه dual یک سنه Conven است در حال هدایت شد

✗ نیاز به Conven بدن ها باشد و بعد زیرمذکور مورد

تضمین تغییر بینه سازی تداخلی به طور غیر مستقیم و از طریق میت گازک (virtual price)

تعیین یک تغییر بینه سازی کا تماطلی ترطیب (CO)

میت Virtual است مون \rightarrow میت: λ ، تولید: x_1 و سرف: x_2 حا

برداشت می شود و سرط مرض است
(امروزه برداشت هر دو ماده تراجع هدف یافتد)
لاغون تولید \rightarrow لاغون میت \rightarrow لاغون میت \rightarrow لاغون میت

✗ تغییر شدنی در هر ماده صرف هدایتی رخداب اگر بدن سنه یا تأمینات

✓ تغییر شدنی در هر ماده الگوریتم

بین سنه (تفصیل بینه سازی)

• Decomposition with Constraints

$$\begin{aligned} \text{minimize } & f_1(x_1) + f_2(x_2) \rightarrow \text{آنده بایع هم ساخته باشند این ایوهای علی قبل استفاده کنید} \\ \text{s.t. } & x_1 \in C_1, x_2 \in C_2 \\ & h_i(x_1) + h_2(x_2) \leq 0 \quad h_i: R^n \rightarrow R^P \rightarrow \text{تعادل تریها} \rightarrow \text{مقدار تریها} (\text{مقدار تریها}) \end{aligned}$$

Primal Decomposition:

$$\text{بخار } t \in R^P \rightarrow \text{دقتی را داشت}$$

$$\rightarrow \text{minimize } f_1(x_1) + f_2(x_2)$$

$$\text{s.t. } x_1 \in C_1, x_2 \in C_2$$

$$h_1(x_1) \leq t, \quad h_2(x_2) \leq -t \rightarrow \text{هر تری بیکنی کنید} \rightarrow \text{آنده بایع شود}$$

لے رخدت مداری این شرط بالا شرط کنید
که t تعنی می کند \rightarrow غیر ترتیبی شرط بالا جایگزین شود
لذا نظریه لازم رکاوی می شود

$$\rightarrow \left\{ \begin{array}{l} P_1: \underset{x_1 \in C_1}{\text{minimize}} \quad f_1(x_1) \rightarrow \Psi_1(t) \\ \text{s.t. } h_1(x_1) \leq t \\ P_2: \underset{x_2 \in C_2}{\text{minimize}} \quad f_2(x_2) \rightarrow \Psi_2(t) \\ \text{s.t. } h_2(x_2) \leq -t \end{array} \right.$$

حال شناسه این است که تعداد t به حدود بینه تعنی شود که این کار ترطیب C_0 انجام خواهد داشت:

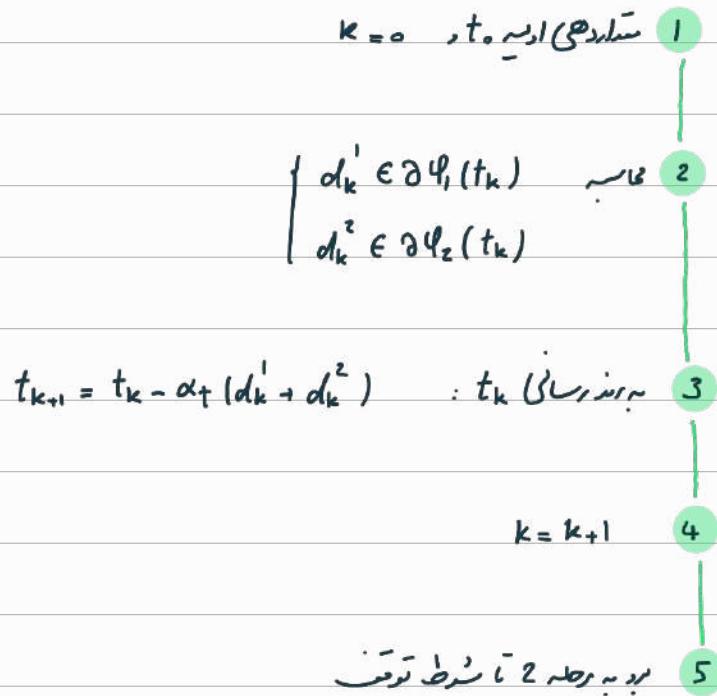
$$\begin{aligned} \text{minimize } & |\Psi_1(t) + \Psi_2(t)| \\ t \end{aligned}$$

حال اسند حالات بدل به گذگ یک آندریم عذری بینی بر زیر تراویل نیاز به ارسال تابع Ψ_1 , Ψ_2 , Ψ از طرف عامل ها C_0 مخواهد بود و فقط سایر عذری زیر تراویل های Ψ_1 , Ψ_2 در هر مرحله برای C_0 ارسال می شود. C_0 بر اساس زیر تراویل Ψ مقدار تغییر t را ببرد و در برگی عامل ها ارسال می کند.

ظاهر درید مسائل Convex مکلی ایجادی کند

پر دلایل باید محب تا مدل عالی باشد
و Φ_1, Φ_2 باید محب تا محب باشد

حل زیر مسائل P_1, P_2 تربط مدل ها و بست آسن ترابع (Primal Decomposition)



برای مسائل محب (f_i محب و h_i محب و مجموعه C_i محب، $i=1,2$) ظاهیر راست:

$$\Phi_i(t) = \sup_{\lambda_i \geq 0} \inf_{x_i \in C_i} (f_i(x_i) + \lambda_i^T h_i(x_i) - t) \quad i=1,2$$

(امكان استادهار duality)

و حل بینه سازی کارست $\sup_t \Phi_i(t) \Leftrightarrow$ منطقه ایست t بهینه شان

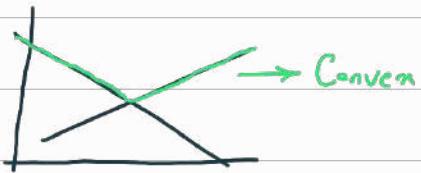
\Leftrightarrow بینه ساز (حدیب t) را می خواهیم $\Leftrightarrow \lambda_i^*$

$$\Rightarrow d_k^1 = -\lambda_1^*(t_k), \quad d_k^2 = \lambda_2^*(t_k)$$

برگردانی های حدیب لامبارد زیر مسئله ها

مشترک \Leftrightarrow حل مشترک نزدیکی

حل $\inf_t \varphi_i(t)$ دارای تابع $\varphi_i(t)$ می‌باشد.



$\varphi_i(t)$ می‌باشد.

برای کل مجموعه $\varphi_i(\tilde{t})$ تابع $\varphi_i(t)$ در مورد t حدودی است.

$$\varphi_i(\tilde{t}) = \sup_{\lambda_i \geq 0} \inf_{x_i \in C_i} (f_i(x_i) + \lambda_i^T (h_i(x_i) - \tilde{t})) \geq \inf_{x_i \in C_i} (f_i(x_i) + \lambda_i^*(t) (h_i(x_i) - \tilde{t}))$$

$$\begin{aligned} \lambda_i^*(\tilde{t}) &= \inf_{x_i \in C_i} (f_i(x_i) + \lambda_i^*(t) (h_i(x_i) - \tilde{t})) + \lambda_i^*(t) \tilde{t} - \lambda_i^*(t) t \\ &= \inf_{x_i \in C_i} (f_i(x_i) + \lambda_i^*(t) (h_i(x_i) - t)) + \lambda_i^*(t) t - \lambda_i^*(t) \tilde{t} \\ &= \varphi_i(t) + (-\lambda_i^*(t))^T (\tilde{t} - t) \end{aligned}$$

$$\Rightarrow \varphi_i(\tilde{t}) \geq \varphi_i(t) + (-\lambda_i^*(t))^T (\tilde{t} - t) \quad \text{تعريف زیرمقدار} \rightarrow -\lambda_i^*(t) \in \partial \varphi_i(t) \quad \text{بطورست} \rightarrow \lambda_2^*(t) \in \partial \varphi_2(t)$$

$$\Rightarrow d_k^1 = -\lambda_1^*(t_k), \quad d_k^2 = \lambda_2^*(t_k)$$

Dual Decomposition:

$$\text{minimize } f_1(x_1) + f_2(x_2)$$

$$\text{s.t. } x_1 \in C_1, \quad x_2 \in C_2$$

$$h_1(x_1) + h_2(x_2) \leq 0$$

$$\boxed{L(x_1, x_2, \lambda) = f_1(x_1) + f_2(x_2) + \lambda^T (h_1(x_1) + h_2(x_2)) = (f_1(x_1) + \lambda^T h_1(x_1)) + (f_2(x_2) + \lambda^T h_2(x_2))}$$

متناهی حالت ملئ

$$\left\{ \begin{array}{l} P_1: \text{minimize } f_1(x_1) + \lambda^T h_1(x_1) \rightarrow g_1(\lambda) \\ \text{s.t. } x_1 \in C_1 \\ P_2: \text{minimize } f_2(x_2) + \lambda^T h_2(x_2) \rightarrow g_2(\lambda) \\ \text{s.t. } x_2 \in C_2 \end{array} \right.$$

راهنمایی تراویحی اینست

$$\Rightarrow g(\lambda) = g_1(\lambda) + g_2(\lambda)$$

$$\text{co طرط}: \left\{ \begin{array}{l} \text{maximize } g(\lambda) \\ \lambda \geq 0 \end{array} \right.$$

1: Dual Decomposition (الدوجی)

$$\left\{ \begin{array}{l} d_k^1 \in \partial g_1(\lambda_k) \\ d_k^2 \in \partial g_2(\lambda_k) \end{array} \right. \quad \text{حل زیر مسئله تقطیع عامل ها را به دست آور}:$$

$$\text{Projected subgradient} \leftarrow \lambda_{k+1} = [\lambda_k - \alpha_k(d_k^1 + d_k^2)]_+$$

λ ده مرحله هدایت کنند

(سنه اولیه dual بنت به آن دنب است)

آخر سنه اولیه دنب باشد به متاریج
هدایت کنند

$$k = k+1$$

به مرحله 2 آمد

$$g_i: \text{Concave} \Rightarrow -g_i: \text{Convex} \Rightarrow \dots \Rightarrow d_k^i = -h_i(x_i^*(\lambda_k)) \quad i=1,2$$

ابت

$$\Rightarrow -h_1(x_1^*(\lambda_k)) - h_2(x_2^*(\lambda_k)) \in \partial(-g(\lambda_k))$$

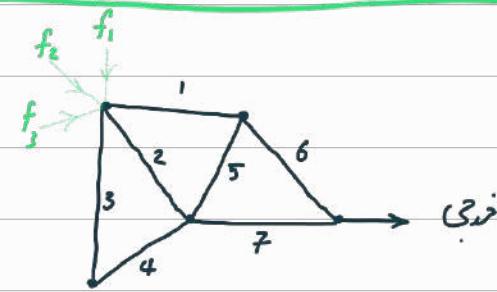
دual decomposition و ترکیب مترادفات Dual Decomposition و ترکیب مترادفات

در حالت تجزیه مترادفاتی می‌باشد حل اعلیٰ بینه سازی کارا کنندگان است Dual Decomposition در این حالت یک تغییر افکار پیوکرد نیازمند حل ترکیب مترادفاتی است (رد صورت) که در Dual Decomposition نزدیکی‌ها بین تجزیه‌ها

Example

Network توزیع کننده

link (کارهای)



هر کس از Agents حاصل خواهد
کرد را از شکل عبور داشت
(شبکه خارجی انتقالی / ...)

n Agents

n flows

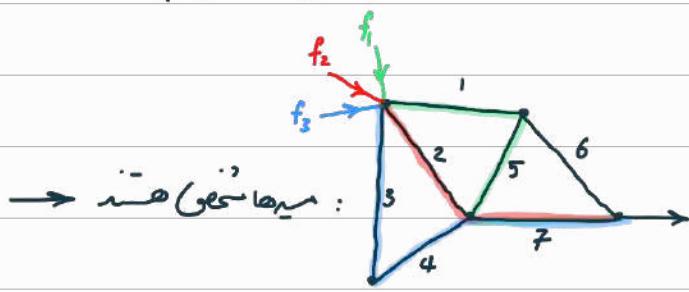
$$f_j \geq 0 \quad j=1, \dots, n \rightarrow n=3$$

Network with m link $\rightarrow m=7$

Utility of agent j: $u_j(f_j) \rightarrow$ strictly concave and increasing (حصار):

$$t_i: \text{traffic on link } i \rightarrow \begin{pmatrix} t_1 \\ \vdots \\ t_n \end{pmatrix} = R_{mn} \times \begin{pmatrix} f_1 \\ \vdots \\ f_n \end{pmatrix}$$

$$[R]_{ij} = \begin{cases} 1 & \text{flow } f_j \text{ passes over link } i \\ 0 & \text{otherwise} \end{cases}$$



$$\Rightarrow R = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \\ 1 & 1 & 1 \end{pmatrix}_{7 \times 3}$$

همچو از 6 استفاده کنند
محل 7 استفاده کنند

$$\Rightarrow t_7 = R \begin{pmatrix} f_1 \\ f_2 \\ f_3 \end{pmatrix} = f_1 + f_2 + f_3$$

$t < c$: مطابق نیز ها

$$\Rightarrow \text{مسئله ساده}: \begin{cases} \text{Minimize} & \sum_{j=1}^n u_j(f_j) \\ \text{s.t.} & Rf \leq c \end{cases}$$

$Rf = [r_1 \ r_2 \ \dots \ r_n] \begin{pmatrix} f_1 \\ f_2 \\ \vdots \\ f_n \end{pmatrix} \leftarrow R$ مسئله زیر را دریس

$$\text{Dual Decomposition: } L(f, \lambda) = \sum_{j=1}^n -u_j(f_j) + \lambda^T (RF - c) = \sum_{j=1}^n -u_j(f_j) + \lambda^T \left(\sum_{j=1}^n r_j f_j \right)$$

$$= -\lambda^T c + \sum_{j=1}^n (-u_j(f_j) + \lambda^T r_j f_j)$$

محض تابع دوستی است \Leftrightarrow سیمی شود

$$\lambda^T r_j f_j = [\lambda_1 \ \dots \ \lambda_m] \begin{pmatrix} r_{1j} \\ \vdots \\ r_{mj} \end{pmatrix} f_j \rightarrow \text{محض تابع انتشار link بین عامل ز}$$

$$\Rightarrow \text{subproblem } j \quad (j=1, \dots, n): g_j(\lambda) = \inf_{f_j} (\lambda^T r_j f_j - u_j(f_j))$$

$$\text{CO: Minimize } g(\lambda), \quad g(\lambda) = -\lambda^T c + \underbrace{\sum_{j=1}^n \inf_{f_j} (\lambda^T r_j f_j - u_j(f_j))}_{\text{affine}} \rightarrow \text{Convex}$$

Concave \leftarrow Concave \Leftarrow affine \Leftarrow inf

$$d(\lambda) \in \partial(-g(\lambda)) \Rightarrow d = c - d^1 - d^2 - \dots - d^n, \quad d^j(\lambda) = r_j f_j^*(\lambda)$$

نرگزهای نزدیک

بنابراین d به این صورت خواهد بود:

1

2

حابه نزدیک هاتر عامل ها:

$$d_k^j = -r_j f_j^*(\lambda_k) \in \partial(-g_j(\lambda_k))$$

هر دلیل f بینهایت امیدوار است و ارسالی کند

: CO بسته λ_k بسته باشی

3

$$\lambda_{k+1} = [\lambda_k - \alpha_k (C - r_1 f_1^*(\lambda_k) - \dots - r_n f_n^*(\lambda_k))]_+$$

$$= [\lambda_k - \alpha_k (C - R f^*(\lambda_k))]_+$$

$k = k + 1$

برای مرحله 2 تا شرط تحقق

4

* Augmented Lagrangian

تعییانت از Lagrangian بدلی حل عددی ریت ها کار آن

minimize $f(x)$

Conven ↘

s.t. $Ax = b$ $x \in \mathbb{R}^n$, $A \in \mathbb{R}^{m \times n}$, $f: \mathbb{R}^n \rightarrow \mathbb{R}$

Lagrangian: $L(x, y) = f(x) + y^T(Ax - b)$

نیازی داشت f بینهایت محدود و حدودی الگوریتم Primal-Dual

برای بست آسن و بیه $\inf L_0$ حل پیر باشد \leftarrow مایل از پس) محدود باشد
 $\inf L_0$ پیر (affine) $f(x)$ دو دو
 (حالات خاص تر \leftarrow

کلی

\leftarrow به عمد بعد ناچ لائار از پس بر قب مایل بست آسن ناچ dual ناچ

\leftarrow بی) ناچ ای ساط معن تعیین می شد Augmented Lagrangian

$$\text{Augmented Lagrangian: } L_p(x, y) = f(x) + y^T(Ax - b) + \underbrace{\left(\frac{P}{2}\right) \|Ax - b\|_2^2}_{P > 0} \quad \downarrow \text{Penalty Parameter}$$

عبد افانه شده همان تبدیلت \leftrightarrow در صورت وجود جواب Feasible، پس را تعیین می دهد

$\circ \Leftarrow \text{Feasible } x$

ناچ لائار فرق را می توان مرتبط با حل پیر بازی نمود

$$\text{minimize } f(x) + \left(\frac{P}{2}\right) \|Ax - b\|^2$$

$$\text{s.t. } Ax = b$$

جواب پیر می توان با جواب پیر اشاره می کن ا است

عبد افانه شده است \leftarrow آر f مطابق با نظریه افانه شدن $\left(\frac{P}{2}\right) \|Ax - b\|^2$ strictly Convex
 کل عبارت \rightarrow strictly Convex می کند و بعثت \inf می شود

$$f(x) = \begin{cases} 0 & x \in C \\ +\infty & x \notin C \end{cases} \quad \begin{array}{l} \nearrow C: \text{Convex} \\ \searrow \text{indicator function} \end{array}$$

بی) بگو f بگو $f(x)$ $(A^T A)^{-1} A^T b$ $\inf f(x)$ indicator function نمود \leftarrow بی نایت شد
 نایت شد \leftarrow عبد Quadratic ناچ ای می شود که x بی نایت شد

$\Rightarrow f(x) = 0 \Rightarrow x \in C$ (Solving Quadratic Programming)

→ بطریقی f از دشمنی آزادی کی تراویث انتخاب نیز در حال است از دید L_1 inf فیلان راست باشد

Augmented Lagrangian یعنی اضافی از لگرانجیان

$$\text{Method of Multipliers: } \begin{cases} x^{k+1} = \operatorname{Arg} \min_x L_p(x, y^k) \\ y^{k+1} = y^k + P(Ax^{k+1} - b) \end{cases}$$

Step Size رعن یا سرعت پالسی است

دالریم همان تابع k از مدل K و بذت \rightarrow
که آنرا در این حالت K_{old} از K و بذت
آپدیت و هم $update$ می شود

جی توان نهان دار } با تغیر α - α^k بر مارکیت اند
باده تظر ترسن Step Size نت آلگوریتم - جواب بینه هدرا می شود

$$\left. \begin{array}{l} \text{Feasibility} \leftarrow A\mathbf{x}^* - \mathbf{b} = \mathbf{0} \\ \text{Lagrangian optimality} \leftarrow \mathbf{0} \in \partial f(\mathbf{x}^*) + A^T \mathbf{y}^* \end{array} \right\} \text{منطقهٔ ممکنی} \rightarrow$$

$$\begin{aligned} \text{برهان طبیعی جایگزینی: } 0 &\in \partial_m L_p(x^{k+1}, y^k) = \partial f(x^{k+1}) + A^T y^k + PA^T(Ax^{k+1} - b) \\ &= \partial f(x^{k+1}) + A^T(y^k + PA^T(Ax^{k+1} - b)) \\ &= \partial f(x^{k+1}) + A^T y^{k+1} \end{aligned}$$

متطرّجیتی y_{∞} (یعنی iteration \rightarrow optimality)

گروه دلاریزشی مامت Decompose شدن شده بازسی می‌برد

Decomposable

$$\text{minimize}_{\mathbf{x}} \sum_{i=1}^n f_i(x_i) + \left(\frac{\rho}{2}\right) \|\mathbf{Ax} - \mathbf{b}\|^2$$

مابین جواباتی نیست
(میان فلکی نیست)

$$\mathbf{x} = \begin{pmatrix} x_1 \\ \vdots \\ x_n \end{pmatrix}$$

s.t. $\mathbf{Ax} = \mathbf{b}$

مقدار الگوریتم MM (Method of Multipliers) تا در مکمل کردن الگوریتم سطح بینی تابع لامارش را برآورد می کند و معنی الگوریتم دنیست هدرا شده و شرط Feasibility (دسترسی) در نهایت برقرار خواهد شد. این سطح ضعف این اینست که لامارشی را می توان با تجزیه آن حل غیر تجزیه نیست.

برای حل نکل منق شی بعنوان Alternating Direction Method of Multipliers (ADMM)

Distributed Optimization and Statistical Learning Survey : درج نسبت

via the Alternating Direction Method of Multipliers

ADMM: minimize $f(\mathbf{x}) + g(\mathbf{z})$

s.t. $\mathbf{Ax} + \mathbf{Bz} = \mathbf{c}$

مقدار \mathbf{g}, \mathbf{f} ، $\mathbf{x} \in \mathbb{R}^n, \mathbf{z} \in \mathbb{R}^m, \mathbf{A} \in \mathbb{R}^{n \times m}, \mathbf{B} \in \mathbb{R}^{m \times m}, \mathbf{c} \in \mathbb{R}^m$

در اینجا نزدیکی دو همیشگی داشتم اسماهاده ایم

$$L_p(\mathbf{x}, \mathbf{z}, \mathbf{y}) = f(\mathbf{x}) + g(\mathbf{z}) + \mathbf{y}^T (\mathbf{Ax} + \mathbf{Bz} - \mathbf{c}) + \left(\frac{\rho}{2}\right) \|\mathbf{Ax} + \mathbf{Bz} - \mathbf{c}\|^2$$

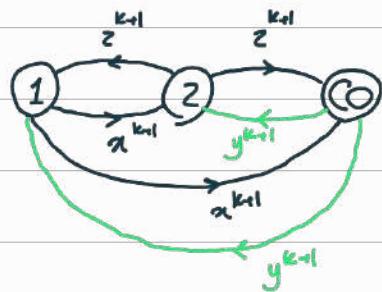
حال الگوریتم ADMM به صفت زیر عمل می کند:

$$\begin{cases} \mathbf{x}^{k+1} = \operatorname{Argmin}_{\mathbf{x}} L_p(\mathbf{x}, \mathbf{z}^k, \mathbf{y}^k) \\ \mathbf{z}^{k+1} = \operatorname{Argmin}_{\mathbf{z}} L_p(\mathbf{x}^{k+1}, \mathbf{z}, \mathbf{y}^k) \\ \mathbf{y}^{k+1} = \mathbf{y}^k + \rho(\mathbf{Ax}^{k+1} + \mathbf{Bz}^{k+1} - \mathbf{c}) \end{cases}$$

برخلاف این ها کی تبلیغاتی، بین سازی با صفت Sequential Agent ها هم ارتبا طی و مجدد است.

Alternating

بنی ترتیب دارای فرآیند زیرا به صفت ترتیبی Alternating بوده که شوندگان Decompose شدن را ب دست می دهد.



Agent ها تغیر قسم کرده اند و در دو دست
کی است که دلی تابع هدف را اعتماد نکنند
(هر Agent باید کمین کردن می خواهد)
تابع هدف بقیه نثار

با تغییر متغیری توان خود را بساده کرد.

$$\begin{aligned} \text{scaled form: } & \begin{cases} r = Ax + Bz - c \rightarrow \text{residual} \\ u = (\frac{1}{p})y \rightarrow \text{scaled dual variable} \end{cases} \end{aligned}$$

$$g^T r + \left(\frac{p}{2}\right) \|r\|^2 = \left(\frac{p}{2}\right) \|r + (\frac{1}{p})y\|^2 - \left(\frac{1}{2p}\right) \|y\|^2$$

$\underbrace{(r + (\frac{1}{p})y)^T (r + (\frac{1}{p})y)}$

ب جایگزینی رابطه فرآیند ADMM خواهی داشت:

$$\begin{cases} x^{k+1} = \operatorname{Argmin}_x \left(f(x) + \frac{p}{2} \|Ax + Bz^{k+1} - c + u^k\|^2 \right) \\ z^{k+1} = \operatorname{Argmin}_z \left(g(z) + \frac{p}{2} \|Ax^{k+1} + Bz - c + u^k\|^2 \right) \\ u^{k+1} = u^k + Ax^{k+1} + Bz^{k+1} - c \end{cases}$$

→ $y = pu^k$

جزء حل y و $g(z)$ → $\min_z g(z) + p^T y$
جزء می شوند

$$r^k = Ax^k + Bz^k - c \Rightarrow u^k = u^0 + \sum_{j=1}^k r^j$$

در مجموعه بسته مغلق است نمایند

تابع هدایتی:

$$f: \mathbb{R}^n \rightarrow \mathbb{R} \cup \{-\infty\} \quad g: \mathbb{R}^m \rightarrow \mathbb{R} \cup \{-\infty\}$$

شرط ۱: محدودات

تابع f و g بسته (closed) و محدود (proper) گویند

closed: ساخت ناشی است! شرط ساده است

بیان دینی ترتیبی است که همه closed مخلوق است

sublevel set: $\{x : f(x) \leq t\}$ شرط ساده است closed

Proper: $\begin{cases} \exists x \in X \quad f(x) < \infty \\ \forall x \in X \quad f(x) > -\infty \end{cases}$ شرط ساده است

(نظریه مدل بهمودیت)

مجموع این شرط بعد این است که



$$\text{epi}(f) = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} \mid f(x) \leq t\}$$

indicator function (برنامه را دارد): $f(x) = \begin{cases} 0 & x \in C \\ +\infty & x \notin C \end{cases}$ در میان ADMM، حلت $+\infty$ دارد تابع هدف نی شود

بنشانید (برنامه را دارد): $x \in C \Rightarrow \text{Quadratic Programming}$ (min $\|x\|^2$ subject to affine)

2 آنچه لگاریتمی سند Augment نموده (L) مارکی یک روش زیرین است

لسته جاب ناشیه بند Unaugmented

$$\begin{aligned} \text{دیده شده زیرین} &= \begin{cases} (\mathbf{x}^*, \mathbf{z}^*) & \text{primal optimal} \\ \mathbf{g}^* & \text{Dual optimal} \\ \text{Strong Duality} \end{cases} \end{aligned}$$

حکم نتایج منقذ خواهی باشد:

1 $k \rightarrow \infty \Rightarrow r^k \rightarrow 0$

2 $k \rightarrow \infty \Rightarrow y^k \rightarrow y^*$

3 $k \rightarrow \infty \Rightarrow f(\mathbf{x}^k) + g(\mathbf{z}^k) \rightarrow p^*$

برای اینجا

نموده \mathbf{x}^k و \mathbf{z}^k به ترتیب همانجا هستند!

$$r = A\mathbf{x}^k + B\mathbf{z}^k - C \xrightarrow{k \rightarrow \infty} 0$$

تبدیل زیرنفراستی می‌کنند که $\mathbf{x}^k, \mathbf{z}^k$ در آن مارکی ایند

مکنی است سلاسل از مسیر $\mathbf{x}^k, \mathbf{z}^k$ را ترکیب کنیم که مجموع مسافتی می‌باشد

به نهایت مسیری دیده شده

$$f_{\text{opt}} \text{ optimality}, \text{ در مراحل ابتداء } S^{k+1} = P A^T B (Z^{k+1} - Z^k) \xrightarrow{k \rightarrow \infty} 0$$

مکنی است $Z^{k+1} - Z^k$ صفر نشود و در نتیجه اینجی $A^T B$ ماتریس مانگید

Z^k optimality مقداری دارد

نیازی میدارد

\Rightarrow آر تارین $A^T B$ طایر رتبه سویی کامل باشد (A, B هر دو دلای رتبه سویی کامل باشند) و این صرط $\Rightarrow z^{k+1} \rightarrow z^k$ دنباله z^k همراه باشد . دنباله z^k براساس $r \rightarrow 0$ (Feasibility condition) دنباله z^k نیز همراه باشد .

حدایقیست \rightarrow کاربرد : به صادگانه نسبت نسبی - جواب مابل قبلی را داشتی حدایقی کامل نیاز به تکریه های

زیادی دارد

نیازی نداریں

*ADMM / Decomposition Applications - Intentions

• Constrained optimization

$$\begin{aligned} & \text{minimize } f(x) \rightarrow f, \begin{cases} \text{Bounded Below} \\ \text{Bounded Subgradient} \end{cases} \\ & \text{s.t. } x \in C \end{aligned}$$

ADMM form \rightarrow minimize $f(x) + g(z)$ indicator function of $C \rightarrow z \notin C \Rightarrow g \rightarrow \infty$

s.t. $x - z = 0$ ← Consensus

$$\Rightarrow \begin{cases} x^{k+1} := \arg\min_x (f(x) + \frac{\rho}{2} \|x - z^k + u^k\|_2^2) \\ z^{k+1} := \Pi_C(x^{k+1} + u^k) \\ u^{k+1} := u^k + x^{k+1} - z^{k+1} \end{cases}$$

\rightarrow f(x) \in C range(f)

\rightarrow minimization پذیران

\rightarrow (Projected subgradient) نیز

$$\arg\min_z (g(z) + \frac{\rho}{2} \|x - z + u^k\|_2^2) \stackrel{!}{=} \arg\min_z (\|x - z + u^k\|_2^2) = \Pi_C(x - u^k)$$

\rightarrow Quadratic بیکار

هفون - علی C بیکار تواند است بشه \leftarrow کاری بیکار ساده شد این عمل اعماق شده

• Lasso (least absolute shrinkage and selection operator)

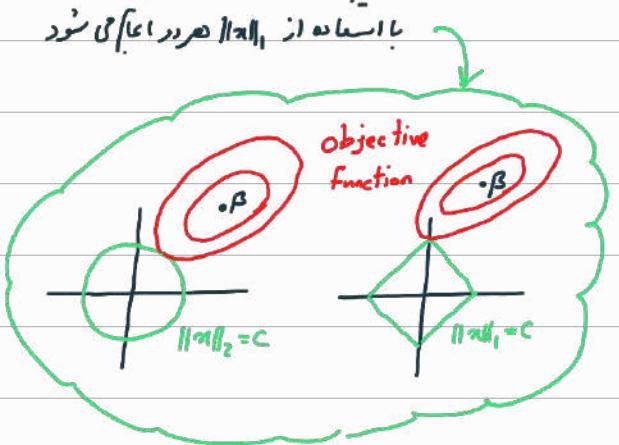
regression \hat{x} regularization: مسارات ill-Posed می باشد
 Lasso \hat{x} : minimize $\frac{1}{2} \|Ax - b\|_2^2 + \lambda \|x\|_1$, که برای بارهای نیاز / sparse / اکثر بارهای خود را حذف می کند

(generalization/shrinkage)

طیوری از بزرگ شدن بارهای $\|x\|_2$ استفاده از $\|x\|_2$

حذف بارهای کم اهمیت $\|x\|_1$ استفاده از $\|x\|_1$

(Feature Selection)



ADMM form \rightarrow minimize $\frac{1}{2} \|Ax - b\|_2^2 + \lambda \|z\|_1$
 s.t. $x - z = 0$

$$\Rightarrow L_p(x, z, y) = \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|z\|_1 + y^T(x - z) + \rho \|x - z\|_2^2$$

$$\Rightarrow \begin{cases} x^{k+1} := (\bar{A}^T \bar{A} + \rho I)^{-1} (\bar{A}^T b + \rho z^k - y^k) \\ z^{k+1} := S_{\lambda/\rho}(x^{k+1} + y^k/\rho) \\ y^{k+1} := y^k + \rho(x^{k+1} - z^{k+1}) \end{cases} \leftarrow \text{Quadratic Programming}$$

$\|z\|_1 \rightarrow$ sign \rightarrow soft thresholding operator: $S_k(a) = \begin{cases} a - k & a > k \\ 0 & |a| < k \\ a + k & a < -k \end{cases}$ \rightarrow shrinkage
 \uparrow optimization \rightarrow selection

• Consensus Optimization

$$\text{minimize } \sum_{i=1}^N f_i(x) \rightarrow N \text{ agents}$$

$\rightarrow N$ blocks of training data

ADMM form $\rightarrow \text{minimize} \sum_{i=1}^N f_i(x_i) \rightarrow g(z) = 0 \rightarrow$ جرمانه مادر f_i regularization g(z) +

s.t. $x_i - z = 0 \rightarrow$ داده های اینجا زیر ADMM بهتر نیستند

local variables global variable

$$\Rightarrow L_p(x, y, z) = \sum_{i=1}^N (f_i(x_i) + y_i^T(x_i - z) + \frac{\rho}{2} \|x_i - z\|_2^2) \rightarrow \text{شکل Decomposition}$$

$$\Rightarrow \begin{cases} x_i^{k+1} := \underset{x_i}{\operatorname{argmin}} (f_i(x_i) + y_i^k)^T(x_i - z^k) + \frac{\rho}{2} \|x_i - z^k\|_2^2 \\ z^{k+1} := \frac{1}{N} \sum_{i=1}^N (x_i^{k+1} + \frac{1}{\rho} y_i^k) \\ y_i^{k+1} := y_i^k + \rho(x_i^{k+1} - z^{k+1}) \end{cases} \leftarrow \text{حل}$$

Example

Consensus SVM classification:

Data (examples): (a_i, b_i) $i=1, \dots, N$ $a_i \in \mathbb{R}^n$ $b_i \in \{-1, 1\}$

Linear classifier: $\text{Sign}(a_i^T w + v)$ w : weight v : offset

margin for i-th example: $b_i(a_i^T w + v) \rightarrow$ جزایم بند

loss for i-th example: $L(b_i(a_i^T w + v)) \rightarrow$ hinge / logistic / Prohibit / exponential / ...
 $\overline{L}_{\text{Margin}}(0, 1 - b_i(a_i^T w + v))$

choose w, v to minimize $\frac{1}{N} \sum_{i=1}^N L(b_i(a_i^T w + v)) + r(w)$

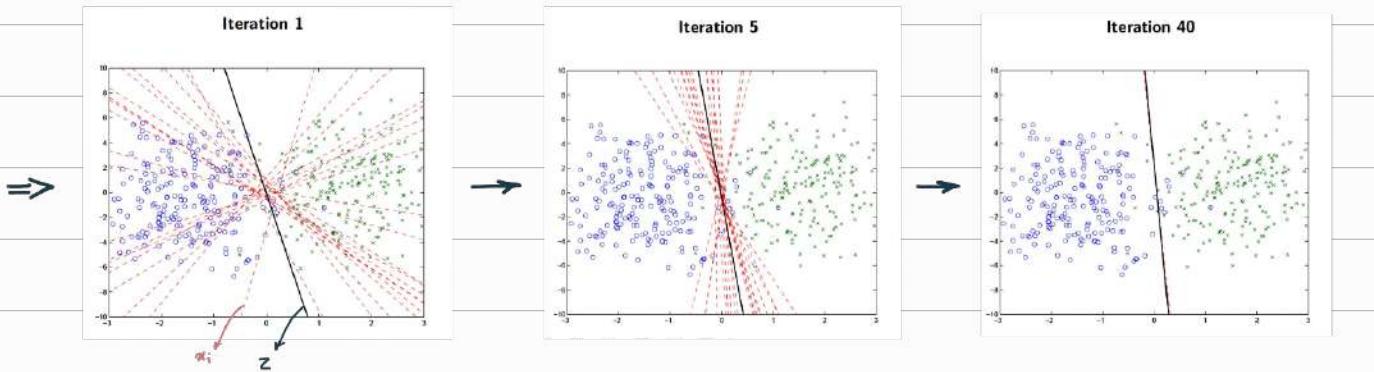
regularization term ($\lambda_1, \lambda_2, \dots$)

لے علاوه بر $\lambda_2 = \|w\|_2^2$ استفاده شود

جی خاص طور پر ADMM با split

hinge loss $l(u) = (1-u)_+$ with L_2 regularization

$n=2, N=400, 20$ groups \rightarrow worst case



Boyd 11.1/03 ↵

• Other Applications

Network Application

Power system / smart Grid

Machine Learning

↳ Robust PCA:

$$M = \underbrace{L}_{\text{low-rank}} + \underbrace{S}_{\text{sparse}}$$

$$\text{Nuclear Norm} := \sum_{i=1}^n \sigma_i(L)$$

$$\begin{aligned} & \text{minimize } \|L\|_* + \lambda \|S\|_* \\ \text{s.t. } & L + S = M \end{aligned}$$

↳ Graphical Lasso

• Extensions

Fast ADMM

Distributed ADMM → نعم - جانی کہ میں اور دشمن داشتہ بھر

Parallel multi-block ADMM

optimal parameter Selection for ADMM → اندازہ ملابس

• Federated Learning

کے تاریخ میں استعمال واقع شدہ Decomposition or Application ←

→ اپنی پردر 2016 مطح شد

→ حل یک نہ یاد رکی اُسی (بـ طریق سُبھی عین اسکی میں Dataset میں)

→ بدلیل Exchange Cost , Privacy (Crowd Sensing , Crowd Sourcing)

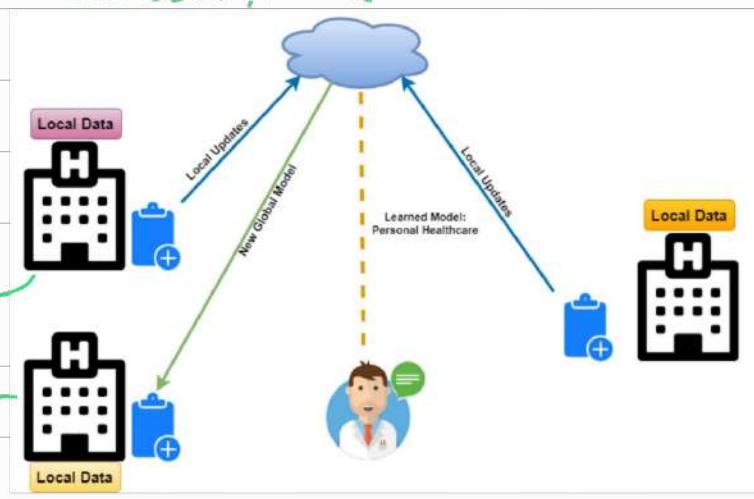
→ الگوریتم بیانیہ است

→ مل ہا بـ صرف میں train کی شود

→ پراستھا کی مل ہا کی جعلی بـ سرور ارسال کی شود

→ سرور پرست پراستھا بـ مل جانی (Global Model) کی سازدہ آن ٹا با Node ہا - اسٹاک کی لئے

Non Convergent



→ Privacy بـ بیانتاں حاصل

→ مل جانی بـ بیدستی مل ساتھیں

→ سرکت نہ کرنا مل ساتھی مل کر کے مل کر کے

دیکھ کر

Core challenges:

- Expensive Communication → بازگشتن مسages با هم
- System Heterogeneity → سیستم های مختلف (تاریخی، مهندسی، تجارتی ...)
- Statistical Heterogeneity → (non iid) جایی که داده های محلی (local) هستند
- Privacy Concerns

نمکی این روش را در مورد یک مدل رگرسیون نسبتی بین داده های کاربران در مجموعه داده های کلی معرفی خواهد کرد.

$$\Rightarrow \min_{w \in \mathbb{R}^d} f(w), \quad f(w) \stackrel{\text{def}}{=} \frac{1}{n} \sum_{i=1}^n f_i(w), \quad f_i(w) = l(x_i, y_i; w)$$

Client k: $F_k(w) = \frac{1}{n_k} \sum_{i \in P_k} f_i(w)$

$$\Rightarrow f(w) = \sum_{k=1}^K \frac{n_k}{n} F_k(w)$$

number of data points of client k

dataset of client k

برای این ابعاد مسئله را به دو قسم تقسیم می کنیم:

→ Non Convex Problem

→ No Personal Variable → میدانی که در هر مرحله Update می شود

→ Flexible local Updating

→ Low Client Participation → Primal Decomposition

$$g_k = \nabla F_k(w_k) \quad f(w) = \sum_{k=1}^K \frac{n_k}{n} F_k(w) \Rightarrow \sum_{k=1}^K \frac{n_k}{n} g_k = \nabla f(w_t)$$

$$\Rightarrow w_{t+1} \leftarrow w_t - \eta \sum_{k=1}^K \frac{n_k}{n} g_k$$

$$\sum_{k=1}^K \frac{n_k}{n} w_t = w_t \sum_{k=1}^K \frac{n_k}{n} = w_t$$

Node Updating: $\forall k \quad w_{t+1}^k \leftarrow w_t - \eta g_k$

معلاج این کار چیزی نیست

$$\Rightarrow w_{t+1} \leftarrow \sum_{k=1}^K \frac{n_k}{n} w_{t+1}^k$$

Algorithm 1 FederatedAveraging. The K clients are indexed by k ; B is the local minibatch size, E is the number of local epochs, and η is the learning rate.

Server executes:

```

initialize  $w_0$ 
for each round  $t = 1, 2, \dots$  do
     $m \leftarrow \max(C \cdot K, 1)$  → to client  $i \in C$  (کلیت مخصوص)
     $S_t \leftarrow$  (random set of  $m$  clients)
    for each client  $k \in S_t$  in parallel do
         $w_{t+1}^k \leftarrow \text{ClientUpdate}(k, w_t)$ 
     $w_{t+1} \leftarrow \sum_{k=1}^K \frac{n_k}{n} w_{t+1}^k$ 

```

```

ClientUpdate( $k, w$ ): // Run on client  $k$ 
 $\mathcal{B} \leftarrow$  (split  $\mathcal{P}_k$  into batches of size  $B$ )
for each local epoch  $i$  from 1 to  $E$  do
    for batch  $b \in \mathcal{B}$  do
         $w \leftarrow w - \eta \nabla \ell(w; b)$  → Update
return  $w$  to server

```

کلیت مخصوص داشته باشد

را در هر یکی از مینی باتچ های

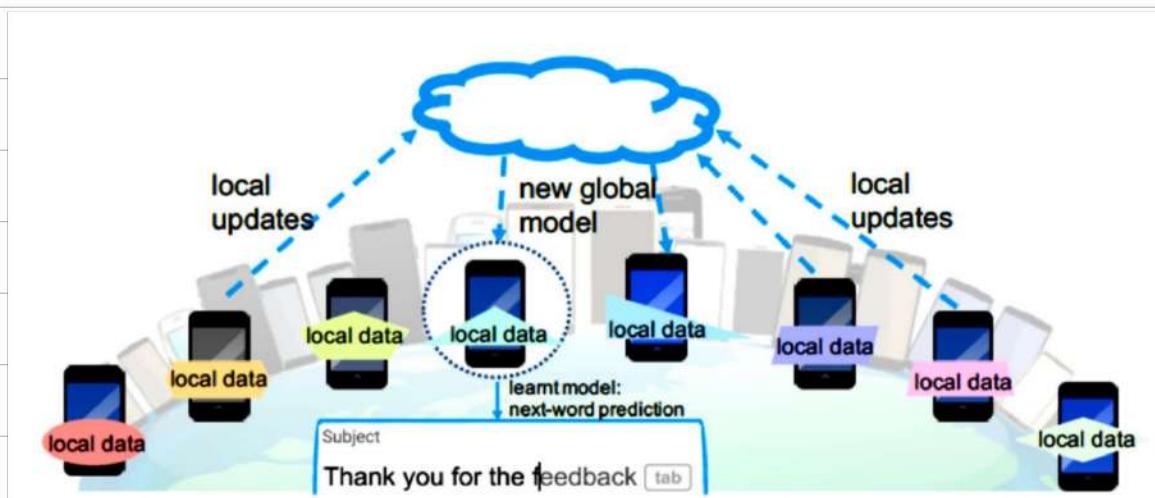
برای آپدیت کنید!

hyperparameter
های ربط قوی
کشید

برای هر یکی از مینی باتچ های E

local update شود : $u_k = E \frac{\eta_k}{B}$

next word prediction (google):



→ Training dataset: 10M public posts from social network

→ The posts grouped by authors, for a total of over 500,000 clients

→ Accuracy: The fraction of data where the highest predicted probability was on the correct next word, out of 1000 possibilities

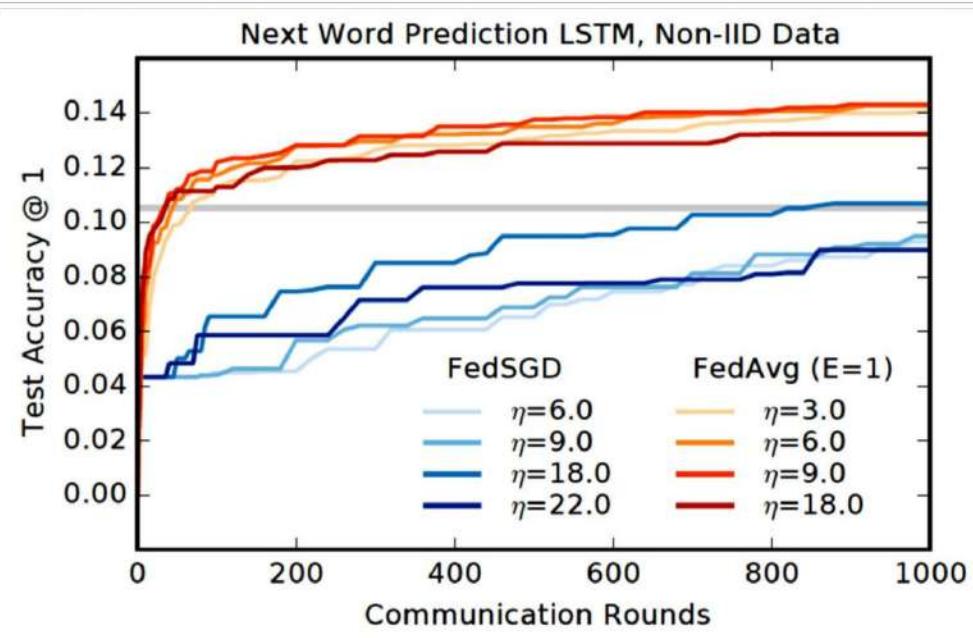
→ highest predicted Prob.
یعنی اینکه

→ Test set: 1e5 posts from different (non-training) authors

→ Comparing FedAvg with $B=8$ and $E=1$ and FedSGD

→ FedAvg اولی است

→ FedAvg نسبتاً سریع و از داده های کم استفاده می کند



→ Research google.com

→ جویا احمدی نایاب زینتی سریع

جیسا کو تجزیع نہ ہے عین عکس

نرمیں تا اپنیا ہٹکاری مالکا برائی حل سندہ بنیں رہ کا بر

Example

$$\begin{aligned} \text{min } & (x_1 - \frac{1}{8}x_1^2) + (x_2 - \frac{1}{8}x_2^2) \\ \text{s.t. } & x_1 + x_2 \leq 7 \end{aligned} \quad \rightarrow \text{Decomposition}$$

ناتھ (0,4] [0,4] محدود ہے چہ تبدیل کیا ہے (ایک ایک صرف 4 اسٹ)

$$\xrightarrow{\text{شرط KKT}} \begin{cases} -(1 - \frac{1}{4}x_1) + \lambda = 0 \\ -(1 - \frac{1}{4}x_2) + \lambda = 0 \\ x_1 + x_2 = 7 \end{cases} \Rightarrow \begin{cases} x_1^* = 3.5 \\ x_2^* = 3.5 \\ \lambda^* = \frac{1}{8} \end{cases}$$

۲ میلی مترهای شدن تبدیل ترکیبی Force to Agent ~ نتیجه حالت کند (نتیجه نیست)

فرضی کننده λ بیت داشت باشد برداشت شد:

$$\text{real payment: } \lambda x_i \quad \Rightarrow \quad \text{payoff: } U_i(x_i, \lambda) = x_i - \frac{1}{8}x_i^2 - \lambda x_i;$$

$$\Rightarrow \text{دفعه بینه دارم: } U_i(x_i^*, \lambda^*) = x_i^* - \frac{1}{8}x_i^{*2} - \lambda^* x_i^* = 1.53125$$

فرضی کننده عامل ۱، $x_i^* = 3.5$ و $\lambda^* = 0$ تعدادی $x_2^* = 3.5$ نسبت می‌باشد. در این حالت نمی‌توان عامل بیت در نیمه $\lambda = 0$

$$\Rightarrow U_i(\hat{x}_i, \lambda^*) = U_i(3.0) = \hat{x}_i - \frac{1}{8}\hat{x}_i^2 - \lambda^* \hat{x}_i = 1.875 > U_i(x_i^*, \lambda^*) = 1.53125$$

↓ Deviate Agent ها اگرچه (قطع) از تعدادی بینه را دارند

در حالی که تابع صرف معکوس باشد، یعنی از Agent ها اگرچه محدودیت تخصیص را تبدیل کنند با محدودیت payment سه افزایش یابند

← Mechanism Design از باستانه اگرچه داشته باشد که از جای بینه قطعی نند
↓ Sub Payment Function

فرضی کرد که در بین

optimal Solution ~ selfish

بریند Agent ها اگرچه قطعی نباشند

• Non - Cooperative optimization (Decision Making / Game)

هندسه کامپیوچری خاصه سردود را مینهاد
 بینی اولی (global optimality) \rightarrow
 سایر حل از نظریه بازی ها، استفاده می شوند
 جانشی (یا فیل) برآورده نمی شوند، تعامل نشوند و ایجاد کنند

(Game Components . اجزای بازی)

set of players (Agents): $N = \{1, \dots, N\}$

strategy sets: $x_n \in X_n \quad \forall n \in N$

objective functions: $J_n(x_n, x_{-n}) \quad \forall n \in N \rightarrow x_n = [x_1^T, \dots, x_{n-1}^T, x_{n+1}^T, \dots, x_N^T]$
 تغییرات همی بازیان جنبه

هر Agent تغییری کندس زنای بازی بینند

تابع صفت فردی تغییر کاند در تابع صفت هر Agent از تغییری کاری بازی

تاثیرگذار (Coupling)

• Best Response Function

$$\Rightarrow BR_n(x_{-n}) = \arg \min_{x_n \in X_n} J_n(x_n, x_{-n}) \quad \forall n \in N \rightarrow \text{تابع برد تغییر تغییر}$$

که باید براحتی x_n توانش برست باید (evaluate شود)
 که آرچه باشی صفت عمل کند و نهایت بینی داشته باشد

• Information and Learning Game

دیگری غیر مطابرانه اطلاعات فرضی وجود دارد (شیخ صفت راست آنکی حقیقی) \rightarrow بهینه سازی مطابانه هم شیخ صفت اطلاعات فرضی عمل نهاد

تاریخی تغییات سایر بازیگران (historical information) در اسکار دیر بازیگر است

لیے بازیگر تکرار شونده
لیے بازیگران تغییراتی ریلان را بسته به CO آرچیتیکت
که broad cast کرده اند aggregation

که بازیگران تغییر حداقت از این است Agent ها از سایرین
خبر را شنیدند. و غیر این صورت پیدا شدن تغییراتی تغییر نمودند

بازیگران اطلاعات شفیعی
هر اطلاعاتی را
بر آن بنامند
که Evaluate

حالت ساده تر را نمی خواهیم که بازیگران تاریخی تغییر حداقتی بسته

Agent ها باشند تاریخی، تغییر بازیگران را نمی خواهند \rightarrow این اتفاق باید تکرار شود

که غمین ساده ای این Naïve expectation استادهای نوو

که استاده از این حکایتی بخوبی مطلب نیست

فرض ناتیج این تغییر سایر Agent ها

\rightarrow با محاسبه BR و تعمیم دهنده iteration . یادگاری آسانی می افتد

• Nash Equilibrium

تبه بازی معرفی شده تعامل داشت (معرفی شده توسط جان نش آیی سود) \rightarrow بازی تعادل شیخ هدروی شود

تعامل شیخی : تضادی که در آن هیچ کس از Agent ها تواند با تغییر استراتژی این بابت بردن اسرائیلی بقیه به تبعه نماید

که هیچ Agent که آنرا غلطی می سارد

(x_1^*, \dots, x_N^*) is an NE if $\forall n \in N \quad \forall x_n \in X_n : J_n(x_n^*, x_{-n}^*) \leq J_n(x_n, x_{-n}^*)$

شیخ هدروی

Prisoner's Dilemma:

		Prisoner 2	
		Cooperate	Defect
Prisoner 1	Cooperate	3, 3	0, 5
	Defect	5, 0	1, 1

هر دوی از اعتراف کردن بگذرد →
بسته حالت می‌آید به عقاید غرضتمند شده
حال مناسبی نمی‌شود

Social optimality

کمینه ارزشی اعتراف نکند Social welfare نمود و بعد از هر دوی، دلیل آن خدعاهاست تصور نمی‌کنند که هر دوی هر کدام اعتراف کردن برداشت. در تجربه هر دوی اعتراف می‌کنند و سال زیان ایجاد می‌کنند!
لے کے خواصی معتبر می‌باشد

تعادل فرضی

• Aggregative / Mean - Field game

→ جو خواص تعامل بازی) غیر همطابق با همه صفات توزیع شده به دست بیارم

objective Function: $J_n(x_n, \sigma(x_N)) \quad \forall n \in N$

Aggregative / Mean - Field Term

← معمولاً از لذاری Agent های دیگر را می‌گیرند

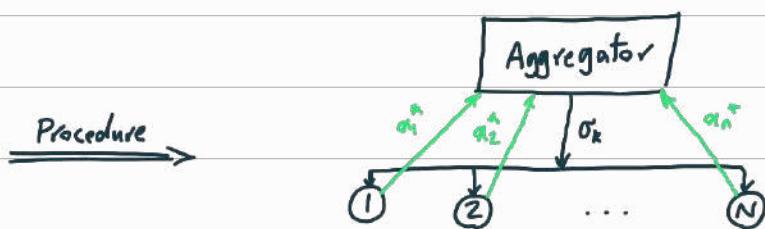
می‌ترسند باید صرف سال شود

Aggregative Term: $\sigma(x_N) = \frac{1}{N} \sum_{n \in N} x_n \quad \rightarrow$ جو تواند هر دیگر کمی بگزیند

Best Response: $x_n^{br} = \arg \min_{y \in X_n} J_n(y, \frac{1}{N} y + \frac{1}{N} \sum_{j \neq n} x_j) \quad \forall n \in N$

↑ این تفکر خود ایجاد می‌کند
و نظرگیرنده شود

بین صرفت ها دسترسی به historical data ندارند و بازیکاری هم با آن ندارند. قیمت نیاز به ماتریس نفع Aggregation نیز ندارند.
Broadcast : Aggregative Term عبارت از Aggregator یعنی Coordinator



$$\Rightarrow \left\{ \begin{array}{l} \text{Agents: } x_n^*(\sigma_k) = \underset{y \in \mathcal{X}_n}{\operatorname{argmin}} J_n(y, \sigma_k) \rightarrow \sigma_k \rightarrow \text{Agent} \\ \text{Aggregator: } \Lambda(\sigma_k) = \sum_{n \in N} \frac{1}{N} x_n^*(\sigma_k) \\ \sigma_{k+1} = (1 - \alpha_k) \sigma_k + \alpha_k \Lambda(\sigma_k) \end{array} \right.$$

تابع تعمیمی σ_k از σ_k برای Agent
 پسندیده می‌باشد آن را به سازمانی دهد
 (BR دین بسته نیست)

$\bar{\sigma}_{k+1}$

initialization

randomly initialize $\sigma_0, k \leftarrow 0$

iteration

for $n \in N$

$x_n^*(\sigma_k) \leftarrow \underset{y \in \mathcal{X}_n}{\operatorname{argmin}} J_n(y, \sigma_k)$

end

$\Lambda(\sigma_k) \leftarrow \sum_{n \in N} \frac{1}{N} x_n^*(\sigma_k)$

$\sigma_{k+1} \leftarrow (1 - \alpha_k) \sigma_k + \alpha_k \Lambda(\sigma_k)$

$k \leftarrow k + 1$

Naive $\bar{\sigma}_{k+1} : \sigma_{k+1} = \Lambda(\sigma_k)$

ان عینی smooth تراست

کل از این تفسیر مر NE می‌باشد صفت نظرنده دستیابی

C-Nash Equilibrium: $J_n(x_n^*, \frac{1}{N} \sum_{j \in N} x_j^*) \leq \min_{x_n \in \mathcal{X}_n} J_n(x_n, \frac{1}{N} x_n + \frac{1}{N} \sum_{j \in N, j \neq n} x_j^*) + \epsilon \quad \forall n \in N$

بسطهی و شعاعی اطلاع

$\bar{\sigma}_{k+1}$

نیجه به انتزاه حدکاره عبارت از σ_k برای Agent

هرچه N بزرگ باشد اما σ_k را کمتر داشته باشد که ممکن نیست

$\sum_{k=1}^{\infty} \alpha_k^2 < \infty$, $\sum_{k=1}^{\infty} \alpha_k = \infty$, $\alpha_k \neq 0$: **فرص** **حال** **هذلول**

: uniformly Lipschitz continuous $J_i(y, \sigma)$

$$J_i(y, \sigma) - J_i(\tilde{y}, \tilde{\sigma}) \leq L (\|y - \tilde{y}\| + \|\sigma - \tilde{\sigma}\|)$$

شرطیانی: متن پیغام را می‌دانیم →
محمد باشد

$x_i^*(\sigma) - x_i^*(\tilde{\sigma}) \leq \|\sigma - \tilde{\sigma}\|$: (سترن بافرس) \Rightarrow Non-Expansive \Rightarrow BR

برای داراءه های باعث شرط \rightarrow impose شوند

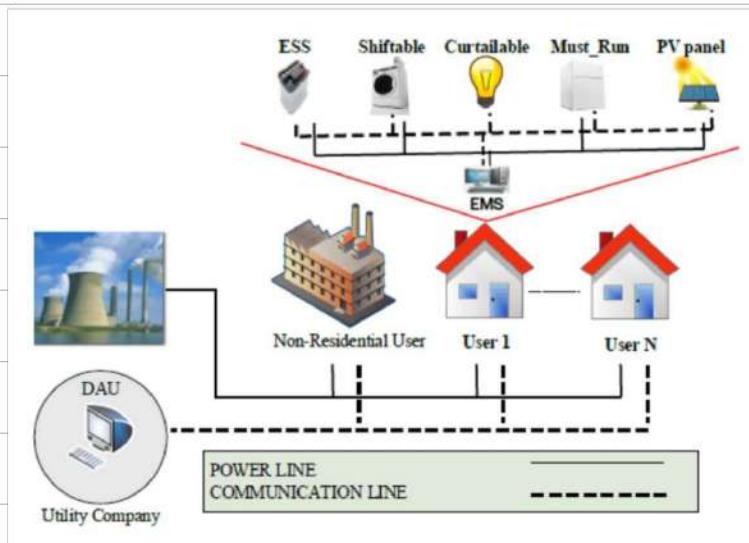
$$\Lambda(\sigma) = \frac{1}{N} \sum_{i=1}^N \pi_i^*(\sigma) = \sigma$$

$$(1 - \alpha_k)\sigma + \alpha_k \sigma = \sigma$$

$\vdash_1 E_N$ -Nash Equilibrium

EN سایه سطحی N مدر ← برای مسائل بابعاد بالا هم است!

• Application : Energy Management



Battery

→ photovoltaic

→ Load

Battery soc (state of the charge) dynamic :

$$SoC_n^t = SoC_n^{t-1} + \frac{\alpha_{1,n}}{\beta_n} p_{ch,n}^t - \frac{\alpha_{2,n}}{\beta_n} p_{dch,n}^t$$

$$SoC_n^{min} \leq SoC_n^t \leq SoC_n^{max}$$

$$0 \leq p_{ch,n}^t \leq p_{ch,n}^{max}, 0 \leq p_{dch,n}^t \leq p_{dch,n}^{max}$$

$$\forall t \in \mathcal{T} = \{1, \dots, T\}$$

Battery Degradation Cost:

$$g(p_{b,n}^t) = a|p_{b,n}^t|^2 + b|p_{b,n}^t| + c$$

$$p_{b,n}^t = p_{ch,n}^t - p_{dch,n}^t$$

بعد خط پیش توان شارژ یا دشارژ
هزارت

توان محدودیت ارتباط سیم با توان انرژی خودستکاری باید بینی نورد \rightarrow نیازمندی بینی داشت
رفت آب راهنمای

$$\Rightarrow P_{PV,n}^t \quad \forall t \in \mathcal{T} \rightarrow$$

برای خلاصه بینی آب راه
قطع ممکن است

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

/ /

* Distributed Optimization



دایرکت، اجاع کارگران، Coordinator

هدف یکنفرن مجموع فراغ هدف معمول است که براساس یک توزیعی تغییر باش (اینست) باهم در ارتباط باشند.

هدف معمول های این است که به صورت همکارانه سه بینه سازی تغییر نمایند.

$$\underset{x}{\text{Minimize}} \sum_{i=1}^m f_i(x)$$

$$x \in X = \bigcap_{i=1}^m X_i$$

که آن $f_i: R^n \rightarrow R$ Convex است و اطلاعات تحقیق عامل i معرف می شود. $X_i \in R^n$ یک مجموعه بسته و X_i می باشد و همچنین عامل های اطلاعات مجموعه مترک $\bigcap_{i=1}^m X_i = X$ دسترسی دارند.

جون مرات strongly Connected Node

اطلاعات معرف می باشد و با بهای خوب از تاک بلنوار

دسترسی حاصل می شود

متداول بینه سه هدف را $\min_x f(x)$ دیگر رموزه باخ های بینه سه را $\min_x g(x)$ دیگر

فرض می شود زده های زیر را در همه نقاط تحقیق نمایند و برابر باشند برای آن ها نویسند \bar{x} به صورت زیر تعریف می شود:

$$f_i(\bar{x}) - f_i(x) \leq S_{f_i}(\bar{x})(x - \bar{x}) \quad \forall x$$

که آن $S_{f_i}(\bar{x}) \in R^n$ نویسند f_i در \bar{x} می باشد.

$$S_{f_i}(\bar{x}) \in \partial f_i(\bar{x}) \subseteq \mathbb{R}^n$$

مجموعه زیرمیزبانی تابع f_i در \bar{x}

الدیم تصویرسازی زیرمیزبانی توزیع شده:

روند الگوریتمی بهینه سازی از یک عامل از جواب نهادن بهینه سازی به صفت $X \in \mathbb{R}^{n \times n}$ می‌کند که هر مرحله از الگوریتمی بهینه سازی ما برداشته شود.

دسته تغییر شخصی از کاربرد این اجرای الگوریتم ندارد، وین عاملی می‌شاند تابع هدفی را بنت به آن بهینه کند
رسانی مادر درینه الگوریتم شده:

$$f_i(x) = \min_{y_i} g_i(y_i, x)$$

⇒ عامل های دنبال می‌گردند یک تغییر است (x) هست

x : عکس عامل؛ از \mathbb{R}^n

این بروزرسانی سه مرحله است: ۱) ترتیب بهینه عامل؛ عامل‌هایی هستند

Weighted Average Consensus (زاویه میانگین وزنی)

۲) حکمت درجهت عکس زیرمیزبانی حکمت کنن؛ f_i بهینه سازی

۳) تغییرسازی مقدار به دست آمده به مجموعه X هست

⇒ دھر بروزرسانی یک ترم به دست آمده توزیع شده است (بدون نظر روش قید) برداشته می‌شود.

باین ترتیب هر مراحل متن را به شکل زیر نمایم گردید:

1 شروع از شرایط اولیه $x^i(0)$ و $k=0$, ..., m

منظور از این مراحل معرفت می‌شود:

2 ترتیب اطلاعات: $v^i(k) = \sum_{j=1}^m a_j^i(k) x^j(k)$

Weighted average \longrightarrow

3 $x^i(k+1) = P_x [v^i(k) - \alpha_k d_i(k)]$

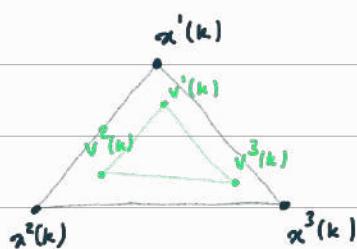
4 $k=k+1$

برای مرحله 2 آن شرط تحقق

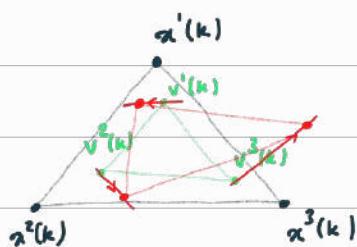
در هر بیان $f_i(x)$ ضوابط مارکوفی داشتیم $A(k)$ و $\alpha_k > 0$ و $d_i(k)$ نرخ تراویح آنچه $x = v^i(k)$ باشد.

Example

$$x \in \mathbb{R}^2, m=3$$



با این در نظر گرفته هر سه نقطه می‌توانند از این سه نقطه میانگین است بگیرند
و در نتیجه تقریباً میانگین شدن با اینجا بینش



با این دو دوست میان نرخ تراویح میان میانگین است \rightarrow
نهایت دوست میان نرخ تراویح میان میانگین است \rightarrow Consensus میانگین شدن

→ باید برای نزد بازیت در مت عکس زیر را باید اعمال ها به اجماع می راند ؟
 → باید برای نزد آنر عامل ها به اجماع بینند، متاریب دست آشده بینه کنن تابع هدف است ؟

↑ ترجیحیاد سازی الگوریتم ساره است، نک از نظر معنی دلخواهی می باشد
 (متنی) - صفت شدنی شخصی بنت

→ سوال اصلی: آیا بر اساس الگوریتم مت عکس هسته اعمال ها به متاریبینه کنن ممکن است ؟
 لے (جذع + بینی)

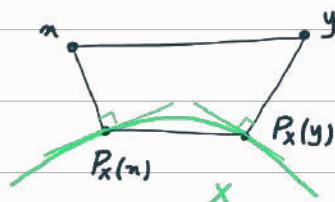
• هدایی الگوریتم بینه سازی توزیع شده.

ایدها بخار رفتہ دنیا است هدایی الگوریتم بینه سازی توزیع شده پر کاربرد است

$$\text{رجی فراص نظری سازی} : P_x(\bar{x}) = \underset{\alpha \in X}{\operatorname{Argmin}} \| \bar{x} - \alpha \|$$

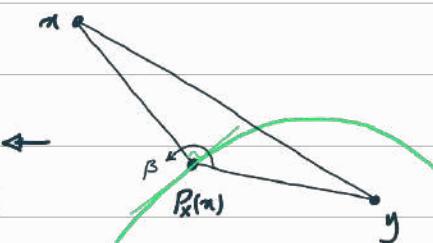
1 non expansivity: $\| P_x(x) - P_x(y) \| \leq \| x - y \|$

→ ضلع در بین دو زاویه نسبت توان 90° نبایدین ضلع چارتانی است



2 $\| P_x(x) - y \| ^2 \leq \| x - y \| ^2 - \| P_x(x) - x \| ^2 \quad \forall y \in X$

→ جن $90^\circ > \beta$ است نتایج باقی می باشد (جهت 90°)
 نتایج بینایی شود



میراث:

1 weight rule $a_j^i \geq q$, if $a_j^i > 0$ then $a_j^i \geq q$ \rightarrow Consensus نیز

ذن عوامل بخشن \rightarrow ذن عوامل حایی که بعمل:
بست است بدل داشت است

→ هدایت بست ازین ذنی، حدیث و دارند

2 Doubly stochasticity of $A(k)$

$$A(k) = [a_j^i(k)]_{ij} \quad I^T A(k) = I^T \quad |A(k)| = 1$$

لے عوامی دست (ایک) $A(k)$ برابر است

3 $G(v, E_\infty)$ Strongly Connected \rightarrow است رفاه داشت

$$E_\infty = \{(j, i) | (j, i) \in E_k \text{ for infinitely many times } k\}$$

strongly connected: بارگھی رفاه داشت: infinitely often, infinitely many times

حکم رفاه داشت بارگھی رفاه داشت (اجماع بارگھی رفاه داشت)

Node strongly connected دصلی رفاه داشت بارگھی رفاه داشت (ایکی محدودیت)

infinitely often

برانگی هر $(i, j) \in E_\infty$ رجید مدار $i \rightarrow j$ که ز حوالین از β تکار اطلاعات خود را برای j ارسال کند

هر دو یا چند تراویت تاکل اطلاعات داشتند

4

→ $\beta(m-1)$ تک در مدل می‌گذاریم و درین Node ها اطلاعات آن بهم برده

3, 4 → Periodically Strongly Connected

5 مجموعه شدنی سلسله نهایی محدود بسته دیریکله عامل های عدده است:

$$\bigcap_{i=1}^m X_i = X \rightarrow \begin{array}{l} \text{مجموعه انتظار حاصل از مجموعه} \\ \text{شدنی خودشی را می‌داند} \end{array}$$

closed and convex

6 فرضی شود زیرا دایان f_i د مجموعه X محدود است به طوری که:

$$d < L > 0 \quad \forall i \in f_i(a) \quad \forall x \in X \quad \forall i$$

حد بازی زیرا دایان

الگوریتم بینه‌سازی توزیع شده:

$$v^i(k) = \sum_{j=1}^m \alpha_j^i(k) x^j(k)$$

اگر Projection

$$x^i(k+1) = v^i(k) - \alpha_k d_i(k) + \overbrace{\varphi^i(k)}$$

$$\varphi^i(k) = P_x [v^i(k) - \alpha_k d_i(k)] - (v^i(k) - \alpha_k d_i(k))$$

نه Project نه Project

→ الگوریتم همیان به اجماع عامل های تجزیه می‌رسد؟

→ اجماع در صورت دفعه ده تعداد بینه تابع صرف فراهم نمود?

بررسی اجماع

حکم اولیه

از آنچه که تأثیری نزدی بمرتبط تهاری دنبال تعیین شده است، انتظار داریم عامل ها به ستاره سلطان هدرا نشوند.
بنابراین شعاع سلطان عامل ها را تعیین می کنیم:

$$y(k) = \frac{1}{m} \sum_{j=1}^m \alpha^j(k)$$

$$y(k+1) = \frac{1}{m} \sum_{j=1}^m \alpha^j(k+1) = \frac{1}{m} \sum_{i=1}^m v^i(k) - \frac{1}{m} \alpha_k \sum_{i=1}^m \alpha_i(k) + \frac{1}{m} \sum_{i=1}^m \varphi^i(k)$$
$$\underbrace{- \frac{1}{m} \sum_{i=1}^m \sum_{j=1}^m \alpha_i^j \alpha^j(k)}_{= \frac{1}{m} \sum_{j=1}^m \alpha^j(k) \sum_{i=1}^m \alpha_i^j} = y(k)$$

1 تهاری دنبال $\Leftrightarrow A$

$$\Rightarrow y(k+1) = y(k) - \frac{\alpha_k}{m} \sum_{i=1}^m \alpha_i(k) + \frac{1}{m} \sum_{i=1}^m \varphi^i(k)$$

نهی: تهمت فرمات زگر شده (6-1) اگر زبانه $\{\alpha^i(k)\}$ توسط الگوریتم تقریب سازی زیربرآین توزیع شده (PDSG)
تلخیش نشود در نهایه $\{y(k)\}$ به شعل منطق تعیین شود آنکه:

خطه ای اجماع

1 $\lim_{k \rightarrow \infty} \|\alpha^i(k) - y(k)\| = 0 \quad \forall i \text{ if } \lim_{k \rightarrow \infty} \alpha_k = 0$

2 $\sum_{k=1}^{\infty} \alpha_k \|\alpha^i(k) - y(k)\| < \infty \quad \forall i \text{ if } \sum_{k=1}^{\infty} \alpha_k^2 < \infty \rightarrow (\alpha_k, \frac{1}{k})$ قبل ناسیم محمد کوتبیت

حدود بدل جمیع نزدی دار خطه ای اجماع نه طول شماره

ابت

$$\alpha(k+1) = A(k)\alpha(k) - \alpha_k d(k) + \varphi(k)$$

بردۀ زیرگران
سابق اجاع

← Compact من
بهار ایوری ساده تر

آنچه های بردۀ کا پسند داریم باشی بازی داده می شود که جبرت باشی بازی ابتدۀ را در خاصیت مدار

جولات را از مرحله $s \leq k$ برخیزیم (برخیزی انتظار مرحله آخر کافی نیست و ممکن است تغییر ایام نیستد)

$$\Phi(k, s) = A(k)A(k-1) \dots A(s)$$

بدین افتد (این عبارات احتماله شدنی)

$$\begin{aligned} \Rightarrow \alpha(k+1) &= \underbrace{\Phi(k, s)\alpha(s)}_{\vdots} + [-\alpha_k d(k) + \varphi(k)] \\ &+ \Phi(k, k) [-\alpha_{k-1} d(k-1) + \varphi(k-1)] \quad \Phi(k, k) = A(k) \\ &+ \Phi(k, k-1) [-\alpha_{k-2} d(k-2) + \varphi(k-2)] \quad \Phi(k, k-1) = A(k)A(k-1) \\ &\vdots \\ &+ \Phi(k, s+1) [-\alpha_s d(s) + \varphi(s)] \end{aligned}$$

بازی رابطه می دهد حالات بردۀ کا برای عامل φ (سایر های خویشان را ترسیم Φ دارد) d_j را φ ضرب می شود:

$$\begin{aligned} \alpha^i(k+1) &= \sum_{j=1}^m [\Phi(k, s)_j^i] \alpha^j(s) \\ &- \sum_{r=s}^{k-1} \sum_{j=1}^m [\Phi(k, r+1)]_j^i \alpha_r d_j(r) - \alpha_k d_i(k) \\ &+ \sum_{r=s}^{k-1} \sum_{j=1}^m [\Phi(k, r+1)]_j^i \varphi^j(r) + \varphi^i(k) \end{aligned}$$

برای داشتن مسأله مرتبط از باطله مفهومی ترتیبی نیز:

$$y(k+1) = y(s) - \frac{1}{m} \sum_{r=s}^{k-1} \sum_{j=1}^m \alpha_r d_j(r)$$

$$- \frac{\alpha_k}{m} \sum_{i=1}^m d_i(k) + \frac{1}{m} \sum_{r=s}^{k-1} \sum_{j=1}^m \varphi^j(r)$$

$$+ \frac{1}{m} \sum_{i=1}^m \varphi^i(k)$$

شاید بترین ارجاعی \sum ها
از هزاری چند

$$y(o) = \frac{1}{m} \sum_{i=1}^m \alpha^i(o) : \text{و دیگر } y(k) = \alpha^i(k) + \text{داین زیرا مثل} \rightarrow k+1 \rightarrow k \rightarrow s \rightarrow o \text{ (حل بار)}$$

$$\| \alpha^i(k) - y(k) \| \leq \sum_{j=1}^m \left| [\Phi(k-1, o)]_j^i - \frac{1}{m} \| \varphi^j(o) \| \right| \quad \leftarrow \text{استفاده از نسبتی ملی ضرب و جمع}$$

$$+ \sum_{r=o}^{k-2} \sum_{j=1}^m \left| [\Phi(k-1, r+1)]_j^i - \frac{1}{m} \| \alpha_r \| d_j(r) \| \right| \quad \rightarrow \text{از حد بار استفاده شود}$$

$$+ \alpha_{k-1} \| d_i(k-1) \| + \frac{\alpha_{k-1}}{m} \sum_{j=1}^m \| d_j(k-1) \|$$

$$+ \sum_{r=o}^{k-2} \sum_{j=1}^m \left| [\Phi(k-1, r+1)]_j^i - \frac{1}{m} \| \varphi^j(r) \| \right|$$

$$+ \| \varphi^i(k-1) \| + \frac{1}{m} \sum_{j=1}^m \| \varphi^i(k-1) \|$$

دستی اجماع نهاده شد: $|\varphi(k, s)|^i_j - \frac{1}{m} \| \varphi^j(s) \| \leq C\beta^{k-s}$

\leftarrow نایهی ها فی باخ خیلی بست $\frac{1}{m}$ بودند

$$\Rightarrow \|\alpha^i(k) - y(k)\| \leq C\beta^{k-1} \sum_{j=1}^m \|\alpha^j(0)\| + mCL \sum_{r=0}^{k-2} \beta^{k-r-2} \alpha_r$$

$$+ 2\alpha_{k-1}L + C \sum_{r=0}^{k-2} \beta^{k-r-2} \sum_{j=1}^m \|\varphi^i(r)\|$$

$$+ \|\varphi^i(k-1)\| + \frac{1}{m} \sum_{j=1}^m \|\varphi^j(k-1)\|$$

: ($\|\varphi_i(k)\| \leq \alpha_k L$) بفریب α_k بهست معرفی اردید ($\varphi^i(k)$) Projection نتیجہ

2: خاصیت تقدیری سازی : $\|P_x(n) - y\|^2 \leq \|\alpha - y\|^2 - \|P_x(n) - \alpha\|^2 \quad \forall y \in X$

عنین در : $\forall \alpha^i \in X \Rightarrow \underline{\alpha^i(k)} \in X$
عنین Combination of α^i 's

$$\begin{aligned} & \underline{\alpha^i(k) - \alpha_k d_i(k) + \varphi^i(k)} \quad \text{Projection از} \underline{\alpha} \\ \Rightarrow & \|\underline{\alpha^i(k+1) - \alpha^i(k)}\|^2 \leq \|\underline{\alpha^i(k) - \alpha_k d_i(k) - \alpha^i(k)}\|^2 - \|\alpha^i(k+1) - (\alpha^i(k) - \alpha_k d_i(k))\|^2 \\ & \leq \alpha_k^2 L^2 - \|\varphi^i(k)\|^2 \Rightarrow 0 \leq \alpha_k^2 L^2 - \|\varphi^i(k)\|^2 \end{aligned}$$

$$\Rightarrow \|\varphi^i(k)\| \leq \alpha_k L$$

: $\int_0^\infty \alpha_s \varphi(s) ds = \varphi(0)$ حسابی اند

$$\|\alpha^i(k) - y(k)\| \leq C\beta^{k-1} \sum_{j=1}^m \|\alpha^j(0)\| + 2mCL \sum_{r=0}^{k-2} \beta^{k-r-2} \alpha_r + 4\alpha_{k-1}L \quad (*)$$

$0 < \beta^k < 1 \Rightarrow \beta \rightarrow 0 \Rightarrow \alpha \rightarrow 0 \Rightarrow k \rightarrow \infty \text{ حالت محدودیتی}$

$$\Rightarrow \lim_{k \rightarrow \infty} \|\alpha^i(k) - y(k)\| \leq 2mCL \beta^{-2} \lim_{k \rightarrow \infty} \sum_{r=0}^{k-2} \beta^{k-r} \alpha_r$$

$$\sum_{r=0}^k \beta^{k-r} \alpha_r < \gamma_k \sum_{r=0}^k \beta^{k-r} + c_k \sum_{r=k+1}^k \beta^{k-r} \quad \text{جداً من الممكن}$$

مان α_r
مان α_r

$\alpha_r \leq k$
 $k \leq r \leq k$

منطقی : $K = \frac{k}{2} \Rightarrow K, k \rightarrow \infty \rightarrow \text{ما يكمل} \infty$

$$\Rightarrow \frac{-\beta^{k-k-1}}{\beta^{k-k-1} - \beta} \xrightarrow{\substack{\downarrow \text{مان } \alpha_r \\ \alpha_r \leq r}} \rightarrow 0, \quad c_k \rightarrow 0 \Rightarrow \lim_{k \rightarrow \infty} \sum_{r=0}^k \beta^{k-r} \alpha_r = 0$$

$\alpha_r \leq r$

$$\Rightarrow \lim_{k \rightarrow \infty} \|\alpha^i(k) - y(k)\| = 0 \quad \forall i \rightarrow \text{اجماع صوت ملحوظ}$$

زوجي متماثل دليل تام يعني ان (حاصل زوجي) دليل نوح متماثل آن دليل

$$\textcircled{*} \times \alpha_k \rightarrow \alpha_k \|\alpha^i(k) - y(k)\| \leq C \alpha_k \beta^{k-1} \sum_{j=1}^m \|\alpha^j(0)\| + 2mCL \sum_{r=0}^{k-2} \beta^{k-r-2} \alpha_k \alpha_r + 4\alpha_k \alpha_{k-1} L$$

برای کار بخوبی کامل سازی خواهی شد $\alpha_k \beta^2 < \alpha_k + \beta^{2(k-1)} \Rightarrow 2\alpha_k \alpha_r < \alpha_k^2 + \alpha_r^2$ (حاصل زوجی)

$$\begin{aligned} \Rightarrow \alpha_k \|\alpha^i(k) - y(k)\| &\leq C \beta^{2(k-1)} \sum_{j=1}^m \|\alpha^j(0)\| + C \alpha_k^2 \sum_{j=1}^m \|\alpha^j(0)\| \\ &+ mC \alpha_k^2 L \underbrace{\sum_{r=0}^{k-2} \beta^{k-r-2}}_{\leq \frac{1}{1-\beta}} + mCL \sum_{r=0}^{k-2} \beta^{k-r-2} \alpha_r^2 + 2L(\alpha_k^2 + \alpha_{k-1}^2) \end{aligned}$$

$\rightarrow \infty$ مع

$$\Rightarrow \alpha_k \|\alpha^i(k) - y(k)\| \leq C \beta^{2(k-1)} \sum_{j=1}^m \|\alpha^j(0)\| + \underbrace{mCA\alpha_k^2}_{A = \frac{1}{m} \sum_{j=1}^m \|\alpha^j(0)\|^2} + mCL \sum_{r=0}^{k-2} \beta^{k-r-2} \alpha_r^2 + 2L(\alpha_k^2 + \alpha_{k-1}^2)$$

$$\sum_{k=1}^{\infty} \alpha_k \|x^i(k) - y(k)\| \leq C \underbrace{\sum_{k=1}^{\infty} \beta^{2(k-1)} \sum_{j=1}^m \|x^j(0)\|}_{T1} + \underbrace{\sum_{k=1}^{\infty} (mcA\alpha_k^2 + 2L(\alpha_k^2 + \alpha_{k-1}^2))}_{T2}$$

$$+ mCL \underbrace{\sum_{k=1}^{\infty} \sum_{r=0}^{k-2} \beta^{k-r-2} \alpha_r^2}_{T3}$$

$$\sum_{k=1}^{\infty} \beta^{2(k-1)} \Rightarrow T1$$

$$\sum_{k=1}^{\infty} \alpha_k^2 \Rightarrow T2$$

$$T3 \text{ برای } k \rightarrow \infty : \sum_{k=1}^{\infty} \sum_{r=0}^{k-1} \beta^{k-r-2} \alpha_r^2 = \sum_{r=0}^{\infty} \alpha_r^2 \sum_{k=r+1}^{\infty} \beta^{k-r} < \frac{1}{1-\beta} \sum_{r=0}^{\infty} \alpha_r^2 < \infty$$

بنابراین α_k تغییری کرد که طبق تراز ۲ نی شود ($k \geq r$)

$$\Rightarrow \sum_{k=1}^{\infty} \alpha_k \|x^i(k) - y(k)\| < \infty \rightarrow \text{ابتدا ممکن است}$$

(ترسل فتنه هدف خطی ایج)

(فتن دارسته با α_k از این دسته از

(Transition time \rightarrow Projection

اگر رضایت بیان شده ۶-۱ برآورده باشد $\{x^i(k)\}$ تربط معادلات نزیر تولید شود : optimality تصدیق

$$v^i(k) = \sum_{j=1}^m \alpha_j^i(k) x^j(k)$$

$$x^i(k+1) = P_x [v^i(k) - \alpha_k d_i(k)]$$

وابحثی است

squared summable non summable

بطریکه $\sum \alpha_k^2 < \infty$ و $\sum \alpha_k = \infty$ بشه در همین مجموعه X^* غیرهی باشد، و این صرتباً باعث بین X^* دو دلار به طریکه تعبیه حد عاملها با این باعث هتلایی شوند. به عبارت دیگر :

$$\lim_{k \rightarrow \infty} \|x^i(k) - x^*\| = 0 \quad \forall i \rightarrow \text{از} X^* \text{ هتلایی شوند}$$

ابت

$$\text{لایح یافیل: } \sum_{i=1}^m \|x^i(k+1) - x^*\|^2 = \sum_{i=1}^m \|P_x[v^i(k) - \alpha_k d_i(k)] - x^*\|^2 \rightarrow \text{این دلخواه ترکیب زیرگراند است مفهومی}$$

حالت ۱ تغییر سازی : $\|P_x(x) - P_x(y)\| \leq \|x - y\|$

(non expandability)

$$\Rightarrow \dots \leq \sum_{i=1}^m \|v^i(k) - \alpha_k d_i(k) - x^*\|^2 \rightarrow P_x[\dots] \text{ نا از بین بردم}$$

$$= \sum_{i=1}^m \|v^i(k) - x^*\|^2 + \sum_{i=1}^m \alpha_k^2 \|d_i(k)\|^2 - 2\alpha_k \sum_{i=1}^m d_i^T(k)(v^i(k) - x^*) \rightarrow \text{من تعیین زیرگراند} \geq f_i(v^i(k)) - f_i(x^*)$$

$$\leq \sum_{i=1}^m \|v^i(k) - x^*\|^2 + m\alpha_k^2 L^2 - 2\alpha_k \sum_{i=1}^m [f_i(v^i(k)) - f_i(x^*)]$$

$$\sum_{j=1}^m a_j^i x^j(k) \quad \sum_{j=1}^m a_j^i x^j(k)$$

$$\sum_{i=1}^m \left\| \sum_{j=1}^m a_j^i (x^j(k) - x^*) \right\|^2 \leq \sum_{i=1}^m \sum_{j=1}^m a_j^i \|x^j(k) - x^*\|^2 = \sum_{i=1}^m \|x^i(k) - x^*\|^2$$

بررسی آن جهت این عبارت

$$\Rightarrow \sum_{j=1}^m \|x^j(k+1) - x^*\|^2 \leq \sum_{j=1}^m \|x^j(k) - x^*\|^2 + m\alpha_k^2 L^2 - 2\alpha_k \sum_{i=1}^m [f_i(v^i(k)) - f_i(x^*) + f_i(y(k)) - f_i(y(k))] \oplus$$

است Convex Combination $\Rightarrow f_i(y(k)) \geq f_i(x^*)$

$$\sum_{i=1}^m |f_i(v^i(k)) - f_i(y(k))| \leq \sum_{i=1}^m L \|v^i(k) - y(k)\| \leq L \sum_{j=1}^m \sum_{i=1}^m a_j^i \|x^j(k) - y(k)\|$$

$$\text{تعیین زیرگراند / سطح مستقر} \quad \sum_{j=1}^m a_j^i x^j \quad \sum_{j=1}^m a_j^i y = \sum_{j=1}^m L \|x^j(k) - y(k)\|$$

$$\Rightarrow \sum_{i=1}^m \|\alpha_i^{(k+1)} - \alpha^*\|^2 \leq \sum_{j=1}^m \|\alpha_j^{(k)} - \alpha^*\|^2 + m\alpha_k^2 L^2 - 2\alpha_k \sum_{i=1}^m [f_i(y(k)) - f_i(\alpha^*)]$$

$$+ 2\alpha_k L \sum_{i=1}^m \|\alpha_i^{(k)} - y(k)\|$$

جبرت بود آنها را مانند کارهای اخیر پس علاوه آن
دایی نمی‌شون

عبارت ظاهر شده تا ان دفعه تری بردن بالعین بآسانی نیست! در میانه حالت حدی و به مردت

به آن حالت اولیه نیست

$$(f = \sum_{i=1}^m f_i) \text{ با جمع حاصلیم}$$

$$\Rightarrow \sum_{i=1}^m \|\alpha_i^{(N+1)} - \alpha^*\|^2 \leq \sum_{i=1}^m \|\alpha_i^{(k)} - \alpha^*\|^2 + mL^2 \sum_{k=k}^N \alpha_k^2$$

$$- 2 \sum_{k=k}^N \alpha_k (f(y(k)) - f(\alpha^*)) + 2L \sum_{k=k}^N \alpha_k \sum_{i=1}^m \|\alpha_i^{(k)} - y(k)\|$$

جبرت اولیه باید به ساده‌گاری اینجا
دست امداد آن را در حالت اولیه مانند

حالت حدی: $K=0, N \rightarrow \infty$

$$\Rightarrow 0 \leq \sum_{i=1}^m \|\alpha_i^{(N+1)} - \alpha^*\|^2 \leq \underbrace{\sum_{i=1}^m \|\alpha_i^{(0)} - \alpha^*\|^2}_{<\infty} + mL^2 \sum_{k=0}^{\infty} \alpha_k^2$$

$$- 2 \sum_{k=0}^{\infty} \alpha_k (f(y(k)) - f(\alpha^*)) + 2L \sum_{k=0}^{\infty} \alpha_k \sum_{i=1}^m \|\alpha_i^{(k)} - y(k)\|$$

باید ∞ باشد و مغایری صفت کلی جبرت را تعقیل نکند
نه صفتی که کلی جبرت بُت است

$$\Rightarrow \sum_{k=0}^{\infty} \alpha_k (f(y(k)) - f(\alpha^*)) < \infty$$

$$\sum_{k=1}^{\infty} \alpha_k = \infty \quad , \quad y(k) \in X \Rightarrow f(y(k)) - f^* > 0$$

$$\Rightarrow \liminf_{k \rightarrow \infty} [f(y(k)) - f^*] = 0$$

از زیر که K ب بعد می باشد نتیجه باشد:

$$\sum_{k=K}^{\infty} \alpha_k (f(y(k)) - f^*) \geq \sum_{k=K}^{\infty} \alpha_k \epsilon = \epsilon \sum_{k=K}^{\infty} \alpha_k \rightarrow \infty \Rightarrow \sum_{k=0}^{\infty} \alpha_k (f(y(k)) - f^*) \rightarrow \infty$$

از زیر ∞

$N \rightarrow \infty, K \rightarrow \infty$ ($\because N = 2K \rightarrow \infty$)

$$\begin{aligned} & \Rightarrow \sum_{i=1}^m \|\alpha^i(N+1) - \alpha^*\|^2 \leq \sum_{i=1}^m \|\alpha^i(k) - \alpha^*\|^2 + mL^2 \sum_{k=K}^N \alpha_k^2 \\ & \quad - 2 \sum_{k=K}^N \alpha_k (f(y(k)) - f(\alpha^*)) + 2L \sum_{k=K}^N \alpha_k \sum_{i=1}^m \|\alpha^i(k) - y(k)\| \end{aligned}$$

و درست تابع $\sum_i \|\alpha^i - y\|$ محدود است!

به دلیل مارکوف کا (حد نهایی ها) استفاده شده در اثبات داعل هدایی خلی مرد ترخ نیاده

میان دنباله لغات شده است (Bounded Below) است میان نت هدایت

$$\lim_{k \rightarrow \infty} \|\alpha^i(k) - y(k)\| = 0 : \text{هدایت دنباله } \sum_{i=1}^m \|\alpha^i(k) - \alpha^*\| \text{ دنباله } \alpha^* \in X^*$$

ناماین دنباله $\{\|y(k) - \alpha^*\|\}$ به ازای هر $\alpha^* \in X^*$ هدایت داشته باشد

و این ب علاوه دیگری تابع f دارای نتیجه $\liminf_{k \rightarrow \infty} f(y(k)) = f^*$ و ب این نتیجه $\alpha^* \in X^*$ هدایت نشود

لکن $y(k)$ در بیانیت نتیجه $\inf f$ حرفی نشود

ابتدا

$$\Rightarrow \lim_{k \rightarrow \infty} y(k) = x^* \quad \downarrow \quad \Rightarrow \lim_{k \rightarrow \infty} x^i(k) = x^* \quad \forall i \quad \rightarrow \begin{array}{l} \text{تغیراتی عامل ها ب متدهای} \\ \text{بینه هسته ای شود.} \end{array}$$

* سلسله بهینه سازی توزیع شده با تمرید تاریخ ناتاری

تقریر سازی دری تمرید ممکن است تکلیف باشد \leftarrow حل با تمرید به صفت تاریخ ناتاری می تواند مزیت داشته باشد

تعیین مسئله:

$$\min_{x \in \mathbb{R}^n} \sum_{i=1}^n f_i(x)$$

ممکن است نرخان هدف تمرید را به صفت تاریخ ناتاری بیان کند

s.t. $g(x) \leq 0 \quad h(x) = 0 \quad x \in X$

Convex $\leftarrow f_i: \mathbb{R}^n \rightarrow \mathbb{R}$ (Private information of agent-i)

X : Compact and Convex

x : global decision variable

Convex $\leftarrow g: \mathbb{R}^n \rightarrow \mathbb{R}^m \quad g(m) \leq 0 \rightarrow g_i \leq 0 \quad i \in \{1, \dots, m\}$

$h: \mathbb{R}^n \rightarrow \mathbb{R}^V \quad h(v) = Ax - b \quad A \in \mathbb{R}^{vn \times n}$

* فرضی کنیم تمرید دو گروه X برای عامل ها معلوم است

* ارتباط عامل ها از طریق یک مراقب (ماتریس تغییر بازنیان) $G_f(V, E_f)$ برقراری شود

* P مدلر بهینه سلسله بهینه سازی ر رمده می باشد

* مجموعه نقاطی بین شده و غیرتی می‌باشد

شدنی ناقص اب صفت زیر بازرسی می‌گیرد:

$$\underset{\alpha}{\text{Min}} \quad \sum_{i=1}^N f_i(\alpha)$$

$$\begin{aligned} \text{s.t.} \quad & N g(\alpha) \leq 0 \quad \rightarrow \text{ضرب } N \text{ در جواب شدنی تابعی شادر} \\ & N h(\alpha) = 0 \quad \text{دلیل حل توزیع شده به همگنی چنان} \\ & \alpha \in X \end{aligned}$$

برای شدنی تابع (یعنی لامارشین modify شده) را تعریف دینه می‌کیم.

ابتدا تابع پالی را ب صفت زیر تعریف می‌گیرد:

$$H: R^n \times R^{m \geq 0} \times R^{v \geq 0} \rightarrow R$$

$$H(\alpha, \mu, \lambda) = f(\alpha) + N \mu^T [g(\alpha)]^+ + N \lambda^T \underbrace{|h(\alpha)|}_{\max(0, g(\alpha))} \quad \rightarrow \text{شادت با تابع لامارشین}$$

برای اصل تابع (Penalty dual) به صفت زیر تعریف می‌شود:

$$q_p: R^{m \geq 0} \times R^{v \geq 0} \rightarrow R$$

$$q_p = \inf_{\alpha \in X} H(\alpha, \mu, \lambda) \quad \rightarrow \quad \text{تبهی ارتباط لامارشین شده را داشت}$$

حل سُنْتِی Penalty dual بِ صِرَاطِ تَعْرِيفِ میسُور:

$$\begin{aligned} \text{Max } & q_p(r, \lambda) \\ r \in R^n & \geq 0 \\ \lambda \in R^V & \geq 0 \\ & \text{s.t. } r \geq 0 \\ & \lambda \geq 0 \end{aligned}$$

Penalty dual \rightarrow Dual

دُعْنِی (r^*, λ^*) يَكُونُ بِحُلْجَهِ سُنْتِی Dual

$$d_a^* = q_a(r^*, \lambda^*) = \inf_{x \in X} \{ f(x) + N r^{*T} g(x) + N \lambda^{*T} h(x) \}$$

$$< \inf_{x \in X} \{ f(x) + N r^{*T} [g(x)]^T + N |\lambda^{*T}| |h(x)| \}$$

$$= q_p(r^*, |\lambda^*|) \leq \max_{\substack{r \geq 0 \\ \lambda \geq 0}} q_p(r, \lambda) = d_p^*$$

dual بِحُلْجَهِ سُنْتِی

حل سُنْتِی Penalty Dual

$$\Rightarrow d_a^* \leq d_p^*$$



Penalty dual بِحُلْجَهِ سُنْتِی

$x^* \in X^*$, $[g(x^*)]^T = 0$, $|h(x^*)| = 0$: $x^* \in X^*$ کَذَبَنِی مُجَابَهَهِ مُدْرِج

$g(x^*) \in 0$



بِسَارِنِی فَاهِمَ دَانَتْ :

$$q_p(r, \lambda) = \inf_x H(x, r, \lambda) \leq H(x^*, r, \lambda) = f(x^*) = p^*$$

($\forall r, \lambda$)

بِحُلْجَهِ سُنْتِی

$$\begin{array}{c} \text{Max} \\ r \geq 0 \quad \lambda \geq 0 \\ \hline \end{array} \rightarrow \text{Max } q_p(r, \lambda) = d_p^* \leq p^*$$

$r \geq 0 \quad \lambda \geq 0$

$$\Rightarrow da^* \leq dp^* \leq p^*$$

لناساری من رعن است اگر سڑاچی برقرار باشد که $P = da$ بند (ولا اگر نہ بینه رزگی مید دست ربط
برقرار باشد) داین صورت خاصیم داشت :

$$dp^* = p^*$$

ـ مسأله Penalty dual ـ Duality gap ـ مسأله Duality gap ـ

$$P^* - d_P^* \leq P^* - d_A^* \rightarrow \text{Penalty dual}$$

میرت دلیر تابع پالی بتہ تابع لارانز، محمد سیدن تابع پالی بتہ بتغیر خ می بند کے در تابع لارانز ب دلیں
المحل سعی بردن خدا سب ۶ این امر نہ رہا معمق نی شد

دابع لارايز گی ترافت سعی باشد \Rightarrow دابع لارايز نزدیکی محمد شرد

تھیلہ زی بکی تابع بنائی: فرنٹی مرتب (α, β, γ) کے سطہ زی تابع پالی بر $R^{\geq 0} \times R^{\geq 0} \times R^{\geq 0}$ پر بننے اور ممکن اور ان فرنٹی مرتب تاحدیہ سانیں Primal, Dual, Penalty dual, Tardیہ زیر برقرار رہنے والیں:

$$\text{Penalty} \rightarrow \inf_{\lambda \geq 0} \sup_{x \in X} H(x, p, \lambda) = \inf_{\lambda \geq 0} \sup_{x \in X} H(x, p, \lambda) \rightarrow \text{Primal} \rightarrow \inf_{x \in X} f(x)$$

جواب توزیع شود
subgradient, supergradient

بسایی ترین نتیجه ممکن (Convex-Concave) بصریت مجموع تابعی $H(x, p, \lambda)$ یعنی λ ثابت است

$$H_i(x, p, \lambda) = f_i(x) + p^T [g_i(x)]^+ + \lambda^T [h_i(x)]^- \Rightarrow H(x, p, \lambda) = \sum_{i=1}^N H_i(x, p, \lambda)$$

مجموع

$H(x, w)$: $w = (p, \lambda)$ fixed \rightarrow Convex in x

$H(x, p, \lambda)$: x fixed \rightarrow Concave in (p, λ) \rightarrow هست (p, λ) دفعه است را مینماییم
هست آن را Maximization
دتفه ای است (p, λ) Concave

: Penalty-Primal-dual method

بنابراین (x, α) است

1 Initialization: $\lambda^i(0) \in \mathbb{R}_{\geq 0}^v$, $p^i(0) \in \mathbb{R}_{\geq 0}^m$, $x^i(0) \in X$, $y^i(0) = Nf_i(x^i(0))$, $\forall i \in V$
معنی اینجا $\sum f_i$ (مجموع اصلی)
(تفصیلی است تا نیزی که در خدمت پیشگیری از این است)

2 Information fusion: $v_n^i(k) = \sum_{j=1}^N \alpha_j^i(k) x^j(k)$

خط برای این ایجاد عمل و خدمات غیرضروری است
 $v_p^i(k) = \sum_{j=1}^N \alpha_j^i(k) p^j(k)$

$$v_\lambda^i(k) = \sum_{j=1}^N \alpha_j^i(k) \lambda^j(k)$$

$$v_y^i(k) = \sum_{j=1}^N \alpha_j^i(k) y^j(k)$$

برای این تابع $H_i(x, v_p^i(k), v_\lambda^i(k), v_y^i(k))$

3 Optimization: $x^i(k+1) = P_x[\underbrace{v_n^i(k) - \alpha(k) D_x^i(k)}_{\text{step size}}]$

$$\alpha = v_n^i(k) \Rightarrow \alpha \geq 0$$

آخره تبدیل به صورت تولید از این

Projection
خواهیم داشت

$$\Rightarrow D_x^i(k) = Df_i(v_n^i(k)) + \sum_{l=1}^m [v_p^i(k)]_l D[g_l(v_n^i(k))]^+ + \sum_{l=1}^v [v_\lambda^i(k)]_l D[h_l(v_n^i(k))]$$

$$p^i(k+1) = \underbrace{V_p^i(k)}_{+} + \underbrace{\alpha(k)}_{+} \underbrace{[g(V_m^i(k))]^+}_{+} > 0$$

supergradient of H_i at $(V_m^i(k), V_p^i(k), V_g^i(k))$

$$\lambda^i(k+1) = \underbrace{V_\lambda^i(k)}_{+} + \underbrace{\alpha(k)}_{+} \underbrace{[|h(V_m^i(k))|]}_{+} > 0$$

supergradient of H_i at $(V_m^i(k), V_p^i(k), V_g^i(k))$

است بای تابع Concave (عن هست به نمودار) است از هر دو عربت
ی خالص است (ساده کن)

$$y^i(k+1) = V_g^i(k) + N(f_i(x^i(k)) - f_i(x^i(k-1)))$$

خط را برای گیرند

خط را برای سازی مدار

$$(Nf_i(0) \rightarrow \sum f_i \rightarrow p^*)$$

شرط پنجم (ج)

$$1 \quad \lim_{k \rightarrow \infty} \alpha(k) = 0$$

شرط پنجم (ج)
شرط پنجم (ج) تردد

$$2 \quad \lim_{k \rightarrow \infty} \alpha(k+1) S(k) = 0 \quad S(k) = \sum_{l=0}^k \alpha(l)$$

$$3 \quad \text{non summable: } \sum_{k=0}^{\infty} \alpha(k) = \infty$$

$$4 \quad \text{squared summable: } \sum_{k=0}^{\infty} \alpha^2(k) < \infty$$

$$5 \quad \sum_{k=0}^{\infty} \alpha^2(k+1) S(k) < \infty$$

$$6 \quad \sum_{k=0}^{\infty} \alpha(k+1) S^2(k) < \infty$$

شرط پنجم (ج) تردد دلیل $\alpha(k) = \frac{1}{k+1}$

تفصیل (هدایتی) الگوریتم توزیع شده (Penalty-Primal-dual)

زیرا هدایتی الگوریتم نزیراولین تغییر شده و توزیع شده

بیان شده بوده است. در این مرحله اثر $\{\alpha^i(k)\}$ داشته باشند

Distributed Penalty Primal (DPPDS) به کمتر الگوریتم

$(\alpha(k))$ step size (Dual subgradient

سُرایط منطق ماتماده کرد، آنکه $\tilde{x} \in X^*$ دارد طبق که

برای این شکل X بجهات

(closed+bounded) Compact

باشد

$$\lim_{k \rightarrow \infty} \|\alpha^i(k) - \tilde{x}\| = 0 \quad \forall i \in V \quad \rightarrow \text{اجماع مرحله ای بینهایت شده}$$

$$\lim_{k \rightarrow \infty} \|y^i(k) - P^*\| = 0 \quad \forall i \in V \quad \rightarrow \text{هدایتی متریک} \sum_i f_i + \underbrace{\gamma y^i}_{P^*}$$

بهترین الگوریتم را با برخی تغییرات و حاصل نهاد

* Extensions / Applications

همه محدودیت هایی Decentralized نهسته، در صورتی که در آن عامل های تراویح ارتباط روانی داشته باشند داینها هم کاربرد فاصله داشت

• stochastic consensus-based subgradient methods

$$w_i(t+1) = P_x [w_i(t+1) - \alpha(t) \nabla f_i(w_i(t+1)) + e_i(t+1)]$$

خطی ماتریس زیراولین ∇f_i (نزیر انتزاعی)، خطای ماتریس تابع صفت (باید تاں) از سی

(...), (Monte Carlo evolution

زیرا می خود خطای از نظر Mean Square from ~ Bound حدود است (داریم خطای حدود است)

حداری الگوریتم به طور سرتاسری بررسی می شود
 ← α هم تغیر نهاده می شود

- Consensus-based Subgradient method for noisy links → دید نزدیک درجهات انتسابی

$$w_i(t+1) = \alpha_i(t) - \eta(t) \sum_{j=1}^m r_{ij} (\alpha_j(t) + \xi_{ij}(t))$$

random zero mean noise on the link
from j to i

$$r_{ij} = 0 \text{ when } j \notin N_i$$

$\eta(t) > 0$ is a noise-damping step size → به حداری کم کننده

$$\alpha_i(t+1) = w_i(t+1) - \alpha(t) g_i(w_i(t+1)) \rightarrow \text{نزدیک نزدیک نزدیک نزدیک}$$

$$\begin{array}{ll} \sum_t \alpha(t) = \infty & \sum_t \alpha^2(t) < \infty \\ \sum_t \eta(t) = \infty & \sum_t \eta^2(t) < \infty \\ \sum_t \alpha(t) \eta(t) < \infty & \sum_t \frac{\alpha^2(t)}{\eta(t)} < \infty \end{array} \quad : \quad \text{شرط حداری بسیار سخت} \quad \alpha, \eta(t) \text{ دید خواهد داشت}$$

- Consensus-based Subgradient methods for distributed sets

- به حال مرضی کردی هر عامل ها از $X = \bigcap_{i=1}^m X_i$ است. هسته دیگری توان X_i اطلاعات تجمعی عامل خود را دارد

داین صفت هر الگوریتم Set فروش اعماقی دارد:

$$\alpha_i(t+1) = P_{X_i} [w_i(t+1) - \alpha(t) \tilde{\nabla} f_i(w_i(t+1))]$$

ابتدا شبیه سازی محدود کننده ای برای همگرایی تعیین شد

پس شبیه سازی شد به حالت relax تعیین شد (Random Graph + Communication Noise) stochastic

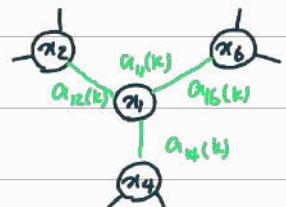
Distributed Random Projection (DRP) Algorithm

هر عامل (x_i) یک تابع است که مجموعه های غیر متعارف / کوچک تری بود \leftarrow local set Projection

→ مرور بر صفت تعدادی ای از آن set ها انتخاب می شود و Projection برآورده آن انجام می شود
← شبیه سازی Stochastic Gradient Descent

\Rightarrow Initialize $x_i(0)$ $\forall i \in V$

for $k > 0$, $\forall i$: 1. Mining $v_i(k) = \sum_{j=1}^m a_{ij}(k) x_j(k)$



2. Gradient Update $\tilde{v}_i(k) = v_i(k) - \alpha_k \nabla f_i(v_i(k))$

x_i (subset \leftarrow)

3. Projection

A random variable $\Omega_i(k) \in I_i$ is drawn

A component $X_i^{\Omega_i(k)}$ of $X_i = \bigcap_{j \in I_i} X_i^j$ is used
for projection: $x_i(k+1) = \pi_{X_i^{\Omega_i(k)}} [\tilde{v}_i(k)]$

Distributed Mini-Batch Random Projection (DMRP)

تعادل سیاهی تابعی زیاد شود (نماینده 10^4 حامل است) \leftarrow لارج SVM هر طبقه یک تیر دارد

→ هر نمونه یعنی معنی از x_i گشود \leftarrow 100 نمونه مبتنی بر x_i ایجاد شود

\Rightarrow Initialize $x_i(0) \forall i \in V$

for $k \geq 0$, $\forall i$: 1. Mining $v_i(k) = \sum_{j=1}^m a_{ij}(k) x_j(k)$

2. Gradient Update $\psi_i^r(k) = v_i(k) - \alpha_k \nabla f_i(v_i(k))$

3. Projections A batch of independent random variables $\zeta_i^r(k) \in J_i$

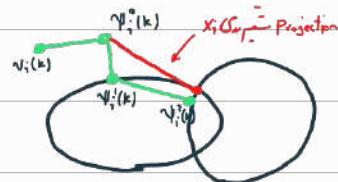
$r = 1, \dots, b$ is drawn.

The components $X_i^{\zeta_i^r(k)}, \dots, X_i^{\zeta_i^b(k)}$ of $X_i = \bigcap_{j \in J_i} X_i^j$ are used for sequential Projections:

$$\Psi_i^r(k) = \pi_{X_i^{\zeta_i^r(k)}} [\Psi_i^{r-1}(k)] \text{ for } r = 1, \dots, b$$

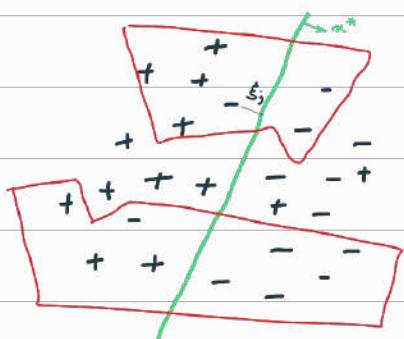
$$x_i(k+1) = \Psi_i^b(k)$$

برهان دلیل کاربردی هزینه محاسباتی پردازش



برهان دلیل کاربردی هزینه محاسباتی پردازش

Support Vector Machine (SVM)



کاربردی معرفی و مفهومی

$$\Rightarrow \min_{\alpha \in R^d, \xi \in R^P} \sum_{i=1}^m \left(\frac{1}{2m} \|\alpha\|^2 + C \sum_{j \in J_i} \xi_j \right)$$

$$\text{s.t. } (\alpha, \xi) \in \bigcap_{i=1}^m X_i$$

$$x_i \triangleq (\alpha, \xi) \mid y_i \langle \alpha, z_j \rangle \geq 1 - \xi_j$$

Constraint (جایزه) local Constraint (جایزه) $\xi_j \geq 0, j \in J_i \} i = 1, \dots, m$

DMRP \leftarrow سازمانی انتشاریان پیویسی نور Projection of Consensus Constraints

- Asynchronous Consensus-based Subgradient methods

\rightarrow Gossip \rightarrow شرکت همچشمی آژانس

$$v_i(k) = (\alpha_{I_k}(k-1) + \alpha_{J_k}(k-1)) / 2 \quad i \in \{I_k, J_k\}$$

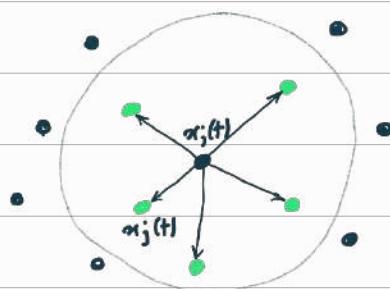
Random Projection + ترتیب $\leftarrow \alpha_i(k) = \pi_{X_i^{\text{rand}}} [v_i(k) - \alpha_i(k) \nabla f_i(v_i(k))]$

$$\alpha_i(k) = \alpha_i(k-1) \quad \forall i \notin \{I_k, J_k\} \rightarrow$$

\rightarrow Broadcast

در مرحله Iteration t عمل تعاملی شود است - gossip در اطلاعات

دستگاه های مختلف ارسال کنند



\Rightarrow At time t , agent I_t wakes up and broadcasts its estimate $\alpha_{i(t)}$

Agent I_t and $j \notin N_{I_t}$ do not update :

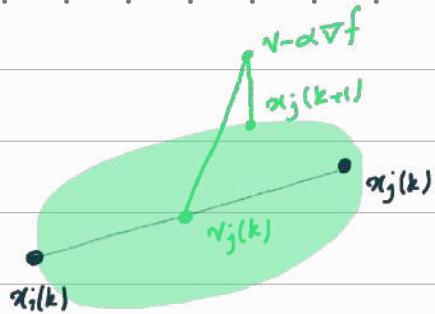
$$\alpha_j(t+1) = \alpha_j(t) \quad \text{for } j \notin \{I_t\} \cup N_{I_t}$$

Neighbors $j \in N_{I_t}$ of agent I_t update :

$$v_j(t) = \beta \alpha_{I_t}(t) + (1-\beta) v_j(t) \rightarrow \beta: \text{ضریب}$$

$$\alpha_j(t+1) = \pi_{X_j} [v_j(t) - \alpha_j(t) (\nabla f_j(v_j(t)) + E_j(t))]$$

Error



• Distributed ADMM

مدخلی که دو Agent ها- صورت اولی بین رسانی کنند و تغیر Dual یا برای ارسال عکس

از Dual Entanglement توزیع شد. همه هزار بین رسانی کنند و هر کدام عینی از قبیل این

بین نیاز به Sequential Coordinator و جزءی از سفارت عملی کنند

برای دفعات بیکارانه

• A Fast Second order Distributed Method

یعنی بیشترین First order gradient-based (sub) برآورده است
که ثابت بوده است داده اما سریع تر است

• Applications

→ electric Power Systems

→ Machine Learning

→ Deep Learning

→ Computer Networks

→ Communication Networks

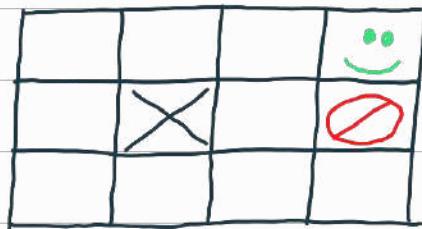
→ طبقه های عاملی تلقی داشته باشند
قابل استفاده است

یادگیری تقویتی چند عامل (Multi Agent Reinforcement Learning)

* Dynamic Optimization

Example

بینه سازی کارهای Grid World



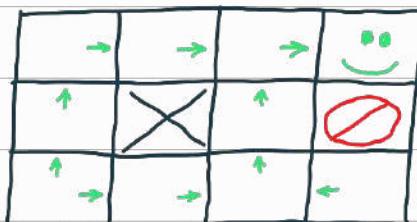
- از هر خانه به چهار جهت آسان حرکت نموده →
- هر حرکت Cost دارد →
- رسیم به \emptyset هزینه بالا دارد →
- رسیم به G بینش بالا دارد →

برای حل بزرگ هر چیز بینه سازی کر نباشد حال دیگر: از ماتع هدف مدل explicit و پرسته نداری (curse of dimensionality)
آن تغییر بینه سازی می بشد، تعداد حالت های زیاد می شود

لطفاً آن را در میان خانه های مساحتی بخواهد

⇒ در دو مرحله (Multi Stage Decision Making) تعیین می کنیم که هر دفعه چه ترتیب جست را بینایی کنیم

⇒ هر خانه را یک وصف دهنده نظری می نماییم



چنین است عمل تباری صرف ندانیم! (به نوعی ماتع هدف مخفی به صورت Implicit هم نداریم)

با Multi Stage Decision Making

یک تغییر جدید به نام state (ریخت) داریم که شخصی می‌نماید و تفصیل نمایم

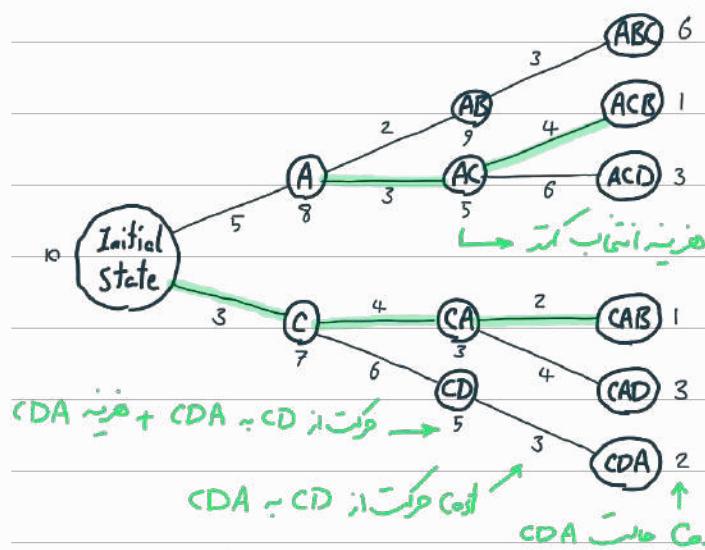
تعییری در هر state می‌براسد شرایطی مجموعه ای از حالت‌ها شود (در یک ترتیب Deterministic) مجموعه ای معمولی است

هر حالت (بارجیه باش) نه فقط در رسیدن به هدف خود می‌گذرد این اینست دلار و دنباله صفت اسلذاد است

و نس از یک حالت به حالت دیگر، به حالتی که دلار بدم رفصی که ترتیم تبلیغ دارد

یک تغییر دنیاگیری است

Example



: (Dynamic Programming) scheduling

د خاصیتی ترتیب می‌شوند + سیاست
که ترتیب تغییر را داشته باشد

با توجه به این Cost ، از آنها Cost را برداشت حاصل کردیم و همین انتخاب در هر state را پیدا کنیم تا به

(Bottom - UP) Initial State

که بر تعداد state حاصل شده ، حل معمولی را فتحیم کردیم

مسیریه : $C \rightarrow CA \rightarrow CAB$ ، هزینه : 10

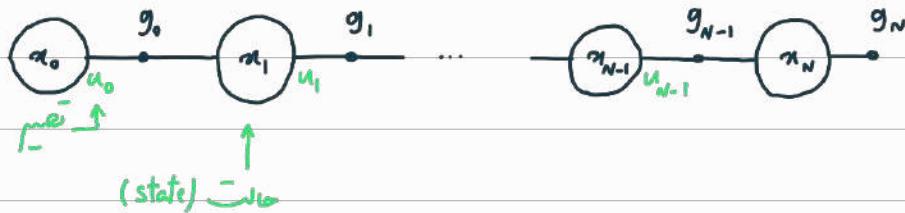
از آنها به حل subproblem هایی بپوشاند و به عقب حرکت می‌کنند

در هر state Cost to go ، سیاست state-time

هزینه ای در state بی بعد

x_0 حالت اولیه Cost

حالات پسی Cost



$$\Rightarrow \min_{u_1, \dots, u_{N-1}} E \left[g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, u_k, w_k) \right]$$

باشد π میانگین u_k

عمل تأثیرگذار کردن حالت تصادفی داشته باشد

\Rightarrow System: $x_{k+1} = f_k(x_k, u_k, w_k)$ $k=0, \dots, N-1 \rightarrow$ Dynamic

Control Constraints: $u_k \in U_k(x_k) \rightarrow$ شرایط کنترل

Probability Distribution: $w_k \sim P(\cdot | x_k, u_k)$

Policies: $\pi = \{p_0, \dots, p_{N-1}\}$, $u_k = p_k(x_k) \rightarrow$ مدل میانگین π در حالت x_k

ویژگی Map p_k از state \rightarrow state \rightarrow action

(state, action) \rightarrow (استات، اکشن)

Expected Cost of π starting from x_0 : $J_\pi(x_0) = E \left[g_N(x_N) + \sum_{k=0}^{N-1} g_k(x_k, p_k(x_k), w_k) \right]$

Optimal Cost Function: $J^*(x_0) = \min_{\pi} J_\pi(x_0)$

Dynamic Programming (DP) Algorithm:

- Start with $J_N(x_N) = g_N(x_N)$

ک - حالت پسی Cost

- go backwards using: $J_k(x_k) = \min_{u_k \in U_k(x_k)} E \left[g_k(x_k, u_k, w_k) + J_{k+1}(f_k(x_k, u_k, w_k)) \right]$

x_N, x_{N-1} تقریبی

k - حالت پسی Cost

x_{k+1}

(for $k=N-1, N-2, \dots, 0$)

ک - ابتدا

برای $k=0$ و ...

Example



$$\text{System: } x_{k+1} = (1-a)x_k + au_k \quad k=0, 1 \quad 0 < a < 1$$

$$\text{Cost: } r(x_2 - T)^2 + u_0^2 + u_1^2 \quad r > 0 \quad \Rightarrow u_0, u_1 = ?$$

منابع محدود
cost (Cost)
state (state cost)

$$\Rightarrow \text{DP Algorithm: } J_2(x_2) = r(x_2 - T)^2$$

$$J_1(x_1) = \min_{u_1} [u_1^2 + r((1-a)x_1 + au_1 - T)^2]$$

$$J_0(x_0) = \min_{u_0} [u_0^2 + J_1(\underbrace{(1-a)x_0 + au_0}_x)]$$

* یادگیری شری

- یک نهاده سازی دینامیک در میان
- رابطه دسته دنده مقطعی از تابع هدف و دسترسی بنت
- دینامیک و نزدیک مقطعی از مدل دینامیک (تغییر حالت اندام)
- حالت های نهاده دنده شخص بنت / نزدیک حالت هایی وجود ندارد
- ممکن است در مجموع بسیار بسیار دسترسی داشته باشد صفات آن حکمت
- (حقد ناشیه بشر)

→ تعداد مراحل تضمیری کمی تواند ناعدم باشد و ناجهود باشد
 → نفعی حالت یا فضی تضمیری تواند به تدریج بزرگ باشد که استفاده از DP را بیار گشته باشد (curse of dimensionality)

↑ reward

↓ state

حالت از نعیم s_t, a_t می‌تواند تغییری بخورد

A	B
A'	+10
	+5

↔ Actions

→ B ؟ بین - A' - A دو بین Agent
 = B' ؟ چند reward تا سب دریافت گشته
 → در چه حرمت گشته را انتظاری خود
 سریعتر خود را انتظاری کنند (حالت پیشی
 نمایم)

: (MDP) تضمیر مارکو

زفعی شرکت محیط خاصیت مارکو دارد: حالت در یادگیری که عامل در مرحله $t+1$ بدست می‌آید در تسابی حالت و لذت (action)
 عامل در زمان $t+1$ دارد

$$\Pr \{ S_{t+1} = s', r_{t+1} = r | S_t, a_t, r_t, S_{t-1}, a_{t-1}, \dots, r_1, s_0, a_0 \}$$

$$= \Pr \{ S_{t+1} = s', r_{t+1} = r | S_t, a_t \}$$

اطلاعات مرور از سده:

a علیت علیت $s' \leftarrow s$ i transition احتمال: $P_{ss'}^a = \Pr \{ S_{t+1} = s' | S_t = s, a_t = a \} \quad \forall s, s' \in S, a \in A(s)$

سل ریاضی سده / اطلاعات حالتها
 (زیارت Explicit نیست)

$$R_{ss'}^a = E[r_{t+1} | S_t = s, a_t = a, S_{t+1} = s'] \quad \forall s, s' \in S, a \in A(s)$$

ملأجع هدف →

در مرحله عامل بايد ناظري بین حلقه که در آن تراكمه دامنه اتفاق هرگز ممکن برقرار نباشد. اين تراكم استاتیزی یا سیاست تمادگرهاں تعیین بهمنی است.

$$\pi_t(s, a) = \text{Prob}(a_t = a \text{ when } S_t = s)$$

عامل بايد سیاست فرد اطلاعاتی تبین کند تا هدف فرد که بینیمه کردن مجموع یا پس های ایست که در طول زمان بروت خواهد

$$R_t = r_{t+1} + \gamma r_{t+2} + \gamma^2 r_{t+3} + \dots = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$$

$0 < \gamma < 1$: Discount Factor → هر آئینه ایشان کمتری پیامی کند reward

$\gamma = 0$ است و تساپل (کفته) را می بینید

$\gamma = 1$ عل کامل سنه بینه سازی

کی تواند ذهنی Cognitive عامل باشد، یعنی راتقی را شناخته باشد (آن ایست ایشان بول نمی ازند)

← در این حالت ملأجع هدف با وجود γ دیگر است

میان ایشان یک حالت به یادش هایی که باشند از آن حالت انتظاری برداشته می شود.

$$V^*(s) = E_\pi [R_t | S_t = s] = E_\pi \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | S_t = s \right]$$

↓ ↗ Reward

ترخط ذهنی بری = ایشان حالت s سیاست

(آزم تصادفی است)

میان اینش یک عمل در حالت به پیش‌هایی که با شروع از آن حالت باعث آن عمل استخراجی ردد نشی می‌شود

$$\text{state-action}: Q^*(s, a) = E_{\pi}[R_t | s_t = s, a_t = a] = E_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} | s_t = s, a_t = a\right]$$

لئے اینش انتخاب a در حالت s تجتی سیاست π
غیره های (راحل بعد مبنی π انتخاب جی سیاست action)

هدف من کردن این تابع بتعلیم دست π است

$$V^*(s) = E_{\pi}[r_{t+1} + \gamma r_{t+2} + \dots | s_t = s] = E_{\pi}[r_{t+1} + \gamma V^*(s_{t+1}) | s_t = s]$$

$$= \sum_a \pi(s, a) \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V^*(s')] \quad \leftarrow \text{غیره می‌بینی} V^* \text{ باش سلسله}$$

$$Q^*(s, a) = E_{\pi}[r_{t+1} + \gamma V^*(s_{t+1}) | s_t = s, a_t = a] = \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V^*(s')]$$

خطه هایی بدهت آنها نسبت دادنی هستند ← فی توان به سادی بنه سازی کرد

سیاست هریچانه (greedy) : انتخاب عملی که ترتیب پادش های سرداشت انتظار را بینیه می‌کند با اقبال ۱ دفعه با اقبال صفر اعتمدی شود

$$\pi^*(s, a) = \underset{a}{\operatorname{Argmax}} Q(s, a)$$

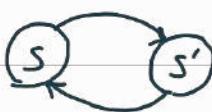
آخر اینش (s, a) می‌بند آنکه استراتژی نهاد بینه است می‌کند
ترتیب پادش های سرداشت انتظار را بینیه می‌کند
سیاست greedy

$$V^*(s) = \underset{a}{\operatorname{Max}} E[r_{t+1} + \gamma V^*(s_{t+1}) | s_t = s, a_t = a]$$

$$= \underset{a}{\operatorname{Max}} \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V^*(s')]$$

$$= \underset{a}{\operatorname{Max}} Q^*(s, a)$$

ماله بینی می‌کنی (اصل برناوری بینی)



دستگاه حاصل است بینکل ده مردار است:

→ معادله بلن در صورتی سعی به نفع بینه می شود که این state ها تعیین شوند (V(S) ها را بايد تاسیس نمایم)

← م و د فرم V(S) در معادله بالا محول است ← عی توان به سلسله بینه سازی کرد

• بناءه بر زیری ابیاتی تعریفی

: (Policy Iteration/PI) ایش بارزی برآسان سیاست

ایش بارزی سیاست:

$$V_{k+1}^{\pi}(S) = E_{\pi} [R_{t+1} + \gamma V_k^{\pi}(S_{t+1}) | S_t = S]$$

$$\uparrow = \sum_a \pi(s, a) \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V_k^{\pi}(s')]$$

دستگاه حاصل شده سیاست
با بعدگاری داشتم

یک تقدیری اولیه
کیم و ب صورت iterative به وزیرانی انجام

بعد سیاست:

$$\pi_{k+1}(s) = \arg \max_a Q^{\pi_k}(s, a) = \arg \max_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V(s')]$$

روانی که سیاست هم تغیر نمود را به بینی بلن برقرار است و سیاست بینه هدرا شده ایم

الgoritم : 1 Initialization: $V(s) \in \mathbb{R}$ and $\pi(s) \in A(s) \quad \forall s \in S$, $V(\text{terminal}) = 0$

2 Policy Evaluation

Loop

$$\Delta \leftarrow 0$$

Loop for each $s \in S$

$$V \leftarrow V(s)$$

$$V(s) \leftarrow \sum_a \pi(s, a) \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V(s')]$$

$$\Delta \leftarrow \max(\Delta, |V - V(s)|)$$

Until $\Delta < \theta$ (θ : small positive number determining the accuracy of estimation)

3 Policy Improvement

Policy-stable \leftarrow true

For each $s \in S$

old-action $\leftarrow \pi(s)$

$\pi(s) \leftarrow \operatorname{argmax}_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V(s')]$

if old-action $\neq \pi(s)$ then Policy-stable \leftarrow false

if Policy-stable then stop and return $V \approx V_*$ and $\pi \approx \pi_*$; else go to 2

	v_k for the random policy	greedy policy w.r.t. v_k																																	
$k=0$	<table border="1"> <tr><td>0.0</td><td>0.0</td><td>0.0</td><td>0.0</td></tr> <tr><td>0.0</td><td>0.0</td><td>0.0</td><td>0.0</td></tr> <tr><td>0.0</td><td>0.0</td><td>0.0</td><td>0.0</td></tr> <tr><td>0.0</td><td>0.0</td><td>0.0</td><td>0.0</td></tr> </table>	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	0.0	<table border="1"> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> </table>	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	random policy
0.0	0.0	0.0	0.0																																
0.0	0.0	0.0	0.0																																
0.0	0.0	0.0	0.0																																
0.0	0.0	0.0	0.0																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
$k=1$	<table border="1"> <tr><td>0.0</td><td>-1.0</td><td>-1.0</td><td>-1.0</td></tr> <tr><td>-1.0</td><td>-1.0</td><td>-1.0</td><td>-1.0</td></tr> <tr><td>-1.0</td><td>-1.0</td><td>-1.0</td><td>-1.0</td></tr> <tr><td>-1.0</td><td>-1.0</td><td>-1.0</td><td>0.0</td></tr> </table>	0.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	-1.0	0.0	<table border="1"> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> </table>	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	
0.0	-1.0	-1.0	-1.0																																
-1.0	-1.0	-1.0	-1.0																																
-1.0	-1.0	-1.0	-1.0																																
-1.0	-1.0	-1.0	0.0																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
$k=2$	<table border="1"> <tr><td>0.0</td><td>-1.7</td><td>-2.0</td><td>-2.0</td></tr> <tr><td>-1.7</td><td>-2.0</td><td>-2.0</td><td>-2.0</td></tr> <tr><td>-2.0</td><td>-2.0</td><td>-2.0</td><td>-1.7</td></tr> <tr><td>-2.0</td><td>-2.0</td><td>-1.7</td><td>0.0</td></tr> </table>	0.0	-1.7	-2.0	-2.0	-1.7	-2.0	-2.0	-2.0	-2.0	-2.0	-2.0	-1.7	-2.0	-2.0	-1.7	0.0	<table border="1"> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> </table>	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	
0.0	-1.7	-2.0	-2.0																																
-1.7	-2.0	-2.0	-2.0																																
-2.0	-2.0	-2.0	-1.7																																
-2.0	-2.0	-1.7	0.0																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
$k=3$	<table border="1"> <tr><td>0.0</td><td>-2.4</td><td>-2.9</td><td>-3.0</td></tr> <tr><td>-2.4</td><td>-2.9</td><td>-3.0</td><td>-2.9</td></tr> <tr><td>-2.9</td><td>-3.0</td><td>-2.9</td><td>-2.4</td></tr> <tr><td>-3.0</td><td>-2.9</td><td>-2.4</td><td>0.0</td></tr> </table>	0.0	-2.4	-2.9	-3.0	-2.4	-2.9	-3.0	-2.9	-2.9	-3.0	-2.9	-2.4	-3.0	-2.9	-2.4	0.0	<table border="1"> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> </table>	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	
0.0	-2.4	-2.9	-3.0																																
-2.4	-2.9	-3.0	-2.9																																
-2.9	-3.0	-2.9	-2.4																																
-3.0	-2.9	-2.4	0.0																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
$k=10$	<table border="1"> <tr><td>0.0</td><td>-6.1</td><td>-8.4</td><td>-9.0</td></tr> <tr><td>-6.1</td><td>-7.7</td><td>-8.4</td><td>-8.4</td></tr> <tr><td>-8.4</td><td>-8.4</td><td>-7.7</td><td>-6.1</td></tr> <tr><td>-9.0</td><td>-8.4</td><td>-6.1</td><td>0.0</td></tr> </table>	0.0	-6.1	-8.4	-9.0	-6.1	-7.7	-8.4	-8.4	-8.4	-8.4	-7.7	-6.1	-9.0	-8.4	-6.1	0.0	<table border="1"> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> </table>	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	optimal policy
0.0	-6.1	-8.4	-9.0																																
-6.1	-7.7	-8.4	-8.4																																
-8.4	-8.4	-7.7	-6.1																																
-9.0	-8.4	-6.1	0.0																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
$k=\infty$	<table border="1"> <tr><td>0.0</td><td>-14</td><td>-20</td><td>-22</td></tr> <tr><td>-14</td><td>-18</td><td>-20</td><td>-20</td></tr> <tr><td>-20</td><td>-20</td><td>-18</td><td>-14</td></tr> <tr><td>-22</td><td>-20</td><td>-14</td><td>0.0</td></tr> </table>	0.0	-14	-20	-22	-14	-18	-20	-20	-20	-20	-18	-14	-22	-20	-14	0.0	<table border="1"> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> <tr><td>↑</td><td>↓</td><td>→</td><td>←</td></tr> </table>	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	↑	↓	→	←	
0.0	-14	-20	-22																																
-14	-18	-20	-20																																
-20	-20	-18	-14																																
-22	-20	-14	0.0																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																
↑	↓	→	←																																

مرحبت پادشاه! - مادر غیر از حکمی که به خانه های شخصی \rightarrow

نه بود

ترنست ویدن داده \rightarrow Policy Evaluation

تھا Iteration

ترنست ذات گیری \rightarrow greedy Policy

بہ دست آئندہ ترنست ذات

نه چند با سرگرد بیانی \rightarrow optimal

جیسا کروں تا ہدایی کامل حل تذبذب

ادس بازنی برآس (VI)

برکی است از مرحله دش P1 (فراتج این) هر بار برآس سیاست greedy

$$V_{k+1}(s) = \max_a E_\pi [r_{t+1} + \gamma V_k^\pi(s_{t+1}) | S_t = s, a_t = a]$$

$$= \max_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma V_k^\pi(s')] = \max_a Q_{k+1}(s, a)$$

هر مرحله مقدار میانگین را محاسبه کنیم

درین قله VI و PI هر کوئی تغیر نمایند

الگوریتم : Initialize $v(s) \forall s \in S^+$, $v(\text{terminal}) = 0$

Loop

$$\Delta \leftarrow 0$$

Loop for each $s \in S$

$$v \leftarrow v(s)$$

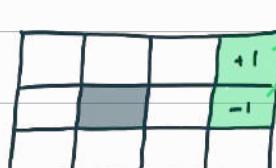
$$v(s) \leftarrow \max_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma v(s')]$$

$$\Delta \leftarrow \max(\Delta, |v - V(s)|)$$

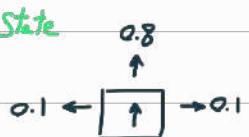
Until $\Delta < \theta$

Output a deterministic Policy $\pi \approx \pi_*$ such that $\pi(s) = \arg\max_a \sum_{s'} P_{ss'}^a [R_{ss'}^a + \gamma v(s')]$

Example



Terminal State



مادر حکمت پیشی راه
انتسابی کنترل

Value Iteration:

0	0	0	+1
0	-1	0	-1
0	0	0	0

0	0	0.8	+1
0	-1	0	-1
0	0	0	0

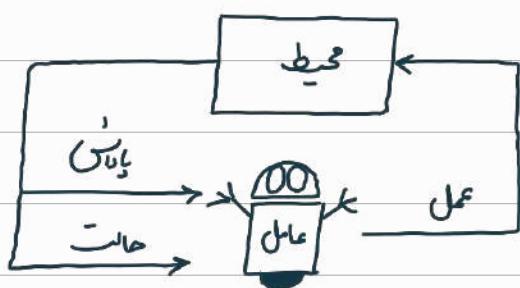
0	0.64	0.8	+1
0	-1	0.54	-1
0	0	0	0

تغییری ساده به عنوان مثال را در اینجا خواهیم داشت

• یادگیری استوایی: سلسله تعامل با محیط

در حلی سلسله سیستم به دست نیت (R_{ss}^a, P_{ss}^a تابعی)

عامل با زندگی تعامل، محیط و دادهای اطلاعاتی عدی از حالت در پاسخ معنی «بینش کردن» سرد فرد خواهد داشت.



در حلی سارانسال هام به من مرد
تعییرکرده ای کند و باز هم
تعییر کرده ای کند

این مرد کارلو:

در این این بالذیر از حالت ها دیده باید پاسخ های معنی در بیند تعبیین خود از $Q(s,a)$ نداشتم



د هر ایندر ز بُعد از یک حالت دنبال نهادن یک سیاست مجموع پاسخ های دریافتی محاسبه می شود

$$\text{Return}_i = r_1 + \gamma r_2 + \gamma^2 r_3 + \dots + \gamma^{k-1} r_k$$

یکی از پارامتر های دیانت نموده در این زددها مخفف داده شده است از بحث عل - حالت (s, a) در k مرتب به عنوان تمحی از $Q(s, a)$ در نظر گرفته می شود

$$Q(s, a) \leftarrow \underset{i}{\text{Average}}(\text{Return}_i)$$

نحو آرچی کار بر تعداد تعداد اعماق شود تا در Q به تأثیر طبقی تزریق می شود. با این صفت نموده عل می شود

- همی خواص دارند و می توانند داشت $\pi(s, a)$ این ادعا را درست کنند
- آنها کافی تجربه نداشته باشند تا درست Q به تأثیر طبقی تزریق می شوند
- سیاست عامل بین کارشناسی و برآوردهای تعامل ایجاد می کنند
- ایجاد تغییراتی باشد که مبنی بر اینکه کارشناسی دستوراتی را ایجاد می کند
- در نهایت سیاست باید بسیار بود که عل مبنی بر انتخاب کند
- سیاست هم تغییر می کند و دستوراتی را ایجاد می کند

ϵ -greedy:

$$\pi(s, a) = \begin{cases} 1 - \epsilon + \frac{\epsilon}{|A(s)|} & \text{if } a = a^* \\ \frac{\epsilon}{|A(s)|} & \text{if } a \neq a^* \end{cases}$$

و اینجا بزرگ در نظر گرفته می شود (تصییری تصادفی، $1 \rightarrow 4$) و با همان دلیل Q آن را بست صفر می برمی (تصییری greedy و بینه)

Softmax:

$$\pi(s, a) = \frac{e^{\frac{Q(a)}{T}}}{\sum_{b \in A(s)} e^{\frac{Q(b)}{T}}}$$

T: Temperature

T بزرگ کرده را بست $\frac{1}{n}$ می برد ($\lim_{T \rightarrow \infty} \frac{Q(a)}{T} = 0$) و سپه تصییری تصادفی می شود

وئی بست صفر بود Q حاصل نه کرده که همیشه (با قسم کرد) $\in \mathbb{R}^{S \times A}$ می توان دید و این حالت افضل که مرتبط با عمل بین ۱، امثال سایر کرده صفر همیشه (با قسم کرد) است.

بیست و هیجدهم soft policy، softmax و ϵ -greedy

الgoritم روت کار: Initialize: $\pi \leftarrow$ an arbitrary ϵ -greedy Policy

$Q(s,a) \in \mathbb{R}$ (arbitrary) $\forall s \in S, a \in A(s)$

$Returns(s,a) \leftarrow$ empty list $\forall s \in S, a \in A(s)$

Repeat forever (for each episode):

Generate an episode following π : $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$

$G \leftarrow 0$

Loop for each step of episode $t = T-1, T-2, \dots, 0$:

$G \leftarrow rG + R_{t+1}$ ← Return

Unless the pair S_t, A_t appears in $S_0, A_0, S_1, A_1, \dots, S_{t-1}, A_{t-1}$:

Append G to $Returns(S_t, A_t)$

$Q(S_t, A_t) \leftarrow \text{average}(Returns(S_t, A_t))$ ← Q اینجا

$A^* \leftarrow \underset{a}{\operatorname{argmax}} Q(S_t, a)$ ← A^* اینجا بر اساس Q انتخاب شد

For all $a \in A(S_t)$:

$$\pi(a | S_t) \leftarrow \begin{cases} 1 - \epsilon + \epsilon / |A(S_t)| & \text{if } a = A^* \\ \epsilon / |A(S_t)| & \text{if } a \neq A^* \end{cases}$$

← π اینجا Policy

تایپی: MC - approximate DP با تعامل سعی با محیط عمل می کند (در حالی که سلسله از خط در دناره)

ساده ترین سلسله کاربری سازی

- احتمال آرجه مبنی به محیط نهضی از حالت ها در تابع حالت های این اینست

لمسی تابع از state های که در این مرحله قصد episode های پیشتر کا شروع کرد

- تعبیری ها کی مرحلت متعال از حالت های دیدار است (برخلاف DP که تعبیری مرحلت
براسک حالت دیدار است) ← دینامیک سنه مارک می باشد نیز شود

تیوچی تاصل زانی (TD)

ایده ااملی براسک ترکیب رشی بر بناء ریکی بربرا درشی نیزت کاربر است

- لـ ماتد MC می توان سبد ناشن اطلاعات از قیمت دبا تعامل با آن عمل یا یاری کا اعماک دار
- لـ براسک ایده DP در مرحله تعبیری خود را براسک تعبیری ماتی رست هدات جدید ببرد می گند و
ماتد MC نظر رسیدن به حدت نهایی برابر تعبیری نیز شود (= برت استرک / Bootstrap)

← از خطای تعبیری مدل عامل در حالت نسخی دسل عامل پس از ایده امل دتلار لرنن در حالت جدید، جست ببرد توالع اینش
استفاده می شود:

$$V(S_t) = E \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \mid S_t = S \right] = E [r_{t+1} + \gamma V(S_{t+1}) \mid S_t = S]$$

$$\text{learning rate: } \alpha \text{ (constant)} \quad \hat{V}(S_t)$$

$$\overbrace{V_{t+1}(S_t) = V_t(S_t) + \alpha \cdot E_t}^{\substack{\text{Update} \\ \text{خطای تاصلی}}} = V_t(S_t) + \alpha \cdot \underbrace{[r_{t+1} + \gamma V_t(S_{t+1}) - V_t(S_t)]}_{\hat{E}_t}$$

$\hat{V}(S_t)$

براسک یا پس از قیمت
تعبیری تبلی املج می شود

$$\hat{V}(S_t) > V_t(S_t) \Rightarrow E_t > 0$$

$$\hat{V}(S_t) < V_t(S_t) \Rightarrow E_t < 0$$

هنر ایجاد دلیل برای (Q15, Q16) هم نیزت

→ بیانی صورت در مرحله تعبیری Update می شود ریاز نیت ماتد episode شونی MC بینی بدم

SARSA | (Temporal Difference) TD (تکمیلی)

Q-Learning

Actor-Critic

: SARSA



عمل a در برآس سیست خود انتخاب می کند (Softmax یا ε-greedy) با این soft Policy عمل a را امانت دارد و بحالت a می آید و در برآس سیست خود عمل a' را انتخاب می کند. پس از این مراحل تابع ارزش a عمل a' نیز بروز نماید.

$$Q(S, a) \leftarrow Q(S, a) + \alpha \cdot [r + \gamma Q(S', a') - Q(S, a)]$$

$\hat{Q}_+(S)$

→ (Softmax/ ε-greedy) تابع ارزشی Q

پردازش: Initialize $Q(s, a)$ arbitrary $\forall s \in S^+, a \in A(s)$ except that $Q(\text{terminal}, \cdot) = 0$

Loop for each episode

Initialize S

choose A from S using policy derived from Q (e.g. ε-greedy)

Loop for each step of episode:

Take action A, observe R, S' → (برخلاف episode می توانیم این را نیاز به وقت نداشتم)

choose A' from S' using policy derived from Q (e.g. ε-greedy)

$$Q(S, a) \leftarrow Q(S, a) + \alpha [R + \gamma Q(S', a') - Q(S, a)]$$

$$S \leftarrow S', A \leftarrow A'$$

Until S is terminal

که حین از terminal State بعد از اینجا نمایند

آن روش است (از action که اعیانی داشت (A') برای استفاده می‌شود) update on policy

بیشتر SARSA است: این ساده تر است - عمل - از ای عل دریافت
Update می‌شود - از این سایی قبل از آغاز عمل بعدی (a') اعیان خواهد شد

off Policy

بعد از s' action a' شنیده شد
اعیان خواهد شد

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_a Q(s', a') - Q(s, a)]$$

برخلاف SARSA انتخاب حالت (طاقع برآینده)
greedy - مرتب - مرتب - Q-Learning

بیست - مرتب تابعی از تابع ارزش است (Softmax, E-greedy)

الگوریتم: Initialize $Q(s, a)$ arbitrary $\forall s \in S^+$, $a \in A(s)$ except that $Q(\text{terminal}, \cdot) = 0$

Loop for each episode

Initialize S

Loop for each step of episode:

Choose A from S using Policy derived from Q (e.g. E-greedy)

Take action A , observe R, S'

$$Q(s, a) \leftarrow Q(s, a) + \alpha [R + \gamma \max_a Q(s', a) - Q(s, a)]$$

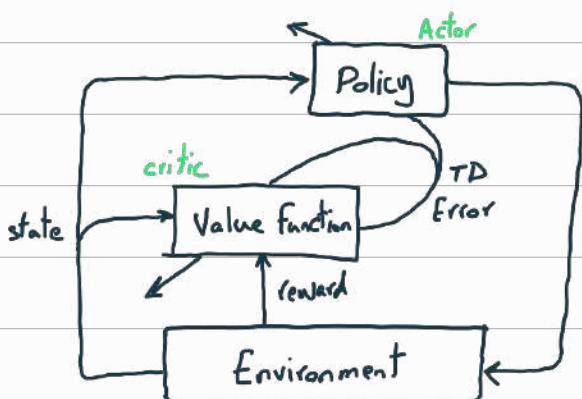
$S \leftarrow S'$

SARSA!

Until S is terminal

: (Actor-Critic) عکس - سار (Actor-Critic)

عنی زندگی شود state first . state-action first (SARSA)



$$\delta_t = r_{t+1} + \gamma V(S_{t+1}) - V(S_t) \leftarrow \text{TD Error}$$

ترجیح دارند به اینش

(نارخ از این action بعداز آن)

باین صفت دارند مخلع اینش
می شوند.

از برای نصیح Policy دعیی اینش استفاده می شود:

$$\pi_t(S, a) = \Pr \{ a_t = a \mid S_t = S \} = \frac{e^{P(S, a)}}{\sum_b e^{P(S, a)}} , P(S_t, a_t) \leftarrow P(S_t, a_t) + \beta \delta_t$$

با اینکه این است که مطابقت
نتایج داده شده با این است

$$V_{t+1}(S_t) = V_t(S_t) + \alpha \delta_t = V_t(S_t) + \alpha [r_{t+1} + \gamma V_t(S_{t+1}) - V_t(S_t)]$$

تجددیل برای سیم: اینش بناهای ریکارڈی میکی ترتیبی

$\pi^*(s) = \underset{a}{\operatorname{Argmax}} Q(s, a)$: (greedy Policy)

تجددیل برای محیط: درست های TD و MC

softmax, ε-greedy: سیاست جت یا گیری کامل بینه سازی

کامل محیط انتساب در Q احمد کارسیا کردن سیاست بینه یادگاری کیا شود

	a_0	a_1	a_2	a_3	a_4	a_5	a_6	a_7
s_0	490	490	490	700	490	490	490	490
s_1	490	490	700	490	490	490	490	490
s_2	490	490	490	700	700	490	490	490
s_3	490	490	700	1000	700	700	490	490
s_4	490	490	490	700	700	700	490	490
s_5	490	490	700	700	1000	700	700	490
s_6	490	490	490	490	700	700	490	490
s_7	490	490	490	490	700	1000	700	490
s_8	700	490	490	490	700	700	1000	700
s_9	700	490	490	490	490	700	700	1000
s_{10}	700	490	490	490	490	490	490	490
s_{11}	490	490	490	490	490	700	490	490
s_{12}	490	490	490	490	490	700	700	490
s_{13}	490	490	490	490	490	700	700	700
s_{14}	490	490	490	490	490	490	700	700
s_{15}	490	490	490	490	490	490	490	700

یادگاری ترتیبی سیستم (Continuous RL)

تاج محل مدل سیستم Table

ساده رسانه های یعنی چیز

بازیابی نتایج state-action ها و اینها برای سود دادن برای تعلم دست Value برای هر کام را خواهی بازیابی کرد که این میتواند مدلی باشد که میتواند اینها را پیش‌بینی کند.

→ جمله ای اعنی مدلی است که state و action را در خروجی دارد

Function Approximator
استفاده از یک

پیش‌بینی (مدل تابعی)

→ $Q(s, a; w)$, $\pi(s, a; \theta) \rightarrow \text{Policy}$ (که Parametrize شده است)

نتیجه تواند که آن را بصریت پیش‌بینی مدل کند که action, state را در خروجی دارد.

اما اگر اینها بسیار smooth تغیری نداشته باشند (و حالت کسره باشند) ممکن است اینها تغیر زیادی در Policy داشته باشند.

→ بصریت مدلی داشت که اینها را بازیابی کند (Prior knowledge)

→ E-greedy → (general function approximator) Parametrize باشد که اینها را بازیابی کند.

با اینها state, action را پیش‌بینی کند.

→ سُرچه ای که بازیابی نتایج state-action را در محدوده دخوار میکند.

قابل استفاده نیست

→ حالت کسره تبلیغ حالت determinstic vs stochastic باشد که Temperature بین 0 و 1 باشد.

حالات پیش‌بینی خود را learn کریں.

Policy Gradient:

π_{θ}



درین همانسته Policy نسبت بود که بازگشتی داشت تا در مرکز تغییر آن شفعت بود. در حالت پیشنهاد خود π_{θ} دیده می‌شود.

می‌دانیم سرین θ را برای $\pi_{\theta}(s,a)$ باید تابع هدف از π_{θ} را داشته باشیم

برای وظایفی start Value حیاتی را در نظر نماییم episodic ایشان state ایشان

$$J_1(\theta) = V^{\pi_{\theta}}(s_1) = E_{\pi_{\theta}}[v_1]$$

در میانه‌ها (Q) حیاتی average Value را در نظر نماییم Continual

$$J_{avg}(\theta) = \sum_s d^{\pi_{\theta}}(s) V^{\pi_{\theta}}(s)$$

T

$\pi_{\theta}(s)$ Markov Chain توزیع

زیرا می‌خواهد این توزیع برای این سیستم π_{θ} را در برداشتن از (s,a) در حدود می‌سازد می‌تواند میانگین انتظاری می‌باشد

میانگین از خواص از توزیع هدف دستیاب می‌شوند غیر بازنگشتی می‌زیم

میانگین حیاتی را در نظر نماییم Average Reward Per time-step:

$$J_{AR}(\theta) = \sum_s d^{\pi_{\theta}}(s) \sum_a \pi_{\theta}(s,a) R_s^a \rightarrow \text{step reward از استفاده}$$

با استفاده از این از توزیع هدف می‌زیم θ را Update کنیم

$$\nabla_{\theta} \pi_{\theta}(s, a) = \pi_{\theta}(s, a) \frac{\nabla_{\theta} \pi_{\theta}(s, a)}{\pi_{\theta}(s, a)} = \pi_{\theta}(s, a) \nabla_{\theta} \log \pi_{\theta}(s, a) \rightarrow \text{آن بخط سوکاری از } J \text{ که درست است نسبت به } \theta \text{ باشید می‌شود}$$

Score Function

Linear

function approximator: $\phi(s, a)^T \theta$ $\xrightarrow{\text{Softmax}}$ $\pi_{\theta}(s, a) = \frac{e^{\phi(s, a)^T \theta}}{\sum_b e^{\phi(s, b)^T \theta}} \propto e^{\phi(s, a)^T \theta}$

\uparrow
Kernel / Feature (شیوه)

$$\Rightarrow \text{Score Function: } \nabla_{\theta} \log \pi_{\theta}(s, a) = \phi(s, a) - E_{\pi_{\theta}}[\phi(s, \cdot)]$$

سازه سطح $\phi(s, a)$ از $\phi(s, \cdot)$ در حالت s کاوش

نیاز به تقویتی کاری نیست

چند چشم پوش رایج نیست

باید one-step MDP شوند

مکت: $r = R_{s,a}$ باید مطابق باشد با $s \sim d(s)$

$J(\theta) = E_{\pi_{\theta}}[r] = \sum_{s \in S} d(s) \sum_{a \in A} \pi_{\theta}(s, a) R_{s,a}$

$$\Rightarrow \nabla_{\theta} J(\theta) = \sum_{s \in S} d(s) \sum_{a \in A} \pi_{\theta}(s, a) \nabla_{\theta} \log \pi_{\theta}(s, a) R_{s,a} = E_{\pi_{\theta}} [\underbrace{\nabla_{\theta} \log \pi_{\theta}(s, a) r}_{\text{ایمپلیکت بانی عبارت تعریف شده}} \underbrace{r}_{\text{(ا، s)}}]$$

(Stochastic Gradient Descent به صفت عربی خوب کرد (نیز Expectation)

$J = \int \omega R \, d\omega \quad J = \int \omega \, d\omega$ دو مرتبه حدف کلی - Differentiable محسوس است $\nabla_{\theta} J(\theta)$: Policy Gradient Theorem

برای $\frac{1}{1-\gamma} \int \omega V \, d\omega$:

→ Multi-step MDP

$$\nabla_{\theta} J(\theta) = E_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(s, a) Q^{\pi_{\theta}}(s, a)]$$

→ (Q) long-term value $V(r)$ (کلیزی پایانی)

→ Sample state-action

stochastic gradient ascent is used

: Monte Carlo Policy Gradient

Policy gradient theorem is used

$\hat{Q}^{\pi_{\theta}}(s, a) \approx Q^{\pi_{\theta}}(s, a)$ is Unbiased Sample

Parametrize π_{θ} by function

$$\rightarrow \Delta \theta_t = \alpha \nabla_{\theta} \log \pi_{\theta}(s_t, a_t) v_t$$

پیشنهادی: function REINFORCE

initialise θ arbitrary

for each episode $\{s_1, a_1, r_2, \dots, s_{T-1}, a_{T-1}, r_T\} \sim \pi_{\theta}$ do

 for $t=1$ to $T-1$ do

$\theta \leftarrow \theta + \alpha \nabla_{\theta} \log \pi_{\theta}(s_t, a_t) v_t$

 end for

end for

return θ

end function

→ پیشنهادی

این روش همیان از حبل برای Q استفاده نمی کند ← خوب است

parametrize Q ← $Q_w(s, a) \approx Q^{\pi_{\theta}}(s, a)$: function Apprimator for Q (باید

$Q_w(s, a)$ براستهای $\pi_{\theta}(s, a)$: Critic ←

$\pi_{\theta}(s, a)$ براستهای $Q_w(s, a)$: Actor ←

آنچه از Q_w استفاده نمی کند

این approximate Policy gradient is Actor-Critic (Actor-Critic)

$$\nabla_{\theta} J(\theta) \approx E_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(s, a) Q_w(s, a)] \Rightarrow \Delta \theta = \alpha \nabla_{\theta} \log \pi_{\theta}(s, a) Q_w(s, a)$$

این عنصر تا بهترین درجه

Action-value function Approximation:

$$\text{Action-Value Function Approximation: } \hat{q}(s, a, w) \approx q_{\pi}(s, a)$$

$$\text{Loss Function (Stochastic Gradient Descent): } J(w) = E_{\pi}[(q_{\pi}(s, a) - \hat{q}(s, a, w))^2]$$

جُن سل ایکسیم از استعداد جی تیر:

$$-\frac{1}{2} \nabla_w J(w) = (q_{\pi}(s, a) - \hat{q}(s, a, w)) \nabla_w \hat{q}(s, a, w)$$

$$\Rightarrow \Delta w = \alpha (q_{\pi}(s, a) - \hat{q}(s, a, w)) \nabla_w \hat{q}(s, a, w)$$

جُن (تارچ) $q_{\pi}(s, a)$ از میں آن استعداد جی تیر: Target

G_t ایکساد جی تیر:

$$\Delta w = \alpha (G_t - \hat{q}(s, a, w)) \nabla_w \hat{q}(s, a, w)$$

استعداد جی تیر: $R_{t+1} + \gamma Q(s_{t+1}, a_{t+1})$ از TD(0) اور MC

$$\Delta w = \alpha (R_{t+1} + \gamma \hat{q}(s_{t+1}, a_{t+1}, w) - \hat{q}(s, a, w)) \nabla_w \hat{q}(s, a, w)$$

Actor-Critic Policy Gradient:

$$Q_w(s, a) = \phi(s, a)^T w : \text{linear Value function approximation}$$

TD (ٹیڈ) کیسی تیر \leftarrow نیکی تیر TD(0) اور w : Critic

Policy gradient $\leftarrow \theta$: Actor

الدورة: function QAC

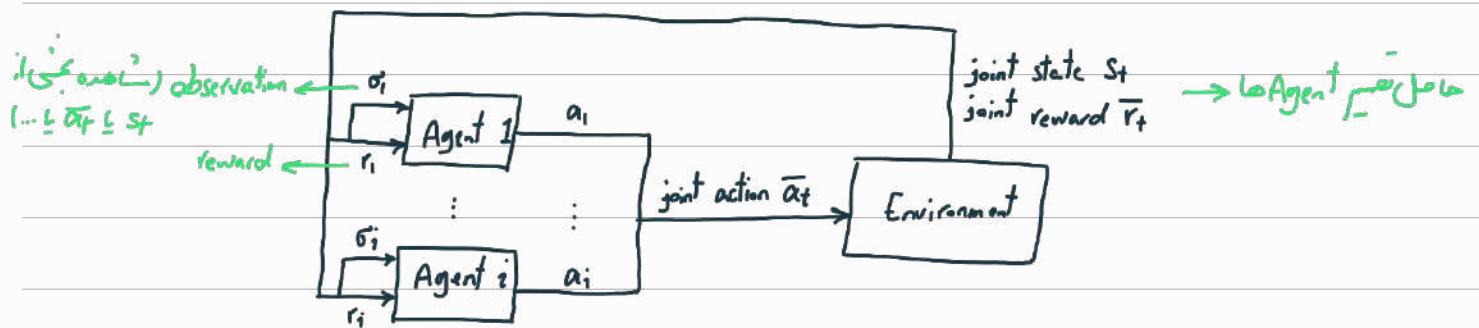
```

    initialize  $s, \theta$  → ابتدئ بـ  $s$  و  $\theta$ 
    Sample  $a \sim \pi_\theta$ 
    for each step do
        Sample reward  $r = R_s^a$ , Sample transition  $s' \sim P_s^a$  → اخذ مكافأة  $r$  و انتقال  $s'$ 
        Sample action  $a' \sim \pi_\theta(s', a')$  target
         $\delta = r + \gamma Q_w(s', a') - Q_w(s, a)$  → TD error
         $\theta = \theta + \alpha \nabla \log \pi_\theta(s, a) Q_w(s, a)$ 
         $w \leftarrow w + \beta \delta \phi(s, a)$ 
         $a \leftarrow a'$ ,  $s \leftarrow s'$  →  $w$  يقترب من  $Q$ 
    end for
end function

```

David Silver (جامعة كامبردج)

(Multi Agent Reinforcement Learning) علم الآلات التعلم بالتجربة



Long term expected reward (جهاز)
Cooperative vs selfish
معطى في ترتيب ديناميكي باشد

Multi Agent MDP :

$$(N, S, \vec{A}, \vec{R}, T)$$

مجموعه مکان ها $(1, \dots, n)$

مجموعه ایجاد کننده ها

$\vec{A} = A_1 \times \dots \times A_n$

مجموعه ایجاد کننده های آژانس A_i

حالت ایجاد کننده ها

$$T: S \times \vec{A} \rightarrow \overline{T(S)}$$

با تابع انتقالی T باتابع انتقالی $T(S)$

دسته بندی Coupling \Leftarrow دسته بندی Coupling \Leftarrow

$$\vec{R} = R_1 \times \dots \times R_n$$

$$R_i: S \times \vec{A} \rightarrow R$$

باعظ اوقایع این اتفاقی است که در S مکانیک ایجاد کننده ها متمایز نباشند

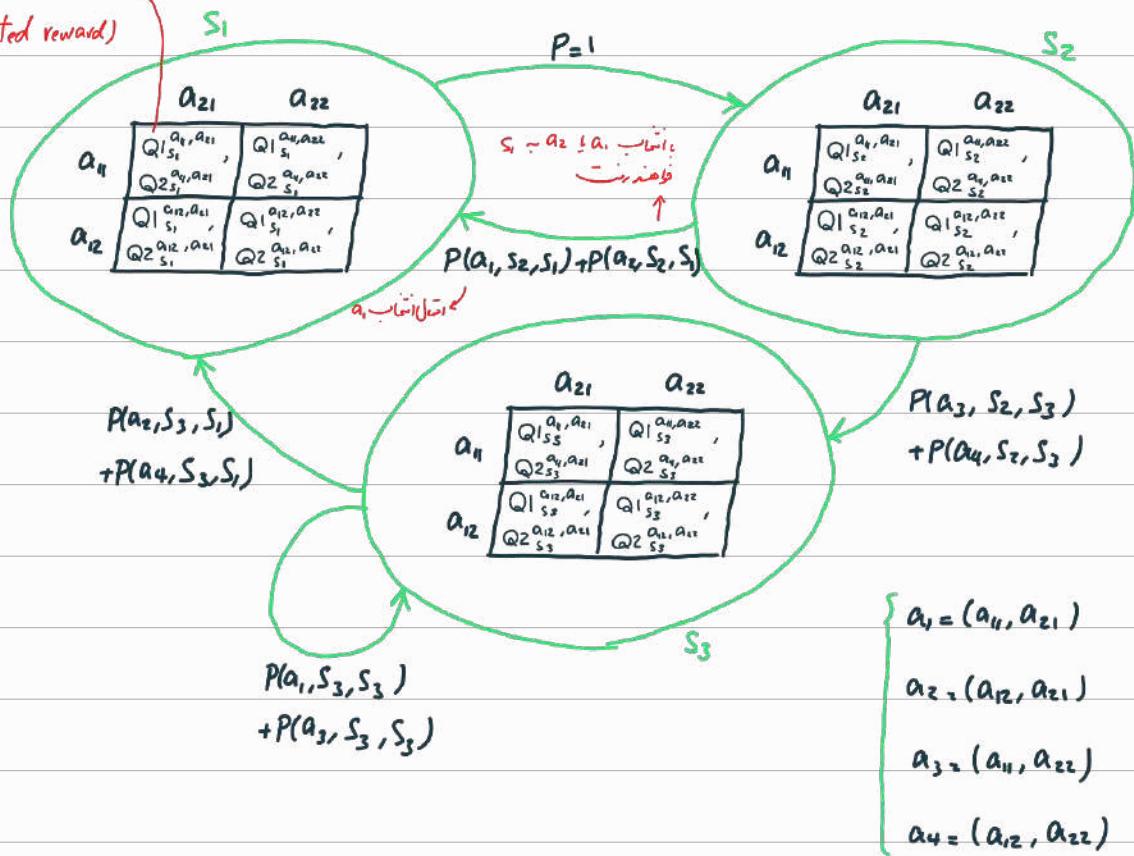
Coupling \Leftarrow

Markov Game , Multi Agent MDP \sim Coupling

: انتخاب action \Rightarrow Agent \Rightarrow دوستانه Agent \Rightarrow state $\sim s_i$. حالی

state-joint action

(long-term expected reward)



وهو يعتمد على Agent (اللعبة) state (الحالة) \rightarrow Sub (Matrix game) table \rightarrow state \rightarrow joint Q-table

- Learning in Multi Agent MDP

ساده ترین مدل انتخابی معرفتی یک نفری (Single Agent MDP) است.

$$Q_i(s, a_i) \leftarrow (1-\alpha) Q_i(s, a_i) + \alpha [R_i(s, \vec{a}) + \gamma \max_{a_i' \in A_i} Q_i(s, a_i')]$$

باینی صفت هر عمل میل Passive نامید کند و این حقیقت را Value action یعنی علی هاکی دلیری کنیز هستند
که میل از دیده عامل non-stationary بـ نظری بر سر داده شده فرمایند یادکری پنهانه ترمی شود ignore کند.

برای دنظربر من action بقیه، باید یک observation سایر عامل ها هم را داشته باشد. با این مرتب Q-table فریم الکترونیک می شود:

$$Q_i(s, \vec{a}) \leftarrow (1-\alpha) Q_i(s, \vec{a}) + \alpha [R_i(s, \vec{a}) + \gamma V_i(s')]$$

5 Curse of dimensionality ←

؟ عن (س) ←

با استفاده از سُرچ های on-Policy SARSA می توان (s,a) را داشت:

و غیر ای صفت برای استفاده از سری های Q-Learning یعنی action یک off-Policy است و چون یکی را ایجاد می کنیم که قبل از تغییر action باید Update کنیم (importation/estimation) سایر عمل های داشته باشد.

action ;1 (expectation/estimation) نیاز ب معنی action selection میگیرد

بیلی چال های (هر عامل به نسبت Max کمترین سود خود است) : (1994) minimax Q-Learning
فرضیه کسر در عامل داریم (بتصاد عامل های دیگر نابل تعیین است)

$$V_1(s) \leftarrow \max_{P_i \in \Pi(A_i)} \min_{a_2 \in A_2} \sum_{a_1 \in A_1} P_i(a_1) Q_1(s, (a_1, a_2))$$

برترین حالتی را عالی 2 می توانیم در محدود بینید
(woot case) در نظر گرفته می شود

نیزی تواند باشیم ایه Update Policy سود

: Belief Based Algorithm

$$V_i(s) \leftarrow \max_{a_i} \sum_{a_{-i} \in A_{-i}} P_i(s, a_i) Q_i(s, (a_i, a_{-i}))$$

که بعنده نشان توزیع انتخاب سیر عملها
نمایان a_i در طبقی کرد expected

قابل توزیع: هستور (نرکاس)

KNN

دیگر pdf estimator

باید انتخاب action نیزی تواند بین سکل عمل کند

هر عامل، بعضی عامل های دیگر را داشت، بعضی نداشت، دلخواهی لبرد Friend-or-Foe (FoF) Algorithm

Friend: $V_1(s) \leftarrow \max_{a_1 \in A_1, a_2 \in A_2} Q_1(s, (a_1, a_2))$

$\rightarrow \max \max$

Foe: $V_1(s) \leftarrow \max_{P_i \in \Pi(A_i)} \min_{a_2 \in A_2} \sum_{a_1 \in A_1} P_i(a_1) Q_1(s, (a_1, a_2))$ $\rightarrow \max \min$

دستے های عمل درستیک اثراپی (Value Function) همچویا کی ترتیب صفتی به دستان درستی کا حصہ Value بهم همچویا کی کشیده.

$$\Rightarrow V_i(s) \leftarrow \underset{\pi \in \Pi(X_1, \dots, X_k)}{\operatorname{Max}} \underset{y_1, \dots, y_k \in Y_1, \dots, Y_k}{\operatorname{Min}} \sum_{a_1, \dots, a_k \in X_1, \dots, X_k} \pi(a_1) \dots \pi(a_k) Q_i[s, a_1, \dots, a_k, y_1, \dots, y_k]$$

Probabilistic Action Selection باند، یا این کس

Deterministic Action Selection باند یا ...

Competition, Cooperation

Action Selection کر کر

• Fully Cooperative Tasks

عملیات ها صفت منفردی دارند و می فراخواهند (reward function) مثلاً Common discount return (انداختی دهنده)

$$Q\text{-Learning} \rightarrow Q_{k+1}(a_k, u_k) = Q_k(a_k, u_k) + \alpha [r_{k+1} + \gamma \max_{u'} Q_k(a_{k+1}, u') - Q_k(a_k, u_k)]$$

Curse of dimensionality (دیدگاری دار)

$$\text{greedy Policy} \rightarrow h_i^*(a) = \underset{u_1, \dots, u_m, u_{m+1}, \dots, u_n}{\operatorname{argmax}} Q^*(a, u)$$

friend ہے

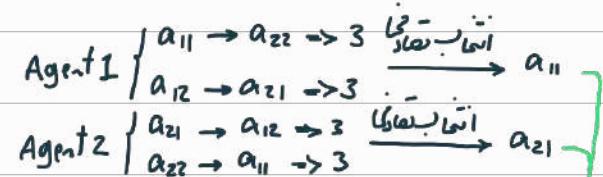
من آجی پر Value

عویضان است Q اندیشید

break tie کی کشیده کی کشیده، جن برعامل بحدت اندیشید tie را

کی کشیده ممکن است بیانی sub optimal بررسی

$U_1^2 \cup U_4$	Agent 1	$\begin{array}{ c c } \hline & 2,2 \\ \hline 3,3 & \\ \hline \end{array}$	Agent 2
------------------	---------	---	---------



لہے سیہے 2 می سودا! (بہتری سیہے حامل می سودا) ← ان سُکھل ہئی بھڈائی کامل مادر رئی وجد ناہد

نهاده می‌شود deterministic آنات هسته‌ای تاریخی tie breaking ، Curse of dimensionality (پیچیدگی ابعادی) دارد : Distributed Q-Learning

رضی امیر حسین Agent دید Agent ignore نہیں دیکھے

$$Q_{i,k+1}(x_k, u_{i,k}) = \max \left\{ Q_{i,k}(x_k, u_{i,k}), r_{k+1} + \gamma \max_{u_i} Q_{i,k}(x_{k+1}, u_i) \right\}$$

← جن reward شکست داری میگیرد Learning هم deterministic است سه ترجی خود را ignore کردن سایر Agent ها به دنبال دارد

Q-Value \leftarrow تابی دھنیہ ماد نظریہ ترمی
Update جی سود کے مبنیہ اترائیں Q-value سوہ (اے حل یا ٹینس)

Q-Value \rightarrow improvement \sim میں سود کے نتیجے Update \sim نیزدہ صفتی (greedy) Policy \leftarrow چاہئے

$$\bar{h}_{i,kii}(x_k) = \begin{cases} u_{i,k} & \text{if } \max_{u_i} Q_{i,x_{ii}}(x_k, u_i) > \max_{u_i} Q_{i,k}(x_k, u_i) \\ \bar{h}_{i,k}(x_k) & \text{otherwise} \end{cases}$$

آخر انتساب $a_{i,k}$ با سی GREEDY میزبانی از انتساب $a_{i,k}$ خود

با تعریف سه تابع از \rightarrow
می‌شود و می‌توان با آنها مجموعه مورد نظر را درست نمود.

بینی تعریف از سیاست greedy، اگر انتخاب action چنانچه نباشد این action انتخاب شده
و انتخاب آنچه می‌ماند! بنابراین باید انتخاب randomness داشته باشیم

در شایعی که بعد reward local عمل های سیاست
بنت باشد و $Q_{ij_0} = 0 \forall i$ ، سیاست local عمل های سیاست

global و $\forall j$ global Q همچنان شود

ما از میان اینها Low Coupling ←
اگری لزدگی داشت شرایط نهاده به global
optimum همچنان شود.

Indirect Coordination Methods:

→ JAL
→ FMQ

Coordinated action selection ← سیاست انتخاب عمل های سیستم بر اساس reward جمعی بینهای را داشته باشد $\pi_{\text{JAL}}(j)$ شود ← حرکت بهترین Agent

← جمعی بینهای reward و action کلی لذتی ←
← همین Agent صاحب سمت local باده اند ←

← بینی بست انتخاب احتیاط اینها، بهتر است reward میانه های statistical data میانه های دیگر اینها شود.
← حرکت بهترین global optimum شود

Single State ← بینی static task برای : joint Action Learners (JAL)

$$Q_i(u_i, u_{-i}) = (1-\gamma)Q_i(u_i, u_{-i-1}) + \gamma r(u_i, u_{-i}) \quad \text{discount factor} = 0$$



Q-Value Update

(Blast Based) از سایر ها عملی کنند (بینهای) emperical model برای

$$\hat{o}_j^i(u_j) = \frac{C_j^i(u_j)}{\sum_{\tilde{u}_j \in U_j} C_j^i(\tilde{u}_j)}$$

تمارین (Blast Based) همچنان عمل را در این عمل زیرین →
عمل این عمل را در سطح عمل زیرین عرضه کنید →

$$\Rightarrow \tilde{Q}_i(u_i) = \sum_{u_j} Q_i(u_i, u_j) \prod_{j \neq i} \hat{\sigma}_j^i(u_j)$$

↑
نامنحني local Q

$$\Rightarrow \tilde{Q}_i(u_i) = (1-\gamma) \tilde{Q}_i(u_i) + \gamma r(u_i)$$

نهان نهان شود که با این ارسن ارجیه عامل ها به صورت local یادگاری می شوند اما یکجا همیشه به یکجا بینه global و نهان شود

Deterministic Tasks / static Tasks ← Frequency Minimum Q-Value (FMQ)

از اینجا Q -Value گیر عامله دنظر سرمه شود (هر عامل فرضی کند مرط قدرش در محیط هفتوانه دارد)

$$Q_i(u_i) = (1-\gamma) Q_i(u_i) + \gamma r(u_i, u_i)$$

$$\tilde{Q}_i(u_i) = Q_i(u_i) + \gamma \frac{C_{max}(u_i)}{c_i(u_i)} r_{max}(u_i)$$

r_{max} ← امثلت شده ← C_{max} ← $c_i(u_i)$ ← u_i ← r_{max} ← $Q_i(u_i)$ ← $\tilde{Q}_i(u_i)$ ← $(1-\gamma) Q_i(u_i)$ ← $\gamma r(u_i, u_i)$

Bias

برای عامل i ، انتخاب i سبب تأثیر گذشتگی شود (به دلیل انتخاب سایر عامل ها). از انتخاب عامل های دیگر در احتمال شده r_{max} که نهاد است.

Q -Value ← ارجیه با امثال r_{max} و مقادیر آن Bias می شود

به جای learning ، Q ← \tilde{Q} ارجی شود

ابت هدایی این روش ~ global optimum نیز دارد

→ A Comprehensive survey of multiagent reinforcement learning ; Busoniu, Lucian, Robert Babuska , 2008

• Multi-Agent Reinforcement Learning via Double Averaging Primal-Dual Optimization

32nd Conference on Neural Information Processing Systems (NeurIPS 2018), Montreal, Canada

از تجزیه حالت تغییر
ML

Multi Agent RL

- Policy evaluation via MARL → جزوی جملی سیستم RL
- Using Neural Networks to avoid curse of dimensionality → استخراج دینامیک برای ارزیابی احتمالات
- Proposing an Optimization Problem to find the parameters of neural network
- Reformulating the problem to become Convenient with model-free approaches
- Reformulating the problem to become Convenient with distributed optimization approaches
- Decomposition of the problem to N sub-Problems to enable agents to Cooperatively solve the optimization problem by preserving the privacy of the agents

Multi-Agent MDP: $(S, \{A_i\}_{i=1}^N, P^a, \{R_i\}_{i=1}^N, \gamma)$



global reward function: $R_c(s, a) = N^{-1} \sum_{i=1}^N R_i(s, a) \rightarrow$ مسئله مارکوف

↑
Collective Reward

states s joint action a اتحادیه ای

رعنی جمیع سیاست را درونه، جی خواهیم آن ایسی بگیر

states s reward r تجربه

$$R_c^\pi := \frac{1}{N} \sum_{i=1}^N R_i^\pi(s) \quad \text{where} \quad R_i^\pi(s) := E_{a \sim \pi(\cdot|s)} [R_i(s, a)]$$

↑ local reward

هریات نسبتی مارکوو چین (Markov Chain) میان ایجاد ماتریس تغییر حالت (transition matrix) آن- بسط زیراست:

$$[P^\pi]_{s,s'} = \sum_{a \in A} \pi(a|s) \cdot [P^a]_{s,s'} \rightarrow s' \sim \text{اموال (من)} \text{ از } s$$

از هر state - state مابین احتمال میانگین بزرگ است (Markov Chain) \rightarrow state - state مابین از هر state میانگین بزرگ است (Strongly Connected) \rightarrow state : irreducible

اگر S میکارن π stationary markov chain است که irreducible و aperiodic باشد، مارکوو چین ای

$$\mu^\pi : S \rightarrow [0,1] \quad \xrightarrow{\text{---}} \quad \mu^\pi(s) : \pi \leftarrow \text{اصل بین } s \in \text{بان} - \text{اندازه طبقاعت}$$

steady state / ثابت دریافتی

$$\text{Value Function: } V^\pi(s) := E \left[\sum_{P=1}^{\infty} \gamma^P R_c^\pi(s_p) \mid s_1 = s, \pi \right] \\ E[v(s)]$$

$$\rightarrow \text{Bellman Equation: } V^{\pi} = R_{\zeta}^{\pi} + \gamma P^{\pi} V^{\pi}$$

$(V^* \in R^{15})$ و $V^*(s)$ بذر حاصل از تبع $R_e^*(s)$ بذر حاصل از تبع

expected transition matrix $[P^{\bar{n}}]_{sr} := E_{\bar{n}}[P_{sr}^n]$

$$\Rightarrow \begin{bmatrix} V^\pi(s_1) \\ \vdots \\ V^\pi(s_n) \end{bmatrix} = \begin{bmatrix} R_c^\pi(s_1) \\ \vdots \\ R_c^\pi(s_n) \end{bmatrix} + \gamma \begin{bmatrix} P_{s_1 s_1}^\pi & \dots & P_{s_1 s_n}^\pi \\ \ddots & \ddots & \vdots \\ P_{s_n s_1}^\pi & \dots & P_{s_n s_n}^\pi \end{bmatrix} \begin{bmatrix} V^\pi(s_1) \\ \vdots \\ V^\pi(s_n) \end{bmatrix}$$

می خواهیم \bar{x} می برسیم باید σ نه داشت بعدها محقق کنیم

Function Approximation in Value (یہ اس تابع کی نامہ) کے ساتھ یہی کو ایجاد کر دیا جائے گا۔ اس کا نامہ اس کی دلیلیت کے لئے ایجاد کیا جائے گا۔

$$V_{\theta}(s) := \phi^T(s)\theta : \theta \in \mathbb{R}^d$$

$$\phi(s) : s \rightarrow \mathbb{R}^d$$

دیگر دل

جی تا زنگ سکب عجی باند

باینی صفت پارامتر θ کا ہوں پیدائی لند (کا حصہ بعد)

بداریگی و تعمیم Compact Value Function کی نسیم:

$$\Phi := (\dots; \phi^T(s); \dots) \in \mathbb{R}^{|S| \times d} \quad V_{\theta} \in \mathbb{R}^{|S|} \Rightarrow V_{\theta} = \Phi \theta$$

باینی θ کا طور پر پیدائیں کے

کچھ دعاوی مبنی صفت جی کسے

Mean Square Projected Bellman Error

$$\Rightarrow \text{MSPBE}(\theta) := \frac{1}{2} \| \Pi_{\Phi} (V_{\theta} - \gamma P^* V_{\theta} - R_c^*) \|_D^2 + \rho \|\theta\|^2$$

bellman error : e

تقریباً e کو زیرخطی کر پڑو ریگل ہادئن تعریف کرہے

$$[\Phi : \theta \in \mathbb{R}^d]$$

داین اخراجی تراجمہ سازی دایبوجم

$$\Rightarrow \frac{1}{2} E[\tilde{e}^T \tilde{e}] = \frac{1}{2} \sum_{s \in S} \tilde{e}^2(s) \mu(s) = \frac{1}{2} \tilde{e}^T D \tilde{e} = \frac{1}{2} \|\tilde{e}\|_D^2 \rightarrow \text{ابن نہر}$$

اصل شاہدہ S

diag([P^*(s)]_{s \in S})

اتریں نظری

/ /